MODEL *MACHINE LEARNING* UNTUK KLASIFIKASI PROFIL KOMPETENSI DAN REKOMENDASI PENGEMBANGAN MAHASISWA BERBASIS KURIKULUM

SKRIPSI

Karya Tulis sebagai syarat memperoleh
Gelar Sarjana Komputer dari Fakultas Teknologi Informasi
Universitas Bale Bandung

Disusun oleh:
TACSHA AULIA NURMAYANTI RESMANA
NPM. 301220012

PROGRAM STRATA 1
PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS BALE BANDUNG
BANDUNG
2026

DAFTAR ISI

DAFTAR ISI i
BAB I PENDAHULUAN 1
1.1. Latar Belakang 1
1.2. Rumusan Masalah 4
1.3. Batasan Masalah 4
1.4. Tujuan Penelitian 5
1.5. Metodologi Penelitian 5
1.6. Sistematika Penulisan 9
BAB II TINJAUAN PUSTAKA 9
2.1 Landasan Teori 9
2.2 Dasar Teori 13
2.2.1. Pengembangan Mahasiswa 13
2.2.2. *Outcome-Based Education* 13
2.2.3. Profil Lulusan 14
2.2.4. Capaian Pembelajaran Lulusan 15
2.2.5. Kompetensi 15
2.2.6. Profil Kompetensi Mahasiswa 15
2.2.7. Faktor Pembentuk Profil Kompetensi Mahasiswa 16
2.2.8. Instrumen Penelitian 17
2.2.9. *Machine Learning* untuk Klasifikasi 18
2.2.10. Pembentukan Label Dataset 20
2.2.11. *Feature Engineering* 22
2.2.12. *Decision Tree* 23
2.2.13. *XGBoost* 25
2.2.14. *Cross Validation* 27
2.2.15. *Explainable Artificial Intelligence* 27
2.2.16. *SHapley Additive exPlanations* 29
2.2.17. *Knowledge Discovery in Database* 31
2.2.18. Evaluasi Model Klasifikasi 32

2.2.19. Sistem Rekomendasi 36
2.2.20. Teknologi Pengembangan Sistem 36
2.2.21. Sistem Berbasis Web 39
2.2.22. *Unified Modeling Language* 40
2.2.23. *Software Development Life Cycle* 42
2.2.24. *Waterfall* 43
2.2.25. Pengujian Sistem 44
BAB III METODOLOGI 41
3.1 Kerangka Pikir 41
3.2 Deskripsi 42
3.2.1. Metode Pengumpulan Data 43
3.2.2. Analisis Kurikulum 44
3.2.3. Sintesis CPL 44
3.2.4. Pembentukan Profil Kompetensi 45
3.2.5. Penyusunan Kuesioner 45
3.2.6. Pengumpulan Data Responden 45
3.2.7. Metode Pemrosesan Data 46
3.2.8. Metode Pembuatan Model 46
3.2.9. Metode Pengembangan Sistem 47
3.2.10. *Output* Sistem 47
DAFTAR PUSTAKA iii

BAB I

PENDAHULUAN

1.1. Latar Belakang

Perguruan tinggi memiliki peran penting dalam menghasilkan lulusan yang tidak hanya memiliki kemampuan akademik, tetapi juga kompetensi yang sesuai dengan kebutuhan dunia kerja dan perkembangan teknologi (Permendikbudristek, 2023). Seiring dengan perkembangan transformasi digital, pemanfaatan data menjadi salah satu pendekatan yang dapat digunakan untuk mendukung pengambilan keputusan secara lebih objektif dan terukur. Dalam lingkungan pendidikan tinggi, mahasiswa memiliki karakteristik, minat, dan tujuan karier yang beragam sehingga membutuhkan arahan pengembangan yang sesuai dengan potensi yang dimiliki. Oleh karena itu, diperlukan pendekatan berbasis data yang mampu membantu proses identifikasi profil kompetensi mahasiswa sebagai dasar dalam penyusunan rekomendasi pengembangan yang lebih terarah dan personal (Alsayed et al., 2021; Hulu & Telaumbanua, 2022).

Selanjutnya, penelitian ini dilaksanakan di Universitas Bale Bandung (UNIBBA) yang berlokasi di Jl. R.A.A. Wiranatakusumah No. 7, Baleendah, Kabupaten Bandung, Jawa Barat. UNIBBA dipilih sebagai lokasi penelitian karena memiliki 7 fakultas dan 12 program studi dengan struktur kurikulum yang terdiri atas Profil Lulusan (PL), Capaian Pembelajaran Lulusan (CPL), mata kuliah, dan Capaian Pembelajaran Mata Kuliah (CPMK). Struktur kurikulum tersebut mengandung informasi yang dapat dimanfaatkan untuk membentuk profil kompetensi mahasiswa berdasarkan sintesis CPL dari berbagai program studi. Untuk memperoleh gambaran kondisi yang terjadi serta kebutuhan sistem yang akan dibangun, penelitian ini menggunakan beberapa teknik pengumpulan data, yaitu observasi, wawancara, studi literatur, analisis dokumen kurikulum, dan penyebaran kuesioner kepada mahasiswa aktif, alumni, serta calon mahasiswa baru.

Berdasarkan hasil observasi dan wawancara, ditemukan bahwa proses pengembangan mahasiswa masih menghadapi beberapa kendala. Mahasiswa sering mengalami kesulitan dalam menentukan arah pengembangan diri yang sesuai

dengan kemampuan dan tujuan yang dimiliki. Selain itu, pemilihan kegiatan akademik maupun non-akademik masih banyak dilakukan berdasarkan pengaruh lingkungan atau tren tertentu tanpa didukung data yang objektif. Untuk memperkuat temuan tersebut, peneliti melakukan penyebaran kuesioner kepada 72 responden yang terdiri atas mahasiswa aktif, alumni, dan calon mahasiswa baru. Hasil kuesioner menunjukkan bahwa 60% mahasiswa aktif menyatakan membutuhkan sistem yang dapat membantu memberikan rekomendasi pengembangan diri berdasarkan karakteristik pribadi. Selain itu, sebanyak 62,2% mahasiswa aktif menyatakan bahwa variabel minat, gaya belajar, dan tujuan karier dapat digunakan sebagai dasar dalam proses pengembangan mahasiswa, serta 62,2% responden meyakini bahwa teknologi *machine learning* mampu menghasilkan rekomendasi yang lebih objektif. Dari sisi alumni, sebanyak 72,7% responden mendukung penerapan *machine learning* dalam proses rekomendasi pengembangan mahasiswa. Namun demikian, hanya 45,5% alumni yang menyatakan bahwa pekerjaan yang dijalani saat ini sesuai dengan bidang atau kompetensi yang dipelajari selama kuliah. Temuan tersebut menunjukkan bahwa proses pemetaan kompetensi mahasiswa masih belum optimal dan memerlukan pendekatan yang mampu mengintegrasikan variabel minat, gaya belajar, dan tujuan karier dalam menghasilkan rekomendasi yang lebih tepat sasaran.

Sementara itu, berbagai penelitian terdahulu telah menunjukkan bahwa algoritma *machine learning* dapat diterapkan untuk mendukung proses klasifikasi dan rekomendasi dalam bidang pendidikan. Penelitian yang dilakukan oleh Shoaib et al. (2024) menerapkan algoritma *Decision Tree* untuk mengklasifikasikan gaya belajar mahasiswa dan memperoleh tingkat akurasi sebesar 90%. Selanjutnya, penelitian Atalla et al. (2023) mengembangkan sistem *academic advising* berbasis web menggunakan pendekatan *machine learning* dan *graph theory* dengan tingkat akurasi mencapai 86%. Selain itu, Abdillah et al. (2020) menerapkan algoritma C4.5 untuk memprediksi keberhasilan pendidikan karakter mahasiswa dan memperoleh tingkat akurasi sebesar 60,91%. Hasil penelitian tersebut menunjukkan bahwa metode klasifikasi mampu memberikan dukungan dalam proses pengambilan keputusan pada bidang pendidikan. Pada penelitian ini, algoritma *Decision Tree* digunakan karena mampu menghasilkan model klasifikasi

yang mudah dipahami melalui struktur pohon keputusan dan aturan *if-then* yang transparan sehingga hasil prediksi dapat dijelaskan secara jelas kepada pengguna (Nurizati et al., 2024). Selain itu, algoritma *XGBoost* dipilih karena kemampuannya dalam meningkatkan performa klasifikasi melalui teknik *gradient boosting*, ketangguhannya dalam menangani data tabular multidimensi, serta terbukti memiliki tingkat akurasi yang unggul dibandingkan algoritma klasifikasi lainnya pada berbagai studi kasus di bidang pendidikan (Kate et al., 2026; A. Ridwan et al., 2024). Untuk mengatasi sifat *black-box* pada model kompleks tersebut dan meningkatkan transparansi hasil prediksi, penelitian ini juga menerapkan pendekatan *Explainable Artificial Intelligence* (XAI) dengan metode SHAP (*SHapley Additive exPlanations*) (Bifarin, 2023). Penggunaan SHAP memungkinkan faktor-faktor penentu yang memengaruhi hasil klasifikasi dapat diinterpretasikan secara lokal maupun global, sehingga rekomendasi yang diberikan sistem menjadi lebih akurat dan mudah dipahami oleh pengguna (Bifarin, 2023). Meskipun demikian, penelitian-penelitian sebelumnya masih berfokus pada klasifikasi gaya belajar, rekomendasi rencana studi, atau prediksi karakter mahasiswa secara terpisah. Penelitian terdahulu juga belum mengintegrasikan data kurikulum, khususnya CPL dan Profil Lulusan, dengan karakteristik mahasiswa berupa minat, gaya belajar, dan tujuan karier untuk membentuk profil kompetensi mahasiswa sebagai dasar rekomendasi pengembangan. Oleh karena itu, masih terdapat *research gap* berupa belum adanya model klasifikasi profil kompetensi mahasiswa yang dibangun berdasarkan sintesis kurikulum dan karakteristik individu dalam satu kerangka yang terintegrasi.

Berdasarkan permasalahan dan *research gap* yang telah diidentifikasi, diperlukan suatu model *machine learning* yang mampu mengklasifikasikan profil kompetensi mahasiswa berdasarkan data kurikulum dan karakteristik individu. Kebaruan penelitian ini terletak pada integrasi sintesis CPL dari 12 program studi Universitas Bale Bandung dengan tiga variabel utama, yaitu minat, gaya belajar, dan tujuan karier, untuk membentuk enam profil kompetensi mahasiswa. Proses pembangunan model dilakukan menggunakan pendekatan *Knowledge Discovery in Databases* (KDD) yang meliputi tahapan seleksi data, pembersihan data, transformasi data, pemodelan, dan evaluasi. Model klasifikasi dibangun

menggunakan algoritma *Decision Tree* dan *XGBoost*, kemudian dibandingkan berdasarkan nilai *accuracy*, *precision*, *recall*, dan *F1-score* untuk memperoleh model terbaik. Selanjutnya, model terbaik dianalisis menggunakan pendekatan XAI berbasis SHAP dan diimplementasikan ke dalam sistem berbasis web. Sistem tersebut menghasilkan rekomendasi pengembangan mahasiswa yang mencakup rekomendasi pengembangan akademik, pengembangan non-akademik, pelatihan atau sertifikasi yang relevan, rekomendasi karier, serta rekomendasi program studi bagi calon mahasiswa baru. Dengan demikian, penelitian ini dilakukan dengan judul **"MODEL *MACHINE LEARNING* UNTUK KLASIFIKASI PROFIL KOMPETENSI DAN REKOMENDASI PENGEMBANGAN MAHASISWA BERBASIS KURIKULUM."**

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana mengidentifikasi profil kompetensi mahasiswa berdasarkan variabel minat, gaya belajar, dan tujuan karier yang disusun berdasarkan sintesis Capaian Pembelajaran Lulusan (CPL) Universitas Bale Bandung?
2. Bagaimana membangun model *machine learning* menggunakan algoritma *Decision Tree* dan *XGBoost* untuk mengklasifikasikan profil kompetensi mahasiswa berdasarkan data hasil kuesioner?
3. Bagaimana menghasilkan rekomendasi pengembangan mahasiswa berdasarkan hasil klasifikasi profil kompetensi yang diimplementasikan dalam sistem berbasis web?

1.3. Batasan Masalah

Agar penelitian lebih terarah dan sesuai dengan ruang lingkup yang ditentukan, maka batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian dilakukan di Universitas Bale Bandung (UNIBBA) dengan melibatkan mahasiswa aktif, alumni, dan calon mahasiswa sebagai responden penelitian.

2. Data penelitian diperoleh melalui kuesioner yang disusun berdasarkan sintesis CPL dari 12 program studi Universitas Bale Bandung dengan tiga variabel utama, yaitu minat, gaya belajar, dan tujuan karier.
3. Profil kompetensi mahasiswa yang digunakan terdiri atas enam kategori, yaitu *Educational and Research Innovator* (PC01), *Digital Technology Specialist* (PC02), *Data and Analytical Intelligence Specialist* (PC03), *Community Development Specialist* (PC04), *Entrepreneurship and Innovation Specialist* (PC05), dan *Professional Leader* (PC06).
4. Proses klasifikasi dilakukan menggunakan algoritma *Decision Tree* dan *XGBoost* yang dievaluasi menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score*.
5. *Output* penelitian berupa model klasifikasi profil kompetensi yang diimplementasikan dalam sistem berbasis web untuk menghasilkan rekomendasi pengembangan mahasiswa.

1.4. Tujuan Penelitian

Tujuan penelitian yang ingin dicapai pada penelitian ini adalah sebagai berikut:

1. Mengidentifikasi profil kompetensi mahasiswa berdasarkan variabel minat, gaya belajar, dan tujuan karier yang disusun dari sintesis CPL Universitas Bale Bandung.
2. Membangun model *machine learning* menggunakan algoritma *Decision Tree* dan *XGBoost* untuk mengklasifikasikan profil kompetensi mahasiswa berdasarkan data hasil kuesioner.
3. Menghasilkan sistem berbasis web yang mampu memberikan rekomendasi pengembangan mahasiswa berdasarkan hasil klasifikasi profil kompetensi.

1.5. Metodologi Penelitian

Metode penelitian yang digunakan dalam penelitian ini adalah metode kuantitatif dengan pendekatan klasifikasi *machine learning* dan pengembangan

sistem berbasis web. Pendekatan kuantitatif digunakan untuk mengolah data hasil kuesioner yang diperoleh dari calon mahasiswa, mahasiswa aktif, dan alumni Universitas Bale Bandung. Data tersebut digunakan untuk membentuk profil kompetensi mahasiswa berdasarkan variabel minat, gaya belajar, dan tujuan karier.

Penelitian ini memanfaatkan pendekatan *Knowledge Discovery in Databases* (KDD) dalam proses pengolahan data dan pembangunan model klasifikasi. Algoritma yang digunakan adalah *Decision Tree* dan *XGBoost* untuk menghasilkan model klasifikasi profil kompetensi mahasiswa. Selanjutnya, hasil klasifikasi dijelaskan menggunakan pendekatan *Explainable Artificial Intelligence* (XAI) dengan metode *SHapley Additive exPlanations* (SHAP) agar faktor-faktor yang memengaruhi hasil klasifikasi dapat dipahami secara lebih transparan.

Selain pembangunan model *machine learning*, penelitian ini juga mengembangkan sistem rekomendasi berbasis web menggunakan metode *Software Development Life Cycle* (SDLC) model *Waterfall*. Sistem yang dikembangkan bertujuan untuk memberikan rekomendasi pengembangan akademik, non-akademik, karier, dan program studi berdasarkan profil kompetensi yang dihasilkan.

A. Metode Pengumpulan Data

Pengumpulan data dalam penelitian ini dilakukan melalui beberapa teknik sebagai berikut.

1. Observasi dilakukan dengan mengamati kondisi mahasiswa di lingkungan Universitas Bale Bandung terkait proses pengembangan diri, pemilihan kegiatan akademik maupun non-akademik, serta penentuan arah karier selama masa studi. Selain itu, observasi juga dilakukan terhadap proses penerimaan mahasiswa baru untuk mengetahui berbagai kendala yang dihadapi calon mahasiswa dalam menentukan program studi yang sesuai.
2. Wawancara dilakukan secara langsung dengan pihak Penerimaan Mahasiswa Baru (PMB), mahasiswa aktif, alumni, dan ketua program studi di Universitas Bale Bandung. Wawancara dengan pihak PMB bertujuan untuk memperoleh informasi mengenai permasalahan yang sering dihadapi calon mahasiswa dalam menentukan program studi. Wawancara dengan mahasiswa aktif dan alumni dilakukan untuk mengetahui kebutuhan pengembangan diri selama masa studi

serta kesesuaian kompetensi dengan karier yang dijalani. Selain itu, wawancara dengan ketua program studi dilakukan untuk memperoleh data CPL, Profil Lulusan (PL), dan informasi kurikulum yang digunakan dalam penelitian.

3. Studi Literatur dilakukan dengan menelaah berbagai sumber ilmiah yang relevan, seperti jurnal dan penelitian terdahulu yang berkaitan dengan klasifikasi, sistem rekomendasi, *machine learning*, *Decision Tree*, *XGBoost*, *Explainable Artificial Intelligence* (XAI), SHAP, serta pengembangan sistem berbasis web. Studi literatur dilakukan terhadap 50 artikel ilmiah yang kemudian diseleksi untuk memperoleh referensi yang paling relevan dengan penelitian.
4. Analisis Dokumen dilakukan terhadap dokumen kurikulum dari 12 program studi di Universitas Bale Bandung. Dokumen yang dianalisis meliputi Capaian Pembelajaran Lulusan (CPL), Profil Lulusan (PL), serta mata kuliah pendukung yang digunakan sebagai dasar dalam proses sintesis kurikulum dan pembentukan profil kompetensi mahasiswa.
5. Kuesioner digunakan untuk memperoleh data karakteristik responden yang terdiri atas variabel minat, gaya belajar, dan tujuan karier. Instrumen penelitian terdiri atas 30 item pernyataan menggunakan skala Likert 1 sampai 5 yang disusun berdasarkan hasil sintesis CPL dan profil kompetensi mahasiswa. Responden penelitian terdiri atas calon mahasiswa, mahasiswa aktif, dan alumni Universitas Bale Bandung dengan target minimal 150 responden.

B. Metode Pemrosesan Data dan Pembangunan Model

Metode pemrosesan data yang digunakan dalam penelitian ini mengacu pada pendekatan *Knowledge Discovery in Databases* (KDD). Tahapan yang dilakukan adalah sebagai berikut.

1. *Selection,* tahap ini dilakukan dengan memilih data yang relevan untuk penelitian, yaitu data hasil kuesioner yang terdiri atas variabel minat, gaya belajar, dan tujuan karier. Selain itu, digunakan pula data hasil sintesis CPL dan Profil Lulusan yang diperoleh dari 12 program studi Universitas Bale Bandung.
2. *Preprocessing,* tahap ini dilakukan proses pembersihan data untuk mengatasi data kosong, data duplikat, maupun data yang tidak konsisten. Tahap ini

bertujuan untuk memastikan kualitas data sebelum digunakan dalam proses pembentukan model.

3. *Transformation,* tahap transformasi dilakukan dengan mengubah data hasil kuesioner ke dalam format yang sesuai untuk proses klasifikasi. Pada tahap ini juga dilakukan proses *rule-based initial labeling* berdasarkan hubungan antara CPL, profil kompetensi, minat, gaya belajar, dan tujuan karier sehingga diperoleh label profil kompetensi mahasiswa.
4. Data *Mining,* tahap *data mining* dilakukan dengan membangun model klasifikasi menggunakan algoritma *Decision Tree* dan *XGBoost*. Untuk memperoleh model yang lebih stabil dan mengurangi potensi *overfitting*, dilakukan proses validasi menggunakan *K-Fold Cross Validation*.
5. *Evaluation,* tahap evaluasi dilakukan untuk membandingkan performa kedua algoritma menggunakan metrik *Accuracy*, *Precision*, *Recall*, *F1-Score*, *Confusion Matrix*, dan *ROC-AUC*. Model terbaik selanjutnya dianalisis menggunakan metode SHAP untuk mengetahui faktor-faktor yang paling berpengaruh terhadap hasil klasifikasi profil kompetensi mahasiswa.

C. Metode Pengembangan Sistem

Metode pengembangan sistem yang digunakan adalah *Software Development Life Cycle* (SDLC) model *Waterfall*. Pemilihan metode ini didasarkan pada kebutuhan sistem yang telah terdefinisi secara jelas sejak awal penelitian sehingga setiap tahapan dapat dilakukan secara berurutan.

1. Analisis Kebutuhan (*Requirements Analysis*), tahap ini dilakukan untuk mengidentifikasi kebutuhan sistem berdasarkan hasil observasi, wawancara, analisis kurikulum, dan hasil pengolahan data. Analisis mencakup kebutuhan fungsional, kebutuhan non-fungsional, kebutuhan pengguna, serta kebutuhan integrasi model klasifikasi ke dalam sistem.
2. Desain Sistem (*System Design*), tahap desain dilakukan dengan menyusun rancangan sistem yang meliputi perancangan UML, basis data, antarmuka pengguna (*user interface*), arsitektur sistem, serta rancangan integrasi model *machine learning* dan basis pengetahuan (*knowledge base*) sistem rekomendasi.
3. Implementasi (*Implementation*), tahap implementasi dilakukan dengan membangun aplikasi berbasis web menggunakan PHP dan MySQL. Pada tahap

ini dilakukan integrasi model klasifikasi *Decision Tree* dan *XGBoost* ke dalam sistem sehingga sistem dapat menghasilkan rekomendasi secara otomatis.

4. Pengujian (*Testing*), pengujian sistem dilakukan menggunakan metode *Black Box Testing* untuk memastikan seluruh fungsi sistem berjalan sesuai kebutuhan. Selain itu, dilakukan *User Acceptance Testing* (UAT) untuk mengetahui tingkat penerimaan pengguna terhadap sistem yang dikembangkan.
5. Pemeliharaan (*Maintenance*), tahap pemeliharaan dilakukan untuk memperbaiki kesalahan yang ditemukan selama penggunaan sistem, melakukan penyempurnaan fitur, serta meningkatkan performa sistem sesuai kebutuhan pengguna.

1.6. Sistematika Penulisan

Sistematika penulisan dalam penelitian ini disusun untuk memberikan gambaran mengenai alur pembahasan yang dilakukan. Adapun sistematika penulisan penelitian ini adalah sebagai berikut:

BAB I PENDAHULUAN

Bab ini berisi latar belakang penelitian, identifikasi masalah, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, metodologi penelitian, serta sistematika penulisan. Pada bab ini juga dijelaskan hasil studi pendahuluan yang menjadi dasar dilakukannya penelitian.

BAB II TINJAUAN PUSTAKA

Bab ini membahas teori-teori yang mendukung penelitian, penelitian terdahulu, serta konsep yang berkaitan dengan Capaian Pembelajaran Lulusan (CPL), Profil Lulusan (PL), profil kompetensi mahasiswa, *machine learning*, *Decision Tree*, *XGBoost*, *Explainable Artificial Intelligence* (XAI), SHAP, *Knowledge Discovery in Databases* (KDD), sistem rekomendasi, PHP, MySQL, dan pengembangan sistem berbasis web.

BAB III METODOLOGI PENELITIAN

Bab ini menjelaskan kerangka pikir penelitian, tahapan pengumpulan data, analisis kurikulum 12 program studi, sintesis CPL, pembentukan profil kompetensi mahasiswa, penyusunan instrumen penelitian, operasional variabel, metode KDD,

pembangunan model klasifikasi menggunakan *Decision Tree* dan *XGBoost*, serta metode pengembangan sistem menggunakan SDLC model *Waterfall*.

BAB IV HASIL DAN PEMBAHASAN

Bab ini membahas hasil analisis kurikulum, hasil sintesis CPL dan Profil Lulusan, pembentukan profil kompetensi mahasiswa, hasil pengolahan data kuesioner, hasil pembangunan model klasifikasi, evaluasi performa model, analisis SHAP, implementasi sistem rekomendasi, hasil pengujian sistem, serta pembahasan hasil penelitian.

BAB V PENUTUP

Bab ini berisi kesimpulan yang diperoleh berdasarkan hasil penelitian serta saran yang dapat digunakan untuk pengembangan penelitian selanjutnya maupun pengembangan sistem di masa mendatang.

BAB VI LAMPIRAN

Bab ini berisi dokumen pendukung penelitian, seperti instrumen kuesioner, hasil wawancara, dokumen CPL dan Profil Lulusan, hasil pengujian sistem, dokumentasi penelitian, serta data pendukung lainnya yang digunakan selama proses penelitian.

BAB II

TINJAUAN PUSTAKA

2.1 Landasan Teori

Penelitian terdahulu digunakan sebagai dasar untuk mengetahui perkembangan penelitian yang berkaitan dengan klasifikasi, sistem rekomendasi, *machine learning*, serta pemanfaatan data pendidikan dalam mendukung pengambilan keputusan. Selain itu, kajian terhadap penelitian terdahulu dilakukan untuk mengidentifikasi persamaan, perbedaan, keterbatasan penelitian sebelumnya, serta menemukan *research gap* yang menjadi dasar pengembangan penelitian ini.

Penelitian mengenai analisis minat siswa berdasarkan mata pelajaran telah dilakukan menggunakan algoritma *Decision Tree* untuk mengidentifikasi kecenderungan minat akademik siswa. Hasil penelitian menunjukkan bahwa algoritma *Decision Tree* mampu melakukan klasifikasi minat siswa berdasarkan pola nilai mata pelajaran yang dimiliki dengan tingkat akurasi yang baik. Persamaan penelitian tersebut dengan penelitian ini terletak pada penggunaan algoritma *Decision Tree* sebagai metode klasifikasi. Perbedaannya terletak pada objek penelitian dan variabel yang digunakan. Penelitian tersebut berfokus pada minat siswa tingkat sekolah menengah berdasarkan nilai mata pelajaran, sedangkan penelitian ini menggunakan variabel minat, gaya belajar, dan tujuan karier mahasiswa yang dikaitkan dengan data kurikulum untuk membentuk profil kompetensi mahasiswa (Haekal, 2025).

Pemanfaatan data kurikulum untuk mendukung proses evaluasi akademik mahasiswa telah diteliti melalui pengembangan model *developmental advising* berbasis *student outcomes* dan *performance indicators*. Hasil penelitian menunjukkan bahwa data capaian pembelajaran dapat digunakan untuk meningkatkan efektivitas evaluasi akademik dan mendukung pengambilan keputusan yang lebih terstruktur. Persamaan penelitian tersebut dengan penelitian ini adalah penggunaan data kurikulum sebagai dasar pengolahan informasi akademik. Namun demikian, penelitian tersebut belum menerapkan algoritma

klasifikasi *machine learning* untuk menghasilkan rekomendasi yang bersifat personal bagi mahasiswa (Hussain et al., 2024).

Penelitian lain memanfaatkan algoritma *Decision Tree* untuk memetakan gaya belajar mahasiswa kedokteran gigi dan menghasilkan rekomendasi strategi pembelajaran yang sesuai. Hasil penelitian menunjukkan bahwa model yang dibangun mampu mengklasifikasikan gaya belajar mahasiswa dengan tingkat akurasi mencapai 90%. Persamaan penelitian tersebut dengan penelitian ini terletak pada penggunaan algoritma *Decision Tree* dan karakteristik mahasiswa sebagai dasar klasifikasi. Perbedaannya adalah penelitian tersebut hanya berfokus pada aspek gaya belajar, sedangkan penelitian ini mengintegrasikan minat, gaya belajar, tujuan karier, serta data kurikulum dalam satu model klasifikasi profil kompetensi mahasiswa (Shoaib et al., 2024).

Pengembangan sistem rekomendasi pemilihan program studi menggunakan pendekatan *machine learning* juga telah dilakukan dengan membandingkan beberapa algoritma klasifikasi, yaitu *Decision Tree, Random Forest*, dan *Gradient Boosting*. Hasil penelitian menunjukkan bahwa sistem yang dibangun mampu membantu calon mahasiswa dalam memilih program studi secara lebih objektif dan akurat berdasarkan data lulusan. Persamaan penelitian tersebut dengan penelitian ini adalah penggunaan metode klasifikasi untuk menghasilkan rekomendasi dalam bidang pendidikan. Perbedaannya terletak pada tujuan penelitian. Penelitian tersebut berfokus pada rekomendasi pemilihan program studi, sedangkan penelitian ini berfokus pada klasifikasi profil kompetensi mahasiswa dan rekomendasi pengembangan mahasiswa selama masa studi (Zayed et al., 2022).

Penelitian lain mengkaji pemilihan program studi yang sesuai bagi calon mahasiswa menggunakan beberapa algoritma *supervised learning*, yaitu *Decision Tree*, *Random Forest*, *Support Vector Machine* (SVM), dan *Gradient Boosting*. Hasil penelitian menunjukkan bahwa algoritma *Random Forest* dan *Gradient Boosting* memberikan performa prediksi yang lebih baik dibandingkan algoritma lainnya dalam menentukan program studi yang sesuai berdasarkan karakteristik mahasiswa. Persamaan penelitian tersebut dengan penelitian ini adalah penggunaan pendekatan klasifikasi berbasis *machine learning* dalam bidang pendidikan. Perbedaannya terletak pada tujuan penelitian dan sumber data yang digunakan.

Penelitian tersebut berfokus pada prediksi pemilihan program studi, sedangkan penelitian ini bertujuan mengklasifikasikan profil kompetensi mahasiswa berdasarkan integrasi data kurikulum, minat, gaya belajar, dan tujuan karier sebagai dasar rekomendasi pengembangan mahasiswa (Alsayed et al., 2021).

Tabel 2.1 Jurnal Acuan

Identitas	Judul Penelitian	Metode	Hasil / Kesimpulan
Haekal (2025)	*Implementation of Decision Tree Algorithm for Student Interest Analysis Based on Subjects at MTs Aisyiyah Binjai*	*Decision Tree*	Algoritma *Decision Tree* mampu menganalisis minat siswa berdasarkan pola nilai mata pelajaran secara cukup akurat.
Hussain et al. (2024)	*Pedagogical and Mixed Methods Developmental Advising Model Using Digital Outcome Assessment Data*	*Developmental Advising* berbasis data kurikulum	Data capaian pembelajaran dan *performance indicators* dapat digunakan untuk meningkatkan efektivitas evaluasi akademik mahasiswa.
Shoaib et al. (2024)	*Utilizing Decision Tree Machine Learning Model to Map Dental Students' Preferred Learning Styles with Suitable Instructional Strategies*	*Decision Tree*	Model menghasilkan klasifikasi gaya belajar mahasiswa dengan tingkat akurasi 100% dan memberikan rekomendasi strategi pembelajaran yang sesuai.
Zayed et al. (2022)	*A Recommendation System for Selecting the Appropriate Undergraduate Program at Higher Education Institutions Using Graduate Student Data*	*Decision Tree*, *Random Forest*, dan *Gradient Boosting*	Sistem rekomendasi mampu membantu pemilihan program studi secara lebih objektif berdasarkan data lulusan.
Alsayed et al. (2021)	*Selection of the Right Undergraduate Major by Students Using Supervised Learning Techniques*	*Decision Tree*, *Random Forest*, *SVM*, dan *Gradient Boosting*	Algoritma *ensemble learning* menghasilkan performa prediksi yang tinggi dalam menentukan program studi yang sesuai bagi mahasiswa.

Berdasarkan kajian penelitian terdahulu, penerapan machine learning dalam bidang pendidikan telah dimanfaatkan untuk berbagai kebutuhan, seperti analisis minat, identifikasi gaya belajar, pemilihan program studi, dan evaluasi akademik

mahasiswa. Namun, masih terdapat beberapa kesenjangan penelitian yang perlu dikaji lebih lanjut. Sebagian besar penelitian hanya berfokus pada satu karakteristik individu, padahal pengembangan kompetensi mahasiswa dipengaruhi oleh kombinasi faktor seperti minat, gaya belajar, dan tujuan karier. Selain itu, penggunaan Profil Lulusan (PL) dan Capaian Pembelajaran Lulusan (CPL) sebagai dasar pembentukan profil kompetensi mahasiswa masih jarang dilakukan, terutama dalam bentuk integrasi kurikulum dengan karakteristik individu. Penelitian sebelumnya juga umumnya menghasilkan klasifikasi minat, gaya belajar, atau rekomendasi program studi, sehingga belum banyak yang mengembangkan model klasifikasi profil kompetensi mahasiswa secara komprehensif berdasarkan sintesis kurikulum. Kesenjangan lainnya adalah belum optimalnya pemanfaatan kurikulum lintas program studi untuk membentuk profil kompetensi multidisiplin yang relevan dengan kebutuhan akademik dan karier. Dari sisi metodologi, sebagian penelitian masih menggunakan satu algoritma klasifikasi tanpa melakukan perbandingan model secara mendalam, serta belum memperhatikan aspek interpretabilitas model sehingga hasil prediksi yang diperoleh kurang transparan dan sulit dipahami oleh pengguna dalam konteks pendidikan.

Berdasarkan *research* gap yang telah diidentifikasi, penelitian ini memiliki beberapa unsur kebaruan dibandingkan penelitian sebelumnya. Penelitian memanfaatkan data kurikulum Universitas Bale Bandung yang mencakup Profil Lulusan (PL) dan Capaian Pembelajaran Lulusan (CPL) dari 12 program studi sebagai dasar pembentukan profil kompetensi mahasiswa. Selain itu, penelitian mengintegrasikan tiga variabel utama, yaitu minat, gaya belajar, dan tujuan karier, ke dalam satu instrumen untuk menghasilkan representasi kompetensi mahasiswa yang lebih komprehensif. Hasil sintesis kurikulum menghasilkan enam profil kompetensi, yaitu *Educational and Research Innovator* (PC01), *Digital Technology Specialist* (PC02), *Data and Analytical Intelligence Specialist* (PC03), *Community Development Specialist* (PC04), *Entrepreneurship and Innovation Specialist* (PC05), *Professional Leader* (PC06). Pembentukan label profil dilakukan menggunakan pendekatan *rule-based initial labeling* yang menghubungkan variabel penelitian dengan domain CPL hasil sintesis kurikulum. Selanjutnya, penelitian membandingkan kinerja algoritma *Decision Tree* dan *XGBoost* melalui

K-Fold Cross Validation berdasarkan metrik *Accuracy, Precision, Recall, F1-Score,* dan *ROC-AUC* untuk memperoleh model klasifikasi terbaik. Untuk meningkatkan transparansi model, penelitian juga menerapkan *Explainable Artificial Intelligence* (XAI) menggunakan metode SHAP guna menjelaskan faktor-faktor yang memengaruhi hasil klasifikasi. Model yang dihasilkan kemudian diimplementasikan ke dalam sistem berbasis web yang tidak hanya mengklasifikasikan profil kompetensi mahasiswa, tetapi juga memberikan rekomendasi pengembangan akademik, non-akademik, sertifikasi, kegiatan MBKM, dan karier yang sesuai. Dengan demikian, penelitian ini menghasilkan model klasifikasi dan sistem rekomendasi pengembangan mahasiswa berbasis kurikulum yang mengintegrasikan data kurikulum, karakteristik mahasiswa, profil kompetensi, dan rekomendasi pengembangan secara terpadu.

2.2 Dasar Teori

Adapun dasar teori-teori yang digunakan sebagai acuan dalam implementasi aplikasi yaitu sebagai berikut:

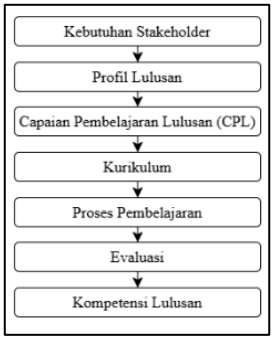
2.2.1. Pengembangan Mahasiswa

Pengembangan mahasiswa merupakan upaya untuk meningkatkan kompetensi, potensi, dan kesiapan mahasiswa dalam menghadapi tuntutan akademik maupun dunia kerja. Proses ini dilakukan melalui identifikasi karakteristik dan kebutuhan mahasiswa guna mendukung pengembangan kemampuan akademik, berpikir kritis, analitis, serta karier. Pemanfaatan data pendidikan dan *machine learning* dapat membantu memetakan kompetensi mahasiswa secara lebih objektif dan terarah (Atalla et al., 2023; Dayanah Ayulani et al., 2023; Deniz, 2024; Okesola, 2021; Osho et al., 2026).

2.2.2. *Outcome-Based Education*

Outcome-Based Education (*OBE*) merupakan pendekatan pendidikan yang berfokus pada pencapaian kompetensi lulusan melalui penyelarasan kurikulum, pembelajaran, dan penilaian berdasarkan Capaian Pembelajaran Lulusan (CPL)

(Direktorat Pembelajaran dan Kemahasiswaan et al., 2024). Pendekatan ini sejalan dengan Permendikbudristek Nomor 53 Tahun 2023 yang menegaskan bahwa penyelenggaraan pendidikan tinggi harus berorientasi pada ketercapaian CPL sebagai hasil akhir proses pendidikan (Permendikbudristek, 2023).



Gambar 2.1 Alur Implementasi *Outcome-Based Education* (OBE)
Sumber: (Direktorat Pembelajaran dan Kemahasiswaan et al., 2024)

Gambar 2.1 penerapan OBE dimulai dari identifikasi kebutuhan pemangku kepentingan yang diterjemahkan ke dalam Profil Lulusan (PL) dan CPL. Selanjutnya, CPL menjadi dasar penyusunan kurikulum, pelaksanaan pembelajaran, dan evaluasi sehingga kompetensi lulusan tetap sesuai dengan tujuan program studi dan kebutuhan dunia kerja (Direktorat Pembelajaran dan Kemahasiswaan et al., 2024).

2.2.3. Profil Lulusan

Profil Lulusan (PL) merupakan gambaran kompetensi dan peran yang diharapkan dimiliki mahasiswa setelah menyelesaikan pendidikan pada suatu program studi. Dalam pendekatan *Outcome-Based Education* (*OBE*), PL menjadi acuan utama dalam penyusunan kurikulum karena mencerminkan kebutuhan dunia kerja, perkembangan ilmu pengetahuan, serta harapan pemangku kepentingan. PL kemudian diterjemahkan ke dalam capaian pembelajaran lulusan yang lebih spesifik dan terukur sehingga dapat menjadi dasar dalam perancangan mata kuliah dan proses pembelajaran (Direktorat Pembelajaran dan Kemahasiswaan et al., 2024). Selain itu, regulasi pendidikan tinggi menegaskan bahwa profil lulusan harus

menjadi dasar dalam menentukan kompetensi yang perlu dicapai mahasiswa selama masa studi (Permendikbudristek, 2023).

2.2.4. Capaian Pembelajaran Lulusan

Capaian Pembelajaran Lulusan (CPL) merupakan kemampuan yang diharapkan dimiliki mahasiswa setelah menyelesaikan seluruh proses pembelajaran pada suatu program studi. Menurut Permendikbudristek Nomor 53 Tahun 2023, CPL mencerminkan hasil belajar yang mencakup aspek sikap, pengetahuan, keterampilan umum, dan keterampilan khusus yang diperoleh selama masa studi. Dalam pendekatan OBE, CPL disusun berdasarkan PL dan menjadi acuan dalam pengembangan kurikulum, penyusunan mata kuliah, serta evaluasi pembelajaran agar kompetensi yang dihasilkan sesuai dengan kebutuhan dunia kerja dan perkembangan ilmu pengetahuan (Direktorat Pembelajaran dan Kemahasiswaan et al., 2024; Kementrian Pendidikan, 2023; Rawis et al., 2025).

2.2.5. Kompetensi

Kompetensi merupakan kemampuan yang dimiliki seseorang untuk melaksanakan tugas atau menyelesaikan pekerjaan berdasarkan pengetahuan, keterampilan, dan sikap yang telah diperoleh melalui proses pembelajaran. Dalam pendidikan tinggi berbasis OBE, kompetensi menjadi hasil yang diharapkan dari pencapaian CPL karena mencerminkan kemampuan nyata yang dapat diterapkan oleh mahasiswa dalam lingkungan akademik maupun dunia kerja (Hussain et al., 2020, 2021). Kompetensi tidak hanya berkaitan dengan penguasaan teori, tetapi juga kemampuan menerapkan pengetahuan secara efektif serta menunjukkan perilaku profesional yang sesuai dengan tuntutan bidang keilmuan tertentu (Atalla et al., 2023; Fernández-García et al., 2020).

2.2.6. Profil Kompetensi Mahasiswa

Profil kompetensi mahasiswa merupakan gambaran mengenai kecenderungan kemampuan, potensi, serta karakteristik yang dimiliki mahasiswa berdasarkan kombinasi aspek pengetahuan, keterampilan, dan sikap yang

berkembang selama proses pendidikan. Dalam pendekatan OBE, profil kompetensi digunakan untuk mengidentifikasi tingkat kesesuaian antara capaian pembelajaran yang diperoleh mahasiswa dengan kebutuhan dunia kerja dan tuntutan profesional di masa depan (Hussain et al., 2020, 2021). Profil kompetensi juga dapat dimanfaatkan sebagai dasar dalam memberikan rekomendasi pengembangan akademik, pelatihan, maupun perencanaan karier sehingga mahasiswa dapat mengembangkan potensinya secara lebih terarah (Atalla et al., 2023; Hussain et al., 2024; Ngozi et al., 2025).

2.2.7. Faktor Pembentuk Profil Kompetensi Mahasiswa

A. Minat

Minat merupakan kecenderungan seseorang untuk memberikan perhatian, ketertarikan, dan keterlibatan yang lebih besar terhadap suatu bidang atau aktivitas tertentu. Dalam lingkungan pendidikan tinggi, minat menjadi salah satu faktor yang memengaruhi pilihan bidang pembelajaran, pengembangan kemampuan, dan perencanaan karier mahasiswa. Penelitian Putri Miya G. (2024) menunjukkan bahwa minat dapat dilihat dari preferensi mahasiswa terhadap bidang keilmuan tertentu serta kecenderungan memilih aktivitas akademik yang sesuai dengan ketertarikannya. Selain itu, minat juga berkaitan dengan tujuan karier dan peluang profesi yang ingin dicapai di masa depan (McKenzie & Bennett, 2022). Oleh karena itu, minat dapat digunakan sebagai indikator untuk memahami arah pengembangan kompetensi mahasiswa.

B. Gaya Belajar

Gaya belajar merupakan kecenderungan seseorang dalam menerima, mengolah, dan memahami informasi selama proses pembelajaran. Setiap mahasiswa memiliki cara belajar yang berbeda sehingga strategi yang efektif bagi satu individu belum tentu sesuai bagi individu lainnya. Salah satu model yang banyak digunakan adalah *Felder-Silverman Learning Style Model* (FSLSM) yang membagi gaya belajar ke dalam empat dimensi, yaitu *Active–Reflective*, *Sensing–Intuitive*, *Visual–Verbal*, dan *Sequential–Global*. Selain itu, model *Visual, Auditory, Read/Write, Kinesthetic* (VARK) mengelompokkan gaya belajar berdasarkan media yang paling disukai dalam memperoleh informasi, yaitu visual, auditori,

membaca/menulis, dan kinestetik. Kedua model tersebut banyak dimanfaatkan untuk mengidentifikasi karakteristik belajar mahasiswa melalui instrumen kuesioner yang terstruktur (Anwar & Wulandari, 2025; Fernández-García et al., 2020; Hasibuan et al., 2025; Hussain et al., 2024).

C. Tujuan Karier

Tujuan karier merupakan gambaran mengenai profesi atau bidang pekerjaan yang ingin dicapai seseorang di masa depan berdasarkan minat, kemampuan, serta harapan pengembangan diri. Dalam lingkungan pendidikan tinggi, tujuan karier menjadi salah satu faktor yang memengaruhi keputusan mahasiswa dalam mengembangkan kompetensi yang relevan dengan kebutuhan dunia kerja. Aspirasi karier mahasiswa tidak hanya dipengaruhi oleh kemampuan akademik, tetapi juga oleh ketertarikan terhadap bidang pekerjaan tertentu, peluang pengembangan, dan prospek karier jangka panjang (McKenzie & Bennett, 2022). Selain itu, tujuan karier dapat diidentifikasi melalui beberapa indikator, seperti bidang pekerjaan yang diminati, posisi yang ingin dicapai, serta rencana pengembangan profesional di masa mendatang (José-García et al., 2023; Pratiwi et al., 2024). Oleh karena itu, tujuan karier dapat menjadi acuan dalam menentukan kompetensi yang perlu dikembangkan agar mahasiswa lebih siap menghadapi dunia kerja (McKenzie & Bennett, 2022).

2.2.8. Instrumen Penelitian

A. *Kuesioner*

Kuesioner merupakan instrumen pengumpulan data yang digunakan untuk memperoleh informasi dari responden melalui serangkaian pertanyaan atau pernyataan yang disusun sesuai tujuan penelitian. Dalam bidang pendidikan dan sistem cerdas, kuesioner sering dimanfaatkan untuk mengukur karakteristik individu yang tidak dapat diamati secara langsung, seperti minat, gaya belajar, dan tujuan karier. Data yang diperoleh kemudian diubah menjadi bentuk terstruktur sehingga dapat dianalisis secara kuantitatif maupun digunakan sebagai masukan bagi sistem berbasis *machine learning* (Anwar & Wulandari, 2025). Selain itu, kuesioner juga banyak digunakan untuk mengumpulkan umpan balik pengguna

secara sistematis sehingga dapat mendukung proses analisis dan pengambilan keputusan (Fitriastuti et al., 2024; Sugiana, 2023).

B. Skala *Likert*

Skala *Likert* merupakan teknik pengukuran yang digunakan untuk mengubah tanggapan, persepsi, atau tingkat persetujuan responden terhadap suatu pernyataan menjadi data berbentuk angka. Skala ini biasanya menggunakan beberapa pilihan jawaban bertingkat, mulai dari tidak setuju hingga sangat setuju, yang masing-masing memiliki nilai tertentu. Melalui pendekatan ini, data yang awalnya bersifat subjektif dapat diolah secara kuantitatif dan digunakan dalam berbagai proses analisis, termasuk penelitian pendidikan, sistem informasi, dan *machine learning* (Fitriastuti et al., 2024; Siti Muthiah Nuralifah et al., 2025; Sugiana, 2023).

Tabel 2.2 Skala *Likert*

Sumber: (Siti Muthiah Nuralifah et al., 2025)

Bobot	Keterangan
1	Tidak Setuju (TS)
2	Kurang Setuju (KS)
3	Cukup Setuju (CS)
4	Setuju (S)
5	Sangat Setuju (SS)

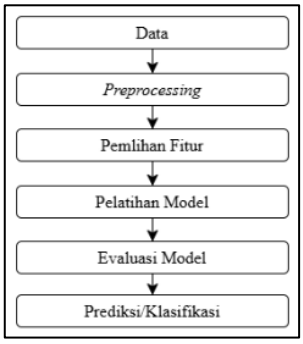
Tabel 2.2 menunjukkan bobot yang digunakan untuk mengonversi jawaban responden ke dalam bentuk numerik. Semakin tinggi tingkat persetujuan yang diberikan, semakin besar pula nilai yang diperoleh. Proses pembobotan ini memungkinkan jawaban kuesioner diolah secara kuantitatif sehingga dapat digunakan sebagai data masukan pada tahap analisis dan pemodelan *machine learning* (Fitriastuti et al., 2024; Siti Muthiah Nuralifah et al., 2025).

2.2.9. *Machine Learning* untuk Klasifikasi

A. *Machine Learning*

Machine Learning merupakan salah satu cabang *Artificial Intelligence* yang memungkinkan komputer mempelajari pola dari data untuk menghasilkan prediksi

atau keputusan secara otomatis. Berbeda dengan pemrograman konvensional yang mengandalkan aturan yang ditentukan secara eksplisit, *Machine Learning* membangun model berdasarkan hubungan yang ditemukan dari data historis. Komponen utama dalam *Machine Learning* meliputi data, fitur, algoritma pembelajaran, model, dan proses evaluasi. Pada pendekatan *supervised learning*, model dilatih menggunakan data yang telah memiliki label sehingga mampu mengklasifikasikan atau memprediksi data baru dengan karakteristik serupa. Dalam bidang pendidikan, *Machine Learning* banyak dimanfaatkan untuk menganalisis karakteristik mahasiswa, memprediksi performa akademik, serta mendukung pengambilan keputusan berbasis data (Alsayed et al., 2021; Dayanah Ayulani et al., 2023; Deniz, 2024).



Gambar 2.2 *Workflow Machine Learning*

Sumber: (Alsayed et al., 2021; Dayanah Ayulani et al., 2023; Deniz, 2024)

Proses *Machine Learning* dimulai dari pengolahan data agar siap digunakan, dilanjutkan dengan pemilihan fitur yang relevan dan pelatihan model menggunakan algoritma tertentu. Setelah model dievaluasi untuk mengetahui tingkat kinerjanya, model tersebut dapat digunakan untuk melakukan prediksi atau klasifikasi terhadap data baru (Dayanah Ayulani et al., 2023; Deniz, 2024).

B. Klasifikasi

Klasifikasi merupakan metode dalam *Machine Learning* yang digunakan untuk mengelompokkan data ke dalam kategori tertentu berdasarkan pola yang dipelajari dari data sebelumnya. Metode ini termasuk *supervised learning* karena proses pembelajarannya menggunakan data yang telah memiliki label sebagai acuan. Komponen utama dalam klasifikasi meliputi data masukan (*features*), label

kelas, data latih, algoritma klasifikasi, dan model prediksi. Dalam bidang pendidikan, klasifikasi banyak dimanfaatkan untuk mengidentifikasi karakteristik mahasiswa serta mendukung proses pengambilan keputusan berbasis data (Dayanah Ayulani et al., 2023; Siswipraptini et al., 2024; Syed Mustapha, 2023).

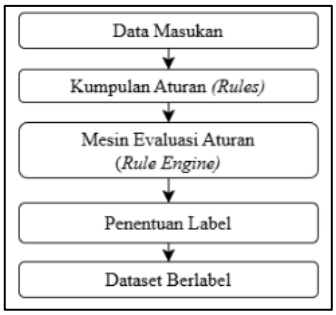
C. *Multi-Class Classification*

Multi-Class Classification merupakan metode klasifikasi dalam *machine learning* yang digunakan untuk mengelompokkan data ke dalam lebih dari dua kelas atau kategori. Berbeda dengan *binary classification* yang hanya menghasilkan dua kemungkinan kelas, *multi-class classification* memungkinkan suatu objek diklasifikasikan ke salah satu dari beberapa kelas yang tersedia berdasarkan karakteristik data yang dimiliki. Pendekatan ini banyak digunakan dalam bidang pendidikan, sistem rekomendasi, dan analisis data karena mampu menangani permasalahan klasifikasi yang memiliki banyak kategori keluaran. Beberapa algoritma seperti *Decision Tree* dan *XGBoost* secara alami mendukung proses *multi-class classification* sehingga dapat digunakan untuk memprediksi kelas berdasarkan pola yang dipelajari dari data pelatihan (Alsayed et al., 2021; Haekal, 2025; Shoaib et al., 2024).

2.2.10. Pembentukan Label Dataset

A. *Rule-Based Initial Labeling*

Rule-Based Initial Labeling merupakan metode pembentukan label awal pada dataset dengan menggunakan seperangkat aturan (*rules*) yang telah ditentukan berdasarkan pengetahuan domain atau hasil analisis pakar. Metode ini bekerja dengan menerapkan aturan berbentuk *IF–THEN* untuk mengelompokkan data ke dalam kategori tertentu sebelum digunakan dalam proses pembelajaran mesin. Pendekatan ini banyak digunakan ketika dataset belum memiliki label asli (*ground truth*) sehingga diperlukan mekanisme pelabelan awal yang konsisten dan dapat dipertanggungjawabkan secara logis. Dalam penelitian berbasis klasifikasi, *rule-based labeling* berfungsi sebagai dasar pembentukan kelas target yang selanjutnya digunakan untuk melatih model *machine learning* (Abouhawwash, 2025; Liu et al., 2024; Song et al., 2023).



Gambar 2.3 Arsitektur Rule-Based Labeling

Sumber: (Abouhawwash, 2025; Liu et al., 2024; Song et al., 2023)

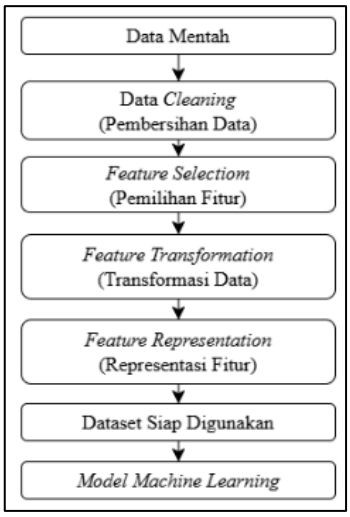
Gambar di atas menunjukkan alur umum *Rule-Based Labeling*. Proses dimulai dari data masukan yang dievaluasi menggunakan kumpulan aturan yang telah ditetapkan. Setiap data akan diperiksa kesesuaiannya terhadap kondisi dalam aturan *IF–THEN*. Apabila suatu aturan terpenuhi, sistem akan memberikan label yang sesuai sehingga menghasilkan dataset yang telah memiliki kelas target. Dataset berlabel tersebut kemudian dapat digunakan pada tahap analisis data maupun pelatihan model klasifikasi.

B. *Pseudo Labeling*

Pseudo labeling merupakan teknik pemberian label pada data yang belum memiliki label (*unlabeled data*) dengan memanfaatkan aturan tertentu atau hasil prediksi dari model yang telah dibangun sebelumnya. Metode ini banyak digunakan dalam pembelajaran mesin ketika data berlabel terbatas, sehingga proses pembentukan label dilakukan secara otomatis berdasarkan pengetahuan domain, aturan pakar, atau prediksi model untuk menghasilkan dataset yang dapat digunakan pada tahap pelatihan (*training*) (Okesola, 2021; A. Ridwan et al., 2024). Dalam konteks klasifikasi, *pseudo labeling* berfungsi sebagai pendekatan *weak supervision* yang memungkinkan data tanpa label diubah menjadi data berlabel sehingga dapat dimanfaatkan untuk membangun model klasifikasi secara lebih efisien (Abdulahi Hasan & Fang, 2021; Syed Mustapha, 2023). Meskipun label yang dihasilkan bukan merupakan *ground truth* yang diperoleh secara langsung dari observasi atau pakar, *pseudo label* tetap dapat digunakan selama proses pembentukannya memiliki dasar logis dan dapat dipertanggungjawabkan secara akademik (A. Ridwan et al., 2024).

2.2.11. *Feature Engineering*

Feature engineering merupakan proses mengubah, memilih, dan menyiapkan data mentah menjadi fitur yang lebih representatif sehingga dapat digunakan secara optimal oleh algoritma *machine learning*. Tahapan ini berperan penting dalam meningkatkan kualitas model karena fitur yang baik dapat membantu algoritma mengenali pola data dengan lebih akurat. Menurut penelitian yang membahas klasifikasi dan prediksi berbasis *machine learning*, *feature engineering* mencakup proses seleksi fitur, transformasi data, pembuatan fitur baru, serta representasi data agar sesuai dengan kebutuhan model. Kualitas fitur yang digunakan sering kali memiliki pengaruh yang lebih besar terhadap performa model dibandingkan pemilihan algoritma itu sendiri karena fitur menjadi sumber informasi utama dalam proses pembelajaran mesin (Haekal, 2025; Nurizati et al., 2024; Shoaib et al., 2024; Zayed et al., 2022).



Gambar 2.4 Tahapan Umum *Feature Engineering*

Sumber: (Nurizati et al., 2024; Shoaib et al., 2024; Zayed et al., 2022)

Alur umum *feature engineering* yang dimulai dari data mentah hingga menghasilkan dataset yang siap digunakan dalam proses pelatihan model. Tahapan tersebut meliputi pembersihan data untuk mengurangi kesalahan atau ketidakkonsistenan, pemilihan fitur yang relevan, transformasi data ke dalam format yang sesuai, serta representasi fitur agar dapat diproses oleh algoritma *machine learning*. Melalui tahapan ini, informasi penting yang terdapat pada data

dapat dipertahankan sehingga model mampu menghasilkan prediksi yang lebih baik.

2.2.12. *Decision Tree*

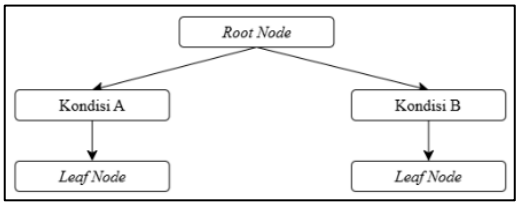
Decision Tree merupakan salah satu algoritma *machine learning* yang digunakan untuk melakukan proses klasifikasi maupun prediksi dengan membentuk struktur pohon keputusan (*decision tree*). Algoritma ini bekerja dengan cara membagi data ke dalam beberapa kelompok berdasarkan atribut yang dianggap paling berpengaruh terhadap variabel target. Setiap percabangan pada pohon keputusan merepresentasikan aturan keputusan yang digunakan untuk memisahkan data hingga diperoleh kelompok yang homogen (Basu, 2025; Dayanah Ayulani et al., 2023)

Decision Tree banyak digunakan karena memiliki tingkat interpretabilitas yang tinggi, mudah dipahami oleh pengguna, serta mampu menghasilkan aturan klasifikasi dalam bentuk logika *if-then*. Selain itu, algoritma ini dapat menangani data kategorikal maupun numerik tanpa memerlukan transformasi yang kompleks (Okesola, 2021).

A. Struktur Dasar *Decision Tree*

Struktur dasar *Decision Tree* terdiri dari:

1. *Root Node*, yaitu simpul awal yang menjadi atribut utama dalam proses klasifikasi.
2. *Internal Node*, yaitu simpul yang berisi proses pengambilan keputusan berdasarkan atribut tertentu.
3. *Branch*, yaitu cabang yang menunjukkan hasil dari suatu keputusan.
4. *Leaf Node*, yaitu simpul akhir yang berisi hasil klasifikasi atau prediksi.



Gambar 2.5 Struktur *Decision Tree*

Sumber: (Dayanah Ayulani et al., 2023; Okesola, 2021)

Gambar 2.6 menunjukkan struktur dasar Decision Tree yang terdiri atas *root node*, *internal node*, *branch*, dan *leaf node*. Proses klasifikasi dimulai dari *root node* sebagai atribut utama, kemudian data dibagi melalui beberapa percabangan berdasarkan nilai atribut tertentu hingga mencapai *leaf node* yang merepresentasikan hasil klasifikasi. Struktur tersebut memungkinkan proses pengambilan keputusan dilakukan secara sistematis dan mudah dipahami oleh pengguna.

B. Tahapan Algoritma *Decision Tree*

Menurut Dayanah Ayulani et al. (2023), tahapan pembentukan *Decision Tree* meliputi:

1. Menyiapkan dataset yang akan digunakan untuk proses klasifikasi.
2. Menghitung nilai *Entropy* pada setiap atribut.
3. Menghitung nilai *Information Gain* dari setiap atribut.
4. Memilih atribut dengan nilai *Information Gain* terbesar sebagai *root node*.
5. Membagi data berdasarkan atribut terpilih.
6. Mengulangi proses perhitungan *Entropy* dan *Information Gain* pada setiap cabang hingga seluruh data berada pada kelas yang sama atau tidak terdapat atribut yang dapat digunakan untuk pemisahan lebih lanjut.
7. Membentuk pohon keputusan hingga menghasilkan *leaf node* sebagai kelas akhir.

C. *Entropy*

Entropy digunakan untuk mengukur tingkat ketidakpastian atau ketidakhomogenan suatu kumpulan data. Semakin kecil nilai *Entropy*, maka data pada kelompok tersebut semakin homogen.

$$Entropy(S) = -\sum pilog2pi$$

Keterangan:

Entropy(S) = nilai *entropy* pada dataset S

p_i = probabilitas kemunculan kelas ke-i

n = jumlah kelas

Nilai *Entropy* akan bernilai 0 apabila seluruh data berada dalam satu kelas yang sama.

D. *Information Gain*

Information Gain digunakan untuk menentukan atribut terbaik yang akan dijadikan dasar percabangan pada pohon keputusan. Semakin besar nilai *Information Gain*, semakin baik atribut tersebut dalam memisahkan data.

$$Gain(S,A)=Entropy(S)-\sum|S||Sv|Entropy(Sv)$$

Keterangan:

Gain(S,A) = nilai *Information Gain* atribut A

Entropy(S) = *entropy* dataset awal

S_v = subset data hasil pembagian berdasarkan atribut A

$|S_v|$ = jumlah data pada subset

|S| = jumlah data keseluruhan

Atribut dengan nilai *Information Gain* terbesar akan dipilih sebagai dasar pembentukan percabangan karena mampu mengurangi ketidakpastian data secara optimal (Dayanah Ayulani et al., 2023).

2.2.13. *XGBoost*

Extreme Gradient Boosting (*XGBoost*) merupakan algoritma machine learning berbasis *Gradient Boosting Decision Tree (GBDT)* yang dikembangkan untuk meningkatkan akurasi prediksi serta mengurangi risiko *overfitting*. *XGBoost* bekerja dengan membangun beberapa pohon keputusan (*decision tree*) secara bertahap, dimana setiap pohon baru digunakan untuk memperbaiki kesalahan prediksi dari pohon sebelumnya. Selain itu, *XGBoost* menerapkan teknik *regularization* sehingga model yang dihasilkan lebih stabil dan memiliki kemampuan generalisasi yang baik (Dayanah Ayulani et al., 2023; Kate et al., 2026; Rafie et al., 2025).

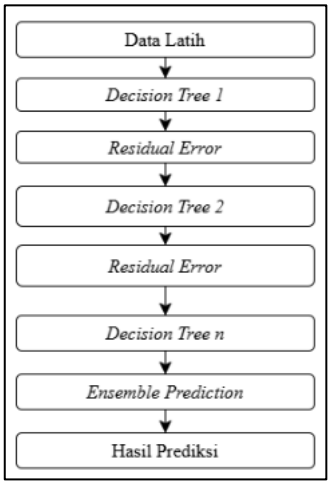
A. Tahapan *XGBoost*

Tahapan kerja algoritma *XGBoost* meliputi:

1. Membentuk pohon keputusan awal (*Decision Tree*).
2. Menghitung kesalahan prediksi (*error*).
3. Membangun pohon baru untuk memperbaiki kesalahan sebelumnya.
4. Menerapkan *regularization* untuk mengurangi *overfitting*.

5. Menggabungkan seluruh pohon menjadi model prediksi akhir.

B. Arsitektur *XGBoost*



Gambar 2.6 Arsitektur *XGBoost*

Sumber: (Kate et al., 2026; Rafie et al., 2025)

Arsitektur *XGBoost* menunjukkan proses pembelajaran yang dilakukan secara berulang. Prediksi dari setiap pohon digunakan untuk menghitung kesalahan yang masih terjadi, kemudian kesalahan tersebut dipelajari kembali oleh pohon berikutnya. Hasil prediksi dari seluruh pohon kemudian digabungkan sehingga menghasilkan model yang lebih akurat dibandingkan penggunaan satu pohon keputusan saja (Dayanah Ayulani et al., 2023; Kate et al., 2026).

C. Fungsi Objektif *XGBoost*

Fungsi objektif pada *XGBoost* dirumuskan sebagai berikut:

$$Obj(\theta) = L(\theta) + \Omega(\theta)$$

Keterangan:

$Obj(\theta)$ = fungsi objektif model

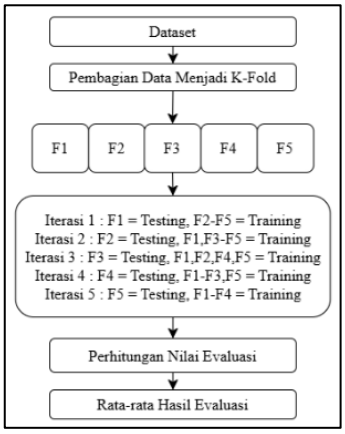
$L(\theta)$ = fungsi kesalahan (*loss function*)

$\Omega(\theta)$ = fungsi *regularization*

Fungsi tersebut menunjukkan bahwa *XGBoost* tidak hanya meminimalkan kesalahan prediksi, tetapi juga mengontrol kompleksitas model sehingga dapat mengurangi risiko *overfitting*.

2.2.14. *Cross Validation*

Cross Validation merupakan teknik evaluasi dalam *machine learning* yang digunakan untuk mengukur kemampuan model dalam memprediksi data baru yang belum pernah dipelajari sebelumnya. Metode ini dilakukan dengan membagi dataset ke dalam beberapa bagian (*fold*), kemudian secara bergantian menggunakan satu bagian sebagai data pengujian dan bagian lainnya sebagai data pelatihan. Proses tersebut membantu menghasilkan nilai evaluasi yang lebih stabil dan mengurangi risiko *overfitting*, sehingga performa model dapat dinilai secara lebih objektif (Devanathan et al., 2025; Hasibuan et al., 2025; Rafie et al., 2025).



Gambar 2.7 Proses *K-Fold Cross Validation*

Sumber: (Rafie et al., 2025)

Alur *K-Fold Cross Validation*, yaitu proses pembagian data ke dalam beberapa *fold* yang digunakan secara bergantian sebagai data pelatihan dan data pengujian. Setelah seluruh proses selesai, nilai evaluasi dari setiap iterasi dirata-ratakan sehingga diperoleh hasil yang lebih representatif terhadap kemampuan model (Rafie et al., 2025).

2.2.15. *Explainable Artificial Intelligence*

Explainable Artificial Intelligence (XAI) merupakan pendekatan dalam kecerdasan buatan yang bertujuan untuk menjelaskan proses pengambilan keputusan model machine learning sehingga hasil prediksi dapat dipahami oleh manusia. XAI dikembangkan untuk mengatasi keterbatasan model *black box* yang

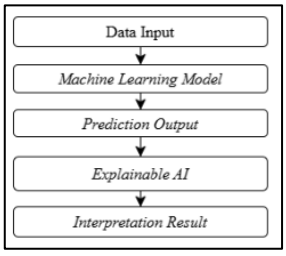
mampu menghasilkan tingkat akurasi tinggi, namun sulit menjelaskan alasan di balik keputusan yang dihasilkan (Basu, 2025; Devanathan et al., 2025; Iban, 2022; Pratiwi et al., 2024). Menurut Basu (2025), XAI memungkinkan pengguna memahami hubungan antara data masukan, proses pembelajaran model, dan hasil prediksi yang dihasilkan. Sementara itu, Devanathan et al. (2025) menjelaskan bahwa XAI berperan dalam meningkatkan transparansi, kepercayaan, dan akuntabilitas sistem kecerdasan buatan. Karakteristik utama *Explainable Artificial Intelligence* meliputi:

1. *Interpretability*, yaitu kemampuan model untuk dijelaskan dan dipahami oleh pengguna.
2. *Transparency*, yaitu keterbukaan proses pengambilan keputusan model.
3. *Trustworthiness*, yaitu meningkatkan kepercayaan pengguna terhadap hasil prediksi.
4. *Accountability*, yaitu kemampuan sistem untuk mempertanggungjawabkan keputusan yang dihasilkan.

Dalam penelitian ini, XAI digunakan untuk menjelaskan faktor-faktor yang memengaruhi hasil klasifikasi profil kompetensi mahasiswa sehingga rekomendasi yang diberikan sistem dapat dipahami oleh pengguna.

Secara umum proses *Explainable Artificial Intelligence* terdiri dari beberapa tahapan sebagai berikut:

1. Data masukan (*input data*) diberikan ke model *machine learning*.
2. Model melakukan proses klasifikasi berdasarkan pola yang dipelajari.
3. Model menghasilkan prediksi kelas.
4. Metode XAI melakukan analisis kontribusi setiap fitur terhadap hasil prediksi.
5. Sistem menghasilkan penjelasan (*explanation*) yang dapat dipahami pengguna.



Gambar 2.8 Tahapan *Explainable Artificial Intelligence*

Sumber: (Basu, 2025; Devanathan et al., 2025; Iban, 2022)

Gambar tersebut menunjukkan bahwa XAI tidak mengubah proses pembelajaran model machine learning, melainkan bekerja setelah model menghasilkan prediksi. Hasil prediksi kemudian dianalisis untuk mengetahui kontribusi masing-masing fitur sehingga keputusan model menjadi lebih transparan dan mudah dipahami (Basu, 2025; Devanathan et al., 2025; Iban, 2022).

2.2.16. *SHapley Additive exPlanations*

SHapley Additive exPlanations (SHAP) merupakan salah satu metode Explainable Artificial Intelligence yang digunakan untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi model machine learning. SHAP dikembangkan berdasarkan konsep *Shapley Value* dalam teori permainan (*cooperative game theory*) yang digunakan untuk menghitung kontribusi setiap pemain secara adil terhadap hasil akhir permainan. Dalam konteks machine learning, setiap fitur dianggap sebagai pemain yang berkontribusi terhadap prediksi model (Basu, 2025; Bifarin, 2023).

Metode SHAP memiliki beberapa keunggulan, yaitu:

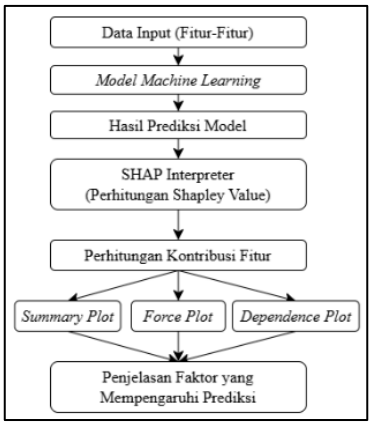
1. Memberikan interpretasi lokal (*local explanation*) pada setiap data.
2. Memberikan interpretasi global (*global explanation*) terhadap keseluruhan model.
3. Dapat digunakan pada berbagai algoritma machine learning.
4. Menjelaskan pengaruh positif maupun negatif setiap fitur terhadap prediksi.

Dalam penelitian ini, SHAP digunakan untuk menjelaskan faktor-faktor yang memengaruhi klasifikasi profil kompetensi mahasiswa berdasarkan variabel minat, gaya belajar, dan tujuan karier.

A. Tahapan SHAP

Proses interpretasi menggunakan SHAP dilakukan melalui tahapan berikut:

1. Model machine learning menghasilkan prediksi.
2. SHAP menghitung nilai kontribusi masing-masing fitur.
3. Nilai kontribusi dihitung menggunakan konsep Shapley Value.
4. SHAP menghasilkan visualisasi interpretasi.
5. Pengguna dapat mengetahui fitur yang paling berpengaruh terhadap hasil klasifikasi.



Gambar 2.9 Arsitektur SHAP dalam Interpretasi Model *Machine Learning*
Sumber: (Basu, 2025; Bifarin, 2023)

Arsitektur SHAP menggambarkan proses interpretasi yang dilakukan setelah model *machine learning* menghasilkan prediksi. SHAP menghitung kontribusi setiap fitur terhadap hasil prediksi, kemudian menyajikannya dalam bentuk visualisasi seperti *summary plot*, *force plot*, dan *dependence plot*. Proses ini membantu menjelaskan faktor-faktor yang paling berpengaruh terhadap keputusan model.

B. Rumus SHAP

Nilai prediksi pada metode SHAP dihitung menggunakan persamaan berikut:

$$f(x) = \phi_0 + \sum_{i=1}^{n} \phi_i$$

Keterangan:

$f(x)$= hasil prediksi model.

ϕ_0= *base value* atau nilai prediksi dasar.

ϕ_i= kontribusi fitur ke-i.

M= jumlah fitur.

Persamaan tersebut menunjukkan bahwa hasil prediksi merupakan kombinasi antara nilai dasar (*base value*) dan kontribusi seluruh fitur yang digunakan dalam model. Nilai kontribusi dapat bernilai positif maupun negatif tergantung pada pengaruh fitur terhadap hasil prediksi.

C. TreeSHAP

Pada penelitian ini algoritma yang digunakan adalah *Decision Tree* dan *XGBoost* yang termasuk dalam kategori model berbasis pohon (*tree-based model*). Oleh karena itu, metode SHAP yang digunakan adalah *TreeSHAP*.

TreeSHAP merupakan pengembangan SHAP yang dirancang khusus untuk model berbasis pohon keputusan sehingga proses perhitungan nilai kontribusi fitur dapat dilakukan lebih cepat dan efisien dibandingkan SHAP umum.

Keunggulan *TreeSHAP* meliputi:

1. Perhitungan lebih cepat untuk *Decision Tree* dan *XGBoost*.
2. Menyediakan interpretasi lokal dan global.
3. Menjelaskan kontribusi fitur secara konsisten.
4. Cocok digunakan pada dataset klasifikasi multikelas.

Dalam penelitian ini *TreeSHAP* digunakan untuk mengidentifikasi fitur minat, gaya belajar, dan tujuan karier yang paling berpengaruh terhadap pembentukan profil kompetensi mahasiswa.

D. Visualisasi SHAP

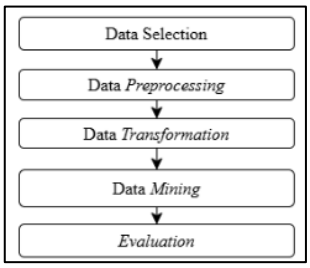
Hasil interpretasi SHAP umumnya disajikan menggunakan beberapa jenis visualisasi, antara lain:

1. *Summary Plot*, menampilkan fitur yang paling berpengaruh terhadap model secara keseluruhan.
2. *Bar Plot*, menunjukkan rata-rata kontribusi setiap fitur terhadap prediksi.
3. *Force Plot*, menjelaskan alasan prediksi pada satu data tertentu.
4. *Dependence Plot*, menunjukkan hubungan antara nilai fitur dengan kontribusinya terhadap model.

2.2.17. *Knowledge Discovery in Database*

Knowledge Discovery in Databases (KDD) adalah proses untuk memperoleh pengetahuan atau informasi yang bermanfaat dari sekumpulan data melalui tahapan yang terstruktur. KDD tidak hanya mencakup proses *data mining*, tetapi juga melibatkan pemilihan data, pembersihan, transformasi, evaluasi, hingga penyajian hasil. Secara umum, tahapan KDD terdiri atas *Data Selection*, *Data Preprocessing*, *Data Transformation*, *Data Mining*, *Evaluation*, dan *Knowledge Presentation* yang

saling mendukung dalam menghasilkan informasi yang relevan dan dapat dimanfaatkan untuk pengambilan keputusan (Okesola, 2021; Syed Mustapha, 2023).



Gambar 2.10 Tahapan *Knowledge Discovery in Databases* (KDD)
Sumber: (Okesola, 2021; Syed Mustapha, 2023)

Proses KDD dimulai dari pemilihan data yang sesuai dengan kebutuhan analisis, kemudian dilanjutkan dengan pembersihan dan transformasi data agar siap digunakan. Selanjutnya dilakukan proses *data mining* untuk menemukan pola atau membangun model. Hasil yang diperoleh dievaluasi untuk memastikan kualitasnya sebelum disajikan dalam bentuk informasi yang mudah dipahami dan digunakan sebagai dasar pengambilan keputusan (Okesola, 2021).

2.2.18. Evaluasi Model Klasifikasi

A. *Confusion Matrix*

Confusion matrix merupakan metode evaluasi yang digunakan untuk membandingkan hasil prediksi model dengan kelas aktual. Matriks ini memberikan informasi mengenai jumlah prediksi yang benar maupun salah pada setiap kelas sehingga dapat digunakan untuk menganalisis performa model secara lebih rinci dibandingkan hanya menggunakan akurasi (Dayanah Ayulani et al., 2023; Kate et al., 2026; Rafie et al., 2025).

Tabel 2.3 *Confusion Matrix*
Sumber: (Dayanah Ayulani et al., 2023; Kate et al., 2026)

	Prediksi Positif	Prediksi Negatif
Aktual Positif	TP	FN
Aktual Negatif	FP	TN

Keterangan:

TP (*True Positive*) = data positif yang diprediksi benar.

TN (*True Negative*) = data negatif yang diprediksi benar.

FP (*False Positive*) = data negatif yang diprediksi sebagai positif.

FN (*False Negative*) = data positif yang diprediksi sebagai negatif.

Confusion Matrix menjadi dasar perhitungan berbagai metrik evaluasi lainnya seperti *accuracy*, *precision*, *recall*, dan F1-*score*.

B. *Accuracy*

Accuracy digunakan untuk mengukur proporsi seluruh prediksi yang benar terhadap jumlah keseluruhan data.

Rumus *accuracy*:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Semakin tinggi nilai *accuracy*, semakin baik kemampuan model dalam melakukan klasifikasi.

C. *Precision*

Precision menunjukkan tingkat ketepatan model dalam memprediksi kelas positif.

Rumus *precision*:

$$Precision = \frac{TP}{TP + FP}$$

Nilai *precision* yang tinggi menunjukkan bahwa sebagian besar prediksi positif yang dihasilkan model memang benar.

D. *Recall*

Recall digunakan untuk mengukur kemampuan model dalam menemukan seluruh data positif yang sebenarnya.

Rumus *recall*:

$$Recall = \frac{TP}{TP + FN}$$

Semakin tinggi nilai *recall*, semakin baik model dalam mendeteksi seluruh data positif.

E. F1-*Score*

F1-*Score* merupakan rata-rata harmonis antara *precision* dan *recall* sehingga memberikan ukuran performa yang lebih seimbang.

Rumus F1-*Score*:

$$F1 - Score = 2x\frac{Precision\ x\ Recall}{Precision + Recall}$$

F1-*Score* sangat bermanfaat ketika distribusi data tidak seimbang karena mempertimbangkan *precision* dan *recall* secara bersamaan.

F. *Classification Report*

Classification report (Dayanah Ayulani et al., 2023; Kate et al., 2026; Rafie et al., 2025).

Tabel 2.4 Struktur *Classification Report*

Sumber: (Kate et al., 2026)

Kelas	***Precision***	***Recall***	**F1-*Score***	***Support***
Kelas A	TP/(TP+FP)	TP/(TP+FN)	2×(P×R)/(P+R)	Jumlah data A
Kelas B	TP/(TP+FP)	TP/(TP+FN)	2×(P×R)/(P+R)	Jumlah data B
Accuracy	-	-	-	Total akurasi
Macro Avg	Rata-rata tiap kelas	Rata-rata tiap kelas	Rata-rata tiap kelas	-
Weighted Avg	Rata-rata berbobot	Rata-rata berbobot	Rata-rata berbobot	Distribusi data

Tabel tersebut menggambarkan struktur umum *classification report* pada *scikit-learn*. *Macro average* menghitung rata-rata tanpa mempertimbangkan jumlah data tiap kelas, sedangkan *weighted average* mempertimbangkan proporsi data sehingga hasilnya lebih representatif terhadap kondisi dataset.

G. *Receiver Operating Characteristic*

Receiver Operating Characteristic (*ROC*) merupakan kurva yang menggambarkan hubungan antara *True Positive Rate* (TPR) dan *False Positive Rate*

(FPR) pada berbagai nilai *threshold*. Kurva ini digunakan untuk mengevaluasi kemampuan model dalam membedakan antar kelas (Basu, 2025; Kate et al., 2026; Rafie et al., 2025). Tahapan ROC adalah sebagai berikut:

1. Menghasilkan probabilitas prediksi dari model.
2. Menentukan berbagai nilai *threshold*.
3. Menghitung TPR dan FPR pada setiap *threshold*.
4. Membentuk kurva ROC.
5. Menghitung nilai AUC.

Rumus *True Positive Rate* (*TPR*):

$$TPR = \frac{TP}{TP + FN}$$

Rumus *False Positive Rate* (*FPR*):

$$FPR = \frac{FP}{FP + TN}$$

H. *Area Under Curve* (AUC)

Area Under Curve (AUC) merupakan luas area di bawah kurva ROC yang digunakan untuk mengukur kemampuan model dalam membedakan kelas secara keseluruhan.

Tabel 2.5 Interpretasi nilai AUC

Sumber: (Kate et al., 2026)

Nilai AUC	**Interpretasi**
0.90-1.00	Sangat Baik
0.80-0.90	Baik
0.70-0.80	Cukup
0.60-0.70	Kurang
< 0.60	Buruk

Semakin mendekati nilai 1, semakin baik kemampuan model dalam membedakan kelas profil kompetensi mahasiswa yang diprediksi.

2.2.19. Sistem Rekomendasi

Sistem rekomendasi adalah sistem yang digunakan untuk memberikan saran atau pilihan yang sesuai dengan kebutuhan dan karakteristik pengguna. Sistem ini bekerja dengan menganalisis data pengguna dan data item untuk menemukan tingkat kesesuaian di antara keduanya. Secara umum, sistem rekomendasi terdiri atas data pengguna, data item, proses analisis, dan modul rekomendasi. Metode yang sering digunakan meliputi *content-based filtering*, *collaborative filtering*, serta pendekatan *hybrid* yang menggabungkan keduanya agar hasil rekomendasi menjadi lebih relevan dan akurat (Fernández-García et al., 2020; José-García et al., 2023; Siswipraptini et al., 2024).



Gambar 2.11 Arsitektur Sistem Rekomendasi

Sumber: (Fernández-García et al., 2020; José-García et al., 2023)

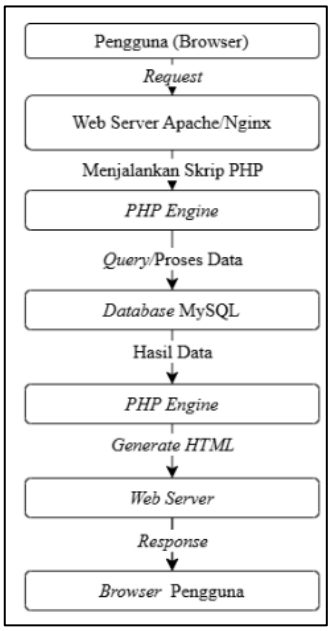
Arsitektur sistem rekomendasi umumnya terdiri atas tahap input, pemrosesan, dan output. Data pengguna dan data item terlebih dahulu dikumpulkan pada tahap input, kemudian diproses menggunakan algoritma rekomendasi untuk menghitung tingkat kesesuaian. Hasil perhitungan tersebut digunakan untuk menyusun urutan rekomendasi, yang selanjutnya ditampilkan kepada pengguna sebagai rekomendasi yang paling sesuai (Fernández-García et al., 2020; Siswipraptini et al., 2024).

2.2.20. Teknologi Pengembangan Sistem

A. *Hypertext Preprocessor*

Hypertext Preprocessor (PHP) merupakan bahasa pemrograman *server-side* yang digunakan untuk mengembangkan aplikasi web dinamis. PHP bekerja dengan

memproses kode di sisi server sebelum hasilnya dikirim ke browser dalam bentuk halaman web. Bahasa pemrograman ini banyak digunakan karena bersifat *open-source*, mudah dikembangkan, dan dapat terhubung dengan berbagai basis data, seperti MySQL. Selain itu, PHP mendukung pengelolaan formulir, *session*, *cookie*, operasi *Create, Read, Update,* dan *Delete* (CRUD), serta integrasi dengan layanan atau sistem lain melalui *Application Programming Interface* (API) (Christanto & Singgalen, 2023; Haekal, 2025; Ngozi et al., 2025).



Gambar 2.12 Arsitektur Kerja PHP pada Aplikasi Web
Sumber: (Christanto & Singgalen, 2023; Ngozi et al., 2025)

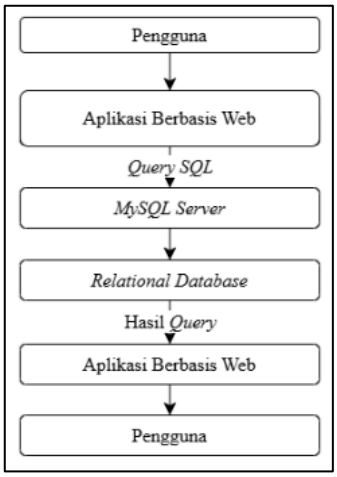
Arsitektur PHP diawali ketika pengguna mengirim permintaan melalui browser ke *web server*. Selanjutnya, server menjalankan skrip PHP dan memproses data yang diperlukan, termasuk akses ke basis data. Hasil pemrosesan tersebut kemudian diubah menjadi halaman HTML dan dikirim kembali ke browser untuk ditampilkan kepada pengguna. Mekanisme ini memungkinkan aplikasi web menyajikan informasi secara dinamis sesuai kebutuhan pengguna (Christanto & Singgalen, 2023; Ngozi et al., 2025).

B. MySQL

MySQL adalah sistem manajemen basis data relasional (*Relational Database Management System* / RDBMS) yang digunakan untuk menyimpan dan mengelola

data dalam bentuk tabel yang saling terhubung menggunakan bahasa SQL (*Structured Query Language*). MySQL memungkinkan proses pengelolaan data seperti penyimpanan, pembacaan, pembaruan, dan penghapusan data dilakukan secara terstruktur, cepat, dan konsisten. Karena bersifat *open-source* serta ringan, MySQL banyak digunakan dalam pengembangan sistem berbasis web dan mampu menangani data dari skala kecil hingga besar secara efisien (Ngozi et al., 2025).

Secara struktur, MySQL terdiri dari *database*, tabel, *record*, dan *field*. *Database* berfungsi sebagai wadah utama yang menampung beberapa tabel yang saling berhubungan, sedangkan tabel berisi baris (*record*) dan kolom (*field*) sebagai tempat penyimpanan data. Hubungan antar tabel diatur menggunakan *primary key* dan *foreign key* agar data tetap konsisten. Proses kerjanya dimulai dari *query* yang dikirim aplikasi, kemudian diproses oleh server MySQL dan hasilnya dikembalikan dalam bentuk data yang sudah diolah (Hossain, 2023; Ngozi et al., 2025).



Gambar 2.13 Arsitektur Pengolahan Data pada MySQL

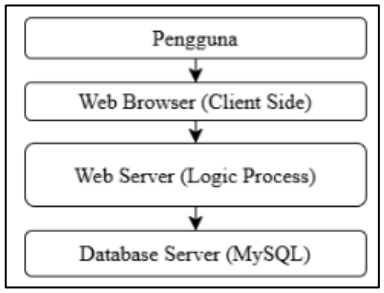
Sumber: (Hossain, 2023; Ngozi et al., 2025)

Gambar tersebut menjelaskan alur kerja MySQL dalam sistem basis data relasional, di mana pengguna berinteraksi melalui aplikasi yang kemudian meneruskan permintaan dalam bentuk *query* ke server database. Server MySQL memproses *query*, mengambil data dari tabel yang sesuai, lalu mengembalikan hasilnya ke aplikasi untuk ditampilkan kepada pengguna. Alur ini menunjukkan hubungan yang jelas antara aplikasi dan basis data yang bekerja secara terstruktur dan saling terhubung.

2.2.21. Sistem Berbasis Web

Sistem berbasis web merupakan sistem informasi yang dapat diakses melalui *web browser* menggunakan jaringan internet tanpa perlu instalasi aplikasi pada perangkat pengguna. Sistem ini umumnya dibangun dengan kombinasi teknologi sisi klien (*client-side*) seperti HTML, CSS, dan JavaScript, serta sisi server (*server-side*) yang berfungsi mengolah logika sistem dan mengatur pertukaran data dengan basis data (Christanto & Singgalen, 2023; Ngozi et al., 2025). Keunggulan utama sistem berbasis web terletak pada kemudahan akses, fleksibilitas penggunaan di berbagai perangkat, serta kemudahan dalam pemeliharaan karena sistem dikelola secara terpusat (Haekal, 2025) .

Dari sisi arsitektur, sistem berbasis web terdiri dari tiga komponen utama yaitu *client*, *web server*, dan *database server*. *Client* berperan sebagai tampilan antarmuka yang digunakan pengguna untuk berinteraksi dengan sistem. *Web server* berfungsi memproses permintaan pengguna serta menjalankan logika aplikasi, sedangkan *database server* digunakan untuk menyimpan dan mengelola data secara terstruktur menggunakan DBMS seperti MySQL (Christanto & Singgalen, 2023; Nuraminudin et al., 2026). Dalam pengembangannya, ketiga komponen ini saling terhubung untuk memastikan aliran data berjalan dengan baik dari pengguna hingga penyimpanan data.



Gambar 2.14 Arsitektur Sistem Berbasis Web Tiga Lapisan
Sumber: (Christanto & Singgalen, 2023; Ngozi et al., 2025)

Arsitektur ini menggambarkan alur sederhana mulai dari pengguna yang mengakses sistem melalui browser, kemudian permintaan dikirim ke *web server* untuk diproses. Setelah itu, server akan berkomunikasi dengan *database server* jika diperlukan, sebelum akhirnya hasil dikirim kembali ke pengguna dalam bentuk

tampilan halaman web. Struktur ini membuat sistem lebih mudah dikembangkan karena setiap bagian memiliki tugas yang jelas dan terpisah.

2.2.22. *Unified Modeling Language*

Unified Modeling Language (*UML*) merupakan bahasa pemodelan visual yang digunakan untuk menggambarkan rancangan sistem perangkat lunak sebelum proses implementasi dilakukan. *UML* membantu menjelaskan struktur dan perilaku sistem secara terstandarisasi sehingga dapat menjadi media komunikasi antara pengembang, analis, dan pihak terkait dalam memahami kebutuhan sistem secara lebih jelas. Dengan adanya representasi visual, proses perancangan menjadi lebih terarah karena setiap komponen sistem dapat divisualisasikan dalam bentuk diagram yang saling terhubung (Fitrani & Puspitaningrum, 2023; Ngozi et al., 2025).

A. *Use Case Diagram*

Use Case Diagram digunakan untuk menggambarkan hubungan antara aktor dan fungsi yang tersedia dalam sistem. Diagram ini membantu mengidentifikasi kebutuhan fungsional serta ruang lingkup sistem secara lebih sederhana dan mudah dipahami. Penggunaan *Use Case Diagram* juga membantu memperjelas interaksi pengguna dengan sistem dalam tahap perancangan (Asrin et al., 2026; Christanto & Singgalen, 2023; Fitrani & Puspitaningrum, 2023).

Tabel 2.6 *Use Case Diagram*
Sumber: (Asrin et al., 2026; Christanto & Singgalen, 2023; Fitrani & Puspitaningrum, 2023)

No.	Simbol	Nama	Keterangan
1		Aktor	Pihak yang berinteraksi dengan sistem.
2		Use Case	Fitur atau layanan yang disediakan sistem.
3		Association	Penghubung aktor dengan *use case*.
4	- - - - - - - >	*Generalization*	Hubungan turunan antar aktor atau *use case*.
5	*<<include>>*	*<<include>>*	Bagian wajib dari *use case* lain.
6	*<<extend>>*	*<<extend>>*	Tambahan opsional pada kondisi tertentu

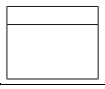
Tabel di atas menjelaskan simbol dasar dalam *Use Case Diagram* yang digunakan untuk memodelkan kebutuhan sistem secara sederhana dan terstruktur (Asrin et al., 2026; Christanto & Singgalen, 2023; Fitrani & Puspitaningrum, 2023)

B. *Activity Diagram*

Activity Diagram digunakan untuk menggambarkan alur aktivitas dalam sistem dari awal hingga akhir proses. Diagram ini membantu memetakan langkah-langkah kerja sistem secara runtut termasuk keputusan dan percabangan yang mungkin terjadi selama proses berlangsung. Dalam pengembangan sistem, *Activity Diagram* sering digunakan untuk memvisualisasikan proses bisnis agar lebih mudah dipahami (Hossain, 2023).

Tabel 2.7 *Activity Diagram*

Sumber: (Hossain, 2023)

No.	Simbol	Nama	Keterangan
1		*Initial Node*	Titik awal aktivitas
2		*Final Node*	Titik akhir aktivitas
3		*Action / Activity*	Kegiatan atau proses.
4		*Decision / Branch*	Titik pengambilan keputusan dalam alur.
5		*Transition*	Panah yang menunjukkan aliran proses antar aktivitas.
6		*Swimlane*	Memisahkan aktivitas berdasarkan pelaku.

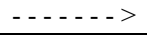
Tabel tersebut menunjukkan simbol utama dalam *Activity Diagram* yang digunakan untuk memetakan alur kerja sistem secara berurutan dan mudah dipahami (Hossain, 2023).

C. *Class Diagram*

Class Diagram menggambarkan struktur sistem dalam bentuk kelas yang terdiri dari atribut, metode, serta hubungan antar kelas. Diagram ini sangat penting karena menjadi dasar dalam membangun struktur data dan logika sistem sebelum proses implementasi dilakukan. Dengan adanya *Class Diagram*, struktur sistem dapat dirancang lebih konsisten dan sesuai dengan kebutuhan fungsional (Christanto & Singgalen, 2023).

Tabel 2.8 *Class Diagram*

Sumber: (Christanto & Singgalen, 2023)

No.	Simbol	Nama	Keterangan
1		*Generalization*	Relasi pewarisan antara kelas induk dan turunan.
2		*Aggregation / Composition*	Hubungan kepemilikan objek antar kelas.
3		*Class*	Representasi objek yang memuat atribut dan metode.
4		*Association*	Relasi antar kelas.
5		*Realization*	Hubungan implementasi antara kelas dan *interface*.
6		*Dependency*	Ketergantungan sementara antar kelas.
7		*Collaboration*	Kerja sama beberapa kelas dalam satu proses.
8		*Interface*	Deklarasi operasi yang harus diimplementasikan kelas.

Tabel tersebut menjelaskan simbol dalam *Class Diagram* yang digunakan untuk menggambarkan struktur sistem secara lebih detail dan terorganisir (Christanto & Singgalen, 2023).

2.2.23. *Software Development Life Cycle*

System Development Life Cycle (SDLC) adalah sebuah metode terstruktur yang digunakan dalam pengembangan sistem informasi agar proses pembuatan sistem dapat berjalan secara sistematis, terarah, dan sesuai dengan kebutuhan pengguna. SDLC menjelaskan tahapan pengembangan mulai dari analisis kebutuhan hingga pemeliharaan sistem, di mana setiap tahap menghasilkan output yang menjadi dasar untuk tahap berikutnya. Beberapa penelitian menjelaskan bahwa SDLC membantu pengembang meminimalkan kesalahan karena seluruh proses dilakukan secara berurutan dan terdokumentasi dengan jelas (Christanto & Singgalen, 2023; Hossain, 2023; Ngozi et al., 2025).

Terdapat berbagai model pengembangan dalam SDLC yang dapat dipilih sesuai kebutuhan proyek, di antaranya *Waterfall*, *Prototype*, *Rapid Application Development* (RAD), *Agile*, *Spiral*, V-*Model*, *Iterative*, *Scrum*, dan *Extreme*

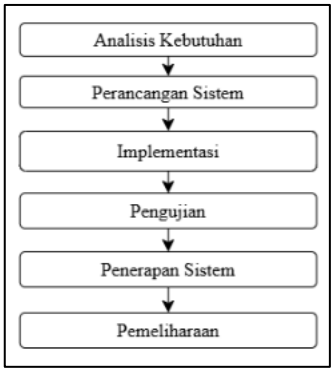
Programming (XP). Setiap model memiliki karakteristik dan pendekatan yang berbeda dalam proses pengembangan perangkat lunak (M. Ridwan & Fitri, 2021).

Pada penelitian ini, model SDLC yang digunakan adalah *Waterfall* karena memiliki tahapan yang terstruktur dan sesuai dengan kebutuhan pengembangan sistem yang telah terdefinisi dengan jelas sejak awal penelitian (Christanto & Singgalen, 2023; Hossain, 2023).

2.2.24. *Waterfall*

Model *Waterfall* adalah salah satu pendekatan dalam *System Development Life Cycle* (SDLC) yang berjalan secara berurutan, di mana setiap tahap harus diselesaikan terlebih dahulu sebelum masuk ke tahap berikutnya. Alur pengembangannya mengalir dari analisis kebutuhan sampai pemeliharaan sistem secara terstruktur, sehingga setiap hasil dari suatu tahap menjadi dasar untuk tahap selanjutnya (Christanto & Singgalen, 2023; Hossain, 2023; Ngozi et al., 2025). Model ini banyak digunakan karena alurnya yang jelas, terdokumentasi dengan baik, dan cocok untuk sistem yang kebutuhannya sudah pasti sejak awal.

Secara umum, *Waterfall* terdiri dari beberapa tahap utama, yaitu analisis kebutuhan, perancangan sistem, implementasi, pengujian, penerapan, dan pemeliharaan. Setiap tahap saling terhubung secara berurutan, sehingga hasil analisis menjadi dasar desain, desain menjadi acuan implementasi, dan seterusnya hingga sistem siap digunakan dan dipelihara (Christanto & Singgalen, 2023; Hossain, 2023).



Gambar 2.15 Diagram Model *Waterfall*

Sumber: (Christanto & Singgalen, 2023; Hossain, 2023)

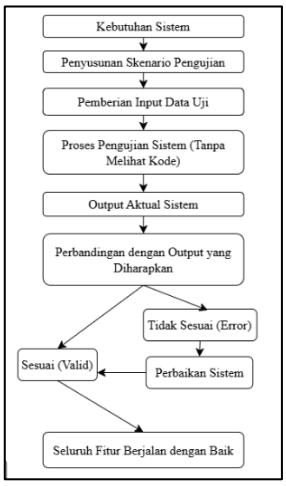
Diagram *Waterfall* menggambarkan alur pengembangan sistem yang berjalan langkah demi langkah dari awal hingga akhir. Proses dimulai dari pengumpulan kebutuhan, lalu masuk ke tahap perancangan sistem, kemudian implementasi kode, pengujian, hingga penerapan sistem. Setelah sistem digunakan, tahap terakhir adalah pemeliharaan untuk perbaikan dan penyesuaian jika diperlukan.

Alur ini menunjukkan bahwa setiap tahap sangat bergantung pada tahap sebelumnya, sehingga kesalahan di awal bisa berdampak ke seluruh proses. Karena itu, setiap tahap harus benar-benar diselesaikan dengan baik sebelum melanjutkan ke tahap berikutnya.

2.2.25. Pengujian Sistem

A. *Black Box Testing*

Black Box Testing adalah metode pengujian perangkat lunak yang menilai fungsi sistem berdasarkan kebutuhan yang telah ditentukan tanpa melihat bagaimana sistem bekerja di dalamnya. Pengujian ini dilakukan dengan memberikan input tertentu dan kemudian membandingkan output yang dihasilkan dengan hasil yang diharapkan. Metode ini umum digunakan pada sistem berbasis web karena dapat menilai apakah sistem sudah berjalan sesuai kebutuhan pengguna secara langsung dari sisi fungsionalnya (Nurizati et al., 2024; Shoaib et al., 2024; Zayed et al., 2022).



Gambar 2.16 Alur *Black Box Testing*

Sumber: (Nurizati et al., 2024; Shoaib et al., 2024)

Alur *Black Box Testing* dimulai dari penentuan kebutuhan sistem, kemudian disusun skenario pengujian berdasarkan kebutuhan tersebut. Selanjutnya sistem diuji dengan berbagai input tanpa melihat kode program. Hasil output kemudian dibandingkan dengan hasil yang diharapkan untuk menentukan apakah fungsi sistem sudah sesuai. Proses ini dilakukan sampai seluruh fitur dinyatakan berjalan dengan baik (Shoaib et al., 2024; Zayed et al., 2022).

B. *User Acceptance Testing*

User Acceptance Testing (*UAT*) merupakan tahap pengujian sistem yang dilakukan langsung oleh pengguna akhir untuk memastikan bahwa aplikasi yang sudah dibangun sesuai dengan kebutuhan dan dapat digunakan dengan baik sebelum sistem benar-benar diterapkan. Pada tahap ini, penilaian lebih menekankan pada pengalaman pengguna, seperti apakah sistem mudah digunakan, apakah fitur sudah sesuai kebutuhan, dan sejauh mana sistem memberikan manfaat bagi pengguna (Fitriastuti et al., 2024; Siti Muthiah Nuralifah et al., 2025).

Secara umum, *UAT* terdiri dari beberapa elemen penting, yaitu pengguna sebagai evaluator utama, skenario penggunaan sistem berdasarkan fitur yang ada, serta kuesioner sebagai alat penilaian. Pengguna diminta mencoba sistem sesuai alur yang telah disiapkan, kemudian memberikan penilaian yang nantinya diolah menjadi data kuantitatif menggunakan skala tertentu seperti skala Likert untuk mengetahui tingkat kelayakan sistem (Fitriastuti et al., 2024).



Gambar 2.17 Alur *User Acceptance Testing* (UAT)

Sumber: (Fitriastuti et al., 2024; Siti Muthiah Nuralifah et al., 2025)

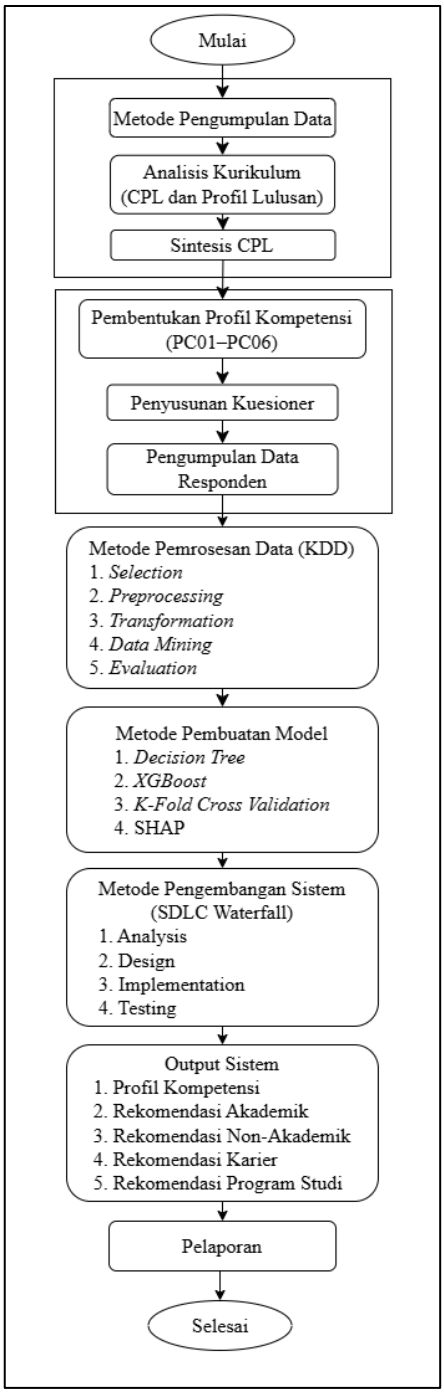
Proses *UAT* dimulai ketika sistem sudah siap digunakan untuk diuji oleh pengguna. Pengguna kemudian menjalankan sistem berdasarkan skenario yang telah disiapkan, lalu memberikan penilaian melalui kuesioner berdasarkan pengalaman mereka saat menggunakan sistem tersebut.

Hasil kuesioner kemudian diolah menjadi nilai kelayakan dalam bentuk persentase. Nilai ini digunakan untuk melihat apakah sistem sudah layak digunakan atau masih perlu perbaikan. Dengan cara ini, *UAT* membantu memastikan sistem tidak hanya berjalan secara teknis, tetapi juga nyaman dan sesuai untuk digunakan oleh pengguna.

BAB III

METODOLOGI

3.1 Kerangka Pikir



Gambar 3.1 Kerangka Pikir

Sumber: Penulis, 2026

3.2 Deskripsi

Kerangka pikir penelitian ini menggambarkan tahapan yang dilakukan dalam membangun sistem klasifikasi profil kompetensi mahasiswa dan sistem rekomendasi pengembangan mahasiswa berbasis *machine learning*. Penelitian memanfaatkan metode *Knowledge Discovery in Databases* (KDD) untuk proses pengolahan data, algoritma *Decision Tree* dan *XGBoost* sebagai model klasifikasi, pendekatan *Explainable Artificial Intelligence* (XAI) menggunakan metode *SHAP* untuk menjelaskan hasil prediksi, serta metode pengembangan sistem *Software Development Life Cycle* (SDLC) model *Waterfall* untuk membangun aplikasi berbasis web.

Penelitian diawali dengan proses pengumpulan data melalui observasi, wawancara, studi literatur, serta pengumpulan dokumen kurikulum dari 12 program studi di Universitas Bale Bandung. Data yang diperoleh kemudian dianalisis untuk mengidentifikasi keterkaitan antara Capaian Pembelajaran Lulusan (CPL), Profil Lulusan (PL), karakteristik mahasiswa, serta kebutuhan pengembangan mahasiswa. Hasil analisis tersebut digunakan untuk menyusun profil kompetensi mahasiswa, membangun instrumen kuesioner, serta membentuk aturan klasifikasi yang akan digunakan dalam proses *machine learning*.

Selanjutnya, data hasil kuesioner diolah menggunakan tahapan KDD yang terdiri atas *selection*, *preprocessing*, *transformation*, *data mining*, dan *evaluation*. Pada tahap *data mining*, dilakukan pembangunan model klasifikasi menggunakan algoritma *Decision Tree* dan *XGBoost* yang kemudian dibandingkan untuk memperoleh model terbaik. Hasil klasifikasi selanjutnya dijelaskan menggunakan pendekatan XAI dengan metode *SHAP* sehingga faktor-faktor yang memengaruhi hasil klasifikasi dapat diketahui secara lebih transparan.

Setelah model klasifikasi diperoleh, dilakukan pengembangan sistem berbasis web menggunakan metode SDLC model *Waterfall* yang meliputi tahap analisis kebutuhan, perancangan sistem, implementasi, pengujian, dan pemeliharaan. Sistem yang dihasilkan mampu menampilkan profil kompetensi mahasiswa beserta rekomendasi pengembangan akademik, non-akademik, karier, dan rekomendasi program studi yang sesuai dengan karakteristik pengguna. Tahap

akhir penelitian adalah penyusunan laporan penelitian sebagai bentuk dokumentasi seluruh proses dan hasil yang diperoleh.

3.2.1. Metode Pengumpulan Data

Tahap awal penelitian dilakukan melalui proses pengumpulan data untuk memperoleh informasi yang relevan dengan permasalahan penelitian. Pengumpulan data dilakukan menggunakan beberapa teknik, yaitu observasi, wawancara, studi literatur, dan dokumentasi.

A. Observasi

Observasi dilakukan dengan mengamati kondisi yang berkaitan dengan proses pemilihan program studi dan pengembangan mahasiswa di lingkungan Universitas Bale Bandung. Selain itu, peneliti juga melakukan pengamatan terhadap mahasiswa aktif untuk memperoleh gambaran mengenai proses pengembangan diri selama masa perkuliahan. Dari hasil observasi ditemukan bahwa masih terdapat mahasiswa yang mengalami kesulitan dalam menentukan arah pengembangan diri sesuai dengan minat, kemampuan, dan tujuan karier yang dimiliki.

B. Wawancara

Wawancara dilakukan kepada pihak Penerimaan Mahasiswa Baru (PMB) Universitas Bale Bandung, mahasiswa aktif, serta ketua program studi dari 12 program studi yang menjadi objek penelitian. Wawancara dengan pihak PMB bertujuan untuk mengetahui permasalahan yang sering dihadapi calon mahasiswa dalam menentukan program studi. Wawancara dengan mahasiswa aktif dilakukan untuk memperoleh informasi mengenai kendala yang dihadapi selama proses pengembangan diri di perguruan tinggi. Sementara itu, wawancara dengan ketua program studi dilakukan untuk memperoleh informasi mengenai CPL, PL, serta karakteristik lulusan pada masing-masing program studi.

C. Studi Literatur

Studi literatur dilakukan dengan mengkaji berbagai referensi yang relevan dengan topik penelitian. Peneliti melakukan penelusuran dan analisis terhadap sekitar 50 artikel ilmiah yang berkaitan dengan *machine learning*, sistem rekomendasi, klasifikasi pada bidang pendidikan, *Decision Tree*, *XGBoost*, dan

XAI. Dari hasil kajian tersebut dipilih beberapa penelitian yang memiliki keterkaitan langsung dengan penelitian ini dan digunakan sebagai jurnal acuan dalam penyusunan landasan teori serta pengembangan metodologi penelitian.

D. Dokumentasi

Dokumentasi dilakukan dengan mengumpulkan dokumen akademik dari 12 program studi Universitas Bale Bandung. Dokumen yang diperoleh meliputi CPL, PL, struktur kurikulum, serta informasi mata kuliah pendukung. Meskipun tidak seluruh program studi memberikan dokumen yang sama secara lengkap, sebagian besar program studi menyediakan data CPL, PL, dan mata kuliah yang dapat digunakan sebagai dasar analisis kurikulum.

3.2.2. Analisis Kurikulum

Tahap analisis kurikulum dilakukan terhadap data CPL, PL, dan kurikulum yang diperoleh dari 12 program studi Universitas Bale Bandung. Analisis ini bertujuan untuk mengidentifikasi kompetensi utama yang menjadi karakteristik lulusan pada masing-masing program studi.

Pada tahap ini dilakukan pengelompokan CPL dan PL yang memiliki kesamaan tujuan, kompetensi, dan bidang pengembangan sehingga diperoleh pola kompetensi yang dapat digunakan sebagai dasar pembentukan profil kompetensi mahasiswa. Hasil analisis kurikulum menjadi fondasi utama dalam proses sintesis CPL dan pembentukan model klasifikasi pada penelitian ini.

3.2.3. Sintesis CPL

Setelah proses analisis kurikulum dilakukan, tahap berikutnya adalah sintesis CPL. Tahap ini bertujuan untuk menyederhanakan berbagai CPL yang berasal dari 12 program studi ke dalam beberapa domain kompetensi yang memiliki karakteristik serupa.

Hasil sintesis menghasilkan delapan domain CPL yang terdiri atas pendidikan dan pembelajaran, penelitian dan pengembangan ilmu, teknologi digital dan sistem informasi, analisis data dan pengambilan keputusan, sosial dan pemberdayaan masyarakat, kewirausahaan dan inovasi, kepemimpinan dan manajemen, serta

profesionalisme dan etika. Domain CPL tersebut kemudian digunakan sebagai dasar dalam pembentukan profil kompetensi mahasiswa.

3.2.4. Pembentukan Profil Kompetensi

Berdasarkan hasil sintesis CPL, dilakukan pembentukan enam profil kompetensi mahasiswa yang menjadi target klasifikasi penelitian. Keenam profil tersebut terdiri atas *Educational and Research Innovator* (PC01), *Digital Technology Specialist* (PC02), *Data and Analytical Intelligence Specialist* (PC03), *Community Development Specialist* (PC04), *Entrepreneurship and Innovation Specialist* (PC05), dan *Professional Leader* (PC06).

Pembentukan profil kompetensi dilakukan melalui pemetaan antara domain CPL hasil sintesis dengan karakteristik lulusan dari berbagai program studi. Profil kompetensi ini selanjutnya digunakan sebagai dasar penyusunan instrumen penelitian, proses pelabelan data, dan sistem rekomendasi yang dikembangkan.

3.2.5. Penyusunan Kuesioner

Tahap penyusunan kuesioner dilakukan berdasarkan hasil analisis CPL, PL, dan profil kompetensi yang telah dibentuk sebelumnya. Instrumen penelitian disusun untuk mengukur tiga variabel utama, yaitu minat, gaya belajar, dan tujuan karier.

Kuesioner terdiri atas 30 item pernyataan yang menggunakan skala Likert lima tingkat. Setiap item dirancang untuk merepresentasikan indikator yang berkaitan dengan salah satu profil kompetensi mahasiswa sehingga hasil pengisian kuesioner dapat digunakan sebagai dasar dalam proses klasifikasi.

3.2.6. Pengumpulan Data Responden

Setelah instrumen penelitian selesai disusun, tahap berikutnya adalah pengumpulan data responden. Responden penelitian terdiri atas mahasiswa aktif, alumni, dan calon mahasiswa baru.

Sebelum pengumpulan data utama dilakukan, peneliti telah melaksanakan penyebaran kuesioner awal kepada 72 responden sebagai studi pendahuluan untuk

memperkuat identifikasi masalah penelitian. Selanjutnya, pengumpulan data utama direncanakan dengan target minimal 150 responden sebagai dataset yang digunakan dalam proses klasifikasi *machine learning*.

3.2.7. Metode Pemrosesan Data

Data yang telah terkumpul kemudian diolah menggunakan metode KDD yang terdiri atas beberapa tahapan sebagai berikut.

1. *Selection,* tahap ini dilakukan dengan memilih data yang relevan dari hasil pengisian kuesioner untuk digunakan dalam penelitian.
2. *Preprocessing,* tahap *preprocessing* dilakukan untuk membersihkan data dari nilai kosong, data tidak konsisten, data duplikat, maupun kesalahan pengisian yang dapat memengaruhi hasil analisis.
3. *Transformation,* tahap transformasi dilakukan dengan mengubah data hasil kuesioner menjadi dataset yang siap digunakan dalam proses klasifikasi. Pada tahap ini juga dilakukan proses *rule-based initial labeling* untuk menentukan label awal profil kompetensi mahasiswa berdasarkan skor tertinggi yang diperoleh dari masing-masing profil kompetensi.
4. *Data Mining,* tahap *data mining* dilakukan untuk membangun model klasifikasi menggunakan algoritma *Decision Tree* dan *XGBoost*.
5. *Evaluation,* tahap evaluasi dilakukan untuk menilai performa model menggunakan *Confusion Matrix*, *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan *ROC-AUC* sehingga dapat diketahui model yang memiliki performa terbaik.

3.2.8. Metode Pembuatan Model

Pada tahap ini dilakukan pembangunan model klasifikasi menggunakan algoritma *Decision Tree* dan *XGBoost*. Kedua algoritma dibandingkan menggunakan teknik *K-Fold Cross Validation* untuk memperoleh model dengan performa terbaik.

Selanjutnya, model terbaik dianalisis menggunakan metode *SHAP* untuk mengetahui faktor-faktor yang paling berpengaruh terhadap hasil klasifikasi profil

kompetensi mahasiswa. Pendekatan ini memungkinkan hasil prediksi dapat dijelaskan secara lebih transparan kepada pengguna.

3.2.9. Metode Pengembangan Sistem

Pengembangan sistem dilakukan menggunakan metode SDLC model *Waterfall* yang terdiri atas:

1. *Analysis,* analisis kebutuhan sistem berdasarkan hasil penelitian dan kebutuhan pengguna.
2. *Design,* perancangan basis data, UML, arsitektur sistem, dan antarmuka pengguna.
3. *Implementation,* pembangunan aplikasi berbasis web serta integrasi model klasifikasi ke dalam sistem.
4. *Testing,* pengujian sistem menggunakan metode *Black Box Testing* dan *User Acceptance Testing* (UAT).
5. *Maintenance,* perbaikan dan penyempurnaan sistem berdasarkan hasil pengujian dan evaluasi.

3.2.10. *Output* Sistem

Output yang dihasilkan dari penelitian ini meliputi:

1. Profil kompetensi mahasiswa (PC01–PC06).
2. Rekomendasi pengembangan akademik.
3. Rekomendasi pengembangan non-akademik.
4. Rekomendasi karier.
5. Rekomendasi program studi.
6. Penjelasan faktor-faktor yang memengaruhi hasil klasifikasi menggunakan metode *SHAP*.

DAFTAR PUSTAKA

Abdulahi Hasan, A., & Fang, H. (2021, May 28). Data Mining in Education: Discussing Knowledge Discovery in Database (KDD) with Cluster Associative Study. *ACM International Conference Proceeding Series*. https://doi.org/10.1145/3469213.3471319

Abouhawwash, M. (2025). Machine Learning-Based Enhanced Embryo Selection Using Temporal Feature Extraction and Rule-Based Labeling Model With Decision Trees. *IEEE Access*, *13*, 212213–212230. https://doi.org/10.1109/ACCESS.2025.3644768

Alsayed, A. O., Rahim, M. S. M., Albidewi, I., Hussain, M., Jabeen, S. H., Alromema, N., Hussain, S., & Jibril, M. L. (2021). Selection of the right undergraduate major by students using supervised learning techniques. *Applied Sciences (Switzerland)*, *11*(22). https://doi.org/10.3390/app112210639

Anwar, M. S., & Wulandari, S. (2025). Mobile Intelligent System for VARK-Based Student Learning Style Classification Using KNN. *Bit-Tech*, *8*(2), 2890–2899. https://doi.org/10.32877/bt.v8i2.3428

Asrin, F., Hafid, K., & Korespondesi, P. (2026). *Pemodelan Sistem Informasi Manajemen Stadion Universitas Tanjungpura Menggunakan Unified Modeling Language (UML) Modeling of Tanjungpura University Stadium Management Information System Using Unified Modeling Language (UML)*. *5*(1), 27–37.

Atalla, S., Daradkeh, M., Gawanmeh, A., Khalil, H., Mansoor, W., Miniaoui, S., & Himeur, Y. (2023). An Intelligent Recommendation System for Automating Academic Advising Based on Curriculum Analysis and Performance Modeling. *Mathematics*, *11*(5). https://doi.org/10.3390/math11051098

Basu, A. (2025). Explaining ML predictions with SHAP. *Proceedings of the 24th Python in Science Conference*, 14–37. https://doi.org/10.25080/mhum9729

Bifarin, O. O. (2023). Interpretable machine learning with treebased shapley additive explanations: Application to metabolomics datasets for binary classification. *PLoS ONE*, *18*(5 May). https://doi.org/10.1371/journal.pone.0284315

Christanto, H. J., & Singgalen, Y. A. (2023). Analysis and Design of Student Guidance Information System through Software Development Life Cycle (SDLC) dan Waterfall Model. *Journal of Information Systems and Informatics*, *5*(1), 259–270. https://doi.org/10.51519/journalisi.v5i1.443

Dayanah Ayulani, I., Yunawan, A. M., Prihutaminingsih, T., Sarwinda, D., Ardaneswari, G., & Desjwiandra Handari, B. (2023). *Tree-Based Ensemble Methods and Their Applications for Predicting Students' Academic Performance*. *13*(3).

Deniz, E. (2024). Evaluating the Effectiveness of Machine Learning Models in Predicting Student Academic Achievement. *ADBA Computer Science*, *1*(1), 8–13. https://doi.org/10.69882/adba.cs.2024072

Devanathan, B., Varshitha, J. J., Kumar, P. P., Lakshmanan, S. A., & Prakash, K. K. (2025). Explainable AI Framework Using XGBoost With SHAP and LIME for Multi-Scale Household Energy Forecasting. *IEEE Access*, *13*, 149750–149764. https://doi.org/10.1109/ACCESS.2025.3602673

Direktorat Pembelajaran dan Kemahasiswaan, Direktorat Jenderal Pendidikan Tinggi, R. dan T., & Kementrian Pendidikan, K. R. dan T. (2024). *PANDUAN PENYUSUNAN KURIKULUM PENDIDIKAN TINGGI MENDUKUNG MERDEKA BELAJAR-KAMPUS MERDEKA MENUJU INDONESIA EMAS*.

Fernández-García, A. J., Rodríguez-Echeverría, R., Preciado, J. C., Conejero Manzano, J. M., & Sánchez-Figueroa, F. (2020). Creating a recommender system to support higher education students in the subject enrollment decision. *IEEE Access*, *8*, 189069–189088. https://doi.org/10.1109/ACCESS.2020.3031572

Fitrani, L. D., & Puspitaningrum, A. C. (2023). *SISTEMASI: Jurnal Sistem Informasi Utilization of Unified Modeling Language (UML) in the Design of Academic Information Systems based on the OOAD Method*. http://sistemasi.ftik.unisi.ac.id

Fitriastuti, F., Eka Putri, A., Kautsar Sunardi, A., & Apriliya Hidayat, R. (2024). Analisis Website SIAKAD Universitas Janabadra Menggunakan Metode UAT. In *JTSI* (Vol. 5, Number 1).

Haekal, M. (2025). *Journal of Artificial Intelligence and Engineering Applications Implementation of Decision Tree Algorithm for Student Interest Analysis Based on Subjects at MTs Aisyiyah Binjai* (Vol. 5, Number 1). https://ioinformatic.org/

Hasibuan, M. S., Isnanto, R. R., Dewi, D. A., Kurniawan, T. B., Yeh, M. L., & Wijaya, A. (2025). A Proposed Model for Detecting Learning Styles Based on the Felder-Silverman Model Using KNN and LR with Electroencephalography (EEG). *Journal of Applied Data Sciences*, *6*(2), 1129–1139. https://doi.org/10.47738/jads.v6i2.659

Hossain, M. I. (2023). *Software Development Life Cycle (SDLC) Methodologies for Information Systems Project Management*. www.ijfmr.com

Hulu, Y., & Telaumbanua, Y. N. (2022). Analisis Minat Dan Hasil Belajar Siswa Menggunakan Model Pembelajaran Discovery Learning. *Educativo: Jurnal Pendidikan*, *1*(1), 283–290. https://doi.org/10.56248/educativo.v1i1.39

Hussain, W., Fong, M., & Spady, W. G. (2024). Digital Developmental Advising Systems for Engineering Students Based on Accreditation Board of Engineering and Technology Student Outcome Evaluations. *Information (Switzerland)*, *15*(9). https://doi.org/10.3390/info15090520

Hussain, W., Spady, W. G., Khan, S. Z., Khawaja, B. A., Naqash, T., & Conner, L. (2021). Impact Evaluations of Engineering Programs Using Abet Student Outcomes. *IEEE Access*, *9*, 46166–46190. https://doi.org/10.1109/ACCESS.2021.3066921

Hussain, W., Spady, W. G., Naqash, M. T., Khan, S. Z., Khawaja, B. A., & Conner, L. (2020). ABET Accreditation during and after COVID19 - Navigating the Digital Age. *IEEE Access*, *8*, 218997–219046. https://doi.org/10.1109/ACCESS.2020.3041736

Iban, M. C. (2022). An explainable model for the mass appraisal of residences: The application of tree-based Machine Learning algorithms and interpretation of value determinants. *Habitat International*, *128*. https://doi.org/10.1016/j.habitatint.2022.102660

José-García, A., Sneyd, A., Melro, A., Ollagnier, A., Tarling, G., Zhang, H., Stevenson, M., Everson, R., & Arthur, R. (2023). C3-IoC: A Career Guidance System for Assessing Student Skills using Machine Learning and Network Visualisation. *International Journal of Artificial Intelligence in Education*, *33*(4), 1092–1119. https://doi.org/10.1007/s40593-022-00317-y

Kate, C., Aditya Sai Srinivas, T., Asim, M., Sai Kumar, M., Vaishali Narayanrao, P., & Sasi, S. (2026). *Journal of Engineering and Technology for Industrial Applications ITEGAM-JETIA EDUBOOST: A HIGH-ACCURACY XGBOOST FRAMEWORK FOR STUDENT ACADEMIC PERFORMANCE PREDICTION*. https://doi.org/10.5935/jetia.v12i58.3734

Kementrian Pendidikan, K. R. dan T. (2023). *BERITA NEGARA REPUBLIK INDONESIA*.

Liu, Q., Liu, J., & Zhang, K. (2024). Research on Precision Education Management Practices in Vocational Colleges Based on Student Profiling. *ACM International Conference Proceeding Series*, 12–15. https://doi.org/10.1145/3700297.3700300

McKenzie, S., & Bennett, D. (2022). Understanding the career interests of Information Technology (IT) students: a focus on choice of major and career aspirations. *Education and Information Technologies*, *27*(9), 12839–12853. https://doi.org/10.1007/s10639-022-11141-1

Ngozi, U. M. R., Overcomer Ifeanyi Alex, A., Francisca, F. N., & Nmesoma, D. N. (2025). Design and Implementation of an Advanced Web-Based Academic Advising System for Optimizing Student Support and Engagement. *International Research Journal of Innovations in Engineering and Technology*, *09*(03), 13–27. https://doi.org/10.47001/irjiet/2025.903003

Nuraminudin, M., Faticha, R., & Aziza, A. (2026). *Pembuatan Sistem Evaluasi dan Rekomendasi Perencanaan Studi Mahasiswa Berbasis Website Menggunakan Laravel* (Vol. 5, Number 1). https://subset.id/index.php/IJCSR

Nurizati, Z., Hidayat, A., Vernanda, D., & Hendriawan, T. (2024). *Analisis Kelayakan Penurunan UKT Pada Mahasiswa dengan Menggunakan Metode Decision Tree*. *18*(1).

Okesola, O. O. (2021). *DATA MINING METHODOLOGY AND ITS APPLICATION TO LIFE INSURANCE*.

Osho, O., Gupta, A., Brown, D., Kninjenburg, B., Kennedy, C., Kraemer, E., Sexton, S., Washington, G., Subedi, P., Demssie, N., Kelsey, E., Porter, J., Gosha, K., & Smarr, S. A. (2026). Gender differences in grit and programming experience across course levels and their relationship to undergraduate students' intention to complete a computer science degree. *Computer Science Education*. https://doi.org/10.1080/08993408.2026.2649867

Permendikbudristek. (2023). *43. Permendikbudristek-No.-53-Tahun-2023-Penjaminan-Mutu-Pendidikan-Tinggi*.

Pratiwi, T. I., AS, U. S., Supriatna, M., & Nadhirah, N. A. (2024). Analisis Kebutuhan Perencanaan Karir Berbasis Aspirasi Karir Mahasiswa:Studi Literatur. *Indonesian Journal of Educational Counseling*, *8*(1), 114–129. https://doi.org/10.30653/001.202481.297

Rafie, Z., Talab, M. S., Koor, B. E. Z., Garavand, A., Salehnasab, C., & Ghaderzadeh, M. (2025). Leveraging XGBoost and explainable AI for accurate prediction of type 2 diabetes. *BMC Public Health*, *25*(1). https://doi.org/10.1186/s12889-025-24953-w

Rawis, J. A. M., Sumual, S. D. M., Azhar, Y., Al Azhar, B. Z., & Pranoto, A. S. (2025). *MANAJEMEN KURIKULUM PERGURUAN TINGGI 2025 BERBASIS OUTCOME BASED EDUCATION (OBE)*. *10*(4). https://doi.org/10.34125/jmp.v10i4.1263

Ridwan, A., Priyatno, A. M., & Ningsih, L. (2024). *Journal of Education and Computer Applications Predict Students' Dropout and Academic Success with XGBoost*. https://jeca.aks.or.id/index.php/jeca/index

Ridwan, M., & Fitri, I. (2021). Rancang Bangun Marketplace Berbasis Website menggunakan Metodologi Systems Development Life Cycle (SDLC) dengan Model Waterfall. *Jurnal Teknologi Informasi Dan Komunikasi)*, *5*(2), 2021. https://doi.org/10.35870/jti

Shoaib, L. A., Safii, S. H., Idris, N., Hussin, R., & Sazali, M. A. H. (2024). Utilizing decision tree machine model to map dental students' preferred learning styles with suitable instructional strategies. *BMC Medical Education*, *24*(1). https://doi.org/10.1186/s12909-023-05022-5

Siswipraptini, P. C., Warnars, H. L. H. S., Ramadhan, A., & Budiharto, W. (2024). Personalized Career-Path Recommendation Model for Information Technology Students in Indonesia. *IEEE Access*, *12*, 49092–49105. https://doi.org/10.1109/ACCESS.2024.3381032

Siti Muthiah Nuralifah, Muhammad Rizal H, Putri Fitriani Ahmad, & Wahda Amelia. (2025). Pengguna (User Acceptance Testing) Pada Sistem Informasi Akademik EMACCA Universitas Teknologi AKBA Makassar. *Inventor: Jurnal Inovasi Dan Tren Pendidikan Teknologi Informasi*, *3*(2), 84–91. https://doi.org/10.37630/inventor.v3i2.2541

Song, M. H., Zhang, L., Yuan, M., Li, Z., Song, Q., Liu, Y., & Zheng, G. (2023). CoTel: Ontology-Neural Co-Enhanced Text Labeling. *ACM Web Conference 2023 - Proceedings of the World Wide Web Conference, WWW 2023*, 1897–1906. https://doi.org/10.1145/3543507.3583533

Sugiana, I. (2023). *PENGEMBANGAN MEDIA LAYANAN INFORMASI KARIER BERBASIS ANDROID DALAM PERENCANAAN KARIER PADA PESERTA DIDIK*.

Syed Mustapha, S. M. F. D. (2023). Predictive Analysis of Students' Learning Performance Using Data Mining Techniques: A Comparative Study of Feature Selection Methods. *Applied System Innovation*, *6*(5). https://doi.org/10.3390/asi6050086

Zayed, Y., Salman, Y., & Hasasneh, A. (2022). A Recommendation System for Selecting the Appropriate Undergraduate Program at Higher Education Institutions Using Graduate Student Data. *Applied Sciences (Switzerland)*, *12*(24). https://doi.org/10.3390/app122412525