MODEL *MACHINE LEARNING* UNTUK KLASIFIKASI PROFIL KOMPETENSI DAN REKOMENDASI PENGEMBANGAN MAHASISWA BERBASIS KURIKULUM

SKRIPSI

Karya Tulis sebagai syarat memperoleh
Gelar Sarjana Komputer dari Fakultas Teknologi Informasi
Universitas Bale Bandung

Disusun oleh:
TACSHA AULIA NURMAYANTI RESMANA
NPM. 301220012

PROGRAM STRATA 1
PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS BALE BANDUNG
BANDUNG
2026

LEMBAR PERSETUJUAN PEMBIMBING

MODEL *MACHINE LEARNING* UNTUK KLASIFIKASI PROFIL KOMPETENSI DAN REKOMENDASI PENGEMBANGAN MAHASISWA BERBASIS KURIKULUM

Disusun oleh:

TACSHA AULIA NURMAYANTI RESMANA
NPM. 301220012

Telah diterima dan disetujui untuk memenuhi persyaratan mencapai gelar
SARJANA KOMPUTER

Pada

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS BALE BANDUNG

Baleendah, Agustus 2026

Disetujui oleh:

Pembimbing Utama	Pembimbing Pendamping
Yudi Herdiana, S.T., M.T.	Mohammad Bayu Anggara, S.Kom., M.Kom
NIK. 04104808008	NIK. 04104823002

LEMBAR PERSETUJUAN PENGUJI

MODEL *MACHINE LEARNING* UNTUK KLASIFIKASI PROFIL KOMPETENSI DAN REKOMENDASI PENGEMBANGAN MAHASISWA BERBASIS KURIKULUM

Disusun oleh:

TACSHA AULIA NURMAYANTI RESMANA
NPM. 301220012

Telah diterima dan disetujui untuk memenuhi persyaratan mencapai gelar
SARJANA KOMPUTER

Pada

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS BALE BANDUNG

Baleendah, Agustus 2026

Disetujui oleh:

Penguji 1	Penguji 2
_____	_____
NIK. 04104808008	NIK. 04104823002

LEMBAR PENGESAHAN PROGRAM STUDI

MODEL *MACHINE LEARNING* UNTUK KLASIFIKASI PROFIL KOMPETENSI DAN REKOMENDASI PENGEMBANGAN MAHASISWA BERBASIS KURIKULUM

Disusun oleh:

TACSHA AULIA NURMAYANTI RESMANA
NPM. 301220012

Telah diterima dan disetujui untuk memenuhi persyaratan mencapai gelar
SARJANA KOMPUTER

Pada

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS BALE BANDUNG

Baleendah, Agustus 2026

Disetujui oleh:

Mengetahui, Dekan,	Mengesahkan, Ketua Program Studi,
Yudi Herdiana, S.T., M.T. NIK. 04104808008	Yusuf Muharam, S.Kom., M.Kom. NIK. 04104820003

LEMBAR PERNYATAAN KEASLIAN

Saya yang bertanda tangan dibawah ini:

Nama : Tacsha Aulia Nurmayanti Resmana

NPM : 301220012

Judul Skripsi : **MODEL *MACHINE LEARNING* UNTUK KLASIFIKASI PROFIL KOMPETENSI DAN REKOMENDASI PENGEMBANGAN MAHASISWA BERBASIS KURIKULUM**

Menyatakan bahwa skripsi ini merupakan hasil penelitian dan pemikiran saya sendiri. Dalam penyusunan skripsi ini, setiap karya atau pendapat yang berasal dari pihak lain telah saya cantumkan sumbernya sesuai dengan ketentuan yang berlaku.

Pernyataan ini saya buat dengan penuh kesadaran dan sesuai dengan keadaan yang sebenarnya. Jika di kemudian hari terdapat ketidaksesuaian atau pelanggaran terhadap pernyataan yang telah saya buat, saya bersedia bertanggung jawab dan menerima konsekuensi maupun sanksi akademik sesuai dengan peraturan yang berlaku di Fakultas Teknologi Informasi Universitas Bale Bandung.

Demikian pernyataan ini saya buat tanpa adanya paksaan atau tekanan dari pihak mana pun dan dapat dipertanggungjawabkan sebagaimana mestinya.

Bandung, Agustus 2026

Yang membuat pernyataan.

Tacsha Aulia Nurmayanti Resmana

NPM. 301220012

ABSTRAK

Perguruan tinggi memiliki peran penting dalam menyiapkan lulusan yang kompeten sesuai kebutuhan dunia kerja. Di Universitas Bale Bandung (UNIBBA), pemetaan potensi mahasiswa masih menghadapi kendala karena arah pengembangan diri dan kegiatan akademik belum sepenuhnya didasarkan pada data objektif. Studi pendahuluan terhadap 72 responden menunjukkan bahwa hanya 45,5% alumni bekerja sesuai bidang studinya, sedangkan 60% mahasiswa aktif membutuhkan rekomendasi pengembangan berdasarkan karakteristik pribadi. Penelitian sebelumnya juga belum mengintegrasikan sintesis Capaian Pembelajaran Lulusan (CPL) dari 12 program studi dengan minat, gaya belajar, dan tujuan karier mahasiswa dalam model klasifikasi.

Penelitian ini bertujuan membangun model *Machine Learning* dan sistem rekomendasi berbasis web untuk mengklasifikasikan profil kompetensi dan memberikan rekomendasi pengembangan berbasis kurikulum. Metode yang digunakan adalah *Knowledge Discovery in Databases* (KDD), meliputi seleksi, pembersihan, transformasi, pemodelan, dan evaluasi data. Data diperoleh melalui kuesioner untuk memetakan enam profil kompetensi (PC01–PC06). Algoritma *Decision Tree* dan *Extreme Gradient Boosting* (*XGBoost*) dibandingkan menggunakan *accuracy*, *precision*, *recall*, *F1-score*, dan *ROC-AUC*. SHAP diterapkan untuk menjelaskan kontribusi fitur terhadap hasil klasifikasi. Model terbaik kemudian diimplementasikan pada sistem berbasis web untuk menghasilkan rekomendasi akademik, non-akademik, pelatihan/sertifikasi, karier, dan program studi.

Hasil penelitian menunjukkan *XGBoost* memiliki performa lebih baik dibandingkan *Decision Tree*. SHAP mampu menunjukkan kontribusi minat, gaya belajar, dan tujuan karier terhadap hasil klasifikasi. Sistem yang dikembangkan dapat menyajikan rekomendasi secara personal. Penelitian ini membantu menyelaraskan potensi mahasiswa dengan kurikulum CPL serta mendukung pengambilan keputusan pengembangan mahasiswa berbasis data.

Kata Kunci: Capaian Pembelajaran Lulusan, *Decision Tree*, *Knowledge Discovery in Databases*, Profil Kompetensi, SHAP, *XGBoost*.

ABSTRACT

Higher education institutions play an important role in preparing competent graduates who meet the needs of the workforce. At Universitas Bale Bandung (UNIBBA), mapping students' potential still faces challenges because decisions regarding personal development and academic activities are not yet fully based on objective data. A preliminary study involving 72 respondents found that only 45.5% of alumni work in fields related to their study programs, while 60% of active students need development recommendations based on their personal characteristics. Previous studies have also not integrated the synthesis of Graduate Learning Outcomes (Capaian Pembelajaran Lulusan/CPL) from 12 study programs with students' interests, learning styles, and career goals into a classification model.

This study aims to develop a Machine Learning model and a web-based recommendation system to classify competency profiles and provide curriculum-based development recommendations. The method used is Knowledge Discovery in Databases (KDD), consisting of data selection, cleaning, transformation, modeling, and evaluation. Data were collected through a questionnaire to identify six competency profiles (PC01–PC06). Decision Tree and Extreme Gradient Boosting (XGBoost) algorithms were compared using accuracy, precision, recall, F1-score, and ROC-AUC. SHAP was applied to explain the contribution of features to the classification results. The best-performing model was then implemented in a web-based system to provide academic, non-academic, training/certification, career, and study program recommendations.

The results show that XGBoost outperformed Decision Tree. SHAP successfully identified the contributions of interests, learning styles, and career goals to the classification results. The developed system provides personalized recommendations and helps align students' potential with CPL-based curriculum while supporting data-driven student development decisions.

***Keywords**: Graduate Learning Outcomes, Decision Tree, Knowledge Discovery in Databases, Competency Profile, SHAP, XGBoost.*

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas rahmat dan hidayah-Nya sehingga penulis dapat menyelesaikan skripsi yang berjudul "MODEL *MACHINE LEARNING* UNTUK KLASIFIKASI PROFIL KOMPETENSI DAN REKOMENDASI PENGEMBANGAN MAHASISWA BERBASIS KURIKULUM". Shalawat serta salam semoga senantiasa tercurah kepada Nabi Muhammad SAW yang telah menjadi teladan bagi umat manusia.

Terima kasih yang paling tulus penulis sampaikan kepada Mamah dan Bapak atas doa, kasih sayang, dukungan, dan kepercayaan yang tak pernah berhenti. Terima kasih telah menjadi tempat pulang dan alasan penulis untuk terus bertahan dalam setiap proses. Skripsi ini mungkin belum sebanding dengan segala pengorbanan Mamah dan Bapak, tetapi semoga dapat menjadi kebahagiaan dan kebanggaan. Terima kasih juga kepada diri sendiri yang telah bertahan hingga titik ini.

Ucapan terima kasih juga penulis sampaikan kepada:

1. Bapak Yudi Herdiana, S.T., M.T., selaku Dekan Fakultas Teknologi Informasi Universitas Bale Bandung sekaligus Pembimbing 1.
2. Bapak Yusuf Muharam, S.Kom., M.Kom., selaku Ketua Program Studi Teknik Informatika.
3. Bapak Mohammad Bayu Anggara, S.Kom., M.Kom., selaku Pembimbing 2.
4. Bapak/Ibu Dosen Fakultas Teknologi Informasi
5. Keluarga, teman, dan semua pihak yang telah memberikan doa, bantuan, serta dukungan selama penyusunan skripsi.
6. Lee Haechan dan IU (Lee Jieun), serta drama-drama Korea yang telah menjadi *mood booster* di sela-sela panjangnya proses penyusunan skripsi.

Penulis menyadari bahwa skripsi ini masih memiliki kekurangan, sehingga kritik dan saran yang membangun sangat diharapkan sebagai bahan perbaikan di masa mendatang.

Bandung, Agustus 2026

Penulis

DAFTAR ISI

LEMBAR PERSETUJUAN PEMBIMBING i
LEMBAR PERSETUJUAN PENGUJI ii
LEMBAR PENGESAHAN PROGRAM STUDI iii
LEMBAR PERNYATAAN KEASLIAN iv
ABSTRAK v
ABSTRACT vi
KATA PENGANTAR vii
DAFTAR ISI viii
DAFTAR GAMBAR xiii
DAFTAR TABEL xv
DAFTAR LAMPIRAN xvii
BAB I PENDAHULUAN 1
1.1. Latar Belakang 1
1.2. Rumusan Masalah 4
1.3. Batasan Masalah 4
1.4. Tujuan Penelitian 5
1.5. Metodologi Penelitian 5
1.6. Sistematika Penulisan 9
BAB II TINJAUAN PUSTAKA 11
2.1 Landasan Teori 11
2.2 Dasar Teori 15
2.2.1. Pengembangan Mahasiswa 15
2.2.2. *Outcome-Based Education* 15
2.2.3. Profil Lulusan 16
2.2.4. Capaian Pembelajaran Lulusan 17
2.2.5. Kompetensi 17
2.2.6. Profil Kompetensi Mahasiswa 17
2.2.7. Faktor Pembentuk Profil Kompetensi Mahasiswa 18
2.2.8. Instrumen Penelitian 19

2.2.9. *Machine Learning* untuk Klasifikasi 20
2.2.10. Pembentukan Label Dataset 22
2.2.11. *Feature Engineering* 24
2.2.12. *Decision Tree* 25
2.2.13. *Extreme Gradient Boosting* 27
2.2.14. *Cross Validation* 29
2.2.15. *Explainable Artificial Intelligence* 29
2.2.16. *SHapley Additive exPlanations* 31
2.2.17. *Knowledge Discovery in Database* 33
2.2.18. Evaluasi Model Klasifikasi 34
2.2.19. Sistem Rekomendasi 38
2.2.20. Teknologi Pengembangan Sistem 38
2.2.21. Sistem Berbasis Web 41
2.2.22. *Unified Modeling Language* 42
2.2.23. *Software Development Life Cycle* 45
2.2.24. *Waterfall* 46
2.2.25. Pengujian Sistem 47
BAB III METODOLOGI 49
3.1 Kerangka Pikir 49
3.2 Deskripsi 50
3.2.1. Metode Pengumpulan Data 50
3.2.2. Analisis Kurikulum 52
3.2.3. Sintesis CPL 52
3.2.4. Pembentukan Profil Kompetensi 52
3.2.5. Penyusunan Kuesioner 53
3.2.6. Pengumpulan Data Responden 53
3.2.7. Metode Pemrosesan Data 53
3.2.8. Metode Pembuatan Model 55
3.2.9. Metode Pembentukan Rekomendasi 55
3.2.10. Metode Pengembangan Sistem 56
3.2.11. *Output* Sistem 57
BAB IV ANALISIS, PERANCANGAN DAN HASIL 58

4.1. Hasil Analisis Kurikulum 58
4.1.1. Hasil Analisis Profil Lulusan dan CPL 58
4.1.2. Hasil *Content Analysis* 59
4.1.3. Hasil Sintesis 8 Domain CPL 60
4.1.4. Hasil Pembentukan Profil Kompetensi PC01-PC06 61
4.1.5. Matriks CPL dan Profil Kompetensi 62
4.2. Hasil Penyusunan Instrumen dan Pengumpulan Data 64
4.2.1. Hasil Penyusunan Kuesioner 64
4.2.2. Karakteristik Responden 65
4.2.3. Distribusi Jawaban Responden 66
4.2.4. Hasil Konversi Skala *Likert* 66
4.3. Hasil Pembentukan Dataset 67
4.3.1. Struktur Dataset 67
4.3.2. *Selection* 68
4.3.3. *Preprocessing* 68
4.3.4. *Transformation* 69
4.3.5. *Feature Dataset* 70
4.3.6. *Rule-Based Initial Labeling* 70
4.3.7. Distribusi Label 71
4.4. Hasil Pembangunan Model Klasifikasi 71
4.4.1. Pembagian Data 71
4.4.2. Model *Decision Tree* 72
4.4.3. Model *XGBoost* 72
4.4.4. *Hyperparameter Tuning* 73
4.4.5. *K-Fold Cross Validation* 74
4.5. Hasil Evaluasi Model 74
4.5.1. Evaluasi *Decision Tree* 74
4.5.2. Evaluasi *XGBoost* 75
4.5.3. *Confusion Matrix* 75
4.5.4. *Accuracy, Precision, Recall, dan F1-Score* 76
4.5.5. *ROC-AUC* 77
4.5.6. Analisis *Overfitting* 77

4.5.7. Perbandingan dan Pemilihan Model Terbaik 78
4.6. Interpretasi Model dengan SHAP 78
4.6.1. *Global Feature Importance* 78
4.6.2. *SHAP Summary Plot* 79
4.6.3. Arah Kontribusi Fitur 80
4.6.4. Interpretasi Faktor Pembentuk Profil Kompetensi 81
4.6.5. Validasi Interpretasi Model 82
4.7. Hasil *Recommendation Engine* 82
4.7.1. *Knowledge Base* Rekomendasi 82
4.7.2. *Recommendation Scoring* 83
4.7.3. *Ranking* 84
4.7.4. *Tie-Breaking* 84
4.7.5. *Explanation Generator* 85
4.7.6. *Traceability* dan *Decision Audit* 85
4.7.7. Rekomendasi Pengembangan Akademik 86
4.7.8. Rekomendasi Pengembangan Non-Akademik 86
4.7.9. Rekomendasi Karier 87
4.7.10. Rekomendasi Sertifikasi 88
4.7.11. Rekomendasi Program Studi 88
4.8. Analisis Sistem 89
4.8.1. Analisis Masalah 89
4.8.2. Analisis *Software* 90
4.8.3. Analisis Pengguna 91
4.8.4. Analisis Data 91
4.8.5. Analisis Fitur 92
4.8.6. Analisis Kebutuhan Sistem 93
4.9. Perancanan Sistem 95
4.9.1. *Unified Modeling Language* 95
4.3.8. *Entity Relational Diagram* 102
4.3.9. Struktur Tabel 103
4.3.10. Desain 111
BAB V IMPLEMENTASI DAN PENGUJIAN 120

5.1. Implementasi 120
5.1.1. *Listing* Program 120
5.1.2. Implementasi Sistem 124
5.1.3. Spesifikasi Sistem 131
5.1.4. Instalasi Sistem 132
5.1.5. Menjalankan Sistem 133
5.2. Pengujian 134
5.2.1. *Black Box Testing* 134
5.2.2. *User Acceptance Testing* 136
BAB VI KESIMPULAN DAN SARAN 140
6.1. Kesimpulan 140
6.2. Saran 141
DAFTAR PUSTAKA 142

DAFTAR GAMBAR

Gambar 2.1 Alur Implementasi *Outcome-Based Education* (OBE) 16
Gambar 2.2 *Workflow Machine Learning* 21
Gambar 2.3 Arsitektur *Rule-Based Labeling* 23
Gambar 2.4 Tahapan Umum *Feature Engineering* 24
Gambar 2.5 Struktur *Decision Tree* 25
Gambar 2.6 Arsitektur *XGBoost* 28
Gambar 2.7 Proses *K-Fold Cross Validation* 29
Gambar 2.8 Tahapan *Explainable Artificial Intelligence* 30
Gambar 2.9 Arsitektur SHAP dalam Interpretasi Model *Machine Learning* 32
Gambar 2.10 Tahapan *Knowledge Discovery in Databases* (KDD) 34
Gambar 2.11 Arsitektur Sistem Rekomendasi 38
Gambar 2.12 Arsitektur Kerja PHP pada Aplikasi Web 39
Gambar 2.13 Arsitektur Pengolahan Data pada MySQL 40
Gambar 2.14 Arsitektur Sistem Berbasis Web Tiga Lapisan 41
Gambar 2.15 Diagram Model *Waterfall* 46
Gambar 2.16 Alur *Black Box Testing* 47
Gambar 2.17 Alur *User Acceptance Testing* (UAT) 48
Gambar 3.1 Kerangka Pikir 49
Gambar 4.1 Alur Transformasi Data 69
Gambar 4.2 *Confusion Matrix XGBoost Optimized* 76
Gambar 4.3 SHAP Bar Plot - Tingkat Kepentingan Fitur Global 79
Gambar 4.4 SHAP Dot Plot 80
Gambar 4.5 Alur Proses Pemeringkatan Alternatif 84
Gambar 4.6 Diagram Alur Audit Keputusan (*End-to-End Traceability*) 85
Gambar 4.7 *Use Case Diagram* Admin 95
Gambar 4.8 *Use Case Diagram* Pengguna 96
Gambar 4.9 *Activity Diagram* Pengisian Kuesioner dan Prosesnya 98
Gambar 4.10 *Sequence Diagram* Hasil 99
Gambar 4.11 *Class Diagram* Sistem Profil Kompetensi 101
Gambar 4.10 *Entity Relational Diagram* (ERD) Sistem 102
Gambar 4.13 Desain *Wireframe* Kuesioner 112
Gambar 4.14 Desain *Wireframe* Formulir Identitas Pengguna 112
Gambar 4.15 Desain *Wireframe* Halaman Hasil Kuesioner 113
Gambar 4.16 Desain *Wireframe* Unduh Laporan Hasil Kuesioner 114
Gambar 4.17 Desain Antarmuka Kuesioner 115
Gambar 4.18 Desain Antarmuka Formulir Identitas Pengguna 116
Gambar 4.19 Desain Antarmuka Halaman Hasil Kuesioner 117
Gambar 4.20 Desain Antarmuka Unduh Laporan Hasil Kuesioner 118
Gambar 5.1 Implementasi *Recommendation Engine* 126

Gambar 5.2 Implementasi Halaman Kuesioner 128
Gambar 5.3 Implementasi Halaman Formulir Identitas Pengguna 128
Gambar 5.4 Implementasi Halaman Hasil Kuesioner 129
Gambar 5.5 Implementasi Halaman Unduh Laporan Hasil 130
Gambar 5.6 Alur Menjalankan Sistem 133

DAFTAR TABEL

Tabel 2.1 Jurnal Acuan 13
Tabel 2.2 Skala *Likert* 20
Tabel 2.3 *Confusion Matrix* 34
Tabel 2.4 Struktur *Classification Report* 36
Tabel 2.5 Interpretasi nilai AUC 37
Tabel 2.6 *Use Case Diagram* 42
Tabel 2.7 *Activity Diagram* 43
Tabel 2.7 *Sequence Diagram* 44
Tabel 2.8 *Class Diagram* 44
Tabel 4.1 Hasil Sintesis 8 Domain CPL 60
Tabel 4.2 Hasil Pembentukan Profil Kompetensi PC01-PC06 61
Tabel 4.3 Matriks CPL dan Profil Kompetensi 63
Tabel 4.4 Hasil Penyusunan Kuesioner 64
Tabel 4.5 Karakteristik Responden Berdasarkan Status 65
Tabel 4.6 Distribusi Jawaban Responden 66
Tabel 4.7 Konversi Skala *Likert* 67
Tabel 4.8 Contoh Struktur Data Hasil Integrasi 68
Tabel 4.9 Parameter Seleksi Atribut Dataset 68
Tabel 4.10 Hasil Audit Kualitas Data (Validation) 69
Tabel 4.12 Metadata *Feature* Dataset Final 70
Tabel 4.13 Aturan Resolusi Skor Seri (*Tie-Breaking*) 70
Tabel 4.14 Sebaran Profil Kompetensi Mahasiswa 71
Tabel 4.15 Ringkasan Pembagian Dataset Latih dan Uji 72
Tabel 4.15 Konfigurasi dan Hasil *Baseline Decision Tree* 72
Tabel 4.16 Evolusi Model *XGBoost* 73
Tabel 4.17 Parameter Terbaik Hasil Pencarian Grid 73
Tabel 4.18 Skor Akurasi Per Lipatan (*Fold*) 74
Tabel 4.19 Performa Dasar *Decision Tree* 75
Tabel 4.20 Performa *Optimized XGBoost* 75
Tabel 4.21 Ringkasan Metrik Klasifikasi Final 76
Tabel 4.22 Skor Diskriminasi Model 77
Tabel 4.23 Perbandingan Stabilitas Model 77
Tabel 4.24 Matriks Keputusan Pemilihan Model 78
Tabel 4.25 Analisis Korelasi Nilai Fitur terhadap Dampak Prediksi 81
Tabel 4.26 Pemicu Utama (*Key Drivers*) per Profil Kompetensi 81
Tabel 4.28 Hasil Uji Konsistensi Logika (*Expert vs Machine*) 82
Tabel 4.29 Parameter Kelompok Basis Pengetahuan (*Knowledge Base Assets*) 83
Tabel 4.29 Hierarki Resolusi Skor Seri (*Tie-Breaking Rules*) 84
Tabel 4.30 Daftar Rekomendasi Aktivitas Akademik per Profil 86

Tabel 4.31 Rekomendasi Organisasi dan UKM Penunjang 87
Tabel 4.32 Proyeksi Prospek Karier Berdasarkan Profil 87
Tabel 4.33 Rekomendasi Sertifikasi Profesional 88
Tabel 4.34 Hasil Akhir Rekomendasi Program Studi (Top-3) 88
Tabel 4.35 Analisis Masalah 89
Tabel 4.36 Kebutuhan Perangkat Lunak Minimum 90
Tabel 4.37 Analisis Pengguna 91
Tabel 4.38 Analisis Data 92
Tabel 4.39 Analisis Fitur Sistem 93
Tabel 4.40 Kebutuhan Fungsional 94
Tabel 4.41 Kebutuhan Nonfungsional 94
Tabel 4.42 Deskripsi *Use Case Diagram* Admin 96
Tabel 4.43 Deskripsi *Use Case Diagram* Pengguna 97
Tabel 4.44 Tabel *Users* 104
Tabel 4.45 Pertanyaan Kuesioner 105
Tabel 4.46 Sesi Kuesioner 105
Tabel 4.47 Jawaban Kuesioner 106
Tabel 4.48 Profil Kompetensi 106
Tabel 4.49 Domain CPL 107
Tabel 4.50 Relasi Profil CPL 108
Tabel 4.51 Prediksi Model 108
Tabel 4.52 Pengetahuan Rekomendasi 109
Tabel 4.53 Program Studi 110
Tabel 4.54 Pemetaan Relevansi Program Studi 111
Tabel 5.1 Lingkungan Implementasi Sistem 125
Tabel 5.2 Implementasi Tabel Database 127
Tabel 5.3 Spesifikasi Minimum Perangkat Keras (*Hardware*) 131
Tabel 5.4 Spesifikasi Minimum Perangkat Lunak (*Software*) 131
Tabel 5.5 Tahapan Instalasi Aplikasi 132
Tabel 5.6 Tahapan Instalasi Database 133
Tabel 5.7 Pengujian Black Box pada Pengguna 134
Tabel 5.8 Pengujian Black Box untuk Admin 135
Tabel 5.9 Pengujian *Black Box* Model *Machine Learning* dan *Scoring Engine* . 136
Tabel 5.10 Pengujian Aspek *Functionality* Pengguna 137
Tabel 5.11 Pengujian Aspek *Reliability* Pengguna 138
Tabel 5.12 Pengujian Aspek *Usability* Pengguna 138
Tabel 5.13 Pengujian Aspek *Efficiency* Pengguna 139
Tabel 5.14 Hasil Pengujian UAT pada Pengguna 139

DAFTAR LAMPIRAN

Lampiran 1: Hasil Wawancara dengan Panitia PMB 147
Lampiran 2: Hasil Wawancara dengan Ketua Program Studi 148
Lampiran 3: Hasil Kuesioner Pra-Penelitian..... 149
Lampiran 4: Bukti Pengumpulan Data Kurikulum 151

BAB I

PENDAHULUAN

1.1. Latar Belakang

Perguruan tinggi memiliki peran penting dalam menghasilkan lulusan yang tidak hanya memiliki kemampuan akademik, tetapi juga kompetensi yang sesuai dengan kebutuhan dunia kerja dan perkembangan teknologi (Permendikbudristek, 2023). Seiring dengan perkembangan transformasi digital, pemanfaatan data menjadi salah satu pendekatan yang dapat digunakan untuk mendukung pengambilan keputusan secara lebih objektif dan terukur. Dalam lingkungan pendidikan tinggi, mahasiswa memiliki karakteristik, minat, dan tujuan karier yang beragam sehingga membutuhkan arahan pengembangan yang sesuai dengan potensi yang dimiliki. Oleh karena itu, diperlukan pendekatan berbasis data yang mampu membantu proses identifikasi profil kompetensi mahasiswa sebagai dasar dalam penyusunan rekomendasi pengembangan yang lebih terarah dan personal (Alsayed et al., 2021; Hulu & Telaumbanua, 2022).

Selanjutnya, penelitian ini dilaksanakan di Universitas Bale Bandung (UNIBBA) yang berlokasi di Jl. R.A.A. Wiranatakusumah No. 7, Baleendah, Kabupaten Bandung, Jawa Barat. UNIBBA dipilih sebagai lokasi penelitian karena memiliki 7 fakultas dan 12 program studi dengan struktur kurikulum yang terdiri atas Profil Lulusan (PL), Capaian Pembelajaran Lulusan (CPL), mata kuliah, dan Capaian Pembelajaran Mata Kuliah (CPMK). Struktur kurikulum tersebut mengandung informasi yang dapat dimanfaatkan untuk membentuk profil kompetensi mahasiswa berdasarkan sintesis CPL dari berbagai program studi. Untuk memperoleh gambaran kondisi yang terjadi serta kebutuhan sistem yang akan dibangun, penelitian ini menggunakan beberapa teknik pengumpulan data, yaitu observasi, wawancara, studi literatur, analisis dokumen kurikulum, dan penyebaran kuesioner kepada mahasiswa aktif, alumni, serta calon mahasiswa baru.

Berdasarkan hasil observasi dan wawancara, ditemukan bahwa proses pengembangan mahasiswa masih menghadapi beberapa kendala. Mahasiswa sering mengalami kesulitan dalam menentukan arah pengembangan diri yang sesuai

dengan kemampuan dan tujuan yang dimiliki. Selain itu, pemilihan kegiatan akademik maupun non-akademik masih banyak dilakukan berdasarkan pengaruh lingkungan atau tren tertentu tanpa didukung data yang objektif. Untuk memperkuat temuan tersebut, peneliti melakukan penyebaran kuesioner kepada 72 responden yang terdiri atas mahasiswa aktif, alumni, dan calon mahasiswa baru. Hasil kuesioner menunjukkan bahwa 60% mahasiswa aktif menyatakan membutuhkan sistem yang dapat membantu memberikan rekomendasi pengembangan diri berdasarkan karakteristik pribadi. Selain itu, sebanyak 62,2% mahasiswa aktif menyatakan bahwa variabel minat, gaya belajar, dan tujuan karier dapat digunakan sebagai dasar dalam proses pengembangan mahasiswa, serta 62,2% responden meyakini bahwa teknologi *machine learning* mampu menghasilkan rekomendasi yang lebih objektif. Dari sisi alumni, sebanyak 72,7% responden mendukung penerapan *machine learning* dalam proses rekomendasi pengembangan mahasiswa. Namun demikian, hanya 45,5% alumni yang menyatakan bahwa pekerjaan yang dijalani saat ini sesuai dengan bidang atau kompetensi yang dipelajari selama kuliah. Temuan tersebut menunjukkan bahwa proses pemetaan kompetensi mahasiswa masih belum optimal dan memerlukan pendekatan yang mampu mengintegrasikan variabel minat, gaya belajar, dan tujuan karier dalam menghasilkan rekomendasi yang lebih tepat sasaran.

Sementara itu, berbagai penelitian terdahulu telah menunjukkan bahwa algoritma *machine learning* dapat diterapkan untuk mendukung proses klasifikasi dan rekomendasi dalam bidang pendidikan. Penelitian yang dilakukan oleh Shoaib et al. (2024) menerapkan algoritma *Decision Tree* untuk mengklasifikasikan gaya belajar mahasiswa dan memperoleh tingkat akurasi sebesar 90%. Selanjutnya, penelitian Atalla et al. (2023) mengembangkan sistem *academic advising* berbasis web menggunakan pendekatan *machine learning* dan *graph theory* dengan tingkat akurasi mencapai 86%. Selain itu, Abdillah et al. (2020) menerapkan algoritma C4.5 untuk memprediksi keberhasilan pendidikan karakter mahasiswa dan memperoleh tingkat akurasi sebesar 60,91%. Hasil penelitian tersebut menunjukkan bahwa metode klasifikasi mampu memberikan dukungan dalam proses pengambilan keputusan pada bidang pendidikan. Pada penelitian ini, algoritma *Decision Tree* digunakan karena mampu menghasilkan model klasifikasi

yang mudah dipahami melalui struktur pohon keputusan dan aturan *if-then* yang transparan sehingga hasil prediksi dapat dijelaskan secara jelas kepada pengguna (Nurizati et al., 2024). Selain itu, algoritma *XGBoost* dipilih karena kemampuannya dalam meningkatkan performa klasifikasi melalui teknik *gradient boosting*, ketangguhannya dalam menangani data tabular multidimensi, serta terbukti memiliki tingkat akurasi yang unggul dibandingkan algoritma klasifikasi lainnya pada berbagai studi kasus di bidang pendidikan (Kate et al., 2026; A. Ridwan et al., 2024). Untuk mengatasi sifat *black-box* pada model kompleks tersebut dan meningkatkan transparansi hasil prediksi, penelitian ini juga menerapkan pendekatan *Explainable Artificial Intelligence* (XAI) dengan metode SHAP (*SHapley Additive exPlanations*) (Bifarin, 2023). Penggunaan SHAP memungkinkan faktor-faktor penentu yang memengaruhi hasil klasifikasi dapat diinterpretasikan secara lokal maupun global, sehingga rekomendasi yang diberikan sistem menjadi lebih akurat dan mudah dipahami oleh pengguna (Bifarin, 2023). Meskipun demikian, penelitian-penelitian sebelumnya masih berfokus pada klasifikasi gaya belajar, rekomendasi rencana studi, atau prediksi karakter mahasiswa secara terpisah. Penelitian terdahulu juga belum mengintegrasikan data kurikulum, khususnya CPL dan Profil Lulusan, dengan karakteristik mahasiswa berupa minat, gaya belajar, dan tujuan karier untuk membentuk profil kompetensi mahasiswa sebagai dasar rekomendasi pengembangan. Oleh karena itu, masih terdapat *research gap* berupa belum adanya model klasifikasi profil kompetensi mahasiswa yang dibangun berdasarkan sintesis kurikulum dan karakteristik individu dalam satu kerangka yang terintegrasi.

Berdasarkan permasalahan dan *research gap* yang telah diidentifikasi, diperlukan suatu model *machine learning* yang mampu mengklasifikasikan profil kompetensi mahasiswa berdasarkan data kurikulum dan karakteristik individu. Kebaruan penelitian ini terletak pada integrasi sintesis CPL dari 12 program studi Universitas Bale Bandung dengan tiga variabel utama, yaitu minat, gaya belajar, dan tujuan karier, untuk membentuk enam profil kompetensi mahasiswa. Proses pembangunan model dilakukan menggunakan pendekatan *Knowledge Discovery in Databases* (KDD) yang meliputi tahapan seleksi data, pembersihan data, transformasi data, pemodelan, dan evaluasi. Model klasifikasi dibangun

menggunakan algoritma *Decision Tree* dan *XGBoost*, kemudian dibandingkan berdasarkan nilai *accuracy*, *precision*, *recall*, dan *F1-score* untuk memperoleh model terbaik. Selanjutnya, model terbaik dianalisis menggunakan pendekatan XAI berbasis SHAP dan diimplementasikan ke dalam sistem berbasis web. Sistem tersebut menghasilkan rekomendasi pengembangan mahasiswa yang mencakup rekomendasi pengembangan akademik, pengembangan non-akademik, pelatihan atau sertifikasi yang relevan, rekomendasi karier, serta rekomendasi program studi bagi calon mahasiswa baru. Dengan demikian, penelitian ini dilakukan dengan judul **"MODEL *MACHINE LEARNING* UNTUK KLASIFIKASI PROFIL KOMPETENSI DAN REKOMENDASI PENGEMBANGAN MAHASISWA BERBASIS KURIKULUM."**

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana mengidentifikasi profil kompetensi mahasiswa berdasarkan variabel minat, gaya belajar, dan tujuan karier yang disusun berdasarkan sintesis Capaian Pembelajaran Lulusan (CPL) Universitas Bale Bandung?
2. Bagaimana membangun model *machine learning* menggunakan algoritma *Decision Tree* dan *XGBoost* untuk mengklasifikasikan profil kompetensi mahasiswa berdasarkan data hasil kuesioner?
3. Bagaimana menghasilkan rekomendasi pengembangan mahasiswa berdasarkan hasil klasifikasi profil kompetensi yang diimplementasikan dalam sistem berbasis web?

1.3. Batasan Masalah

Agar penelitian lebih terarah dan sesuai dengan ruang lingkup yang ditentukan, maka batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian dilakukan di Universitas Bale Bandung (UNIBBA) dengan melibatkan mahasiswa aktif, alumni, dan calon mahasiswa sebagai responden penelitian.

2. Data penelitian diperoleh melalui kuesioner yang disusun berdasarkan sintesis CPL dari 12 program studi Universitas Bale Bandung dengan tiga variabel utama, yaitu minat, gaya belajar, dan tujuan karier.
3. Profil kompetensi mahasiswa yang digunakan terdiri atas enam kategori, yaitu *Educational and Research Innovator* (PC01), *Digital Technology Specialist* (PC02), *Data and Analytical Intelligence Specialist* (PC03), *Community Development Specialist* (PC04), *Entrepreneurship and Innovation Specialist* (PC05), dan *Professional Leader* (PC06).
4. Proses klasifikasi dilakukan menggunakan algoritma *Decision Tree* dan *XGBoost* yang dievaluasi menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score,* dan *ROC-AUC*.
5. *Output* penelitian berupa model klasifikasi profil kompetensi yang diimplementasikan dalam sistem berbasis web untuk menghasilkan rekomendasi pengembangan mahasiswa.

1.4. Tujuan Penelitian

Tujuan penelitian yang ingin dicapai pada penelitian ini adalah sebagai berikut:

1. Mengidentifikasi profil kompetensi mahasiswa berdasarkan variabel minat, gaya belajar, dan tujuan karier yang disusun dari sintesis CPL Universitas Bale Bandung.
2. Membangun model *machine learning* menggunakan algoritma *Decision Tree* dan *XGBoost* untuk mengklasifikasikan profil kompetensi mahasiswa berdasarkan data hasil kuesioner.
3. Menghasilkan sistem berbasis web yang mampu memberikan rekomendasi pengembangan mahasiswa berdasarkan hasil klasifikasi profil kompetensi.

1.5. Metodologi Penelitian

Metode penelitian yang digunakan dalam penelitian ini adalah metode kuantitatif dengan pendekatan klasifikasi *machine learning* dan pengembangan

sistem berbasis web. Pendekatan kuantitatif digunakan untuk mengolah data hasil kuesioner yang diperoleh dari calon mahasiswa, mahasiswa aktif, dan alumni Universitas Bale Bandung. Data tersebut digunakan untuk membentuk profil kompetensi mahasiswa berdasarkan variabel minat, gaya belajar, dan tujuan karier.

Penelitian ini memanfaatkan pendekatan *Knowledge Discovery in Databases* (KDD) dalam proses pengolahan data dan pembangunan model klasifikasi. Algoritma yang digunakan adalah *Decision Tree* dan *XGBoost* untuk menghasilkan model klasifikasi profil kompetensi mahasiswa. Selanjutnya, hasil klasifikasi dijelaskan menggunakan pendekatan *Explainable Artificial Intelligence* (XAI) dengan metode *SHapley Additive exPlanations* (SHAP) agar faktor-faktor yang memengaruhi hasil klasifikasi dapat dipahami secara lebih transparan.

Selain pembangunan model *machine learning*, penelitian ini juga mengembangkan sistem rekomendasi berbasis web menggunakan metode *Software Development Life Cycle* (SDLC) model *Waterfall*. Sistem yang dikembangkan bertujuan untuk memberikan rekomendasi pengembangan akademik, non-akademik, karier, dan program studi berdasarkan profil kompetensi yang dihasilkan.

A. Metode Pengumpulan Data

Pengumpulan data dalam penelitian ini dilakukan melalui beberapa teknik sebagai berikut.

1. Observasi dilakukan dengan mengamati kondisi mahasiswa di lingkungan Universitas Bale Bandung terkait proses pengembangan diri, pemilihan kegiatan akademik maupun non-akademik, serta penentuan arah karier selama masa studi. Selain itu, observasi juga dilakukan terhadap proses penerimaan mahasiswa baru untuk mengetahui berbagai kendala yang dihadapi calon mahasiswa dalam menentukan program studi yang sesuai.
2. Wawancara dilakukan secara langsung dengan pihak Penerimaan Mahasiswa Baru (PMB), mahasiswa aktif, alumni, dan ketua program studi di Universitas Bale Bandung. Wawancara dengan pihak PMB bertujuan untuk memperoleh informasi mengenai permasalahan yang sering dihadapi calon mahasiswa dalam menentukan program studi. Wawancara dengan mahasiswa aktif dan alumni dilakukan untuk mengetahui kebutuhan pengembangan diri selama masa studi

serta kesesuaian kompetensi dengan karier yang dijalani. Selain itu, wawancara dengan ketua program studi dilakukan untuk memperoleh data CPL, Profil Lulusan (PL), dan informasi kurikulum yang digunakan dalam penelitian.

3. Studi Literatur dilakukan dengan menelaah berbagai sumber ilmiah yang relevan, seperti jurnal dan penelitian terdahulu yang berkaitan dengan klasifikasi, sistem rekomendasi, *machine learning*, *Decision Tree*, *XGBoost*, *Explainable Artificial Intelligence* (XAI), SHAP, serta pengembangan sistem berbasis web. Studi literatur dilakukan terhadap 50 artikel ilmiah yang kemudian diseleksi untuk memperoleh referensi yang paling relevan dengan penelitian.
4. Analisis Dokumen dilakukan terhadap dokumen kurikulum dari 12 program studi di Universitas Bale Bandung. Dokumen yang dianalisis meliputi Capaian Pembelajaran Lulusan (CPL), Profil Lulusan (PL), serta mata kuliah pendukung yang digunakan sebagai dasar dalam proses sintesis kurikulum dan pembentukan profil kompetensi mahasiswa.
5. Kuesioner digunakan untuk memperoleh data karakteristik responden yang terdiri atas variabel minat, gaya belajar, dan tujuan karier. Instrumen penelitian terdiri atas 30 item pernyataan menggunakan skala Likert 1 sampai 5 yang disusun berdasarkan hasil sintesis CPL dan profil kompetensi mahasiswa. Responden penelitian terdiri atas mahasiswa aktif dan alumni dengan target 161 responden.

B. Metode Pemrosesan Data dan Pembangunan Model

Metode pemrosesan data yang digunakan dalam penelitian ini mengacu pada pendekatan *Knowledge Discovery in Databases* (KDD). Tahapan yang dilakukan adalah sebagai berikut.

1. *Selection,* tahap ini dilakukan dengan memilih data yang relevan untuk penelitian, yaitu data hasil kuesioner yang terdiri atas variabel minat, gaya belajar, dan tujuan karier. Selain itu, digunakan pula data hasil sintesis CPL dan Profil Lulusan yang diperoleh dari 12 program studi Universitas Bale Bandung.
2. *Preprocessing,* tahap ini dilakukan proses pembersihan data untuk mengatasi data kosong, data duplikat, maupun data yang tidak konsisten. Tahap ini

bertujuan untuk memastikan kualitas data sebelum digunakan dalam proses pembentukan model.

3. *Transformation,* tahap transformasi dilakukan dengan mengubah data hasil kuesioner ke dalam format yang sesuai untuk proses klasifikasi. Pada tahap ini juga dilakukan proses *rule-based initial labeling* berdasarkan hubungan antara CPL, profil kompetensi, minat, gaya belajar, dan tujuan karier sehingga diperoleh label profil kompetensi mahasiswa.
4. Data *Mining,* tahap *data mining* dilakukan dengan membangun model klasifikasi menggunakan algoritma *Decision Tree* dan *XGBoost*. Untuk memperoleh model yang lebih stabil dan mengurangi potensi *overfitting*, dilakukan proses validasi menggunakan *K-Fold Cross Validation* serta optimasi hyperparameter menggunakan model final.
5. *Evaluation,* tahap evaluasi dilakukan untuk membandingkan performa kedua algoritma menggunakan metrik *Accuracy*, *Precision*, *Recall*, *F1-Score*, *Confusion Matrix*, dan *ROC-AUC*. Model terbaik selanjutnya dianalisis menggunakan metode SHAP untuk mengetahui faktor-faktor yang paling berpengaruh terhadap hasil klasifikasi profil kompetensi mahasiswa.

C. Metode Pengembangan Sistem

Metode yang digunakan dalam pengembangan sistem pada penelitian ini adalah *Software Development Life Cycle* (SDLC) dengan model Waterfall. Model ini dipilih karena kebutuhan sistem telah ditentukan sejak tahap awal, sehingga proses pengembangannya dapat dilakukan secara bertahap dan sistematis. Setiap tahapan dikerjakan secara berurutan, mulai dari analisis kebutuhan hingga sistem siap digunakan.

1. Analisis Kebutuhan (*Requirements Analysis*), tahap ini dilakukan untuk mengidentifikasi kebutuhan sistem berdasarkan hasil observasi, wawancara, analisis kurikulum, dan hasil pengolahan data. Analisis mencakup kebutuhan fungsional, kebutuhan non-fungsional, kebutuhan pengguna, serta kebutuhan integrasi model klasifikasi ke dalam sistem.
2. Desain Sistem (*System Design*), tahap desain dilakukan dengan menyusun rancangan sistem yang meliputi perancangan UML, basis data, antarmuka

pengguna (*user interface*), arsitektur sistem, serta rancangan integrasi model *machine learning* dan basis pengetahuan (*knowledge base*) sistem rekomendasi.

3. Implementasi (*Implementation*), tahap implementasi dilakukan dengan membangun aplikasi berbasis web menggunakan PHP dan MySQL. Pada tahap ini dilakukan integrasi model klasifikasi *Decision Tree* dan *XGBoost* ke dalam sistem sehingga sistem dapat menghasilkan rekomendasi secara otomatis.
4. Pengujian (*Testing*), pengujian sistem dilakukan menggunakan metode *Black Box Testing* untuk memastikan seluruh fungsi sistem berjalan sesuai kebutuhan. Selain itu, dilakukan *User Acceptance Testing* (UAT) untuk mengetahui tingkat penerimaan pengguna terhadap sistem yang dikembangkan.
5. Pemeliharaan (*Maintenance*), tahap pemeliharaan dilakukan untuk memperbaiki kesalahan yang ditemukan selama penggunaan sistem, melakukan penyempurnaan fitur, serta meningkatkan performa sistem sesuai kebutuhan pengguna.

1.6. Sistematika Penulisan

Sistematika penulisan penelitian ini disusun sebagai gambaran umum mengenai tahapan dan arah pembahasan dalam penelitian. Susunan setiap bab dibuat secara berurutan agar pembahasan dapat dipahami dengan lebih mudah dan memberikan gambaran yang jelas mengenai keseluruhan isi penelitian.

BAB I PENDAHULUAN

Bab ini berisi latar belakang penelitian, identifikasi masalah, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, metodologi penelitian, serta sistematika penulisan. Pada bab ini juga dijelaskan hasil studi pendahuluan yang menjadi dasar dilakukannya penelitian.

BAB II TINJAUAN PUSTAKA

Bab ini membahas teori-teori yang mendukung penelitian, penelitian terdahulu, serta konsep yang berkaitan dengan Capaian Pembelajaran Lulusan (CPL), Profil Lulusan (PL), profil kompetensi mahasiswa, *machine learning*, *Decision Tree*, *XGBoost*, *Explainable Artificial Intelligence* (XAI), SHAP, *Knowledge Discovery in Databases* (KDD), sistem rekomendasi, PHP, MySQL, dan pengembangan sistem berbasis web.

BAB III METODOLOGI

Bab ini menjelaskan kerangka pikir penelitian, tahapan pengumpulan data, analisis kurikulum 12 program studi, sintesis CPL, pembentukan profil kompetensi mahasiswa, penyusunan instrumen penelitian, operasional variabel, metode KDD, pembangunan model klasifikasi menggunakan *Decision Tree* dan *XGBoost*, serta metode pengembangan sistem menggunakan SDLC model *Waterfall*.

BAB IV ANALISIS, PERANCANGAN DAN HASIL

Bab ini membahas hasil analisis kurikulum, hasil sintesis CPL dan Profil Lulusan, pembentukan profil kompetensi mahasiswa, hasil pengolahan data kuesioner, hasil pembangunan model klasifikasi, evaluasi performa model, analisis SHAP, implementasi sistem rekomendasi, hasil pengujian sistem, serta pembahasan hasil penelitian.

BAB V IMPLEMENTASI DAN PENGUJIAN

Bab ini berisi kesimpulan yang diperoleh berdasarkan hasil penelitian serta saran yang dapat digunakan untuk pengembangan penelitian selanjutnya maupun pengembangan sistem di masa mendatang.

BAB VI KESIMPULAN DAN SARAN

Bab ini berisi dokumen pendukung penelitian, seperti instrumen kuesioner, hasil wawancara, dokumen CPL dan Profil Lulusan, hasil pengujian sistem, dokumentasi penelitian, serta data pendukung lainnya yang digunakan selama proses penelitian.

BAB II

TINJAUAN PUSTAKA

2.1 Landasan Teori

Penelitian terdahulu digunakan sebagai dasar untuk mengetahui perkembangan penelitian yang berkaitan dengan klasifikasi, sistem rekomendasi, *machine learning*, serta pemanfaatan data pendidikan dalam mendukung pengambilan keputusan. Selain itu, kajian terhadap penelitian terdahulu dilakukan untuk mengidentifikasi persamaan, perbedaan, keterbatasan penelitian sebelumnya, serta menemukan *research gap* yang menjadi dasar pengembangan penelitian ini.

Penelitian mengenai analisis minat siswa berdasarkan mata pelajaran telah dilakukan menggunakan algoritma *Decision Tree* untuk mengidentifikasi kecenderungan minat akademik siswa. Hasil penelitian menunjukkan bahwa algoritma *Decision Tree* mampu melakukan klasifikasi minat siswa berdasarkan pola nilai mata pelajaran yang dimiliki dengan tingkat akurasi yang baik. Persamaan penelitian tersebut dengan penelitian ini terletak pada penggunaan algoritma *Decision Tree* sebagai metode klasifikasi. Perbedaannya terletak pada objek penelitian dan variabel yang digunakan. Penelitian tersebut berfokus pada minat siswa tingkat sekolah menengah berdasarkan nilai mata pelajaran, sedangkan penelitian ini menggunakan variabel minat, gaya belajar, dan tujuan karier mahasiswa yang dikaitkan dengan data kurikulum untuk membentuk profil kompetensi mahasiswa (Haekal, 2025).

Pemanfaatan data kurikulum untuk mendukung proses evaluasi akademik mahasiswa telah diteliti melalui pengembangan model *developmental advising* berbasis *student outcomes* dan *performance indicators*. Hasil penelitian menunjukkan bahwa data capaian pembelajaran dapat digunakan untuk meningkatkan efektivitas evaluasi akademik dan mendukung pengambilan keputusan yang lebih terstruktur. Persamaan penelitian tersebut dengan penelitian ini adalah penggunaan data kurikulum sebagai dasar pengolahan informasi akademik. Namun demikian, penelitian tersebut belum menerapkan algoritma

klasifikasi *machine learning* untuk menghasilkan rekomendasi yang bersifat personal bagi mahasiswa (Hussain et al., 2024).

Penelitian lain memanfaatkan algoritma *Decision Tree* untuk memetakan gaya belajar mahasiswa kedokteran gigi dan menghasilkan rekomendasi strategi pembelajaran yang sesuai. Hasil penelitian menunjukkan bahwa model yang dibangun mampu mengklasifikasikan gaya belajar mahasiswa dengan tingkat akurasi mencapai 90%. Persamaan penelitian tersebut dengan penelitian ini terletak pada penggunaan algoritma *Decision Tree* dan karakteristik mahasiswa sebagai dasar klasifikasi. Perbedaannya adalah penelitian tersebut hanya berfokus pada aspek gaya belajar, sedangkan penelitian ini mengintegrasikan minat, gaya belajar, tujuan karier, serta data kurikulum dalam satu model klasifikasi profil kompetensi mahasiswa (Shoaib et al., 2024).

Pengembangan sistem rekomendasi pemilihan program studi menggunakan pendekatan *machine learning* juga telah dilakukan dengan membandingkan beberapa algoritma klasifikasi, yaitu *Decision Tree, Random Forest*, dan *Gradient Boosting*. Hasil penelitian menunjukkan bahwa sistem yang dibangun mampu membantu calon mahasiswa dalam memilih program studi secara lebih objektif dan akurat berdasarkan data lulusan. Persamaan penelitian tersebut dengan penelitian ini adalah penggunaan metode klasifikasi untuk menghasilkan rekomendasi dalam bidang pendidikan. Perbedaannya terletak pada tujuan penelitian. Penelitian tersebut berfokus pada rekomendasi pemilihan program studi, sedangkan penelitian ini berfokus pada klasifikasi profil kompetensi mahasiswa dan rekomendasi pengembangan mahasiswa selama masa studi (Zayed et al., 2022).

Penelitian lain mengkaji pemilihan program studi yang sesuai bagi calon mahasiswa menggunakan beberapa algoritma *supervised learning*, yaitu *Decision Tree*, *Random Forest*, *Support Vector Machine* (SVM), dan *Gradient Boosting*. Hasil penelitian menunjukkan bahwa algoritma *Random Forest* dan *Gradient Boosting* memberikan performa prediksi yang lebih baik dibandingkan algoritma lainnya dalam menentukan program studi yang sesuai berdasarkan karakteristik mahasiswa. Persamaan penelitian tersebut dengan penelitian ini adalah penggunaan pendekatan klasifikasi berbasis *machine learning* dalam bidang pendidikan. Perbedaannya terletak pada tujuan penelitian dan sumber data yang digunakan.

Penelitian tersebut berfokus pada prediksi pemilihan program studi, sedangkan penelitian ini bertujuan mengklasifikasikan profil kompetensi mahasiswa berdasarkan integrasi data kurikulum, minat, gaya belajar, dan tujuan karier sebagai dasar rekomendasi pengembangan mahasiswa (Alsayed et al., 2021).

Tabel 2.1 Jurnal Acuan

Identitas	Judul Penelitian	Metode	Hasil / Kesimpulan
Haekal (2025)	*Implementation of Decision Tree Algorithm for Student Interest Analysis Based on Subjects at MTs Aisyiyah Binjai*	*Decision Tree*	Algoritma *Decision Tree* mampu menganalisis minat siswa berdasarkan pola nilai mata pelajaran secara cukup akurat.
Hussain et al. (2024)	*Pedagogical and Mixed Methods Developmental Advising Model Using Digital Outcome Assessment Data*	*Developmental Advising* berbasis data kurikulum	Data capaian pembelajaran dan *performance indicators* dapat digunakan untuk meningkatkan efektivitas evaluasi akademik mahasiswa.
Shoaib et al. (2024)	*Utilizing Decision Tree Machine Learning Model to Map Dental Students' Preferred Learning Styles with Suitable Instructional Strategies*	*Decision Tree*	Model menghasilkan klasifikasi gaya belajar mahasiswa dengan tingkat akurasi 100% dan memberikan rekomendasi strategi pembelajaran yang sesuai.
Zayed et al. (2022)	*A Recommendation System for Selecting the Appropriate Undergraduate Program at Higher Education Institutions Using Graduate Student Data*	*Decision Tree*, *Random Forest*, dan *Gradient Boosting*	Sistem rekomendasi mampu membantu pemilihan program studi secara lebih objektif berdasarkan data lulusan.
Alsayed et al. (2021)	*Selection of the Right Undergraduate Major by Students Using Supervised Learning Techniques*	*Decision Tree*, *Random Forest*, *SVM*, dan *Gradient Boosting*	Algoritma *ensemble learning* menghasilkan performa prediksi yang tinggi dalam menentukan program studi yang sesuai bagi mahasiswa.

Berdasarkan kajian penelitian terdahulu, penerapan *machine learning* dalam bidang pendidikan telah dimanfaatkan untuk berbagai kebutuhan, seperti analisis minat, identifikasi gaya belajar, pemilihan program studi, dan evaluasi akademik

mahasiswa. Namun, masih terdapat beberapa kesenjangan penelitian yang perlu dikaji lebih lanjut. Sebagian besar penelitian hanya berfokus pada satu karakteristik individu, padahal pengembangan kompetensi mahasiswa dipengaruhi oleh kombinasi faktor seperti minat, gaya belajar, dan tujuan karier. Selain itu, penggunaan Profil Lulusan (PL) dan Capaian Pembelajaran Lulusan (CPL) sebagai dasar pembentukan profil kompetensi mahasiswa masih jarang dilakukan, terutama dalam bentuk integrasi kurikulum dengan karakteristik individu. Penelitian sebelumnya juga umumnya menghasilkan klasifikasi minat, gaya belajar, atau rekomendasi program studi, sehingga belum banyak yang mengembangkan model klasifikasi profil kompetensi mahasiswa secara komprehensif berdasarkan sintesis kurikulum. Kesenjangan lainnya adalah belum optimalnya pemanfaatan kurikulum lintas program studi untuk membentuk profil kompetensi multidisiplin yang relevan dengan kebutuhan akademik dan karier. Dari sisi metodologi, sebagian penelitian masih menggunakan satu algoritma klasifikasi tanpa melakukan perbandingan model secara mendalam, serta belum memperhatikan aspek interpretabilitas model sehingga hasil prediksi yang diperoleh kurang transparan dan sulit dipahami oleh pengguna dalam konteks pendidikan.

Berdasarkan *research* gap yang telah diidentifikasi, penelitian ini memiliki beberapa unsur kebaruan dibandingkan penelitian sebelumnya. Penelitian memanfaatkan data kurikulum Universitas Bale Bandung yang mencakup Profil Lulusan (PL) dan Capaian Pembelajaran Lulusan (CPL) dari 12 program studi sebagai dasar pembentukan profil kompetensi mahasiswa. Selain itu, penelitian mengintegrasikan tiga variabel utama, yaitu minat, gaya belajar, dan tujuan karier, ke dalam satu instrumen untuk menghasilkan representasi kompetensi mahasiswa yang lebih komprehensif. Hasil sintesis kurikulum menghasilkan enam profil kompetensi, yaitu *Educational and Research Innovator* (PC01), *Digital Technology Specialist* (PC02), *Data and Analytical Intelligence Specialist* (PC03), *Community Development Specialist* (PC04), *Entrepreneurship and Innovation Specialist* (PC05), *Professional Leader* (PC06). Pembentukan label profil dilakukan menggunakan pendekatan *rule-based initial labeling* yang menghubungkan variabel penelitian dengan domain CPL hasil sintesis kurikulum. Selanjutnya, penelitian membandingkan kinerja algoritma *Decision Tree* dan *XGBoost* melalui

K-Fold Cross Validation berdasarkan metrik *Accuracy, Precision, Recall, F1-Score,* dan *ROC-AUC* untuk memperoleh model klasifikasi terbaik. Untuk meningkatkan transparansi model, penelitian juga menerapkan *Explainable Artificial Intelligence* (XAI) menggunakan metode SHAP guna menjelaskan faktor-faktor yang memengaruhi hasil klasifikasi. Model yang dihasilkan kemudian diimplementasikan ke dalam sistem berbasis web yang tidak hanya mengklasifikasikan profil kompetensi mahasiswa, tetapi juga memberikan rekomendasi pengembangan akademik, non-akademik, sertifikasi, kegiatan MBKM, dan karier yang sesuai. Dengan demikian, penelitian ini menghasilkan model klasifikasi dan sistem rekomendasi pengembangan mahasiswa berbasis kurikulum yang mengintegrasikan data kurikulum, karakteristik mahasiswa, profil kompetensi, dan rekomendasi pengembangan secara terpadu.

2.2 Dasar Teori

Adapun dasar teori-teori yang digunakan sebagai acuan dalam implementasi aplikasi yaitu sebagai berikut:

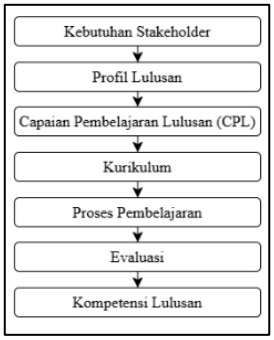
2.2.1. Pengembangan Mahasiswa

Pengembangan mahasiswa merupakan upaya untuk meningkatkan kompetensi, potensi, dan kesiapan mahasiswa dalam menghadapi tuntutan akademik maupun dunia kerja. Proses ini dilakukan melalui identifikasi karakteristik dan kebutuhan mahasiswa guna mendukung pengembangan kemampuan akademik, berpikir kritis, analitis, serta karier. Pemanfaatan data pendidikan dan *machine learning* dapat membantu memetakan kompetensi mahasiswa secara lebih objektif dan terarah (Atalla et al., 2023; Dayanah Ayulani et al., 2023; Deniz, 2024; Okesola, 2021; Osho et al., 2026).

2.2.2. *Outcome-Based Education*

Outcome-Based Education (*OBE*) merupakan pendekatan pendidikan yang berfokus pada pencapaian kompetensi lulusan melalui penyelarasan kurikulum, pembelajaran, dan penilaian berdasarkan Capaian Pembelajaran Lulusan (CPL)

(Direktorat Pembelajaran dan Kemahasiswaan et al., 2024). Pendekatan ini sejalan dengan Permendikbudristek Nomor 53 Tahun 2023 yang menegaskan bahwa penyelenggaraan pendidikan tinggi harus berorientasi pada ketercapaian CPL sebagai hasil akhir proses pendidikan (Permendikbudristek, 2023).



Gambar 2.1 Alur Implementasi *Outcome-Based Education* (OBE)
Sumber: (Direktorat Pembelajaran dan Kemahasiswaan et al., 2024)

Gambar 2.1 penerapan OBE dimulai dari identifikasi kebutuhan pemangku kepentingan yang diterjemahkan ke dalam Profil Lulusan (PL) dan CPL. Selanjutnya, CPL menjadi dasar penyusunan kurikulum, pelaksanaan pembelajaran, dan evaluasi sehingga kompetensi lulusan tetap sesuai dengan tujuan program studi dan kebutuhan dunia kerja (Direktorat Pembelajaran dan Kemahasiswaan et al., 2024).

2.2.3. Profil Lulusan

Profil Lulusan (PL) merupakan gambaran kompetensi dan peran yang diharapkan dimiliki mahasiswa setelah menyelesaikan pendidikan pada suatu program studi. Dalam pendekatan *Outcome-Based Education* (*OBE*), PL menjadi acuan utama dalam penyusunan kurikulum karena mencerminkan kebutuhan dunia kerja, perkembangan ilmu pengetahuan, serta harapan pemangku kepentingan. PL kemudian diterjemahkan ke dalam capaian pembelajaran lulusan yang lebih spesifik dan terukur sehingga dapat menjadi dasar dalam perancangan mata kuliah dan proses pembelajaran (Direktorat Pembelajaran dan Kemahasiswaan et al., 2024). Selain itu, regulasi pendidikan tinggi menegaskan bahwa profil lulusan harus

menjadi dasar dalam menentukan kompetensi yang perlu dicapai mahasiswa selama masa studi (Permendikbudristek, 2023).

2.2.4. Capaian Pembelajaran Lulusan

Capaian Pembelajaran Lulusan (CPL) merupakan kemampuan yang diharapkan dimiliki mahasiswa setelah menyelesaikan seluruh proses pembelajaran pada suatu program studi. Menurut Permendikbudristek Nomor 53 Tahun 2023, CPL mencerminkan hasil belajar yang mencakup aspek sikap, pengetahuan, keterampilan umum, dan keterampilan khusus yang diperoleh selama masa studi. Dalam pendekatan OBE, CPL disusun berdasarkan PL dan menjadi acuan dalam pengembangan kurikulum, penyusunan mata kuliah, serta evaluasi pembelajaran agar kompetensi yang dihasilkan sesuai dengan kebutuhan dunia kerja dan perkembangan ilmu pengetahuan (Direktorat Pembelajaran dan Kemahasiswaan et al., 2024; Kementrian Pendidikan, 2023; Rawis et al., 2025).

2.2.5. Kompetensi

Kompetensi merupakan kemampuan yang dimiliki seseorang untuk melaksanakan tugas atau menyelesaikan pekerjaan berdasarkan pengetahuan, keterampilan, dan sikap yang telah diperoleh melalui proses pembelajaran. Dalam pendidikan tinggi berbasis OBE, kompetensi menjadi hasil yang diharapkan dari pencapaian CPL karena mencerminkan kemampuan nyata yang dapat diterapkan oleh mahasiswa dalam lingkungan akademik maupun dunia kerja (Hussain et al., 2020, 2021). Kompetensi tidak hanya berkaitan dengan penguasaan teori, tetapi juga kemampuan menerapkan pengetahuan secara efektif serta menunjukkan perilaku profesional yang sesuai dengan tuntutan bidang keilmuan tertentu (Atalla et al., 2023; Fernández-García et al., 2020).

2.2.6. Profil Kompetensi Mahasiswa

Profil kompetensi mahasiswa merupakan gambaran mengenai kecenderungan kemampuan, potensi, serta karakteristik yang dimiliki mahasiswa berdasarkan kombinasi aspek pengetahuan, keterampilan, dan sikap yang

berkembang selama proses pendidikan. Dalam pendekatan OBE, profil kompetensi digunakan untuk mengidentifikasi tingkat kesesuaian antara capaian pembelajaran yang diperoleh mahasiswa dengan kebutuhan dunia kerja dan tuntutan profesional di masa depan (Hussain et al., 2020, 2021). Profil kompetensi juga dapat dimanfaatkan sebagai dasar dalam memberikan rekomendasi pengembangan akademik, pelatihan, maupun perencanaan karier sehingga mahasiswa dapat mengembangkan potensinya secara lebih terarah (Atalla et al., 2023; Hussain et al., 2024; Ngozi et al., 2025).

2.2.7. Faktor Pembentuk Profil Kompetensi Mahasiswa

A. Minat

Minat merupakan kecenderungan seseorang untuk memberikan perhatian, ketertarikan, dan keterlibatan yang lebih besar terhadap suatu bidang atau aktivitas tertentu. Dalam lingkungan pendidikan tinggi, minat menjadi salah satu faktor yang memengaruhi pilihan bidang pembelajaran, pengembangan kemampuan, dan perencanaan karier mahasiswa. Penelitian Putri Miya G. (2024) menunjukkan bahwa minat dapat dilihat dari preferensi mahasiswa terhadap bidang keilmuan tertentu serta kecenderungan memilih aktivitas akademik yang sesuai dengan ketertarikannya. Selain itu, minat juga berkaitan dengan tujuan karier dan peluang profesi yang ingin dicapai di masa depan (McKenzie & Bennett, 2022). Oleh karena itu, minat dapat digunakan sebagai indikator untuk memahami arah pengembangan kompetensi mahasiswa.

B. Gaya Belajar

Gaya belajar merupakan kecenderungan seseorang dalam menerima, mengolah, dan memahami informasi selama proses pembelajaran. Setiap mahasiswa memiliki cara belajar yang berbeda sehingga strategi yang efektif bagi satu individu belum tentu sesuai bagi individu lainnya. Salah satu model yang banyak digunakan adalah *Felder-Silverman Learning Style Model* (FSLSM) yang membagi gaya belajar ke dalam empat dimensi, yaitu *Active–Reflective*, *Sensing–Intuitive*, *Visual–Verbal*, dan *Sequential–Global*. Selain itu, model *Visual, Auditory, Read/Write, Kinesthetic* (VARK) mengelompokkan gaya belajar berdasarkan media yang paling disukai dalam memperoleh informasi, yaitu visual, auditori,

membaca/menulis, dan kinestetik. Kedua model tersebut banyak dimanfaatkan untuk mengidentifikasi karakteristik belajar mahasiswa melalui instrumen kuesioner yang terstruktur (Anwar & Wulandari, 2025; Fernández-García et al., 2020; Hasibuan et al., 2025; Hussain et al., 2024).

C. Tujuan Karier

Tujuan karier merupakan gambaran mengenai profesi atau bidang pekerjaan yang ingin dicapai seseorang di masa depan berdasarkan minat, kemampuan, serta harapan pengembangan diri. Dalam lingkungan pendidikan tinggi, tujuan karier menjadi salah satu faktor yang memengaruhi keputusan mahasiswa dalam mengembangkan kompetensi yang relevan dengan kebutuhan dunia kerja. Aspirasi karier mahasiswa tidak hanya dipengaruhi oleh kemampuan akademik, tetapi juga oleh ketertarikan terhadap bidang pekerjaan tertentu, peluang pengembangan, dan prospek karier jangka panjang (McKenzie & Bennett, 2022). Selain itu, tujuan karier dapat diidentifikasi melalui beberapa indikator, seperti bidang pekerjaan yang diminati, posisi yang ingin dicapai, serta rencana pengembangan profesional di masa mendatang (José-García et al., 2023; Pratiwi et al., 2024). Oleh karena itu, tujuan karier dapat menjadi acuan dalam menentukan kompetensi yang perlu dikembangkan agar mahasiswa lebih siap menghadapi dunia kerja (McKenzie & Bennett, 2022).

2.2.8. Instrumen Penelitian

A. *Kuesioner*

Kuesioner merupakan instrumen pengumpulan data yang digunakan untuk memperoleh informasi dari responden melalui serangkaian pertanyaan atau pernyataan yang disusun sesuai tujuan penelitian. Dalam bidang pendidikan dan sistem cerdas, kuesioner sering dimanfaatkan untuk mengukur karakteristik individu yang tidak dapat diamati secara langsung, seperti minat, gaya belajar, dan tujuan karier. Data yang diperoleh kemudian diubah menjadi bentuk terstruktur sehingga dapat dianalisis secara kuantitatif maupun digunakan sebagai masukan bagi sistem berbasis *machine learning* (Anwar & Wulandari, 2025). Selain itu, kuesioner juga banyak digunakan untuk mengumpulkan umpan balik pengguna

secara sistematis sehingga dapat mendukung proses analisis dan pengambilan keputusan (Fitriastuti et al., 2024; Sugiana, 2023).

B. Skala *Likert*

Skala *Likert* merupakan teknik pengukuran yang digunakan untuk mengubah tanggapan, persepsi, atau tingkat persetujuan responden terhadap suatu pernyataan menjadi data berbentuk angka. Skala ini biasanya menggunakan beberapa pilihan jawaban bertingkat, mulai dari tidak setuju hingga sangat setuju, yang masing-masing memiliki nilai tertentu. Melalui pendekatan ini, data yang awalnya bersifat subjektif dapat diolah secara kuantitatif dan digunakan dalam berbagai proses analisis, termasuk penelitian pendidikan, sistem informasi, dan *machine learning* (Fitriastuti et al., 2024; Siti Muthiah Nuralifah et al., 2025; Sugiana, 2023).

Tabel 2.2 Skala *Likert*

Sumber: (Siti Muthiah Nuralifah et al., 2025)

Bobot	Keterangan
1	Tidak Setuju (TS)
2	Kurang Setuju (KS)
3	Cukup Setuju (CS)
4	Setuju (S)
5	Sangat Setuju (SS)

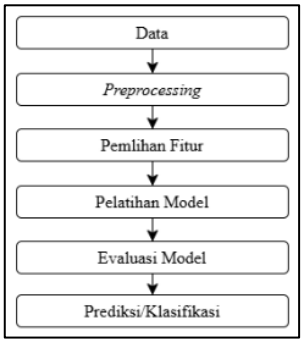
Tabel 2.2 menunjukkan bobot yang digunakan untuk mengonversi jawaban responden ke dalam bentuk numerik. Semakin tinggi tingkat persetujuan yang diberikan, semakin besar pula nilai yang diperoleh. Proses pembobotan ini memungkinkan jawaban kuesioner diolah secara kuantitatif sehingga dapat digunakan sebagai data masukan pada tahap analisis dan pemodelan *machine learning* (Fitriastuti et al., 2024; Siti Muthiah Nuralifah et al., 2025).

2.2.9. *Machine Learning* untuk Klasifikasi

A. *Machine Learning*

Machine Learning merupakan salah satu cabang *Artificial Intelligence* yang memungkinkan komputer mempelajari pola dari data untuk menghasilkan prediksi

atau keputusan secara otomatis. Berbeda dengan pemrograman konvensional yang mengandalkan aturan yang ditentukan secara eksplisit, *Machine Learning* membangun model berdasarkan hubungan yang ditemukan dari data historis. Komponen utama dalam *Machine Learning* meliputi data, fitur, algoritma pembelajaran, model, dan proses evaluasi. Pada pendekatan *supervised learning*, model dilatih menggunakan data yang telah memiliki label sehingga mampu mengklasifikasikan atau memprediksi data baru dengan karakteristik serupa. Dalam bidang pendidikan, *Machine Learning* banyak dimanfaatkan untuk menganalisis karakteristik mahasiswa, memprediksi performa akademik, serta mendukung pengambilan keputusan berbasis data (Alsayed et al., 2021; Dayanah Ayulani et al., 2023; Deniz, 2024).



Gambar 2.2 *Workflow Machine Learning*

Sumber: (Alsayed et al., 2021; Dayanah Ayulani et al., 2023; Deniz, 2024)

Proses *Machine Learning* dimulai dari pengolahan data agar siap digunakan, dilanjutkan dengan pemilihan fitur yang relevan dan pelatihan model menggunakan algoritma tertentu. Setelah model dievaluasi untuk mengetahui tingkat kinerjanya, model tersebut dapat digunakan untuk melakukan prediksi atau klasifikasi terhadap data baru (Dayanah Ayulani et al., 2023; Deniz, 2024).

B. Klasifikasi

Klasifikasi merupakan metode dalam *Machine Learning* yang digunakan untuk mengelompokkan data ke dalam kategori tertentu berdasarkan pola yang dipelajari dari data sebelumnya. Metode ini termasuk *supervised learning* karena proses pembelajarannya menggunakan data yang telah memiliki label sebagai acuan. Komponen utama dalam klasifikasi meliputi data masukan (*features*), label

kelas, data latih, algoritma klasifikasi, dan model prediksi. Dalam bidang pendidikan, klasifikasi banyak dimanfaatkan untuk mengidentifikasi karakteristik mahasiswa serta mendukung proses pengambilan keputusan berbasis data (Dayanah Ayulani et al., 2023; Siswipraptini et al., 2024; Syed Mustapha, 2023).

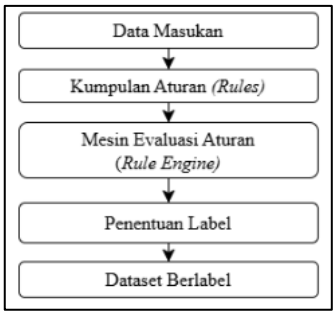
C. *Multi-Class Classification*

Multi-Class Classification merupakan metode klasifikasi dalam *machine learning* yang digunakan untuk mengelompokkan data ke dalam lebih dari dua kelas atau kategori. Berbeda dengan *binary classification* yang hanya menghasilkan dua kemungkinan kelas, *multi-class classification* memungkinkan suatu objek diklasifikasikan ke salah satu dari beberapa kelas yang tersedia berdasarkan karakteristik data yang dimiliki. Pendekatan ini banyak digunakan dalam bidang pendidikan, sistem rekomendasi, dan analisis data karena mampu menangani permasalahan klasifikasi yang memiliki banyak kategori keluaran. Beberapa algoritma seperti *Decision Tree* dan *XGBoost* secara alami mendukung proses *multi-class classification* sehingga dapat digunakan untuk memprediksi kelas berdasarkan pola yang dipelajari dari data pelatihan (Alsayed et al., 2021; Haekal, 2025; Shoaib et al., 2024).

2.2.10. Pembentukan Label Dataset

A. *Rule-Based Initial Labeling*

Rule-Based Initial Labeling merupakan metode pembentukan label awal pada dataset dengan menggunakan seperangkat aturan (*rules*) yang telah ditentukan berdasarkan pengetahuan domain atau hasil analisis pakar. Metode ini bekerja dengan menerapkan aturan berbentuk *IF–THEN* untuk mengelompokkan data ke dalam kategori tertentu sebelum digunakan dalam proses pembelajaran mesin. Pendekatan ini banyak digunakan ketika dataset belum memiliki label asli (*ground truth*) sehingga diperlukan mekanisme pelabelan awal yang konsisten dan dapat dipertanggungjawabkan secara logis. Dalam penelitian berbasis klasifikasi, *rule-based labeling* berfungsi sebagai dasar pembentukan kelas target yang selanjutnya digunakan untuk melatih model *machine learning* (Abouhawwash, 2025; Liu et al., 2024; Song et al., 2023).



Gambar 2.3 Arsitektur *Rule-Based Labeling*

Sumber: (Abouhawwash, 2025; Liu et al., 2024; Song et al., 2023)

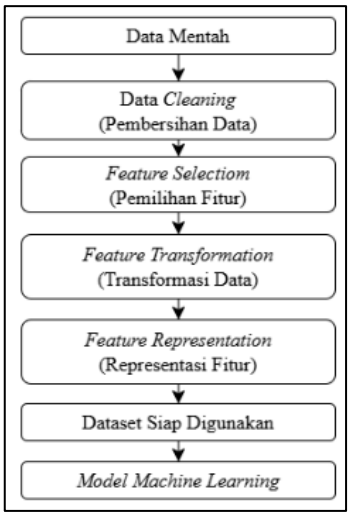
Gambar di atas menunjukkan alur umum *Rule-Based Labeling*. Proses dimulai dari data masukan yang dievaluasi menggunakan kumpulan aturan yang telah ditetapkan. Setiap data akan diperiksa kesesuaiannya terhadap kondisi dalam aturan *IF–THEN*. Apabila suatu aturan terpenuhi, sistem akan memberikan label yang sesuai sehingga menghasilkan dataset yang telah memiliki kelas target. Dataset berlabel tersebut kemudian dapat digunakan pada tahap analisis data maupun pelatihan model klasifikasi.

B. *Pseudo Labeling*

Pseudo labeling merupakan teknik pemberian label pada data yang belum memiliki label (*unlabeled data*) dengan memanfaatkan aturan tertentu atau hasil prediksi dari model yang telah dibangun sebelumnya. Metode ini banyak digunakan dalam pembelajaran mesin ketika data berlabel terbatas, sehingga proses pembentukan label dilakukan secara otomatis berdasarkan pengetahuan domain, aturan pakar, atau prediksi model untuk menghasilkan dataset yang dapat digunakan pada tahap pelatihan (*training*) (Okesola, 2021; A. Ridwan et al., 2024). Dalam konteks klasifikasi, *pseudo labeling* berfungsi sebagai pendekatan *weak supervision* yang memungkinkan data tanpa label diubah menjadi data berlabel sehingga dapat dimanfaatkan untuk membangun model klasifikasi secara lebih efisien (Abdulahi Hasan & Fang, 2021; Syed Mustapha, 2023). Meskipun label yang dihasilkan bukan merupakan *ground truth* yang diperoleh secara langsung dari observasi atau pakar, *pseudo label* tetap dapat digunakan selama proses pembentukannya memiliki dasar logis dan dapat dipertanggungjawabkan secara akademik (A. Ridwan et al., 2024).

2.2.11. *Feature Engineering*

Feature engineering merupakan proses mengubah, memilih, dan menyiapkan data mentah menjadi fitur yang lebih representatif sehingga dapat digunakan secara optimal oleh algoritma *machine learning*. Tahapan ini berperan penting dalam meningkatkan kualitas model karena fitur yang baik dapat membantu algoritma mengenali pola data dengan lebih akurat. Menurut penelitian yang membahas klasifikasi dan prediksi berbasis *machine learning*, *feature engineering* mencakup proses seleksi fitur, transformasi data, pembuatan fitur baru, serta representasi data agar sesuai dengan kebutuhan model. Kualitas fitur yang digunakan sering kali memiliki pengaruh yang lebih besar terhadap performa model dibandingkan pemilihan algoritma itu sendiri karena fitur menjadi sumber informasi utama dalam proses pembelajaran mesin (Haekal, 2025; Nurizati et al., 2024; Shoaib et al., 2024; Zayed et al., 2022).



Gambar 2.4 Tahapan Umum *Feature Engineering*

Sumber: (Nurizati et al., 2024; Shoaib et al., 2024; Zayed et al., 2022)

Alur umum *feature engineering* yang dimulai dari data mentah hingga menghasilkan dataset yang siap digunakan dalam proses pelatihan model. Tahapan tersebut meliputi pembersihan data untuk mengurangi kesalahan atau ketidakkonsistenan, pemilihan fitur yang relevan, transformasi data ke dalam format yang sesuai, serta representasi fitur agar dapat diproses oleh algoritma *machine learning*. Melalui tahapan ini, informasi penting yang terdapat pada data

dapat dipertahankan sehingga model mampu menghasilkan prediksi yang lebih baik.

2.2.12. *Decision Tree*

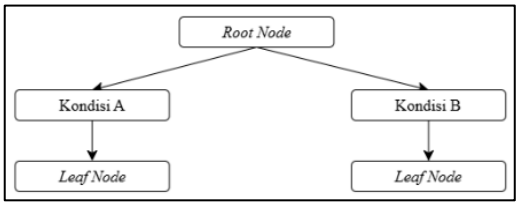
Decision Tree merupakan salah satu algoritma *machine learning* yang digunakan untuk melakukan proses klasifikasi maupun prediksi dengan membentuk struktur pohon keputusan (*decision tree*). Algoritma ini bekerja dengan cara membagi data ke dalam beberapa kelompok berdasarkan atribut yang dianggap paling berpengaruh terhadap variabel target. Setiap percabangan pada pohon keputusan merepresentasikan aturan keputusan yang digunakan untuk memisahkan data hingga diperoleh kelompok yang homogen (Basu, 2025; Dayanah Ayulani et al., 2023)

Decision Tree banyak digunakan karena memiliki tingkat interpretabilitas yang tinggi, mudah dipahami oleh pengguna, serta mampu menghasilkan aturan klasifikasi dalam bentuk logika *if-then*. Selain itu, algoritma ini dapat menangani data kategorikal maupun numerik tanpa memerlukan transformasi yang kompleks (Okesola, 2021).

A. Struktur Dasar *Decision Tree*

Struktur dasar *Decision Tree* terdiri dari:

1. *Root Node*, yaitu simpul awal yang menjadi atribut utama dalam proses klasifikasi.
2. *Internal Node*, yaitu simpul yang berisi proses pengambilan keputusan berdasarkan atribut tertentu.
3. *Branch*, yaitu cabang yang menunjukkan hasil dari suatu keputusan.
4. *Leaf Node*, yaitu simpul akhir yang berisi hasil klasifikasi atau prediksi.



Gambar 2.5 Struktur *Decision Tree*

Sumber: (Dayanah Ayulani et al., 2023; Okesola, 2021)

Gambar di atas menunjukkan struktur dasar Decision Tree yang terdiri atas *root node*, *internal node*, *branch*, dan *leaf node*. Proses klasifikasi dimulai dari *root node* sebagai atribut utama, kemudian data dibagi melalui beberapa percabangan berdasarkan nilai atribut tertentu hingga mencapai *leaf node* yang merepresentasikan hasil klasifikasi. Struktur tersebut memungkinkan proses pengambilan keputusan dilakukan secara sistematis dan mudah dipahami oleh pengguna.

B. Tahapan Algoritma *Decision Tree*

Menurut Dayanah Ayulani et al. (2023), tahapan pembentukan *Decision Tree* meliputi:

1. Menyiapkan dataset yang akan digunakan untuk proses klasifikasi.
2. Menghitung nilai *Entropy* pada setiap atribut.
3. Menghitung nilai *Information Gain* dari setiap atribut.
4. Memilih atribut dengan nilai *Information Gain* terbesar sebagai *root node*.
5. Membagi data berdasarkan atribut terpilih.
6. Mengulangi proses perhitungan *Entropy* dan *Information Gain* pada setiap cabang hingga seluruh data berada pada kelas yang sama atau tidak terdapat atribut yang dapat digunakan untuk pemisahan lebih lanjut.
7. Membentuk pohon keputusan hingga menghasilkan *leaf node* sebagai kelas akhir.

C. *Entropy*

Entropy digunakan untuk mengukur tingkat ketidakpastian atau ketidakhomogenan suatu kumpulan data. Semakin kecil nilai *Entropy*, maka data pada kelompok tersebut semakin homogen.

$$Entropy(S) = -\sum pilog2pi$$

Keterangan:

Entropy(S) = nilai *entropy* pada dataset S

p_i = probabilitas kemunculan kelas ke-i

n = jumlah kelas

Nilai *Entropy* akan bernilai 0 apabila seluruh data berada dalam satu kelas yang sama.

D. *Information Gain*

Information Gain digunakan untuk menentukan atribut terbaik yang akan dijadikan dasar percabangan pada pohon keputusan. Semakin besar nilai *Information Gain*, semakin baik atribut tersebut dalam memisahkan data.

$$Gain(S,A)=Entropy(S)-\sum|S||Sv|Entropy(Sv)$$

Keterangan:

Gain(S,A) = besarnya nilai *Information Gain* pada atribut A

Entropy(S) = *entropy* dataset awal

S_v = subset data hasil pembagian berdasarkan atribut A

$|S_v|$ = jumlah data pada subset

|S| = jumlah data keseluruhan

Atribut dengan nilai *Information Gain* terbesar akan dipilih sebagai dasar pembentukan percabangan karena mampu mengurangi ketidakpastian data secara optimal (Dayanah Ayulani et al., 2023).

2.2.13. *Extreme Gradient Boosting*

Extreme Gradient Boosting (*XGBoost*) merupakan algoritma machine learning berbasis *Gradient Boosting Decision Tree (GBDT)* yang dikembangkan untuk meningkatkan akurasi prediksi serta mengurangi risiko *overfitting*. *XGBoost* bekerja dengan membangun beberapa pohon keputusan (*decision tree*) secara bertahap, dimana setiap pohon baru digunakan untuk memperbaiki kesalahan prediksi dari pohon sebelumnya. Selain itu, *XGBoost* menerapkan teknik *regularization* sehingga model yang dihasilkan lebih stabil dan memiliki kemampuan generalisasi yang baik (Dayanah Ayulani et al., 2023; Kate et al., 2026; Rafie et al., 2025).

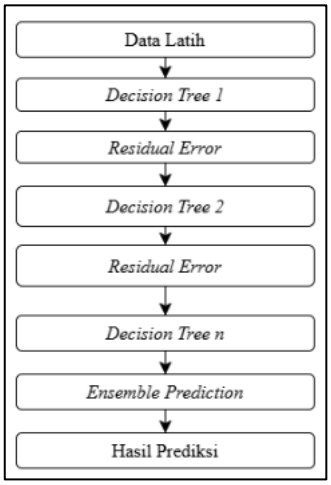
A. Tahapan *XGBoost*

Tahapan kerja algoritma *XGBoost* meliputi:

1. Membentuk pohon keputusan awal (*Decision Tree*).
2. Menghitung kesalahan prediksi (*error*).
3. Membangun pohon baru untuk memperbaiki kesalahan sebelumnya.
4. Menerapkan *regularization* untuk mengurangi *overfitting*.

5. Menggabungkan seluruh pohon menjadi model prediksi akhir.

B. Arsitektur *XGBoost*



Gambar 2.6 Arsitektur *XGBoost*

Sumber: (Kate et al., 2026; Rafie et al., 2025)

Arsitektur *XGBoost* menunjukkan proses pembelajaran yang dilakukan secara berulang. Prediksi dari setiap pohon digunakan untuk menghitung kesalahan yang masih terjadi, kemudian kesalahan tersebut dipelajari kembali oleh pohon berikutnya. Hasil prediksi dari seluruh pohon kemudian digabungkan sehingga menghasilkan model yang lebih akurat dibandingkan penggunaan satu pohon keputusan saja (Dayanah Ayulani et al., 2023; Kate et al., 2026).

C. Fungsi Objektif *XGBoost*

Fungsi objektif pada *XGBoost* dirumuskan sebagai berikut:

$$Obj(\theta) = L(\theta) + \Omega(\theta)$$

Keterangan:

$Obj(\theta)$ = fungsi objektif model

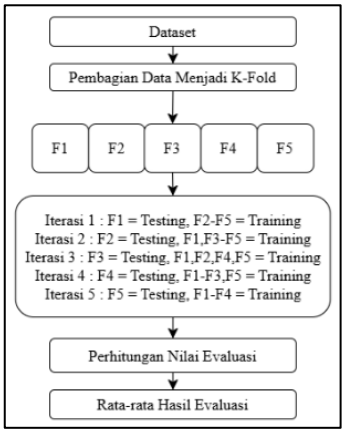
$L(\theta)$ = fungsi kesalahan (*loss function*)

$\Omega(\theta)$ = fungsi *regularization*

Fungsi tersebut menunjukkan bahwa *XGBoost* tidak hanya meminimalkan kesalahan prediksi, tetapi juga mengontrol kompleksitas model sehingga dapat mengurangi risiko *overfitting*.

2.2.14. *Cross Validation*

Cross Validation merupakan teknik evaluasi dalam *machine learning* yang digunakan untuk mengukur kemampuan model dalam memprediksi data baru yang belum pernah dipelajari sebelumnya. Metode ini dilakukan dengan membagi dataset ke dalam beberapa bagian (*fold*), kemudian secara bergantian menggunakan satu bagian sebagai data pengujian dan bagian lainnya sebagai data pelatihan. Proses tersebut membantu menghasilkan nilai evaluasi yang lebih stabil dan mengurangi risiko *overfitting*, sehingga performa model dapat dinilai secara lebih objektif (Devanathan et al., 2025; Hasibuan et al., 2025; Rafie et al., 2025).



Gambar 2.7 Proses *K-Fold Cross Validation*

Sumber: (Rafie et al., 2025)

Alur *K-Fold Cross Validation*, yaitu proses pembagian data ke dalam beberapa *fold* yang digunakan secara bergantian sebagai data pelatihan dan data pengujian. Setelah seluruh proses selesai, nilai evaluasi dari setiap iterasi dirata-ratakan sehingga diperoleh hasil yang lebih representatif terhadap kemampuan model (Rafie et al., 2025).

2.2.15. *Explainable Artificial Intelligence*

Explainable Artificial Intelligence (XAI) merupakan pendekatan dalam kecerdasan buatan yang bertujuan untuk menjelaskan proses pengambilan keputusan model machine learning sehingga hasil prediksi dapat dipahami oleh manusia. XAI dikembangkan untuk mengatasi keterbatasan model *black box* yang

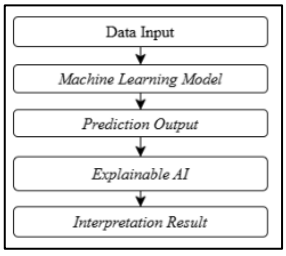
mampu menghasilkan tingkat akurasi tinggi, namun sulit menjelaskan alasan di balik keputusan yang dihasilkan (Basu, 2025; Devanathan et al., 2025; Iban, 2022; Pratiwi et al., 2024). Menurut Basu (2025), XAI memungkinkan pengguna memahami hubungan antara data masukan, proses pembelajaran model, dan hasil prediksi yang dihasilkan. Sementara itu, Devanathan et al. (2025) menjelaskan bahwa XAI berperan dalam meningkatkan transparansi, kepercayaan, dan akuntabilitas sistem kecerdasan buatan. Karakteristik utama *Explainable Artificial Intelligence* meliputi:

1. *Interpretability*, yaitu kemampuan model untuk dijelaskan dan dipahami oleh pengguna.
2. *Transparency*, yaitu keterbukaan proses pengambilan keputusan model.
3. *Trustworthiness*, yaitu meningkatkan kepercayaan pengguna terhadap hasil prediksi.
4. *Accountability*, yaitu kemampuan sistem untuk mempertanggungjawabkan keputusan yang dihasilkan.

Dalam penelitian ini, XAI digunakan untuk menjelaskan faktor-faktor yang memengaruhi hasil klasifikasi profil kompetensi mahasiswa sehingga rekomendasi yang diberikan sistem dapat dipahami oleh pengguna.

Secara umum proses *Explainable Artificial Intelligence* terdiri dari beberapa tahapan sebagai berikut:

1. Data masukan (*input data*) diberikan ke model *machine learning*.
2. Model melakukan proses klasifikasi berdasarkan pola yang dipelajari.
3. Model menghasilkan prediksi kelas.
4. Metode XAI melakukan analisis kontribusi setiap fitur terhadap hasil prediksi.
5. Sistem menghasilkan penjelasan (*explanation*) yang dapat dipahami pengguna.



Gambar 2.8 Tahapan *Explainable Artificial Intelligence*

Sumber: (Basu, 2025; Devanathan et al., 2025; Iban, 2022)

Gambar tersebut menunjukkan bahwa XAI tidak mengubah proses pembelajaran model machine learning, melainkan bekerja setelah model menghasilkan prediksi. Hasil prediksi kemudian dianalisis untuk mengetahui kontribusi masing-masing fitur sehingga keputusan model menjadi lebih transparan dan mudah dipahami (Basu, 2025; Devanathan et al., 2025; Iban, 2022).

2.2.16. *SHapley Additive exPlanations*

SHapley Additive exPlanations (SHAP) merupakan salah satu metode Explainable Artificial Intelligence yang digunakan untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi model machine learning. SHAP dikembangkan berdasarkan konsep *Shapley Value* dalam teori permainan (*cooperative game theory*) yang digunakan untuk menghitung kontribusi setiap pemain secara adil terhadap hasil akhir permainan. Dalam konteks machine learning, setiap fitur dianggap sebagai pemain yang berkontribusi terhadap prediksi model (Basu, 2025; Bifarin, 2023).

Metode SHAP memiliki beberapa keunggulan, yaitu:

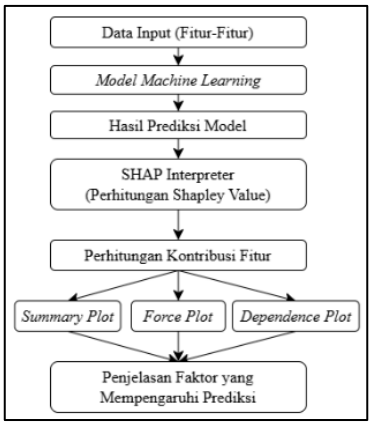
1. Memberikan interpretasi lokal (*local explanation*) pada setiap data.
2. Memberikan interpretasi global (*global explanation*) terhadap keseluruhan model.
3. Dapat digunakan pada berbagai algoritma machine learning.
4. Menjelaskan pengaruh positif maupun negatif setiap fitur terhadap prediksi.

Dalam penelitian ini, SHAP digunakan untuk menjelaskan faktor-faktor yang memengaruhi klasifikasi profil kompetensi mahasiswa berdasarkan variabel minat, gaya belajar, dan tujuan karier.

A. Tahapan SHAP

Proses interpretasi menggunakan SHAP dilakukan melalui tahapan berikut:

1. Model machine learning menghasilkan prediksi.
2. SHAP menghitung nilai kontribusi masing-masing fitur.
3. Nilai kontribusi dihitung menggunakan konsep Shapley Value.
4. SHAP menghasilkan visualisasi interpretasi.
5. Pengguna dapat mengetahui fitur yang paling berpengaruh terhadap hasil klasifikasi.



Gambar 2.9 Arsitektur SHAP dalam Interpretasi Model *Machine Learning*
Sumber: (Basu, 2025; Bifarin, 2023)

Arsitektur SHAP menggambarkan proses interpretasi yang dilakukan setelah model *machine learning* menghasilkan prediksi. SHAP menghitung kontribusi setiap fitur terhadap hasil prediksi, kemudian menyajikannya dalam bentuk visualisasi seperti *summary plot*, *force plot*, dan *dependence plot*. Proses ini membantu menjelaskan faktor-faktor yang paling berpengaruh terhadap keputusan model.

B. Rumus SHAP

Nilai prediksi pada metode SHAP dihitung menggunakan persamaan berikut:

$$f(x) = \phi_0 + \sum_{i=1}^{n} \phi_i$$

Keterangan:

$f(x)$= hasil prediksi model.

ϕ_0= *base value* atau nilai prediksi dasar.

ϕ_i= kontribusi fitur ke-i.

M= jumlah fitur.

Persamaan tersebut menunjukkan bahwa hasil prediksi merupakan kombinasi antara nilai dasar (*base value*) dan kontribusi seluruh fitur yang digunakan dalam model. Nilai kontribusi dapat bernilai positif maupun negatif tergantung pada pengaruh fitur terhadap hasil prediksi.

C. *TreeSHAP*

Pada penelitian ini algoritma yang digunakan adalah *Decision Tree* dan *XGBoost* yang termasuk dalam kategori model berbasis pohon (*tree-based model*). Oleh karena itu, metode SHAP yang digunakan adalah *TreeSHAP*.

TreeSHAP merupakan pengembangan SHAP yang dirancang khusus untuk model berbasis pohon keputusan sehingga proses perhitungan nilai kontribusi fitur dapat dilakukan lebih cepat dan efisien dibandingkan SHAP umum.

Keunggulan *TreeSHAP* meliputi:

1. Perhitungan lebih cepat untuk *Decision Tree* dan *XGBoost*.
2. Menyediakan interpretasi lokal dan global.
3. Menjelaskan kontribusi fitur secara konsisten.
4. Cocok digunakan pada dataset klasifikasi multikelas.

Dalam penelitian ini *TreeSHAP* digunakan untuk mengidentifikasi fitur minat, gaya belajar, dan tujuan karier yang paling berpengaruh terhadap pembentukan profil kompetensi mahasiswa.

D. Visualisasi SHAP

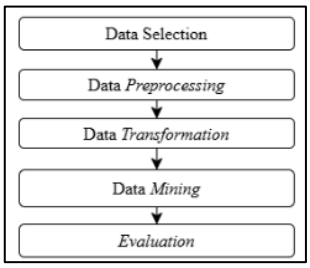
Hasil interpretasi SHAP umumnya disajikan menggunakan beberapa jenis visualisasi, antara lain:

1. *Summary Plot*, menampilkan fitur yang paling berpengaruh terhadap model secara keseluruhan.
2. *Bar Plot*, menunjukkan rata-rata kontribusi setiap fitur terhadap prediksi.
3. *Force Plot*, menjelaskan alasan prediksi pada satu data tertentu.
4. *Dependence Plot*, menunjukkan hubungan antara nilai fitur dengan kontribusinya terhadap model.

2.2.17. *Knowledge Discovery in Database*

Knowledge Discovery in Databases (KDD) adalah proses untuk memperoleh pengetahuan atau informasi yang bermanfaat dari sekumpulan data melalui tahapan yang terstruktur. KDD tidak hanya mencakup proses *data mining*, tetapi juga melibatkan pemilihan data, pembersihan, transformasi, evaluasi, hingga penyajian hasil. Secara umum, tahapan KDD terdiri atas *Data Selection*, *Data Preprocessing*, *Data Transformation*, *Data Mining*, *Evaluation*, dan *Knowledge Presentation* yang

saling mendukung dalam menghasilkan informasi yang relevan dan dapat dimanfaatkan untuk pengambilan keputusan (Okesola, 2021; Syed Mustapha, 2023).



Gambar 2.10 Tahapan *Knowledge Discovery in Databases* (KDD)
Sumber: (Okesola, 2021; Syed Mustapha, 2023)

Proses KDD dimulai dari pemilihan data yang sesuai dengan kebutuhan analisis, kemudian dilanjutkan dengan pembersihan dan transformasi data agar siap digunakan. Selanjutnya dilakukan proses *data mining* untuk menemukan pola atau membangun model. Hasil yang diperoleh dievaluasi untuk memastikan kualitasnya sebelum disajikan dalam bentuk informasi yang mudah dipahami dan digunakan sebagai dasar pengambilan keputusan (Okesola, 2021).

2.2.18. Evaluasi Model Klasifikasi

A. *Confusion Matrix*

Confusion matrix merupakan metode evaluasi yang digunakan untuk membandingkan hasil prediksi model dengan kelas aktual. Matriks ini memberikan informasi mengenai jumlah prediksi yang benar maupun salah pada setiap kelas sehingga dapat digunakan untuk menganalisis performa model secara lebih rinci dibandingkan hanya menggunakan akurasi (Dayanah Ayulani et al., 2023; Kate et al., 2026; Rafie et al., 2025).

Tabel 2.3 *Confusion Matrix*
Sumber: (Dayanah Ayulani et al., 2023; Kate et al., 2026)

	Prediksi Positif	Prediksi Negatif
Aktual Positif	TP	FN
Aktual Negatif	FP	TN

Keterangan:

TP (True Positive) = data positif yang berhasil diprediksi dengan tepat.

TN (True Negative) = data negatif yang berhasil diprediksi dengan tepat.

FP (False Positive) = data negatif yang justru diprediksi sebagai data positif.

FN (False Negative) = data positif yang diprediksi sebagai data negatif.

Confusion Matrix menjadi dasar perhitungan berbagai metrik evaluasi lainnya seperti *accuracy*, *precision*, *recall*, dan F1-*score*.

B. *Accuracy*

Accuracy digunakan untuk mengukur proporsi seluruh prediksi yang benar terhadap jumlah keseluruhan data.

Rumus *accuracy*:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Semakin tinggi nilai *accuracy*, semakin baik kemampuan model dalam melakukan klasifikasi.

C. *Precision*

Precision menunjukkan tingkat ketepatan model dalam memprediksi kelas positif.

Rumus *precision*:

$$Precision = \frac{TP}{TP + FP}$$

Nilai *precision* yang tinggi menunjukkan bahwa sebagian besar prediksi positif yang dihasilkan model memang benar.

D. *Recall*

Recall digunakan untuk mengukur kemampuan model dalam menemukan seluruh data positif yang sebenarnya.

Rumus *recall*:

$$Recall = \frac{TP}{TP + FN}$$

Semakin tinggi nilai *recall*, semakin baik model dalam mendeteksi seluruh data positif.

E. F1-*Score*

F1-*Score* merupakan rata-rata harmonis antara *precision* dan *recall* sehingga memberikan ukuran performa yang lebih seimbang.

Rumus F1-*Score*:

$$F1 - Score = 2x\frac{Precision\ x\ Recall}{Precision + Recall}$$

F1-*Score* sangat bermanfaat ketika distribusi data tidak seimbang karena mempertimbangkan *precision* dan *recall* secara bersamaan.

F. *Classification Report*

Classification report (Dayanah Ayulani et al., 2023; Kate et al., 2026; Rafie et al., 2025).

Tabel 2.4 Struktur *Classification Report*

Sumber: (Kate et al., 2026)

Kelas	***Precision***	***Recall***	**F1-*Score***	***Support***
Kelas A	TP/(TP+FP)	TP/(TP+FN)	2×(P×R)/(P+R)	Jumlah data A
Kelas B	TP/(TP+FP)	TP/(TP+FN)	2×(P×R)/(P+R)	Jumlah data B
Accuracy	-	-	-	Total akurasi
Macro Avg	Rata-rata tiap kelas	Rata-rata tiap kelas	Rata-rata tiap kelas	-
Weighted Avg	Rata-rata berbobot	Rata-rata berbobot	Rata-rata berbobot	Distribusi data

Tabel tersebut menggambarkan struktur umum *classification report* pada *scikit-learn*. *Macro average* menghitung rata-rata tanpa mempertimbangkan jumlah data tiap kelas, sedangkan *weighted average* mempertimbangkan proporsi data sehingga hasilnya lebih representatif terhadap kondisi dataset.

G. *Receiver Operating Characteristic*

Receiver Operating Characteristic (*ROC*) merupakan kurva yang menggambarkan hubungan antara *True Positive Rate* (TPR) dan *False Positive Rate*

(FPR) pada berbagai nilai *threshold*. Kurva ini digunakan untuk mengevaluasi kemampuan model dalam membedakan antar kelas (Basu, 2025; Kate et al., 2026; Rafie et al., 2025). Tahapan ROC adalah sebagai berikut:

1. Menghasilkan probabilitas prediksi dari model.
2. Menentukan berbagai nilai *threshold*.
3. Menghitung TPR dan FPR pada setiap *threshold*.
4. Membentuk kurva ROC.
5. Menghitung nilai AUC.

Rumus *True Positive Rate* (*TPR*):

$$TPR = \frac{TP}{TP + FN}$$

Rumus *False Positive Rate* (*FPR*):

$$FPR = \frac{FP}{FP + TN}$$

H. *Area Under Curve* (AUC)

Area Under Curve (AUC) merupakan luas area di bawah kurva ROC yang digunakan untuk mengukur kemampuan model dalam membedakan kelas secara keseluruhan.

Tabel 2.5 Interpretasi nilai AUC

Sumber: (Kate et al., 2026)

Nilai AUC	**Interpretasi**
0.90-1.00	Sangat Baik
0.80-0.90	Baik
0.70-0.80	Cukup
0.60-0.70	Kurang
< 0.60	Buruk

Semakin mendekati nilai 1, semakin baik kemampuan model dalam membedakan kelas profil kompetensi mahasiswa yang diprediksi.

2.2.19. Sistem Rekomendasi

Sistem rekomendasi adalah sistem yang digunakan untuk memberikan saran atau pilihan yang sesuai dengan kebutuhan dan karakteristik pengguna. Sistem ini bekerja dengan menganalisis data pengguna dan data item untuk menemukan tingkat kesesuaian di antara keduanya. Secara umum, sistem rekomendasi terdiri atas data pengguna, data item, proses analisis, dan modul rekomendasi. Metode yang sering digunakan meliputi *content-based filtering*, *collaborative filtering*, serta pendekatan *hybrid* yang menggabungkan keduanya agar hasil rekomendasi menjadi lebih relevan dan akurat (Fernández-García et al., 2020; José-García et al., 2023; Siswipraptini et al., 2024).



Gambar 2.11 Arsitektur Sistem Rekomendasi

Sumber: (Fernández-García et al., 2020; José-García et al., 2023)

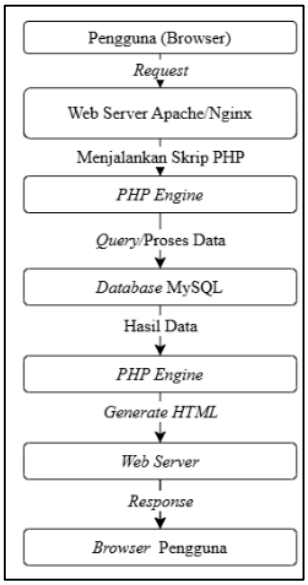
Arsitektur sistem rekomendasi umumnya terdiri atas tahap input, pemrosesan, dan output. Data pengguna dan data item terlebih dahulu dikumpulkan pada tahap input, kemudian diproses menggunakan algoritma rekomendasi untuk menghitung tingkat kesesuaian. Hasil perhitungan tersebut digunakan untuk menyusun urutan rekomendasi, yang selanjutnya ditampilkan kepada pengguna sebagai rekomendasi yang paling sesuai (Fernández-García et al., 2020; Siswipraptini et al., 2024).

2.2.20. Teknologi Pengembangan Sistem

A. *Hypertext Preprocessor*

Hypertext Preprocessor (PHP) merupakan bahasa pemrograman *server-side* yang digunakan untuk mengembangkan aplikasi web dinamis. PHP bekerja dengan

memproses kode di sisi server sebelum hasilnya dikirim ke browser dalam bentuk halaman web. Bahasa pemrograman ini banyak digunakan karena bersifat *open-source*, mudah dikembangkan, dan dapat terhubung dengan berbagai basis data, seperti MySQL. Selain itu, PHP juga menyediakan berbagai fitur, seperti pengelolaan formulir, *session, cookie,* operasi *Create*, *Read*, *Update*, dan *Delete* (CRUD), serta memungkinkan integrasi dengan layanan atau sistem lain melalui *Application Programming Interface* (API) (Christanto & Singgalen, 2023; Haekal, 2025; Ngozi et al., 2025).



Gambar 2.12 Arsitektur Kerja PHP pada Aplikasi Web
Sumber: (Christanto & Singgalen, 2023; Ngozi et al., 2025)

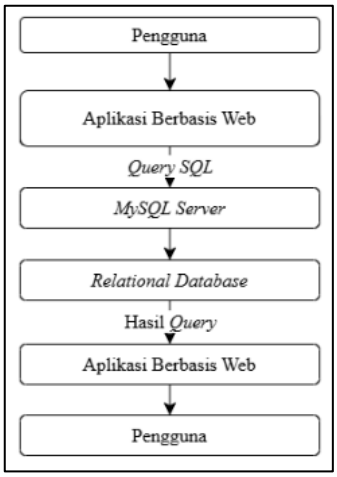
Arsitektur PHP diawali ketika pengguna mengirim permintaan melalui browser ke *web server*. Selanjutnya, server menjalankan skrip PHP dan memproses data yang diperlukan, termasuk akses ke basis data. Hasil pemrosesan tersebut kemudian diubah menjadi halaman HTML dan dikirim kembali ke browser untuk ditampilkan kepada pengguna. Mekanisme ini memungkinkan aplikasi web menyajikan informasi secara dinamis sesuai kebutuhan pengguna (Christanto & Singgalen, 2023; Ngozi et al., 2025).

B. MySQL

MySQL adalah sistem manajemen basis data relasional (*Relational Database Management System* / RDBMS) yang digunakan untuk menyimpan dan mengelola

data dalam bentuk tabel yang saling terhubung menggunakan bahasa SQL (*Structured Query Language*). MySQL memungkinkan proses pengelolaan data seperti penyimpanan, pembacaan, pembaruan, dan penghapusan data dilakukan secara terstruktur, cepat, dan konsisten. Karena bersifat *open-source* serta ringan, MySQL banyak digunakan dalam pengembangan sistem berbasis web dan mampu menangani data dari skala kecil hingga besar secara efisien (Ngozi et al., 2025).

Secara struktur, MySQL terdiri dari *database*, tabel, *record*, dan *field*. *Database* berfungsi sebagai wadah utama yang menampung beberapa tabel yang saling berhubungan, sedangkan tabel berisi baris (*record*) dan kolom (*field*) sebagai tempat penyimpanan data. Hubungan antar tabel diatur menggunakan *primary key* dan *foreign key* agar data tetap konsisten. Proses kerjanya dimulai dari *query* yang dikirim aplikasi, kemudian diproses oleh server MySQL dan hasilnya dikembalikan dalam bentuk data yang sudah diolah (Hossain, 2023; Ngozi et al., 2025).



Gambar 2.13 Arsitektur Pengolahan Data pada MySQL

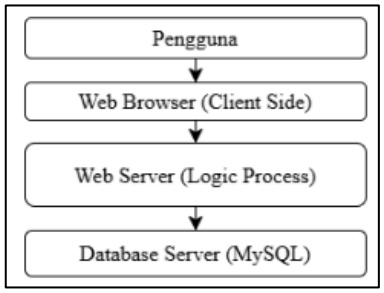
Sumber: (Hossain, 2023; Ngozi et al., 2025)

Gambar tersebut menjelaskan alur kerja MySQL dalam sistem basis data relasional, di mana pengguna berinteraksi melalui aplikasi yang kemudian meneruskan permintaan dalam bentuk *query* ke server database. Server MySQL memproses *query*, mengambil data dari tabel yang sesuai, lalu mengembalikan hasilnya ke aplikasi untuk ditampilkan kepada pengguna. Alur ini menunjukkan hubungan yang jelas antara aplikasi dan basis data yang bekerja secara terstruktur dan saling terhubung.

2.2.21. Sistem Berbasis Web

Sistem berbasis web merupakan sistem informasi yang dapat diakses melalui *web browser* menggunakan jaringan internet tanpa perlu instalasi aplikasi pada perangkat pengguna. Sistem ini umumnya dibangun dengan kombinasi teknologi sisi klien (*client-side*) seperti HTML, CSS, dan JavaScript, serta sisi server (*server-side*) yang berfungsi mengolah logika sistem dan mengatur pertukaran data dengan basis data (Christanto & Singgalen, 2023; Ngozi et al., 2025). Keunggulan utama sistem berbasis web terletak pada kemudahan akses, fleksibilitas penggunaan di berbagai perangkat, serta kemudahan dalam pemeliharaan karena sistem dikelola secara terpusat (Haekal, 2025) .

Dari sisi arsitektur, sistem berbasis web terdiri dari tiga komponen utama yaitu *client*, *web server*, dan *database server*. *Client* berperan sebagai tampilan antarmuka yang digunakan pengguna untuk berinteraksi dengan sistem. *Web server* berfungsi memproses permintaan pengguna serta menjalankan logika aplikasi, sedangkan *database server* digunakan untuk menyimpan dan mengelola data secara terstruktur menggunakan DBMS seperti MySQL (Christanto & Singgalen, 2023; Nuraminudin et al., 2026). Dalam pengembangannya, ketiga komponen ini saling terhubung untuk memastikan aliran data berjalan dengan baik dari pengguna hingga penyimpanan data.



Gambar 2.14 Arsitektur Sistem Berbasis Web Tiga Lapisan
Sumber: (Christanto & Singgalen, 2023; Ngozi et al., 2025)

Arsitektur ini menggambarkan alur sederhana mulai dari pengguna yang mengakses sistem melalui browser, kemudian permintaan dikirim ke *web server* untuk diproses. Setelah itu, server akan berkomunikasi dengan *database server* jika diperlukan, sebelum akhirnya hasil dikirim kembali ke pengguna dalam bentuk

tampilan halaman web. Struktur ini membuat sistem lebih mudah dikembangkan karena setiap bagian memiliki tugas yang jelas dan terpisah.

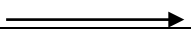
2.2.22. *Unified Modeling Language*

Unified Modeling Language (*UML*) merupakan bahasa pemodelan visual yang digunakan untuk menggambarkan rancangan sistem perangkat lunak sebelum proses implementasi dilakukan. *UML* membantu menjelaskan struktur dan perilaku sistem secara terstandarisasi sehingga dapat menjadi media komunikasi antara pengembang, analis, dan pihak terkait dalam memahami kebutuhan sistem secara lebih jelas. Dengan adanya representasi visual, proses perancangan menjadi lebih terarah karena setiap komponen sistem dapat divisualisasikan dalam bentuk diagram yang saling terhubung (Fitrani & Puspitaningrum, 2023; Ngozi et al., 2025).

A. *Use Case Diagram*

Use Case Diagram digunakan untuk menggambarkan hubungan antara aktor dan fungsi yang tersedia dalam sistem. Diagram ini membantu mengidentifikasi kebutuhan fungsional serta ruang lingkup sistem secara lebih sederhana dan mudah dipahami. Penggunaan *Use Case Diagram* juga membantu memperjelas interaksi pengguna dengan sistem dalam tahap perancangan (Asrin et al., 2026; Christanto & Singgalen, 2023; Fitrani & Puspitaningrum, 2023).

Tabel 2.6 *Use Case Diagram*
Sumber: (Asrin et al., 2026; Christanto & Singgalen, 2023; Fitrani & Puspitaningrum, 2023)

No.	Simbol	Nama	Keterangan
1		Aktor	Pihak yang berinteraksi dengan sistem.
2		Use Case	Fitur atau layanan yang disediakan sistem.
3		Association	Penghubung aktor dengan *use case*.
4	- - - - - - - >	*Generalization*	Hubungan turunan antar aktor atau *use case*.
5	*<<include>>* 	*<<include>>*	Bagian wajib dari *use case* lain.
6	*<<extend>>*	*<<extend>>*	Tambahan opsional pada kondisi tertentu

Tabel di atas memaparkan simbol-simbol dasar yang terdapat dalam Use Case Diagram sebagai representasi kebutuhan sistem agar lebih mudah dipahami dan tersusun secara sistematis (Asrin et al., 2026; Christanto & Singgalen, 2023; Fitrani & Puspitaningrum, 2023)

B. *Activity Diagram*

Activity Diagram digunakan untuk menggambarkan alur aktivitas dalam sistem dari awal hingga akhir proses. Diagram ini membantu memetakan langkah-langkah kerja sistem secara runtut termasuk keputusan dan percabangan yang mungkin terjadi selama proses berlangsung. Dalam pengembangan sistem, *Activity Diagram* sering digunakan untuk memvisualisasikan proses bisnis agar lebih mudah dipahami (Hossain, 2023).

Tabel 2.7 *Activity Diagram*

Sumber: (Hossain, 2023)

No.	Simbol	Nama	Keterangan
1		*Initial Node*	Titik awal aktivitas
2		*Final Node*	Titik akhir aktivitas
3		*Action / Activity*	Kegiatan atau proses.
4		*Decision / Branch*	Titik pengambilan keputusan dalam alur.
5		*Transition*	Panah yang menunjukkan aliran proses antar aktivitas.
6		*Swimlane*	Memisahkan aktivitas berdasarkan pelaku.

Tabel tersebut menunjukkan simbol utama dalam *Activity Diagram* yang digunakan untuk memetakan alur kerja sistem secara berurutan dan mudah dipahami (Hossain, 2023).

C. *Sequence Diagram*

Sequence Diagram dapat digunakan untuk menggambarkan proses yang melibatkan pengguna, antarmuka sistem, proses pengolahan data, serta komponen lain yang berperan dalam menghasilkan keluaran. Penggunaan *Sequence Diagram* membantu memperjelas urutan komunikasi antarbagian sistem sehingga proses bisnis yang telah digambarkan melalui *Activity Diagram* dapat dijabarkan lebih

rinci berdasarkan interaksi antarobjek (Hossain, 2023).

Tabel 2.8 *Sequence Diagram*

Sumber: (Hossain, 2023)

No.	Simbol	Nama	Keterangan
1		*Actor*	Pengguna yang berinteraksi dengan sistem.
2	□	*Object / Participant*	Komponen yang terlibat dalam proses.
3	|	*Lifeline*	Menunjukkan keberadaan objek selama proses.
4	→	*Message*	Pesan atau permintaan antarobjek.
5	▭	*Activation*	Menunjukkan objek sedang menjalankan proses.
6	←	*Return Message*	Menunjukkan hasil atau balasan proses.
7	[ ]	*Combined Fragment*	Menggambarkan kondisi, perulangan, atau percabangan.
8	- - →	*Dependency*	Menunjukkan ketergantungan antar komponen.

Tabel tersebut menunjukkan simbol utama pada Sequence Diagram yang digunakan untuk menggambarkan aktor, objek, pesan, serta urutan komunikasi antarbagian sistem berdasarkan waktu. Penggunaan simbol tersebut membantu memperjelas bagaimana proses dijalankan dari input hingga menghasilkan keluaran (Hossain, 2023).

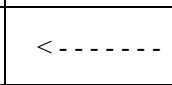
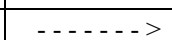
D. *Class Diagram*

Class Diagram menggambarkan struktur sistem dalam bentuk kelas yang terdiri dari atribut, metode, serta hubungan antar kelas. Diagram ini sangat penting karena menjadi dasar dalam membangun struktur data dan logika sistem sebelum proses implementasi dilakukan. Dengan adanya *Class Diagram*, struktur sistem dapat dirancang lebih konsisten dan sesuai dengan kebutuhan fungsional (Christanto & Singgalen, 2023).

Tabel 2.9 *Class Diagram*

Sumber: (Christanto & Singgalen, 2023)

No.	Simbol	Nama	Keterangan

1		*Generalization*	Relasi pewarisan antara kelas induk dan turunan.
2		*Aggregation / Composition*	Hubungan kepemilikan objek antar kelas.
3		*Class*	Representasi objek yang memuat atribut dan metode.
4		*Association*	Relasi antar kelas.
5		*Realization*	Hubungan implementasi antara kelas dan *interface*.
6		*Dependency*	Ketergantungan sementara antar kelas.
7		*Collaboration*	Kerja sama beberapa kelas dalam satu proses.
8		*Interface*	Deklarasi operasi yang harus diimplementasikan kelas.

Tabel tersebut menjelaskan simbol dalam *Class Diagram* yang digunakan untuk menggambarkan struktur sistem secara lebih detail dan terorganisir (Christanto & Singgalen, 2023).

2.2.23. *Software Development Life Cycle*

System Development Life Cycle (SDLC) adalah sebuah metode terstruktur yang digunakan dalam pengembangan sistem informasi agar proses pembuatan sistem dapat berjalan secara sistematis, terarah, dan sesuai dengan kebutuhan pengguna. SDLC menjelaskan tahapan pengembangan mulai dari analisis kebutuhan hingga pemeliharaan sistem, di mana setiap tahap menghasilkan output yang menjadi dasar untuk tahap berikutnya. Beberapa penelitian menjelaskan bahwa SDLC membantu pengembang meminimalkan kesalahan karena seluruh proses dilakukan secara berurutan dan terdokumentasi dengan jelas (Christanto & Singgalen, 2023; Hossain, 2023; Ngozi et al., 2025).

Terdapat berbagai model pengembangan dalam SDLC yang dapat dipilih sesuai kebutuhan proyek, di antaranya *Waterfall*, *Prototype*, *Rapid Application Development* (RAD), *Agile*, *Spiral*, V-*Model*, *Iterative*, *Scrum*, dan *Extreme Programming* (XP). Setiap model memiliki karakteristik dan pendekatan yang berbeda dalam proses pengembangan perangkat lunak (M. Ridwan & Fitri, 2021).

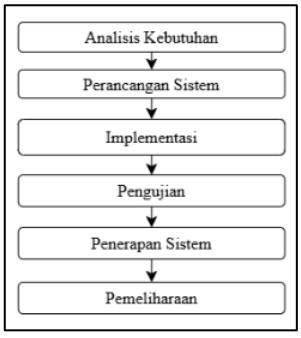
Pada penelitian ini, model SDLC yang digunakan adalah *Waterfall* karena memiliki tahapan yang terstruktur dan sesuai dengan kebutuhan pengembangan

sistem yang telah terdefinisi dengan jelas sejak awal penelitian (Christanto & Singgalen, 2023; Hossain, 2023).

2.2.24. *Waterfall*

Model *Waterfall* adalah salah satu pendekatan dalam *System Development Life Cycle* (SDLC) yang berjalan secara berurutan, di mana setiap tahap harus diselesaikan terlebih dahulu sebelum masuk ke tahap berikutnya. Alur pengembangan model ini dimulai dari analisis kebutuhan hingga pemeliharaan sistem secara terstruktur. Hasil yang diperoleh pada setiap tahap selanjutnya menjadi landasan bagi pelaksanaan tahap berikutnya (Christanto & Singgalen, 2023; Hossain, 2023; Ngozi et al., 2025). *Waterfall* banyak diterapkan karena memiliki tahapan yang runtut dan mudah didokumentasikan, terutama pada pengembangan sistem yang kebutuhan dasarnya telah ditentukan sejak awal.

Secara umum, *Waterfall* terdiri atas beberapa tahap utama, yaitu analisis kebutuhan, perancangan sistem, implementasi, pengujian, penerapan, dan pemeliharaan. Setiap tahap dilakukan secara berurutan, sehingga hasil analisis menjadi dasar perancangan, perancangan menjadi acuan implementasi, dan proses berlanjut hingga sistem siap digunakan serta dipelihara (Christanto & Singgalen, 2023; Hossain, 2023).



Gambar 2.15 Diagram Model *Waterfall*
Sumber: (Christanto & Singgalen, 2023; Hossain, 2023)

Diagram *Waterfall* menggambarkan alur pengembangan sistem yang berjalan langkah demi langkah dari awal hingga akhir. Proses dimulai dari pengumpulan kebutuhan, lalu masuk ke tahap perancangan sistem, kemudian implementasi kode,

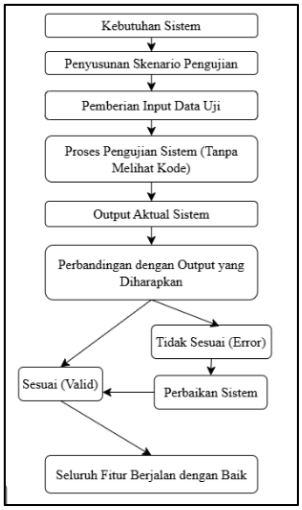
pengujian, hingga penerapan sistem. Setelah sistem digunakan, tahap terakhir adalah pemeliharaan untuk perbaikan dan penyesuaian jika diperlukan.

Alur ini menunjukkan bahwa setiap tahap sangat bergantung pada tahap sebelumnya, sehingga kesalahan di awal bisa berdampak ke seluruh proses. Karena itu, setiap tahap harus benar-benar diselesaikan dengan baik sebelum melanjutkan ke tahap berikutnya.

2.2.25. Pengujian Sistem

A. *Black Box Testing*

Black Box Testing adalah metode pengujian perangkat lunak yang menilai fungsi sistem berdasarkan kebutuhan yang telah ditentukan tanpa melihat bagaimana sistem bekerja di dalamnya. Pengujian ini dilakukan dengan memberikan input tertentu dan kemudian membandingkan output yang dihasilkan dengan hasil yang diharapkan. Metode ini umum digunakan pada sistem berbasis web karena dapat menilai apakah sistem sudah berjalan sesuai kebutuhan pengguna secara langsung dari sisi fungsionalnya (Nurizati et al., 2024; Shoaib et al., 2024; Zayed et al., 2022).



Gambar 2.16 Alur *Black Box Testing*

Sumber: (Nurizati et al., 2024; Shoaib et al., 2024)

Alur *Black Box Testing* dimulai dari penentuan kebutuhan sistem, kemudian disusun skenario pengujian berdasarkan kebutuhan tersebut. Selanjutnya sistem

diuji dengan berbagai input tanpa melihat kode program. Hasil output kemudian dibandingkan dengan hasil yang diharapkan untuk menentukan apakah fungsi sistem sudah sesuai. Proses ini dilakukan sampai seluruh fitur dinyatakan berjalan dengan baik (Shoaib et al., 2024; Zayed et al., 2022).

B. *User Acceptance Testing*

User Acceptance Testing (*UAT*) merupakan pengujian yang dilakukan oleh pengguna akhir untuk memastikan sistem sesuai dengan kebutuhan dan dapat digunakan dengan baik sebelum diterapkan. Penilaian *UAT* mencakup kemudahan penggunaan, kesesuaian fitur, dan manfaat sistem bagi pengguna (Fitriastuti et al., 2024; Siti Muthiah Nuralifah et al., 2025).

Secara umum, *UAT* melibatkan pengguna sebagai evaluator, skenario pengujian berdasarkan fitur sistem, dan kuesioner sebagai instrumen penilaian. Pengguna menjalankan sistem sesuai skenario, kemudian memberikan penilaian yang dapat diolah secara kuantitatif menggunakan skala Likert untuk mengetahui tingkat kelayakan sistem (Fitriastuti et al., 2024).



Gambar 2.17 Alur *User Acceptance Testing* (UAT)

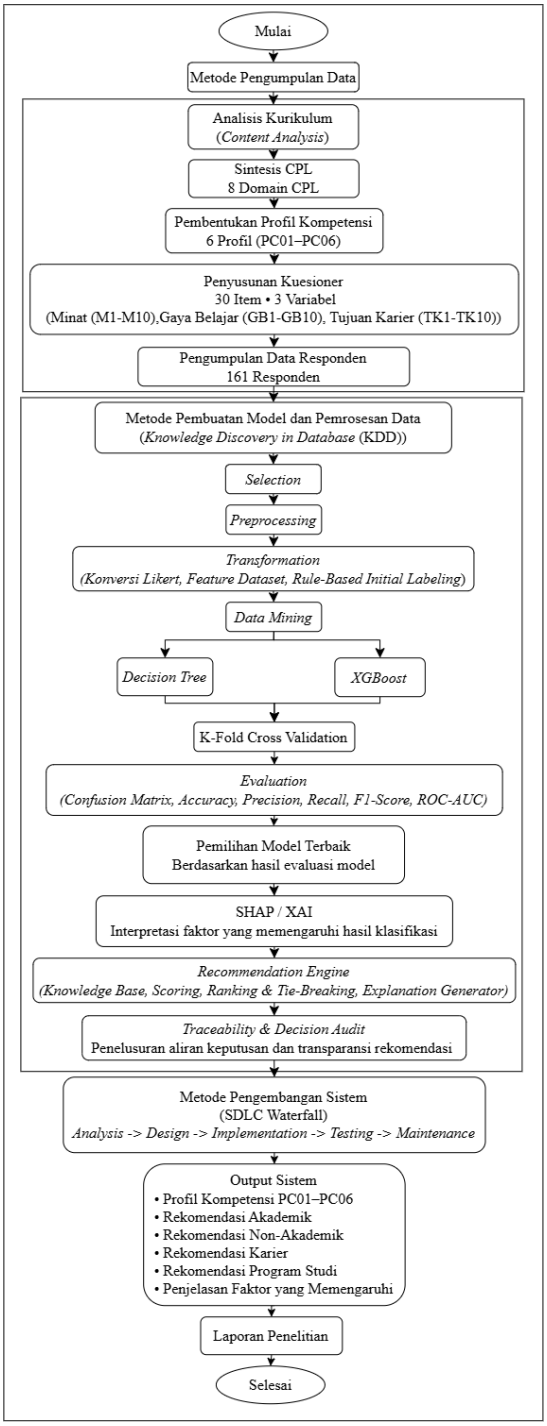
Sumber: (Fitriastuti et al., 2024; Siti Muthiah Nuralifah et al., 2025)

Proses *UAT* dimulai ketika sistem siap diuji. Pengguna menjalankan sistem berdasarkan skenario yang telah disiapkan dan memberikan penilaian melalui kuesioner. Hasil penilaian kemudian diolah menjadi persentase untuk mengetahui tingkat kelayakan sistem dan menentukan apakah sistem masih memerlukan perbaikan.

BAB III

METODOLOGI

3.1 Kerangka Pikir



Gambar 3.1 Kerangka Pikir

Sumber: Penulis, 2026

3.2 Deskripsi

Kerangka pikir penelitian ini menggambarkan tahapan pembangunan sistem cerdas pemetaan profil kompetensi dan rekomendasi pengembangan mahasiswa di Universitas Bale Bandung. Tahap awal berfokus pada pengumpulan data kurikulum dari 12 program studi untuk menyintesis delapan domain CPL menjadi enam Profil Kompetensi Mahasiswa (PC01–PC06), dilanjutkan penyebaran kuesioner 30 butir (variabel minat, gaya belajar, dan tujuan karier) kepada 161 responden.

Tahap kedua menerapkan metodologi *Knowledge Discovery in Databases* (KDD) untuk memproses data responden, mulai dari prapemrosesan, pelabelan aturan (*rule-based labeling*), hingga komparasi model klasifikasi *Decision Tree* dan XGBoost. Model terpilih selanjutnya diinterpretasikan menggunakan SHAP untuk memetakan kontribusi faktor pembentuk kompetensi secara transparan.

Tahap akhir mengintegrasikan hasil prediksi model ke dalam *Recommendation Scoring Engine* dan basis pengetahuan (*Knowledge Base*) guna menentukan peringkat rekomendasi program studi dan jalur pengembangan mahasiswa. Seluruh proses tersebut diimplementasikan ke dalam aplikasi berbasis *web* menggunakan model pengembangan *Waterfall*.

3.2.1. Metode Pengumpulan Data

Tahap awal penelitian dilakukan melalui proses pengumpulan data untuk memperoleh data dan informasi yang diperlukan dalam membangun model klasifikasi profil kompetensi mahasiswa serta sistem rekomendasi pengembangan mahasiswa. Pengumpulan data dilakukan menggunakan empat teknik, yaitu observasi, wawancara, studi literatur, dan dokumentasi. Data yang diperoleh dari proses tersebut digunakan sebagai dasar dalam analisis kurikulum, pembentukan profil kompetensi mahasiswa, penyusunan instrumen penelitian, pembangunan *dataset*, serta perancangan model dan sistem rekomendasi.

A. Observasi

Observasi dilakukan dengan mengamati kondisi yang berkaitan dengan proses pengembangan mahasiswa dan kebutuhan dalam menentukan arah pengembangan sesuai dengan minat, kemampuan, serta tujuan karier. Observasi

juga dilakukan untuk memperoleh gambaran mengenai kondisi nyata yang menjadi dasar permasalahan penelitian.

B. Wawancara

Wawancara dilakukan dengan Gin Gin Ginanjar, S.Pd., M.Pd., selaku Kepala Bagian Hubungan Masyarakat dan Penerimaan Mahasiswa Baru (PMB) Bidang Kemahasiswaan Universitas Bale Bandung, mahasiswa aktif, serta ketua program studi dari 12 program studi yang menjadi objek penelitian. Wawancara dengan Kepala Bagian Hubungan Masyarakat dan PMB bertujuan untuk memperoleh informasi mengenai permasalahan yang sering dihadapi calon mahasiswa dalam menentukan program studi, serta kebutuhan terhadap sistem yang dapat mendukung proses pengembangan mahasiswa. Selain itu, wawancara dengan mahasiswa aktif dilakukan untuk memperoleh informasi mengenai pengalaman dan kendala yang dihadapi selama menjalani proses pengembangan diri di perguruan tinggi. Sementara itu, wawancara dengan ketua program studi dilakukan untuk memperoleh data mengenai Capaian Pembelajaran Lulusan (CPL), Profil Lulusan (PL), dan karakteristik lulusan pada masing-masing program studi sebagai dasar dalam proses sintesis CPL dan pembentukan profil kompetensi mahasiswa.

C. Studi Literatur

Studi literatur dilakukan dengan menelaah berbagai referensi yang relevan sebagai dasar penyusunan landasan teori dan metodologi penelitian. Peneliti menganalisis sekitar 50 artikel ilmiah mengenai *machine learning*, sistem rekomendasi, klasifikasi pendidikan, *Decision Tree*, *XGBoost*, XAI, KDD, dan pengembangan sistem berbasis web. Dari hasil kajian tersebut, dipilih lima jurnal yang paling relevan sebagai acuan utama untuk mengidentifikasi *research gap*, menentukan metode, serta mendukung pemilihan algoritma dan pendekatan penelitian.

D. Dokumentasi

Dokumentasi dilakukan dengan mengumpulkan dokumen akademik dari 12 program studi Universitas Bale Bandung. Dokumen yang diperoleh meliputi CPL, PL, struktur kurikulum, serta informasi mata kuliah pendukung. Meskipun tidak seluruh program studi memberikan dokumen yang sama secara lengkap, sebagian

besar program studi menyediakan data CPL, PL, dan mata kuliah yang dapat digunakan sebagai dasar analisis kurikulum.

3.2.2. Analisis Kurikulum

Analisis kurikulum dilakukan terhadap dokumen Profil Lulusan (PL), Capaian Pembelajaran Lulusan (CPL), dan mata kuliah pendukung dari 12 program studi Universitas Bale Bandung. Analisis menggunakan metode *Content Analysis* dengan mengidentifikasi dan memberikan kode (*coding*) pada kompetensi yang memiliki kesamaan makna, kemudian mengelompokkannya berdasarkan keterkaitan kompetensi. Hasil pengelompokan digunakan sebagai dasar sintesis CPL.

3.2.3. Sintesis CPL

Sintesis CPL dilakukan setelah analisis kurikulum dengan menyederhanakan CPL berdasarkan kesamaan makna ke dalam domain kompetensi. Berdasarkan *Content Analysis* terhadap CPL dan Profil Lulusan (PL) dari 12 program studi, diperoleh delapan domain utama, yaitu CPL01 (Pendidikan dan Pembelajaran), CPL02 (Penelitian dan Pengembangan Ilmu), CPL03 (Teknologi Digital dan Sistem Informasi), CPL04 (Analisis Data dan Pengambilan Keputusan), CPL05 (Sosial, Pengabdian, dan Pemberdayaan Masyarakat), CPL06 (Kewirausahaan dan Inovasi), CPL07 (Kepemimpinan dan Manajemen), serta CPL08 (Profesionalisme dan Etika). Kedelapan domain tersebut mencakup seluruh kompetensi dalam dokumen CPL dan menjadi dasar dalam pembentukan profil kompetensi mahasiswa.

3.2.4. Pembentukan Profil Kompetensi

Pembentukan profil kompetensi dilakukan dengan memetakan keterkaitan antara delapan domain CPL untuk membentuk kelompok kompetensi yang merepresentasikan karakteristik lulusan. Hasil pemetaan menghasilkan enam profil kompetensi, yaitu PC01 *Educational and Research Innovator*, PC02 *Digital Technology Specialist*, PC03 *Data and Analytical Intelligence Specialist*, PC04

Community Development Specialist, PC05 *Entrepreneurship and Innovation Specialist*, dan PC06 *Professional Leader*. Profil tersebut selanjutnya digunakan sebagai dasar penyusunan kuesioner dan *rule-based initial labeling* untuk menghasilkan target klasifikasi pada model *machine learning*.

3.2.5. Penyusunan Kuesioner

Kuesioner disusun berdasarkan hasil analisis kurikulum, sintesis CPL, pembentukan profil kompetensi, kuesioner pra-penelitian dengan jumlah 75 responden serta hasil observasi, wawancara, dan studi literatur. Instrumen mengukur tiga variabel, yaitu minat, gaya belajar, dan tujuan karier.

Kuesioner terdiri atas 30 butir pernyataan dengan skala *Likert* lima tingkat. Setiap butir dipetakan ke profil kompetensi mahasiswa dan hasilnya digunakan sebagai fitur dalam proses klasifikasi.

3.2.6. Pengumpulan Data Responden

Setelah instrumen selesai disusun, kuesioner disebarkan secara *online* menggunakan *Google Forms*. Responden penelitian terdiri atas mahasiswa aktif dan alumni yang menjadi sumber data untuk menggambarkan karakteristik responden dalam penelitian.

Dari proses pengumpulan data diperoleh 161 responden. Data yang terkumpul kemudian diperiksa dan digunakan sebagai data awal dalam proses pengolahan menggunakan metode *Knowledge Discovery in Databases* (KDD).

Data responden yang digunakan terutama berupa jawaban terhadap 30 butir pernyataan kuesioner yang menjadi dasar pembentukan *dataset* untuk proses klasifikasi profil kompetensi mahasiswa.

3.2.7. Metode Pemrosesan Data

Data yang diperoleh dari kuesioner selanjutnya diproses menggunakan metode *Knowledge Discovery in Databases* (KDD). Seluruh proses pengolahan dan pemodelan dilakukan menggunakan bahasa pemrograman Python pada lingkungan *Google Colab*. Pustaka yang digunakan antara lain *Pandas* dan *NumPy* untuk

pengolahan data, *Scikit-learn* untuk proses pemodelan dan evaluasi, *XGBoost* untuk algoritma *XGBoost*, serta *SHAP* untuk interpretasi model.

Tahapan pemrosesan data terdiri atas lima tahap berikut:

1. *Selection,* tahap ini dipilih data yang relevan dengan penelitian dari hasil pengisian kuesioner. Data yang digunakan mencakup jawaban responden terhadap 30 item kuesioner serta atribut yang diperlukan dalam proses pembentukan *dataset* klasifikasi.
2. *Preprocessing,* tahap *preprocessing* dilakukan untuk memastikan data berada dalam kondisi yang dapat digunakan untuk proses pemodelan. Pemeriksaan dilakukan terhadap kelengkapan data, data ganda, format data, dan konsistensi jawaban responden.
3. *Transformation,* pada tahap ini jawaban kuesioner diubah ke dalam bentuk numerik sesuai dengan skala *Likert*. Selanjutnya dilakukan pembentukan fitur dan *rule-based initial labeling* berdasarkan pemetaan item terhadap enam profil kompetensi mahasiswa, yaitu PC01 sampai PC06. Label yang dihasilkan digunakan sebagai *target* dalam proses klasifikasi. Dengan demikian, data hasil transformasi memiliki 30 fitur kuesioner dan satu label profil kompetensi mahasiswa.
4. *Data Mining,* tahap *data mining* digunakan untuk membangun model klasifikasi profil kompetensi mahasiswa. Dua algoritma digunakan dalam penelitian ini, yaitu *Decision Tree* dan *XGBoost*. Kedua model dilatih menggunakan *dataset* yang sama sehingga performanya dapat dibandingkan secara objektif. Evaluasi model dilakukan dengan pendekatan *cross validation* untuk memperoleh gambaran performa model yang lebih stabil.
5. *Evaluation,* tahap evaluasi dilakukan untuk membandingkan kinerja kedua model berdasarkan *Accuracy*, *Precision*, *Recall*, *F1-Score*, *Confusion Matrix*, dan *ROC-AUC*. Hasil perbandingan digunakan untuk menentukan model yang paling sesuai sebagai model utama penelitian. Model terbaik selanjutnya dianalisis menggunakan *SHapley Additive exPlanations* (SHAP) untuk mengetahui kontribusi fitur terhadap hasil klasifikasi. Analisis ini digunakan untuk memberikan penjelasan mengenai faktor yang berpengaruh terhadap keputusan model.

3.2.8. Metode Pembuatan Model

Pada tahap ini dilakukan pembangunan model klasifikasi profil kompetensi mahasiswa menggunakan algoritma *Decision Tree* dan *XGBoost*. Proses dilakukan dengan bahasa pemrograman Python pada lingkungan *Google Colab* menggunakan *dataset* hasil tahapan *Knowledge Discovery in Databases* (KDD). Data tersebut memiliki 30 fitur yang berasal dari item kuesioner dan enam kelas profil kompetensi mahasiswa, yaitu PC01 sampai PC06.

Model *Decision Tree* digunakan sebagai model pembanding yang memiliki struktur keputusan relatif mudah dipahami, sedangkan *XGBoost* digunakan sebagai model pembanding berbasis *ensemble learning*. Kedua model dilatih menggunakan data yang sama dan dievaluasi dengan *K-Fold Cross Validation* untuk memperoleh gambaran performa yang lebih stabil.

Hasil pengujian kedua model kemudian dibandingkan menggunakan *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan *ROC-AUC*. Model dengan hasil evaluasi terbaik ditetapkan sebagai model utama yang digunakan dalam sistem klasifikasi. Tahapan evaluasi dan perbandingan ini mengacu pada proses *data mining* dan *evaluation* yang telah dijelaskan pada KDD.

Selanjutnya, model terpilih dianalisis menggunakan *SHapley Additive exPlanations* (SHAP) untuk mengetahui kontribusi fitur terhadap hasil klasifikasi. Hasil interpretasi ini digunakan untuk memberikan penjelasan mengenai faktor yang berpengaruh terhadap profil kompetensi mahasiswa sehingga hasil klasifikasi dapat dipahami dengan lebih baik. Pendekatan tersebut sejalan dengan penggunaan XAI dalam penelitian ini untuk meningkatkan transparansi hasil klasifikasi.

3.2.9. Metode Pembentukan Rekomendasi

Pembentukan rekomendasi dilakukan setelah diperoleh hasil klasifikasi profil kompetensi mahasiswa. Proses ini menggunakan *knowledge base* dan mekanisme *scoring* untuk menentukan rekomendasi yang paling sesuai berdasarkan jawaban kuesioner dan hasil pemetaan kompetensi.

1. *Knowledge Base,* berisi pemetaan antara item kuesioner, kompetensi, dan alternatif rekomendasi seperti pengembangan akademik, non-akademik, karier,

dan program studi. Setiap hubungan memiliki bobot yang menunjukkan tingkat keterkaitannya.

2. *Recommendation Scoring,* setiap alternatif rekomendasi dihitung berdasarkan nilai jawaban kuesioner dan bobot pada *knowledge base*. Hasil perhitungan berupa skor kesesuaian yang digunakan sebagai dasar penentuan rekomendasi.
3. *Ranking, a*lternatif rekomendasi diurutkan berdasarkan skor kesesuaian dari nilai tertinggi hingga terendah. Alternatif dengan skor tertinggi menjadi rekomendasi utama.
4. *Tie-Breaking*, apabila terdapat rekomendasi dengan skor yang sama, sistem menggunakan aturan *tie-breaking* yang telah ditentukan untuk menetapkan urutan secara konsisten.
5. *Explanation Generator*, sistem menghasilkan penjelasan singkat mengenai alasan suatu rekomendasi diberikan berdasarkan keterkaitan jawaban, profil kompetensi, dan skor rekomendasi.
6. *Traceability,* proses rekomendasi dapat ditelusuri dari item kuesioner hingga profil kompetensi dan rekomendasi yang dihasilkan. Hal ini menjaga keterkaitan antara data masukan, hasil klasifikasi, dan keluaran sistem.
7. *Decision Audit,* digunakan untuk memeriksa aliran keputusan dari data masukan, hasil klasifikasi, proses *scoring*, hingga rekomendasi akhir sehingga hasil yang diberikan dapat ditelusuri dan diperiksa kembali.

3.2.10. Metode Pengembangan Sistem

Metode pengembangan sistem yang digunakan adalah Software *Development Life Cycle* (SDLC) dengan model *Waterfall* karena tahapan pengembangan dilakukan secara berurutan. Tahapannya meliputi:

1. *Analysis,* mengidentifikasi kebutuhan sistem, data, aktor, dan proses integrasi model klasifikasi serta rekomendasi.
2. *Design,* merancang alur sistem, UML, basis data, antarmuka, serta integrasi *machine learning*, *Knowledge Base*, dan rekomendasi.
3. *Implementation,* membangun aplikasi berbasis web menggunakan PHP, Laravel, dan MySQL serta mengintegrasikan model klasifikasi dan rekomendasi.

4. *Testing,* menguji fungsi sistem menggunakan *Black Box Testing* dan *User Acceptance Testing* (UAT), sedangkan evaluasi model mengacu pada hasil pengujian *machine learning*.
5. *Maintenance,* melakukan perbaikan kesalahan, penyempurnaan fitur, dan pengembangan sistem sesuai kebutuhan.

3.2.11. *Output* Sistem

Sistem menghasilkan keluaran berdasarkan hasil klasifikasi profil kompetensi dan proses *recommendation scoring*. Hasil tersebut disajikan kepada pengguna secara ringkas agar dapat digunakan sebagai bahan pertimbangan dalam menentukan arah pengembangan diri. *Output* sistem meliputi:

1. Profil kompetensi mahasiswa (PC01–PC06) sebagai hasil klasifikasi berdasarkan jawaban kuesioner.
2. Informasi faktor yang memengaruhi klasifikasi berdasarkan hasil interpretasi SHAP, sehingga pengguna dapat mengetahui faktor yang berkontribusi terhadap profil kompetensinya.
3. Rekomendasi pengembangan akademik yang disesuaikan dengan profil dan karakteristik pengguna.
4. Rekomendasi pengembangan non-akademik yang dapat mendukung penguatan kompetensi pengguna.
5. Rekomendasi karier yang diperoleh melalui proses pencocokan dan pembobotan pada *Knowledge Base*.
6. Rekomendasi program studi berdasarkan keterkaitan profil kompetensi dengan kompetensi dan karakteristik program studi.
7. Penjelasan rekomendasi yang menunjukkan dasar atau faktor yang mendukung rekomendasi yang diberikan.
8. Informasi keterlacakan keputusan yang menunjukkan hubungan antara data masukan, profil kompetensi, dan rekomendasi sehingga proses pengambilan keputusan dapat ditelusuri dan diperiksa.

BAB IV

ANALISIS, PERANCANGAN DAN HASIL

4.1. Hasil Analisis Kurikulum

Analisis kurikulum dilakukan terhadap 12 program studi di Universitas Bale Bandung dengan menelaah Profil Lulusan (PL), Capaian Pembelajaran Lulusan (CPL), serta kompetensi yang muncul dalam dokumen kurikulum. Hasil analisis kemudian diklasifikasikan berdasarkan kesamaan makna kompetensi sehingga diperoleh kelompok kompetensi yang dapat digunakan sebagai dasar pembentukan profil kompetensi mahasiswa.

4.1.1. Hasil Analisis Profil Lulusan dan CPL

Hasil penelaahan menunjukkan bahwa setiap program studi memiliki Profil Lulusan yang berbeda sesuai dengan karakteristik bidang keilmuannya. Meskipun demikian, terdapat beberapa pola kompetensi yang muncul secara berulang, seperti pendidikan dan pembelajaran, penelitian, teknologi digital, analisis data, pemberdayaan masyarakat, kewirausahaan, kepemimpinan, serta profesionalisme.

Pada bidang pertanian, misalnya, Agribisnis memiliki profil seperti manajer agribisnis, wirausahawan, peneliti, konsultan, dan penyuluh pertanian. Agroteknologi memiliki profil yang berkaitan dengan praktik budidaya, penelitian, penyuluhan, analisis lahan dan tanaman, serta kewirausahaan. Sementara itu, Akuntansi lebih banyak mengarah pada profesi akuntan, auditor, konsultan keuangan dan perpajakan, wirausahawan, serta peneliti.

Program studi kependidikan menunjukkan kecenderungan yang lebih kuat pada profil pendidik, pengembang bahan ajar, dan peneliti. Pola tersebut terlihat pada Pendidikan Geografi, Pendidikan IPS, Pendidikan Bahasa dan Sastra Indonesia, Pendidikan Bahasa Inggris, serta Pendidikan Matematika. Pada bidang teknologi, Sistem Informasi dan Teknik Informatika menunjukkan profil yang berkaitan dengan pengembangan perangkat lunak, analisis data, pengelolaan proyek teknologi, kecerdasan buatan, serta keamanan jaringan. Keperawatan

memiliki profil yang berhubungan dengan pelayanan, pendidikan kesehatan, dan penelitian.

Perbedaan profil tersebut kemudian dipertemukan melalui CPL yang memiliki cakupan lebih umum. Hasil sintesis menghasilkan delapan domain CPL, yaitu pendidikan dan pembelajaran, penelitian dan pengembangan ilmu, teknologi digital dan sistem informasi, analisis data dan pengambilan keputusan, sosial dan pemberdayaan masyarakat, kewirausahaan dan inovasi, kepemimpinan dan manajemen, serta profesionalisme dan etika.

Dengan demikian, hasil analisis menunjukkan bahwa meskipun setiap program studi memiliki arah lulusan yang berbeda, terdapat kompetensi lintas bidang yang dapat digunakan sebagai dasar untuk melihat kecenderungan kompetensi mahasiswa secara lebih terpadu.

4.1.2. Hasil *Content Analysis*

Content Analysis dilakukan dengan mengidentifikasi kata, frasa, dan makna kompetensi yang terdapat dalam Profil Lulusan dan CPL masing-masing program studi. Kompetensi yang memiliki makna serupa kemudian dikelompokkan ke dalam kategori yang sama. Proses ini memungkinkan kompetensi yang awalnya ditulis dengan istilah berbeda untuk ditempatkan dalam kelompok yang lebih seragam.

Hasil ekstraksi menunjukkan adanya 12 kelompok master kompetensi, yaitu KC01 Profesionalisme dan Etika, KC02 Kepemimpinan dan Kolaborasi, KC03 Pendidikan dan Pembelajaran, KC04 Penelitian dan Pengembangan Ilmu, KC05 Teknologi Digital dan Sistem Informasi, KC06 Analisis Data dan Pengambilan Keputusan, KC07 Sosial dan Pemberdayaan Masyarakat, KC08 Kewirausahaan dan Inovasi, KC09 Manajemen dan Organisasi, KC10 Komunikasi Profesional, KC11 Kompetensi Keilmuan Bidang, serta KC12 Pemecahan Masalah dan Berpikir Kritis.

Pengelompokan tersebut menunjukkan bahwa kompetensi dalam kurikulum tidak berdiri sendiri. Sebagai contoh, kompetensi penelitian dapat berjalan bersama kemampuan analisis data, pemecahan masalah, komunikasi ilmiah, dan penggunaan teknologi. Begitu pula kompetensi kewirausahaan tidak hanya

berkaitan dengan kemampuan membangun usaha, tetapi juga melibatkan inovasi, pengambilan keputusan, komunikasi, dan pengelolaan organisasi.

Hasil Content Analysis menjadi dasar untuk melihat keterkaitan antara kompetensi spesifik setiap program studi dengan kompetensi yang lebih luas. Dengan cara tersebut, perbedaan istilah dalam dokumen kurikulum dapat tetap dipertahankan maknanya, tetapi dapat dibandingkan dalam satu kerangka analisis.

4.1.3. Hasil Sintesis 8 Domain CPL

Berdasarkan hasil pengelompokan kompetensi, diperoleh delapan domain CPL yang mewakili pola kompetensi utama dari seluruh program studi. Kedelapan domain tersebut adalah sebagai berikut:

Tabel 4.1 Hasil Sintesis 8 Domain CPL

Sumber: (Penulis, 2026)

Kode	Domain CPL	Gambaran Kompetensi
CPL01	Pendidikan dan Pembelajaran	Merancang, melaksanakan, mengevaluasi, dan mengembangkan proses pembelajaran.
CPL02	Penelitian dan Pengembangan Ilmu	Melakukan penelitian, publikasi ilmiah, pengembangan ilmu, dan inovasi akademik.
CPL03	Teknologi Digital dan Sistem Informasi	Mengembangkan dan memanfaatkan teknologi digital, sistem informasi, perangkat lunak, AI, dan teknologi terkait.
CPL04	Analisis Data dan Pengambilan Keputusan	Mengolah dan menganalisis data menggunakan pendekatan statistik maupun komputasional sebagai dasar pengambilan keputusan.
CPL05	Sosial, Pengabdian, dan Pemberdayaan Masyarakat	Mengembangkan kegiatan pemberdayaan, pelayanan publik, pembangunan daerah, kesehatan masyarakat, dan pengabdian.
CPL06	Kewirausahaan dan Inovasi	Menghasilkan inovasi serta mengembangkan produk, jasa, dan usaha berbasis ilmu pengetahuan dan teknologi.

CPL07	Kepemimpinan dan Manajemen	Memimpin tim, mengelola organisasi dan proyek, serta mengambil keputusan secara efektif.
CPL08	Profesionalisme dan Etika	Menerapkan etika, tanggung jawab, integritas, komunikasi, kolaborasi, dan pembelajaran sepanjang hayat.

Delapan domain tersebut menunjukkan adanya kompetensi yang bersifat lintas program studi. CPL02 dan CPL08, misalnya, muncul pada seluruh program studi, sedangkan domain lainnya memiliki tingkat keterkaitan yang berbeda sesuai karakteristik masing-masing bidang. Data pemetaan juga memperlihatkan bahwa CPL03 dan CPL04 lebih kuat pada program studi yang berkaitan dengan teknologi dan analisis, sedangkan CPL01 lebih menonjol pada program studi kependidikan.

Hasil sintesis ini menjadi penghubung antara kompetensi yang bersifat spesifik pada program studi dengan profil kompetensi mahasiswa yang lebih umum.

4.1.4. Hasil Pembentukan Profil Kompetensi PC01-PC06

Setelah kompetensi dikelompokkan dan disintesiskan, enam profil kompetensi dibentuk untuk menggambarkan kecenderungan kompetensi mahasiswa secara lebih sederhana. Keenam profil tersebut tidak menggantikan kompetensi asli setiap program studi, tetapi menjadi representasi dari beberapa kompetensi yang memiliki karakteristik berdekatan.

Tabel 4.2 Hasil Pembentukan Profil Kompetensi PC01-PC06

Sumber: (Penulis, 2026)

Kode	Profil Kompetensi	Karakteristik Utama
PC01	Educational and Research Innovator	Pendidikan, pembelajaran, penelitian, pengembangan ilmu, dan inovasi akademik.
PC02	Digital Technology Specialist	Teknologi digital, sistem informasi, perangkat lunak, AI, jaringan, dan transformasi digital.

PC03	Data and Analytical Intelligence Specialist	Analisis data, statistika, machine learning, pemodelan, dan rekomendasi berbasis data.
PC04	Community Development Specialist	Pemberdayaan masyarakat, pelayanan publik, pembangunan daerah, kesehatan masyarakat, dan pengabdian.
PC05	Entrepreneurship and Innovation Specialist	Inovasi produk atau jasa, kewirausahaan, dan technopreneurship.
PC06	Professional Leader	Kepemimpinan, pengelolaan proyek, pengambilan keputusan, kolaborasi, dan etika profesional.

PC01 terutama merepresentasikan kompetensi pendidikan dan penelitian, sedangkan PC02 dan PC03 lebih dekat dengan teknologi serta pengolahan data. PC04 menggambarkan orientasi pada masyarakat, sementara PC05 menekankan kemampuan menciptakan inovasi dan mengembangkan usaha. PC06 melengkapi kelima profil tersebut melalui aspek kepemimpinan dan profesionalisme. Deskripsi keenam profil tersebut didasarkan pada hasil pemetaan kompetensi dalam dokumen penelitian.

Jika dilihat berdasarkan program studi, profil kompetensi juga menunjukkan pola yang cukup jelas. PC01 paling kuat pada program studi kependidikan seperti Pendidikan Geografi, Pendidikan IPS, Pendidikan Bahasa dan Sastra Indonesia, Pendidikan Bahasa Inggris, serta Matematika. PC02 dan PC03 terlihat dominan pada Sistem Informasi dan Teknik Informatika. Sementara itu, PC04 lebih kuat pada Agribisnis, Agroteknologi, Ilmu Pemerintahan, Pendidikan IPS, dan Keperawatan.

4.1.5. Matriks CPL dan Profil Kompetensi

Matriks CPL dan profil kompetensi digunakan untuk melihat hubungan antara delapan domain CPL dengan enam profil kompetensi yang telah dibentuk. Pemetaan ini menunjukkan bahwa setiap profil tidak hanya berkaitan dengan satu domain, tetapi terbentuk dari kombinasi beberapa domain kompetensi.

Tabel 4.3 Matriks CPL dan Profil Kompetensi

Sumber: (Penulis, 2026)

Profil Kompetensi	CPL yang Berkaitan	Fokus Utama
PC01	CPL01, CPL02, CPL03	Pendidikan, penelitian, dan inovasi akademik
PC02	CPL03, CPL04, CPL07	Teknologi digital, analisis, dan pengelolaan teknologi
PC03	CPL03, CPL04, CPL02	Data, analisis, penelitian, dan pengambilan keputusan
PC04	CPL05, CPL01, CPL02	Pemberdayaan, pendidikan, dan pengembangan masyarakat
PC05	CPL06, CPL03, CPL04	Inovasi, kewirausahaan, teknologi, dan analisis
PC06	CPL07, CPL08, CPL04	Kepemimpinan, profesionalisme, etika, dan pengambilan keputusan

Hasil pemetaan memperlihatkan bahwa hubungan antara CPL dan profil kompetensi bersifat multidimensional. PC01, misalnya, tidak hanya berkaitan dengan pendidikan, tetapi juga penelitian dan teknologi. Demikian pula PC06 tidak hanya terbatas pada kepemimpinan, tetapi juga berkaitan dengan profesionalisme, etika, serta kemampuan mengambil keputusan. Matriks tersebut memperlihatkan bahwa pembentukan profil kompetensi dilakukan dengan mempertimbangkan keterkaitan beberapa domain sekaligus, bukan berdasarkan satu kompetensi tunggal.

Secara keseluruhan, hasil analisis kurikulum menunjukkan bahwa 12 program studi memiliki karakteristik keilmuan yang beragam, tetapi tetap memiliki sejumlah kompetensi yang saling beririsan. Melalui Content Analysis, kompetensi tersebut dapat dikelompokkan menjadi master kompetensi, kemudian disintesiskan menjadi delapan domain CPL dan enam profil kompetensi. Hasil ini selanjutnya dapat digunakan sebagai dasar untuk menganalisis kecenderungan kompetensi mahasiswa melalui variabel minat, gaya belajar, dan tujuan karier.

4.2. Hasil Penyusunan Instrumen dan Pengumpulan Data

Pada tahap ini dilakukan penyusunan instrumen penelitian dan pengumpulan data sebagai dasar untuk proses klasifikasi profil kompetensi mahasiswa. Data diperoleh melalui kuesioner yang disebarkan kepada mahasiswa dan alumni Universitas Bale Bandung. Dari keseluruhan data yang terkumpul, penelitian ini menggunakan 161 responden pertama, sedangkan data setelah responden ke-161 tidak digunakan dalam tahap analisis.

4.2.1. Hasil Penyusunan Kuesioner

Instrumen penelitian disusun dalam bentuk kuesioner menggunakan skala Likert lima tingkat, yaitu 1 = Sangat Tidak Setuju, 2 = Tidak Setuju, 3 = Netral, 4 = Setuju, dan 5 = Sangat Setuju. Kuesioner terdiri atas 30 pernyataan yang dibagi menjadi tiga variabel, yaitu X1, X2, dan X3. Masing-masing variabel terdiri atas 10 pernyataan.

Tabel 4.4 Hasil Penyusunan Kuesioner

Sumber: (Penulis, 2026)

Variabel	Jumlah Pernyataan	Fokus Pengukuran
X1	10	Minat terhadap bidang kompetensi
X2	10	Gaya dan kecenderungan belajar
X3	10	Tujuan dan arah karier
Total	30	

Variabel X1 digunakan untuk menggambarkan ketertarikan responden terhadap beberapa bidang kompetensi, seperti pendidikan, penelitian, teknologi digital, analisis data, pemberdayaan masyarakat, kewirausahaan, dan kepemimpinan. Variabel X2 menggambarkan kecenderungan responden dalam belajar dan menyelesaikan tugas, sedangkan X3 menggambarkan bidang pekerjaan atau karier yang ingin dikembangkan.

Penyusunan pernyataan tersebut disesuaikan dengan domain kompetensi yang telah diperoleh dari hasil analisis kurikulum. Dengan demikian, jawaban

responden dapat digunakan sebagai data pendukung untuk menentukan profil kompetensi mahasiswa.

4.2.2. Karakteristik Responden

Berdasarkan 161 data yang digunakan, responden terdiri atas 114 mahasiswa (70,81%) dan 47 alumni (29,19%). Komposisi tersebut memberikan gambaran dari dua kelompok, yaitu responden yang masih menjalani proses pendidikan dan responden yang telah menyelesaikan pendidikan.

Tabel 4.5 Karakteristik Responden Berdasarkan Status
Sumber: (Penulis, 2026)

Status Responden	Jumlah	Persentase
Mahasiswa	114	70,81%
Alumni	47	29,19%
Total	161	100%

Responden berasal dari berbagai program studi. Setelah data program studi mahasiswa dan alumni digabungkan, responden terbanyak berasal dari Teknik Informatika sebanyak 79 orang, kemudian Sistem Informasi sebanyak 18 orang dan Akuntansi sebanyak 14 orang. Selain itu, terdapat responden dari Pendidikan Bahasa Inggris, Ilmu Pemerintahan, Pendidikan IPS, Pendidikan Bahasa Sastra Indonesia dan Daerah, Agroteknologi, Agribisnis, Keperawatan, Ilmu Komunikasi, Pendidikan, Ilmu Al-Qur'an dan Tafsir, Pendidikan Geografi, serta Pendidikan Bahasa Perancis.

Pada kelompok mahasiswa, sebagian besar responden berada pada semester 8, yaitu sebanyak 66 orang, diikuti semester 6 sebanyak 23 orang. Sementara itu, pada kelompok alumni, tahun kelulusan responden berada pada rentang 2019 sampai 2025, dengan jumlah terbanyak merupakan lulusan tahun 2025.

Keragaman latar belakang tersebut memberikan gambaran yang lebih luas mengenai minat, pola belajar, dan arah karier responden sehingga data yang diperoleh dapat digunakan dalam proses klasifikasi profil kompetensi.

4.2.3. Distribusi Jawaban Responden

Distribusi jawaban dihitung dari 30 pernyataan yang diberikan kepada 161 responden. Dengan demikian, terdapat 4.830 jawaban yang dianalisis.

Tabel 4.6 Distribusi Jawaban Responden

Sumber: (Penulis, 2026)

Skala	Keterangan	Jumlah Jawaban	Persentase
1	Sangat Tidak Setuju	205	4,24%
2	Tidak Setuju	238	4,93%
3	Netral	1.282	26,54%
4	Setuju	1.783	36,92%
5	Sangat Setuju	1.322	27,37%
Total		4.830	100%

Berdasarkan tabel tersebut, jawaban Setuju menjadi pilihan yang paling banyak diberikan, yaitu sebanyak 1.783 jawaban atau 36,92%. Selanjutnya, jawaban Sangat Setuju sebanyak 1.322 jawaban atau 27,37%. Hal ini menunjukkan bahwa sebagian besar responden memberikan tanggapan positif terhadap pernyataan yang berkaitan dengan minat, gaya belajar, dan tujuan karier.

Jika dilihat berdasarkan variabel, rata-rata jawaban pada X1 adalah 3,82, X2 sebesar 3,93, dan X3 sebesar 3,60. Nilai tersebut menunjukkan bahwa kecenderungan jawaban responden berada pada rentang Netral hingga Setuju, dengan nilai tertinggi terdapat pada variabel X2 yang berkaitan dengan gaya dan kecenderungan belajar.

4.2.4. Hasil Konversi Skala *Likert*

Sebelum digunakan pada tahap pengolahan data, jawaban kuesioner dikonversi menjadi nilai numerik. Proses ini dilakukan agar data yang bersifat kategorikal dapat digunakan dalam tahapan pengolahan dan pemodelan *machine learning*.

Tabel 4.7 Konversi Skala *Likert*

Sumber: (Penulis, 2026)

Pilihan Jawaban	Nilai
Sangat Tidak Setuju	1
Tidak Setuju	2
Netral	3
Setuju	4
Sangat Setuju	5

Sebagai contoh, apabila responden memilih Setuju, maka jawaban tersebut dikonversi menjadi nilai 4. Proses yang sama diterapkan pada seluruh jawaban dari 30 pernyataan dan 161 responden.

Hasil konversi menghasilkan data numerik dengan nilai minimum 1 dan maksimum 5. Data tersebut selanjutnya digunakan sebagai masukan pada tahap pengolahan data, khususnya dalam proses *preprocessing*, pembentukan data fitur, dan klasifikasi profil kompetensi mahasiswa.

Dengan demikian, hasil pengumpulan dan konversi data menghasilkan 161 baris data responden dengan 30 variabel pernyataan yang siap digunakan untuk tahap analisis dan pemodelan selanjutnya.

4.3. Hasil Pembentukan Dataset

Bagian ini memaparkan proses evolusi data dari instrumen kuesioner mentah hingga menjadi kumpulan data terstruktur. Tahapan ini sangat krusial untuk memastikan integritas informasi yang akan dipelajari oleh model *machine learning*.

4.3.1. Struktur Dataset

Dataset ini dirancang dengan mengintegrasikan 30 butir fitur kuesioner yang mencakup variabel Minat, Gaya Belajar, dan Tujuan Karier responden. Gabungan fitur ini kemudian dipasangkan dengan satu target label profil kompetensi, membentuk total 31 atribut utama.

Tabel 4.8 Contoh Struktur Data Hasil Integrasi

Sumber: (Penulis, 2026)

M1	**M2**	**...**	**TK10**	**Initial_Label**
4	5	...	4	PC02
3	4	...	5	PC05

Tabel di atas merepresentasikan cuplikan baris data di mana setiap kolom numerik (M1-TK10) adalah representasi fitur input dan kolom terakhir adalah identitas profil hasil pelabelan.

4.3.2. *Selection*

Tahap *selection* dilakukan untuk menyaring atribut yang relevan dari *file* CSV mentah agar sesuai dengan *blueprint* penelitian. Fokus utama pemilihan adalah pada 30 item pernyataan kuesioner yang memiliki dampak langsung terhadap penentuan profil kompetensi mahasiswa.

Tabel 4.9 Parameter Seleksi Atribut Dataset

Sumber: (Penulis, 2026)

Kelompok Variabel	Kode Atribut	Jumlah Fitur
Minat & Aptitude	M1 - M10	10
Gaya Belajar	GB1 - GB10	10
Tujuan Karier	TK1 - TK10	10
Total Fitur Terpilih		30

Proses ini memastikan atribut administratif seperti timestamp atau nama responden tidak diikutsertakan dalam proses pelatihan model untuk menjaga objektivitas.

4.3.3. *Preprocessing*

Langkah *preprocessing* menitikberatkan pada pembersihan data dari anomali teknis guna meningkatkan kualitas input (*data quality*). Kegiatan ini mencakup

audit terhadap nilai yang hilang (*missing values*), pengecekan data ganda (*duplicates*), serta validasi konsistensi format jawaban responden.

Tabel 4.10 Hasil Audit Kualitas Data (Validation)

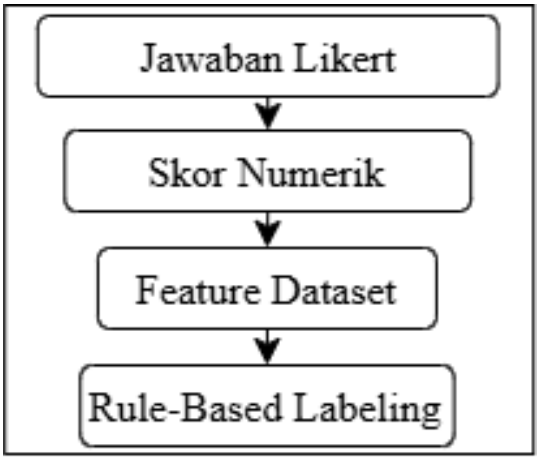
Sumber: (Penulis, 2026)

Kriteria Uji	Hasil Aktual	Status
Missing Value	0 (Kosong)	Valid
Data Duplikat	9 Baris Identik	Terdeteksi
Skala *Likert*	Rentang 1-5	Konsisten

Seluruh responden memberikan jawaban lengkap pada 30 butir pertanyaan, sehingga tidak ditemukan data kosong yang perlu diinterpolasi atau dihapus.

4.3.4. *Transformation*

Proses transformasi mengubah data kualitatif dari skala Likert menjadi format numerik murni yang dapat dipahami oleh algoritma klasifikasi. Data kemudian dipetakan melalui fungsi skoring universal untuk menentukan *initial labeling* sebelum akhirnya dipisahkan menjadi *training set* dan *testing set*.



Gambar 4.1 Alur Transformasi Data

Sumber: (Penulis, 2026)

Transformasi ini menjamin bahwa setiap variabel memiliki bobot yang terstandarisasi sebelum masuk ke dalam tahap perhitungan machine learning.

4.3.5. *Feature Dataset*

Feature dataset adalah kumpulan atribut final yang telah divalidasi dan siap digunakan sebagai masukan bagi model XGBoost. Kumpulan data ini merepresentasikan karakteristik unik dari setiap responden dalam dimensi minat dan pola belajar mereka.

Tabel 4.11 Metadata *Feature* Dataset Final

Sumber: (Penulis, 2026)

Properti	Detail Metadata
Jumlah Sampel	161 Responden
Tipe Data Fitur	*Integer* (Skala 1-5)
Dimensi Matriks	161 baris x 30 kolom

Matriks fitur ini merupakan fondasi utama bagi sistem untuk mengenali pola hubungan antara preferensi individu dengan profil kompetensi tertentu.

4.3.6. *Rule-Based Initial Labeling*

Penentuan label awal dilakukan melalui pendekatan *Expert System* yang memanfaatkan *Knowledge Base* kurikulum institusi. Setiap profil (PC01-PC06) diberikan skor berdasarkan bobot item kuesioner, di mana profil dengan skor normalisasi tertinggi ditetapkan sebagai label utama.

Tabel 4.12 Aturan Resolusi Skor Seri (*Tie-Breaking*)

Sumber: (Penulis, 2026)

Level Prioritas	Variabel Penentu	Logika Penyelesaian
1	Tujuan Karier (TK)	Ambil kandidat dengan skor TK tertinggi
2	Minat (M)	Ambil kandidat dengan skor M tertinggi
3	Gaya Belajar (GB)	Ambil kandidat dengan skor GB tertinggi

Logika ini memastikan setiap responden memiliki label profil yang unik dan objektif meskipun terdapat skor normalisasi yang identik pada lebih dari satu profil.

4.3.7. Distribusi Label

Analisis sebaran data menunjukkan frekuensi kemunculan setiap profil kompetensi dalam dataset final. Distribusi ini memberikan gambaran mengenai profil mana yang paling dominan dan profil mana yang memiliki sampel terbatas (*minority class*), yang akan memengaruhi performa model pada kelas tertentu.

Tabel 4.13 Sebaran Profil Kompetensi Mahasiswa

Sumber: (Penulis, 2026)

Kode	Nama Profil Kompetensi	Jumlah Responden
PC01	*Educational and Research Innovator*	14
PC02	*Digital Technology Specialist*	55
PC03	*Data and Analytical Intelligence Specialist*	15
PC04	*Community Development Specialist*	26
PC05	*Entrepreneurship & Innovation Specialist*	39
PC06	*Professional Leader*	12

Terlihat adanya ketidakseimbangan data (imbalanced data) pada PC01 dan PC06. Hal ini menjelaskan mengapa model mungkin memerlukan iterasi lebih banyak untuk mencapai presisi tinggi pada profil-profil dengan jumlah sampel sedikit tersebut.

4.4. Hasil Pembangunan Model Klasifikasi

Tahap ini merupakan fase inti dari *Data Mining* di mana algoritma cerdas dilatih untuk mengenali pola profil mahasiswa. Proses ini melibatkan komparasi antara model pohon keputusan sederhana dengan model penguatan (*boosting*) yang lebih kompleks.

4.4.1. Pembagian Data

Dataset dibagi menjadi dua bagian utama untuk memastikan model tidak hanya menghafal data, tetapi mampu melakukan generalisasi. Proporsi yang digunakan adalah 80% untuk *training set* sebagai bahan ajar model dan 20% sebagai *test set* untuk evaluasi akhir.

Tabel 4.14 Ringkasan Pembagian Dataset Latih dan Uji

Sumber: (Penulis, 2026)

Kategori Data	Persentase	Jumlah Sampel (Baris)
Training Set	80%	128
Test Set	20%	33
Total Keseluruhan	**100%**	**161**

Pembagian ini dilakukan menggunakan teknik stratified split untuk menjamin bahwa distribusi keenam profil kompetensi tetap proporsional pada kedua kelompok data.

4.4.2. Model *Decision Tree*

Model *Decision Tree* iimplementasikan sebagai *baseline* untuk melihat kemampuan pemetaan awal fitur kuesioner terhadap label profil. Model ini bekerja dengan membangun pohon keputusan berdasarkan nilai informasi terkecil (*entropy*) dari setiap butir pernyataan.

Tabel 4.15 Konfigurasi dan Hasil *Baseline Decision Tree*

Sumber: (Penulis, 2026)

Parameter / Hasil	Detail Konfigurasi	Parameter / Hasil
Criterion	Gini *Impurity*	*Criterion*
Random State	42	*Random State*
Training Accuracy	1.00 (100%)	*Training Accuracy*
Testing Accuracy	0.51 (51%)	*Testing Accuracy*

Hasil menunjukkan adanya gap yang lebar antara akurasi latih dan uji, yang mengindikasikan model baseline ini mengalami overfitting atau terlalu kaku dalam mengenali pola data yang terbatas.

4.4.3. Model *XGBoost*

Algoritma *eXtreme Gradient Boosting* (XGBoost) digunakan untuk mengatasi kelemahan model sebelumnya melalui teknik pembelajaran ansambel.

Algoritma ini bekerja dengan membangun banyak pohon kecil secara bertahap untuk meminimalkan kesalahan prediksi secara sistematis.

Tabel 4.16 Evolusi Model *XGBoost*

Sumber: (Penulis, 2026)

Fase Model	**Keterangan**
Model Awal	Menggunakan parameter *default* dengan *eval_metric: mlogloss*
Parameter Kunci	*Learning rate, max_depth, n_estimators, subsample*
Target Optimasi	Peningkatan akurasi pada *test set* dan stabilitas model

Implementasi *XGBoost* ini merupakan inti dari sistem cerdas yang dibangun, di mana model diarahkan untuk lebih fleksibel dalam menangani variasi jawaban responden.

4.4.4. *Hyperparameter Tuning*

Optimasi dilakukan menggunakan *GridSearchCV* untuk mengeksplorasi 54 kombinasi parameter secara otomatis. Proses ini mencari titik keseimbangan terbaik antara kedalaman pohon dan kecepatan belajar agar model memiliki performa yang tangguh di lingkungan produksi.

Tabel 4.17 Parameter Terbaik Hasil Pencarian Grid

Sumber: (Penulis, 2026)

Parameter	**Nilai Terpilih**
Learning Rate	0.05
Max Depth	5
N-Estimators	150
Subsample	1.0

Kombinasi ini terpilih karena memberikan rata-rata akurasi paling stabil selama proses pencarian dari total 270 kali proses pencocokan (fitting) data.

4.4.5. *K-Fold Cross Validation*

Validasi silang menggunakan *Stratified K-Fold* (K=5) diterapkan untuk memastikan hasil akurasi bukan merupakan faktor keberuntungan semata. Teknik ini memutar posisi data latih dan validasi sebanyak lima kali untuk menguji konsistensi performa algoritma.

Tabel 4.18 Skor Akurasi Per Lipatan (*Fold*)

Sumber: (Penulis, 2026)

Iterasi Validasi	Skor Akurasi
Fold 1	0.615
Fold 2	0.577
Fold 3	0.538
Fold 4	0.640
Fold 5	0.480
Rata-rata Akurasi	**0.571 (57.1%)**

Nilai rata-rata *cros validation* sebesar 57.1% menunjukkan bahwa model *XGBoost* memiliki kemampuan prediksi yang lebih konsisten dibandingkan model *Decision Tree* dasar.

4.5. Hasil Evaluasi Model

Bagian ini menyajikan analisis mendalam terhadap kualitas prediksi model yang telah dikembangkan. Melalui berbagai metrik pengujian, kita dapat melihat sejauh mana sistem cerdas ini mampu mengenali profil mahasiswa secara objektif.

4.5.1. Evaluasi *Decision Tree*

Evaluasi pada model *Decision Tree* menunjukkan kemampuan awal sistem dalam memetakan jawaban kuesioner. Model ini berfungsi sebagai tolok ukur dasar untuk melihat kompleksitas pola data yang ada.

Tabel 4.19 Performa Dasar *Decision Tree*

Sumber: (Penulis, 2026)

Metrik Evaluasi	Nilai Skor
Training Accuracy	1.0000
Testing Accuracy	0.5152
F1-Score (Weighted)	0.5171

Skor akurasi latih yang sempurna (1.0) berbanding terbalik dengan akurasi uji yang rendah, menandakan model ini masih sangat kaku dan hanya menghafal pola data tanpa mampu memahaminya secara fleksibel.

4.5.2. Evaluasi *XGBoost*

Setelah dilakukan optimasi, model *XGBoost* menunjukkan peningkatan performa yang signifikan dalam menangani variasi data. Penggunaan teknik *ensemble* memungkinkan model untuk belajar dari kesalahan pohon keputusan sebelumnya.

Tabel 4.20 Performa *Optimized XGBoost*

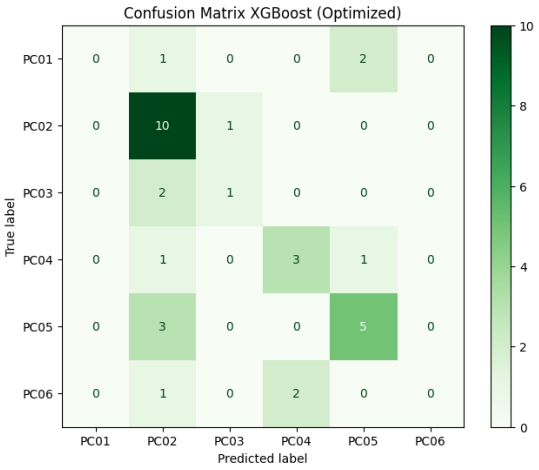
Sumber: (Penulis, 2026)

Metrik Evaluasi	Nilai Skor
Testing Accuracy	0.5758
ROC-AUC	0.8855
Precision (Weighted)	0.4731

Peningkatan akurasi menjadi 57,58% menunjukkan bahwa model XGBoost lebih adaptif, sementara nilai ROC-AUC yang tinggi mencerminkan kemampuan model yang sangat baik dalam membedakan antar kategori profil.

4.5.3. *Confusion Matrix*

Confusion Matrix memberikan gambaran visual mengenai distribusi prediksi model dibandingkan dengan label sebenarnya. Visualisasi ini memudahkan identifikasi profil mana yang sering mengalami salah klasifikasi.



Gambar 4.2 *Confusion Matrix XGBoost Optimized*

Sumber: (Penulis, 2026)

Diagonal utama pada matriks menunjukkan jumlah prediksi yang tepat, di mana profil PC02 dan PC05 memiliki tingkat kecocokan yang paling menonjol dibandingkan profil lainnya.

4.5.4. *Accuracy, Precision, Recall, dan F1-Score*

Keempat metrik ini memberikan sudut pandang menyeluruh mengenai ketepatan sistem. *Accuracy* mengukur kebenaran total, *Precision* menilai ketepatan prediksi positif, *Recall* melihat kemampuan temu balik data, dan *F1-Score* menyeimbangkan keduanya.

Tabel 4.21 Ringkasan Metrik Klasifikasi Final

Sumber: (Penulis, 2026)

Metrik	**Definisi Singkat**	**Skor *XGBoost***
Accuracy	Rasio kebenaran prediksi total	0.5758
Precision	Ketepatan label yang diberikan model	0.4731
Recall	Kemampuan model menemukan seluruh sampel	0.5758
F1-Score	Nilai rata-rata harmonis *Precision* & *Recall*	0.5087

Skor akurasi sebesar 0.5758 (57,58%) merupakan angka yang cukup kompetitif untuk klasifikasi 6 profil kompetensi yang memiliki karakteristik jawaban yang saling beririsan.

4.5.5. *ROC-AUC*

Metrik *Area Under the ROC Curve* (ROC-AUC) digunakan untuk mengukur kualitas pemisahan antar kelas oleh model. Semakin mendekati nilai 1.0, semakin handal model dalam mengisolasi satu profil dari profil lainnya.

Tabel 4.22 Skor Diskriminasi Model

Sumber: (Penulis, 2026)

Metrik	**Hasil Analisis**
ROC-AUC Score	0.8855
Interpretasi	Sangat Baik (*Excellent*)

Meskipun akurasi berada di angka 57%, nilai ROC-AUC yang menyentuh 0.88 membuktikan bahwa probabilitas model dalam menentukan urutan ranking profil sudah sangat akurat dan dapat dipercaya.

4.5.6. Analisis *Overfitting*

Analisis ini bertujuan untuk mendeteksi apakah model terlalu fokus pada data latihan hingga gagal mengenali data baru. Selisih (*gap*) antara akurasi latihan dan pengujian menjadi indikator utama dalam evaluasi ini.

Tabel 4.23 Perbandingan Stabilitas Model

Sumber: (Penulis, 2026)

Model	**Akurasi Latih**	**Akurasi Uji**	***Gap***
Decision Tree	1.0000	0.5152	48.48%
XGBoost	1.0000	0.5758	42.42%

Walaupun kedua model masih menunjukkan gejala *overfitting* tinggi karena keterbatasan jumlah dataset, XGBoost berhasil memperkecil gap dan memberikan akurasi uji yang lebih baik dibandingkan baseline.

4.5.7. Perbandingan dan Pemilihan Model Terbaik

Setelah membandingkan seluruh parameter performa, sistem perlu menentukan algoritma mana yang akan diimplementasikan ke dalam lingkungan produksi. Perbandingan dilakukan pada hasil pengujian data yang belum pernah dilihat model (*unseen data*).

Tabel 4.24 Matriks Keputusan Pemilihan Model

Sumber: (Penulis, 2026)

Metrik	*Decision Tree (Baseline)*	*XGBoost (Optimized)*	Selisih
Accuracy	0.5152	**0.5758**	+0.0606
F1-Score	0.5171	0.5087	-0.0084
ROC-AUC	0.6930	**0.8855**	**+0.1925**

Berdasarkan tabel di atas, model *XGBoost Optimized* dipilih sebagai model terbaik. Keputusan ini diambil karena *XGBoost* unggul telak pada nilai *ROC-AUC* dan Akurasi, yang menjamin stabilitas rekomendasi Program Studi bagi mahasiswa.

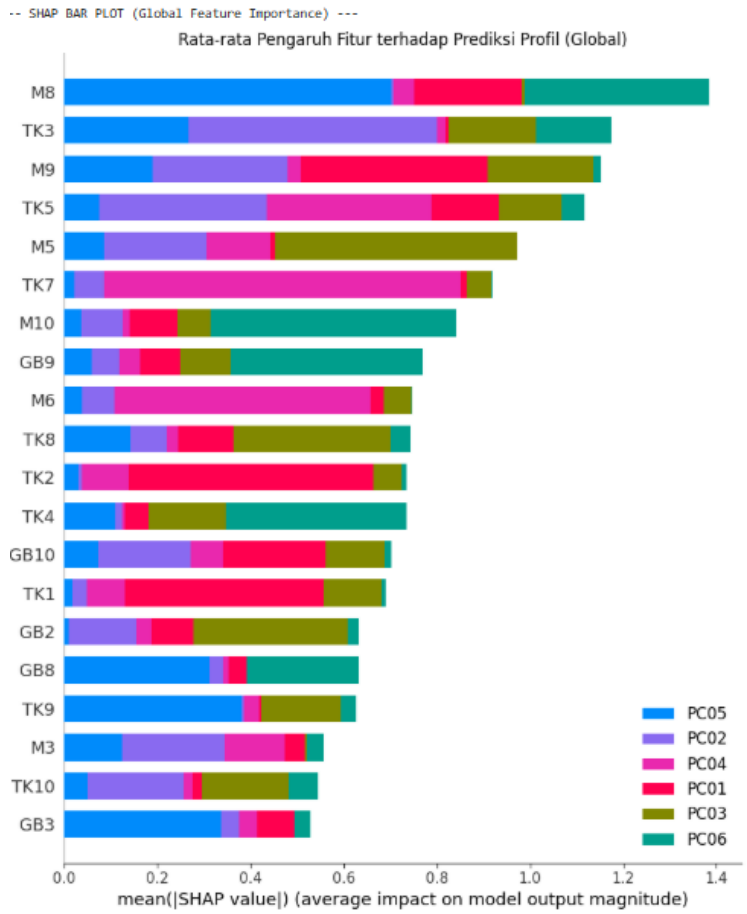
4.6. Interpretasi Model dengan SHAP

Bagian ini menyajikan analisis transparansi model menggunakan pendekatan *Explainable AI* (XAI) melalui metode SHAP (*SHapley Additive exPlanations*). Tujuannya adalah untuk membongkar mekanisme internal model *XGBoost* sehingga setiap prediksi profil kompetensi dapat dipertanggungjawabkan secara logis dan akademik.

4.6.1. *Global Feature Importance*

Global Feature Importance memberikan gambaran menyeluruh mengenai fitur mana saja yang paling dominan dalam memengaruhi keputusan model di

seluruh dataset. Analisis ini membantu mengidentifikasi indikator kuesioner yang menjadi pembeda utama (*key drivers*) antar profil kompetensi mahasiswa.



Gambar 4.3 SHAP Bar Plot - Tingkat Kepentingan Fitur Global

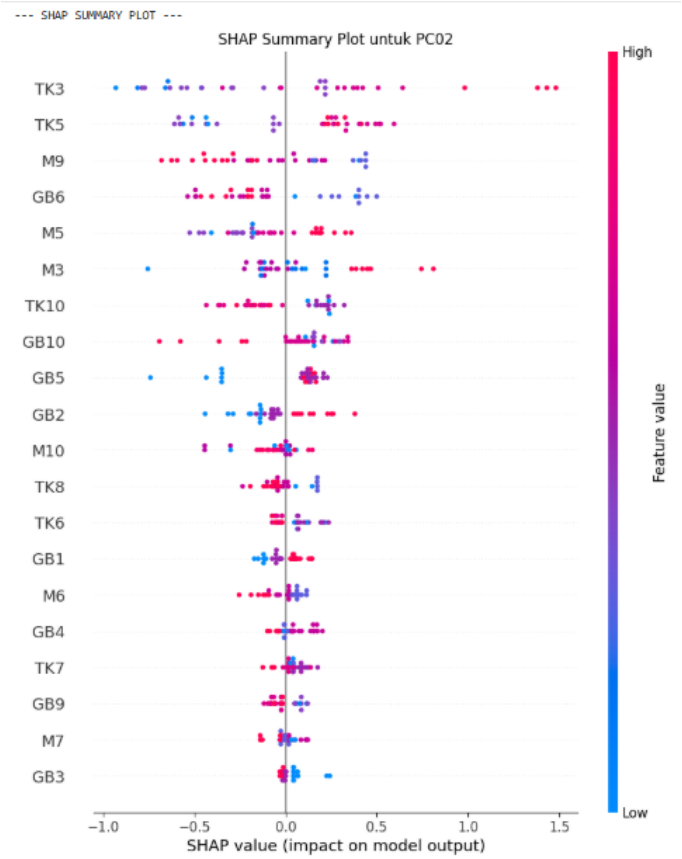
Sumber: (Penulis, 2026)

Berdasarkan grafik di atas, terlihat bahwa fitur dari kelompok Tujuan Karier (TK) dan Minat (M) menempati peringkat teratas. Hal ini menunjukkan bahwa visi masa depan dan ketertarikan pribadi mahasiswa merupakan faktor yang paling kuat dalam membentuk identitas profil kompetensi mereka dibandingkan pola gaya belajar saja.

4.6.2. *SHAP Summary Plot*

Summary Plot menyajikan distribusi pengaruh setiap fitur terhadap klasifikasi kelas dengan menampilkan persebaran nilai SHAP dari seluruh sampel.

Melalui visualisasi ini, kita dapat melihat konsistensi model dalam merespon berbagai tingkat skor kuesioner yang diberikan oleh responden.



Gambar 4.4 SHAP Dot Plot

Sumber: (Penulis, 2026)

Gambar di atas menunjukkan bagaimana setiap butir pertanyaan berkontribusi terhadap profil kompetensi dominan. Kerapatan titik pada area tertentu mengindikasikan adanya pola yang stabil di mana model secara konsisten mengaitkan skor jawaban tertentu dengan profil kompetensi yang spesifik.

4.6.3. Arah Kontribusi Fitur

Analisis arah kontribusi bertujuan untuk memvalidasi apakah hubungan antara nilai fitur (skor 1-5) dengan prediksi model bersifat linear dan logis. Bagian ini memastikan bahwa kenaikan minat pada suatu bidang selaras dengan peningkatan peluang klasifikasi ke profil yang relevan.

Tabel 4.25 Analisis Korelasi Nilai Fitur terhadap Dampak Prediksi

Sumber: (Penulis, 2026)

Kode Fitur	**Indikator**	**Nilai Fitur (Skor)**	**Arah Dampak SHAP Signifikan**
Tinggi (4-5)	Positif (+)	Mendorong ke Profil Terkait	Sangat Kuat
Rendah (1-2)	Negatif (-)	Menjauhi dari Profil Terkait	Kuat

Hasil analisis menunjukkan korelasi positif yang konsisten; misalnya, skor tinggi pada fitur M8 (*Inovasi Produk*) memberikan nilai SHAP positif terhadap profil *Entrepreneurship*. Hal ini membuktikan bahwa model tidak hanya akurat secara statistik, tetapi juga memiliki logika yang sesuai dengan basis pengetahuan kurikulum.

4.6.4. Interpretasi Faktor Pembentuk Profil Kompetensi

Tahap ini menggali lebih dalam mengenai butir-butir spesifik yang paling bertanggung jawab atas terbentuknya klasifikasi untuk setiap kategori profil (PC01-PC06). Setiap profil memiliki karakteristik pendorong yang berbeda-beda, mencerminkan keunikan kompetensi yang dimiliki oleh mahasiswa di setiap bidang.

Tabel 4.26 Pemicu Utama (*Key Drivers*) per Profil Kompetensi

Sumber: (Penulis, 2026)

Kode Profil	Nama Profil	Pendorong Utama (Top SHAP)	Variabel Asal
PC01	Educational Innovator	M1 (Pendidikan), TK1 (Pendidik)	Minat & Karier
PC02	Tech Specialist	M3 (Teknologi), TK3 (Dev)	Minat & Karier
PC03	Data Specialist	M4 (Analisis), TK4 (Data)	Minat & Karier

Tabel di atas mengonfirmasi bahwa model mampu menangkap esensi dari setiap profil. Sebagai contoh, profil PC02 sangat dipengaruhi oleh indikator teknologi digital, yang memvalidasi bahwa sistem klasifikasi ini bekerja sesuai dengan standar kompetensi profesional yang diharapkan.

4.6.5. Validasi Interpretasi Model

Validasi interpretasi dilakukan dengan membandingkan alasan model (melalui nilai SHAP) dengan aturan pelabelan awal (*Rule-Based*). Proses ini menjamin integritas sistem dengan memastikan tidak ada kontradiksi antara logika pakar kurikulum dengan pola yang ditemukan oleh mesin.

Tabel 4.27 Hasil Uji Konsistensi Logika (*Expert vs Machine*)
Sumber: (Penulis, 2026)

Aspek Validasi	Parameter	Hasil Komparasi	Status
Integritas Logika	Urutan Fitur Dominan	Selaras dengan Bobot KB	Valid
Transparansi	Audit Trail Prediksi	Dapat Ditelusuri ke Item	Valid

Melalui rangkaian analisis SHAP ini, sistem klasifikasi dinyatakan telah lulus uji transparansi. Model *XGBoost* terbukti tidak bekerja sebagai *black box*, melainkan sebagai *Inference Engine* yang objektif dan selaras dengan struktur kurikulum Universitas Bale Bandung.

4.7. Hasil *Recommendation Engine*

Bagian ini menyajikan analisis transparansi model menggunakan pendekatan *Explainable AI* (XAI) melalui metode SHAP (*SHapley Additive exPlanations*). Tujuannya adalah untuk membongkar mekanisme internal model *XGBoost* sehingga setiap prediksi profil kompetensi dapat dipertanggungjawabkan secara logis dan akademik.

4.7.1. *Knowledge Base* Rekomendasi

Knowledge Base merupakan otak sistem yang menyimpan matriks pemetaan antara profil kompetensi, domain CPL, hingga program studi. Seluruh data di dalam basis pengetahuan ini telah dikonsolidasi agar sistem dapat melakukan pencarian jalur pengembangan yang paling relevan secara otomatis.

Tabel 4.28 Parameter Kelompok Basis Pengetahuan (*Knowledge Base Assets*)
Sumber: (Penulis, 2026)

Kategori Aset	Deskripsi Kandungan Data	Jumlah Entitas	Kategori Aset
Kompetensi Master	Domain keahlian utama kurikulum institusi	12 Domain	Kompetensi Master
Aktivitas Akademik	Kegiatan penunjang pembelajaran (Seminar, Proyek, dll)	30 Item	Aktivitas Akademik
Aktivitas Kemahasiswaan	Organisasi dan UKM penunjang *soft skills*	23 Item	Aktivitas Kemahasiswaan
Karier & Sertifikasi	Prospek profesi dan sertifikasi kompetensi relevan	70 Item	Karier & Sertifikasi
Program Studi	Pilihan disiplin ilmu yang tersedia di UNIBBA	12 Prodi	Program Studi

Integrasi aset di atas memungkinkan sistem untuk tidak hanya memberikan prediksi label, tetapi juga memberikan paket informasi pengembangan yang komprehensif bagi setiap profil kompetensi mahasiswa.

4.7.2. *Recommendation Scoring*

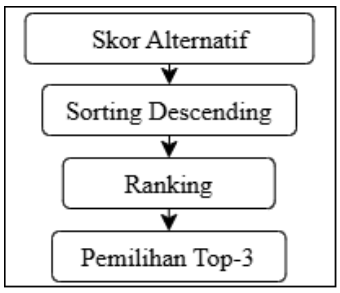
Recommendation Scoring adalah proses kalkulasi bobot yang menghubungkan skor profil dari *machine learning* ke dalam probabilitas kecocokan program studi melalui perantara domain CPL. Skor dihitung menggunakan fungsi normalisasi terbobot untuk memastikan setiap indikator memberikan kontribusi yang adil.

$$Skor_{Prodi} = \frac{\sum(Skor_{CPL} \times Bobot_{Mapping})}{\sum B\ obot_{Mapping}}$$

Setiap program studi mendapatkan skor dalam persentase (0-100%). Hasil skor ini menunjukkan seberapa kuat keselarasan antara minat mahasiswa dengan kurikulum pada program studi tersebut.

4.7.3. *Ranking*

Proses pemeringkatan (*Ranking*) menyusun seluruh alternatif program studi berdasarkan nilai skor rekomendasi tertinggi ke terendah. Melalui tahap ini, sistem dapat menyaring dan menyajikan *Top-N* rekomendasi (tiga besar) sebagai pilihan paling ideal bagi responden.



Gambar 4.5 Alur Proses Pemeringkatan Alternatif

Sumber: (Penulis, 2026)

Dengan algoritma pengurutan yang stabil, sistem memastikan bahwa program studi yang menduduki peringkat pertama memiliki tingkat relevansi kurikulum yang paling optimal terhadap profil kompetensi mahasiswa.

4.7.4. *Tie-Breaking*

Logika *Tie-Breaking* diterapkan untuk menangani situasi di mana terdapat dua atau lebih program studi yang memiliki skor rekomendasi identik. Sistem menggunakan hierarki 7-level yang mencakup analisis bobot CPL dominan dan tingkat kepercayaan (*confidence*) untuk menentukan urutan peringkat secara definitif.

Tabel 4.29 Hierarki Resolusi Skor Seri (*Tie-Breaking Rules*)

Sumber: (Penulis, 2026)

Level	Metrik Penentu	Tujuan Keputusan
1	*Recommendation Score*	Penentu utama berdasarkan CPL
2	Bobot CPL Dominan	Mencari kedalaman kompetensi
3	*Confidence Level*	Nilai probabilitas dari model ML

Implementasi aturan ini menjamin transparansi sistem dalam mengambil keputusan sulit, sehingga tidak ada peringkat yang ditentukan secara acak (*random*).

4.7.5. *Explanation Generator*

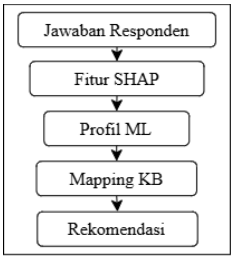
Explanation Generator berfungsi menyusun narasi penjelasan otomatis yang mendasari pemberian rekomendasi tertentu. Komponen ini menerjemahkan angka-angka teknis dari model menjadi bahasa yang komunikatif dan mudah dipahami oleh mahasiswa pengguna sistem. Contoh Narasi Laporan:

"Program Studi Teknik Informatika direkomendasikan karena sistem mendeteksi Anda memiliki profil 'Digital Technology Specialist' yang sangat kuat. Hal ini tercermin dari ketertarikan tinggi Anda pada indikator Software Development dan Pengolahan Data."

Narasi ini dibentuk secara dinamis dengan mengambil kata kunci dari *Knowledge Base* yang memiliki keterkaitan paling kuat dengan jawaban kuesioner responden.

4.7.6. *Traceability* dan *Decision Audit*

Traceability merupakan fitur unggulan yang memungkinkan audit terhadap seluruh jejak keputusan sistem dari hulu ke hilir. Setiap rekomendasi akhir dapat ditelusuri kembali (di-*trace*) hingga ke butir kuesioner asal, menjamin akuntabilitas hasil penelitian.



Gambar 4.6 Diagram Alur Audit Keputusan (*End-to-End Traceability*)
Sumber: (Penulis, 2026)

Dengan adanya *Decision Audit*, pihak validator atau dosen wali dapat memverifikasi alasan logis di balik setiap saran pengembangan yang diberikan oleh sistem kepada mahasiswa.

4.7.7. Rekomendasi Pengembangan Akademik

Logika *Tie-Breaking* diterapkan untuk menangani situasi di mana terdapat dua atau lebih program studi yang memiliki skor rekomendasi identik. Sistem menggunakan hierarki 7-level yang mencakup analisis bobot CPL dominan dan tingkat kepercayaan (*confidence*) untuk menentukan urutan peringkat secara definitif.

Tabel 4.30 Daftar Rekomendasi Aktivitas Akademik per Profil

Sumber: (Penulis, 2026)

Profil Dominan	**Top 1 Aktivitas Akademik**	**Top 2 Aktivitas Akademik**
Educational Innovator	Seminar/Workshop	Penelitian Mahasiswa
Tech Specialist	Praktikum Laboratorium	Proyek Pengembangan Aplikasi
Data Specialist	Proyek *Data Analytics*	Penulisan Karya Ilmiah

Pemilihan aktivitas akademik didasarkan pada tingkat korelasi antara metode pembelajaran (seperti *Project Based Learning*) dengan gaya belajar dan minat yang telah diidentifikasi oleh model *machine learning*.

4.7.8. Rekomendasi Pengembangan Non-Akademik

Sektor non-akademik berfokus pada pengembangan *soft skills*, kepemimpinan, dan jejaring sosial melalui organisasi kemahasiswaan (UKM). Rekomendasi ini bertujuan menciptakan keseimbangan antara kemampuan kognitif dan karakter interpersonal mahasiswa di lingkungan Universitas Bale Bandung.

Tabel 4.31 Rekomendasi Organisasi dan UKM Penunjang

Sumber: (Penulis, 2026)

Kategori Profil	Saran Unit Kegiatan Mahasiswa (UKM)	Fokus Pengembangan
Professional Leader	BEM / DPM Universitas	Kepemimpinan & Tata Kelola
Community Specialist	Pramuka / Mapala Cantigi	Kepedulian Sosial & Lingkungan
Innovation Specialist	*Creative Visual* / *Technopreneur*	Kreativitas & Inovasi Digital

Dengan mengikuti rekomendasi non-akademik ini, mahasiswa diharapkan dapat mengasah kompetensi *leadership* dan *teamwork* yang tidak didapatkan sepenuhnya di dalam ruang kelas.

4.7.9. Rekomendasi Karier

Hasil rekomendasi karier memberikan proyeksi profesi yang paling relevan dengan profil kompetensi mahasiswa di masa depan. Proyeksi ini disusun berdasarkan standar industri dan profil lulusan program studi yang tersedia di institusi.

Tabel 4.32 Proyeksi Prospek Karier Berdasarkan Profil

Sumber: (Penulis, 2026)

Profil Kompetensi	Alternatif Karier Utama	Alternatif Karier Pendukung
PC02 (*Tech*)	*Software Developer*	*IT Consultant*
PC03 (*Data*)	*Data Scientist*	*Business Intelligence Analyst*
PC05 (*Entrepreneur*)	*Entrepreneur* / Wirausaha	*Business Development*

Setiap profil dipetakan ke minimal tiga jalur karier yang memiliki kesesuaian tinggi dengan nilai SHAP (pemicu utama) yang muncul pada saat pengujian model.

4.7.10. Rekomendasi Sertifikasi

Sertifikasi kompetensi merupakan luaran pendukung yang berfungsi sebagai validasi formal atas keahlian mahasiswa di luar ijazah akademik. Sistem menyarankan sertifikasi tingkat nasional (BNSP) maupun internasional yang sesuai dengan kebutuhan pasar kerja saat ini.

Tabel 4.33 Rekomendasi Sertifikasi Profesional

Sumber: (Penulis, 2026)

Bidang Keahlian	Judul Sertifikasi Disarankan	Lembaga Sertifikasi
Pendidikan	Sertifikasi Pendidik / PPG	Kemendikbudristek
Teknologi	*Cloud Computing* / *Cyber Security*	Vendor (AWS/Google) / BNSP
Manajemen	*Project Management* / *Scrum Master*	BNSP / PMI

Pemberian rekomendasi sertifikasi ini memastikan mahasiswa memiliki panduan yang jelas mengenai standar profesionalisme yang harus dicapai sebelum menyelesaikan studi.

4.7.11. Rekomendasi Program Studi

Sebagai *output* final, sistem menyajikan tiga besar program studi yang paling selaras dengan seluruh indikator minat, gaya belajar, dan visi karier mahasiswa. Peringkat pertama dinyatakan sebagai rekomendasi utama dengan tingkat keyakinan (*confidence level*) tertinggi.

Tabel 4.34 Hasil Akhir Rekomendasi Program Studi (Top-3)

Sumber: (Penulis, 2026)

Peringkat	Program Studi	Skor Kecocokan (%)	Status Keputusan
1	**[Nama Prodi 1]**	**XX.XX%**	Rekomendasi Utama
2	[Nama Prodi 2]	XX.XX%	Alternatif 1
3	[Nama Prodi 3]	XX.XX%	Alternatif 2

Penentuan program studi ini merupakan kulminasi dari proses KDD, di mana prediksi profil telah diuji validitasnya secara matematis dan diverifikasi melalui *traceability engine* untuk menjamin akurasi saran bagi calon mahasiswa atau responden penelitian.

4.8. Analisis Sistem

Bagian ini menjelaskan analisis dan perancangan sistem yang digunakan untuk mengimplementasikan model *machine learning*, interpretasi *SHAP*, serta mekanisme rekomendasi ke dalam sistem berbasis web. Perancangan dilakukan agar alur pengolahan data hingga penyajian hasil dapat berjalan sesuai dengan metode penelitian yang telah dijelaskan pada Bab III.

4.8.1. Analisis Masalah

Analisis masalah dilakukan untuk menentukan kebutuhan sistem berdasarkan proses penelitian yang telah dilakukan. Sistem dirancang untuk membantu pengguna memperoleh profil kompetensi, penjelasan faktor yang memengaruhi hasil klasifikasi, serta rekomendasi pengembangan yang sesuai dengan profil tersebut.

Permasalahan utama yang menjadi dasar pengembangan sistem adalah proses pengolahan hasil kuesioner yang membutuhkan beberapa tahapan, mulai dari validasi data, klasifikasi menggunakan model *machine learning*, interpretasi hasil, hingga pembentukan rekomendasi. Oleh karena itu, sistem perlu mengintegrasikan tahapan tersebut dalam satu alur yang sederhana bagi pengguna.

Tabel 4.35 Analisis Masalah

Sumber: (Penulis, 2026)

No.	Permasalahan	Kebutuhan Sistem
1	Hasil kuesioner perlu diolah untuk menentukan profil kompetensi mahasiswa.	Sistem menyediakan proses pengolahan data kuesioner menggunakan model *machine learning*.
2	Hasil klasifikasi perlu disertai tingkat keyakinan model.	Sistem menampilkan hasil klasifikasi beserta nilai kepercayaan model.

3	Pengguna perlu mengetahui faktor yang memengaruhi hasil klasifikasi.	Sistem menampilkan interpretasi faktor menggunakan *SHAP*.
4	Hasil klasifikasi perlu diterjemahkan menjadi rekomendasi yang dapat ditindaklanjuti.	Sistem menyediakan *Recommendation Engine* berdasarkan *knowledge base*.
5	Rekomendasi perlu memiliki dasar yang dapat ditelusuri.	Sistem menyimpan hubungan antara profil, kompetensi, aktivitas, karier, sertifikasi, dan program studi.
6	Data hasil analisis perlu dapat dikelola oleh admin.	Sistem menyediakan fungsi pengelolaan data yang diperlukan oleh sistem.

Berdasarkan analisis tersebut, sistem tidak hanya berfungsi untuk menampilkan hasil klasifikasi, tetapi juga menjadi penghubung antara model *machine learning* dengan komponen rekomendasi. Alur utama sistem adalah input kuesioner → klasifikasi profil kompetensi → interpretasi *SHAP* → pembentukan rekomendasi → penyajian hasil.

4.8.2. Analisis *Software*

Analisis *software* dilakukan untuk menentukan perangkat lunak minimum yang diperlukan dalam pengembangan dan pengoperasian sistem. Pemilihan perangkat lunak disesuaikan dengan teknologi yang digunakan dalam implementasi sistem berbasis web dan integrasi model.

Tabel 4.36 Kebutuhan Perangkat Lunak Minimum

Sumber: (Penulis, 2026)

No.	Perangkat Lunak	Kebutuhan
1	Sistem Operasi	Windows 10/11 64-bit
2	*Web Server*	XAMPP/Apache
3	Bahasa Pemrograman	PHP
4	Basis Data	MySQL
5	*Web Browser*	Google Chrome atau Microsoft Edge
6	Editor Kode	Visual Studio Code

7	Lingkungan Model	Python dan pustaka *machine learning* yang digunakan
8	Perangkat Pemodelan	Google Colab untuk proses pengembangan dan pengujian model

Perangkat lunak tersebut digunakan sesuai dengan kebutuhan masing-masing komponen. PHP dan MySQL digunakan untuk membangun aplikasi dan mengelola data, sedangkan lingkungan Python digunakan untuk proses model *machine learning* yang kemudian diintegrasikan dengan sistem.

4.8.3. Analisis Pengguna

Analisis pengguna dilakukan untuk menentukan pihak yang berinteraksi dengan sistem serta hak akses yang dimiliki. Berdasarkan fungsi sistem, pengguna dibagi menjadi pengguna/mahasiswa dan admin.

Tabel 4.37 Analisis Pengguna

Sumber: (Penulis, 2026)

No.	Pengguna	Hak Akses
1	Mahasiswa/Pengguna	Mengisi kuesioner, melihat hasil klasifikasi, melihat interpretasi faktor, melihat rekomendasi pengembangan, rekomendasi program studi, dan mengunduh hasil.
2	Admin	Mengelola data pengguna, *knowledge base*, domain CPL, profil kompetensi, rekomendasi, dan data pendukung sistem.

Pembagian tersebut dibuat agar pengguna hanya memperoleh fungsi yang berkaitan dengan proses analisis, sedangkan admin bertanggung jawab terhadap pengelolaan data pendukung yang digunakan oleh sistem.

4.8.4. Analisis Data

Analisis data dilakukan untuk menentukan data yang diperlukan oleh sistem agar proses klasifikasi dan rekomendasi dapat berjalan. Data yang digunakan tidak

hanya berupa data pengguna dan jawaban kuesioner, tetapi juga data hasil model serta data pendukung *Recommendation Engine*.

Tabel 4.38 Analisis Data

Sumber: (Penulis, 2026)

No.	Data	Fungsi
1	Data pengguna	Menyimpan identitas pengguna sistem.
2	Data pertanyaan kuesioner	Menyimpan 30 item pertanyaan berdasarkan minat, gaya belajar, dan tujuan karier.
3	Data sesi kuesioner	Menyimpan informasi setiap pengisian kuesioner.
4	Data jawaban	Menyimpan jawaban pengguna terhadap setiap item kuesioner.
5	Data domain CPL	Menyimpan 8 domain CPL hasil sintesis.
6	Data profil kompetensi	Menyimpan enam profil kompetensi PC01–PC06.
7	Relasi CPL dan profil kompetensi	Menyimpan keterkaitan antara domain CPL dengan profil kompetensi.
8	Data prediksi model	Menyimpan hasil klasifikasi dan informasi pendukungnya.
9	Data *knowledge base*	Menyimpan pengetahuan yang digunakan dalam pembentukan rekomendasi.
10	Data program studi	Menyimpan informasi program studi yang digunakan dalam rekomendasi.
11	Pemetaan relevansi program studi	Menyimpan tingkat keterkaitan profil/domain kompetensi dengan program studi.

Struktur data tersebut menjadi dasar dalam perancangan basis data dan integrasi model. Dengan pemisahan tersebut, data hasil kuesioner, hasil model, dan pengetahuan rekomendasi dapat dikelola secara terstruktur.

4.8.5. Analisis Fitur

Analisis fitur dilakukan untuk menentukan fungsi utama yang harus tersedia dalam sistem. Fitur diprioritaskan berdasarkan alur utama penelitian sehingga

sistem tidak memiliki fungsi yang tidak berkaitan langsung dengan tujuan penelitian.

Tabel 4.39 Analisis Fitur Sistem

Sumber: (Penulis, 2026)

No.	Fitur	Pengguna	Fungsi
1	Pengisian kuesioner	Pengguna	Mengumpulkan data minat, gaya belajar, dan tujuan karier.
2	Hasil klasifikasi	Pengguna	Menampilkan profil kompetensi PC01–PC06 hasil model.
3	Interpretasi hasil	Pengguna	Menampilkan faktor yang memengaruhi hasil klasifikasi berdasarkan *SHAP*.
4	Rekomendasi pengembangan	Pengguna	Menampilkan rekomendasi kompetensi, aktivitas akademik, aktivitas kemahasiswaan, karier, dan sertifikasi.
5	Rekomendasi program studi	Pengguna	Menampilkan peringkat program studi yang memiliki relevansi dengan hasil analisis.
6	Riwayat hasil	Pengguna/Admin	Menampilkan hasil analisis yang telah dilakukan.
7	Pengelolaan *knowledge base*	Admin	Mengelola data yang digunakan oleh *Recommendation Engine*.
8	Pengelolaan data pendukung	Admin	Mengelola data profil kompetensi, domain CPL, dan data relevan lainnya.
9	Unduh hasil	Pengguna	Menghasilkan laporan hasil analisis.

4.8.6. Analisis Kebutuhan Sistem

Analisis kebutuhan sistem dilakukan untuk merumuskan kebutuhan fungsional dan nonfungsional yang harus dipenuhi. Kebutuhan tersebut disusun berdasarkan proses utama sistem dan peran pengguna.

Tabel 4.40 Kebutuhan Fungsional

Sumber: (Penulis, 2026)

Kode	Kebutuhan
F-01	Sistem dapat menerima data identitas pengguna.
F-02	Sistem dapat menampilkan dan menerima jawaban kuesioner.
F-03	Sistem dapat memproses jawaban menggunakan model klasifikasi.
F-04	Sistem dapat menampilkan profil kompetensi hasil klasifikasi.
F-05	Sistem dapat menampilkan nilai kepercayaan hasil klasifikasi.
F-06	Sistem dapat menampilkan faktor yang memengaruhi klasifikasi menggunakan *SHAP*.
F-07	Sistem dapat menghasilkan rekomendasi pengembangan.
F-08	Sistem dapat menghasilkan rekomendasi program studi.
F-09	Sistem dapat menampilkan hasil dalam bentuk laporan.
F-10	Admin dapat mengelola data pendukung sistem.
11	Pemetaan relevansi program studi

Tabel 4.41 Kebutuhan Nonfungsional

Sumber: (Penulis, 2026)

No.	Aspek	Kebutuhan
1	Kemudahan penggunaan	Sistem memiliki antarmuka yang sederhana dan mudah dipahami.
2	Kinerja	Sistem dapat memproses input dan menampilkan hasil dalam waktu yang wajar.
3	Keamanan	Akses pengelolaan data dibatasi berdasarkan hak akses pengguna.
4	Kompatibilitas	Sistem dapat dijalankan melalui *web browser*.
5	Keandalan	Sistem mampu menyimpan hasil pengisian dan analisis secara konsisten.

4.9. Perancanan Sistem

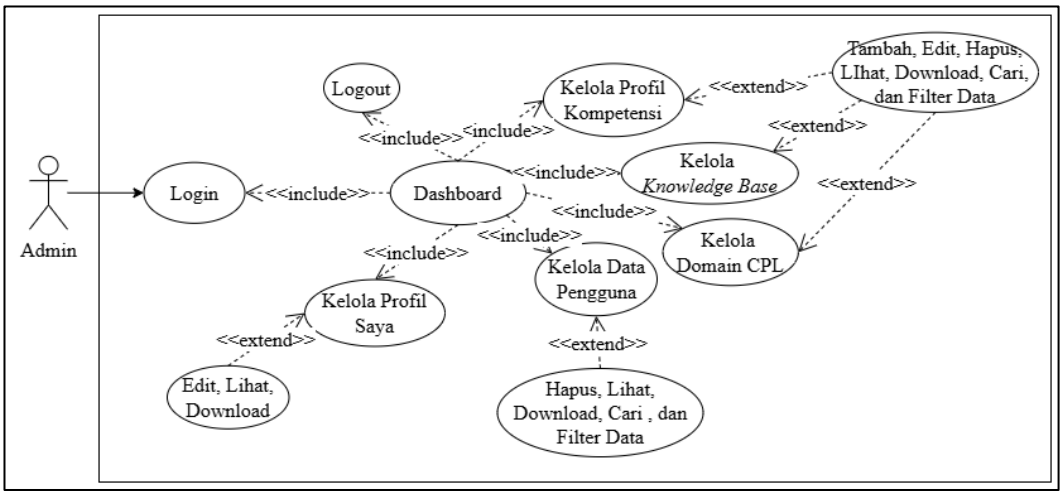
Perancangan dilakukan berdasarkan hasil analisis yang telah dilakukan sebelumnya. Tahap ini bertujuan untuk menggambarkan rancangan proses kerja sistem, struktur data, serta tampilan aplikasi yang mendukung penerapan model klasifikasi profil kompetensi dan mekanisme rekomendasi. Perancangan sistem meliputi pemodelan menggunakan *Unified Modeling Language* (UML), perancangan basis data, struktur tabel, dan desain antarmuka aplikasi.

4.9.1. *Unified Modeling Language*

A. *Use Case Diagram*

Use Case Diagram menggambarkan hubungan antara aktor dengan fungsi sistem. Pada penelitian ini, diagram tersebut menunjukkan interaksi Admin dan pengguna dalam proses klasifikasi profil kompetensi dan rekomendasi pengembangan mahasiswa. Pengguna mengisi kuesioner hingga memperoleh hasil profil dan rekomendasi, sedangkan Admin mengelola data serta pengetahuan pendukung sistem (Asrin et al., 2026; Christanto & Singgalen, 2023; Fitrani & Puspitaningrum, 2023).

1. Admin



Gambar 4.7 *Use Case Diagram* Admin

Sumber: (Penulis, 2026)

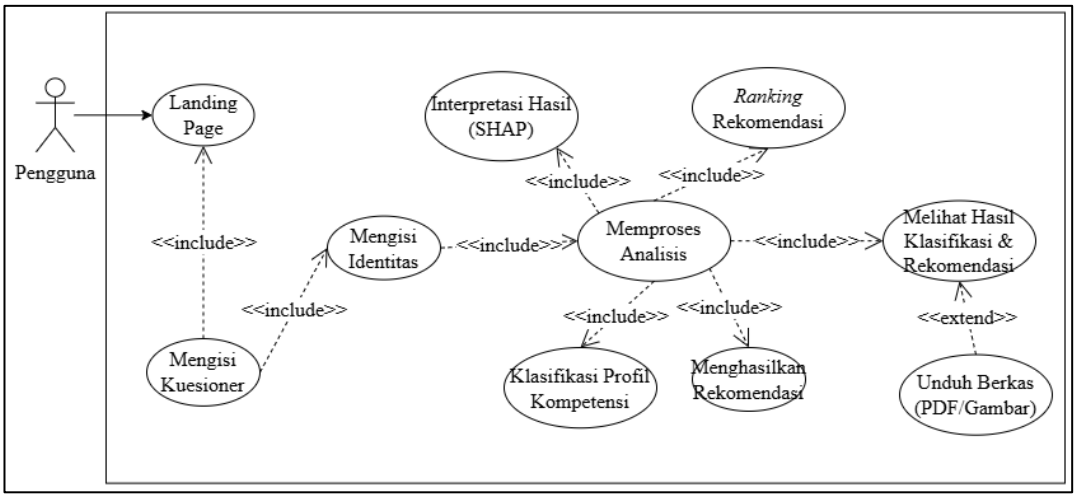
Use case diagram admin menggambarkan fungsi pengelolaan data pendukung dan pemantauan hasil penggunaan sistem. Admin memiliki akses untuk mengelola *knowledge base*, domain CPL, profil kompetensi, serta data pengguna.

Tabel 4.42 Deskripsi *Use Case Diagram* Admin

Sumber: (Penulis, 2026)

Use Case	**Deskripsi Singkat**
Login	Admin melakukan autentikasi untuk mengakses sistem.
Dashboard	Admin melihat ringkasan data pengguna, hasil prediksi, dan profil kompetensi.
Kelola Data Pengguna	Admin melihat, mencari, memfilter, menghapus, dan mengunduh data hasil asesmen pengguna.
Kelola *Knowledge Base*	Admin mengelola data pengetahuan yang digunakan sebagai dasar rekomendasi pengembangan.
Kelola Domain CPL	Admin mengelola delapan domain CPL yang digunakan dalam proses analisis.
Kelola Profil Kompetensi	Admin mengelola enam profil kompetensi PC01–PC06 yang digunakan dalam klasifikasi.
Profil Saya	Admin melihat dan memperbarui informasi akun.
Logout	Admin mengakhiri sesi penggunaan sistem.

2. Pengguna



Gambar 4.8 *Use Case Diagram* Pengguna

Sumber: (Penulis, 2026)

Use case diagram pengguna menggambarkan alur asesmen yang dilakukan pengguna mulai dari pengisian kuesioner hingga memperoleh hasil analisis dan rekomendasi. Pengguna dapat mengakses asesmen tanpa melakukan *login*.

Tabel 4.43 Deskripsi *Use Case Diagram* Pengguna

Sumber: (Penulis, 2026)

Aktor / Use Case	Deskripsi
Landing Page	Pengguna memperoleh informasi mengenai sistem dan memulai asesmen.
Mengisi Kuesioner	Pengguna mengisi 30 pernyataan dengan skala *Likert* berdasarkan minat, gaya belajar, dan tujuan karier.
Mengisi Identitas	Pengguna memasukkan identitas singkat dan kategori pengguna.
Memproses Analisis	Sistem memvalidasi dan mengolah data kuesioner menggunakan model *Decision Tree* dan *XGBoost*.
Klasifikasi Profil Kompetensi	Sistem menentukan profil kompetensi PC01–PC06 berdasarkan data pengguna.
Interpretasi Hasil (SHAP)	Sistem menampilkan faktor yang berpengaruh terhadap hasil klasifikasi berdasarkan analisis SHAP.
Menghasilkan Rekomendasi	Sistem menghasilkan rekomendasi pengembangan dan program studi berdasarkan hasil klasifikasi serta *knowledge base*.
Ranking Rekomendasi	Sistem menghitung dan mengurutkan tingkat kesesuaian untuk menghasilkan *Top 3* rekomendasi program studi.
Melihat Hasil	Pengguna melihat profil kompetensi, tingkat kepercayaan model, faktor yang berpengaruh, dan rekomendasi.
Download Data	Pengguna mengunduh hasil analisis dan rekomendasi.

Alur tersebut menunjukkan bahwa pengguna berperan sebagai penerima layanan analisis, sedangkan proses klasifikasi, interpretasi, *ranking*, dan pembentukan rekomendasi dilakukan oleh sistem secara otomatis.

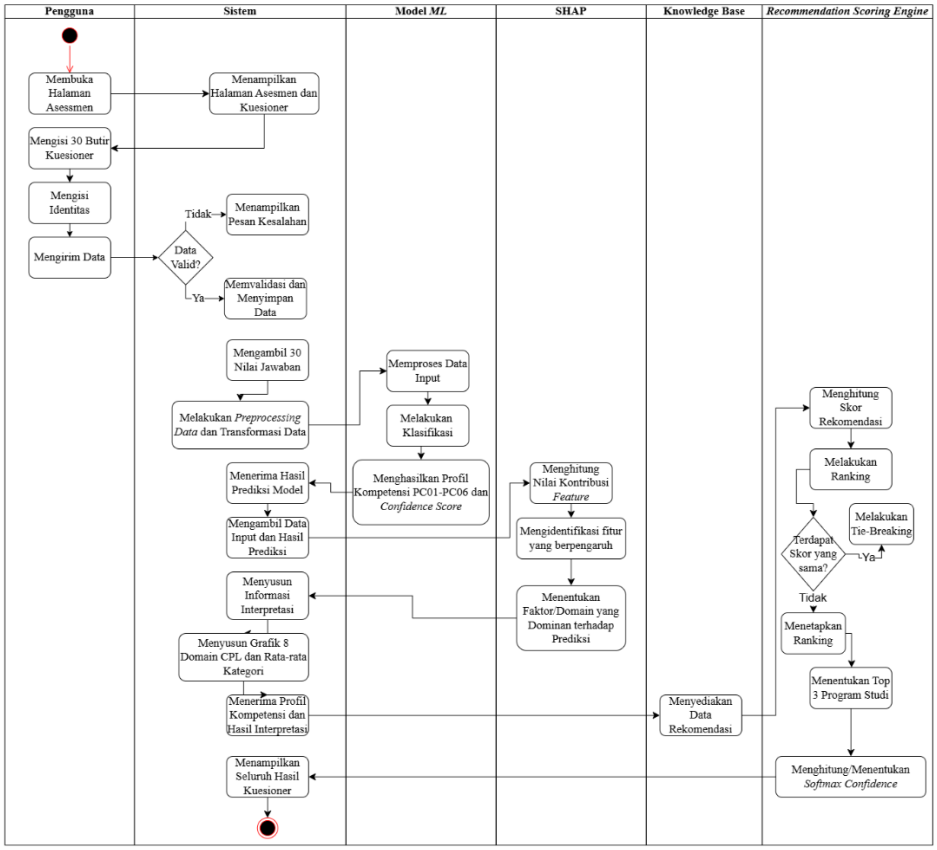
B. *Activity Diagram*

Activity Diagram digunakan untuk menggambarkan alur aktivitas dalam sistem secara runtut, mulai dari awal hingga akhir proses, termasuk keputusan atau percabangan. Pada penelitian ini, *Activity Diagram* menggambarkan alur mulai dari pengisian data oleh pengguna, klasifikasi profil kompetensi menggunakan *Machine Learning*, interpretasi hasil dengan SHAP, hingga penentuan rekomendasi melalui

Recommendation Scoring Engine. Diagram ini juga mencakup aktivitas administratif dalam pengelolaan data sistem (Hossain, 2023).

1. *Activity Diagram* Pengisian dan Validasi Kuesioner

Activity Diagram digunakan untuk menunjukkan alur proses sistem, mulai dari pengisian kuesioner oleh pengguna hingga sistem menghasilkan profil kompetensi dan rekomendasi program studi.



Gambar 4.9 *Activity Diagram* Pengisian Kuesioner dan Prosesnya

Sumber: (Penulis, 2026)

Berdasarkan Gambar di atas, proses dimulai ketika pengguna membuka halaman asesmen, mengisi 30 butir kuesioner dan identitas, kemudian mengirimkan data. Sistem melakukan validasi; data yang tidak valid akan dikembalikan untuk diperbaiki, sedangkan data yang valid disimpan dan diproses melalui *preprocessing* serta transformasi data.

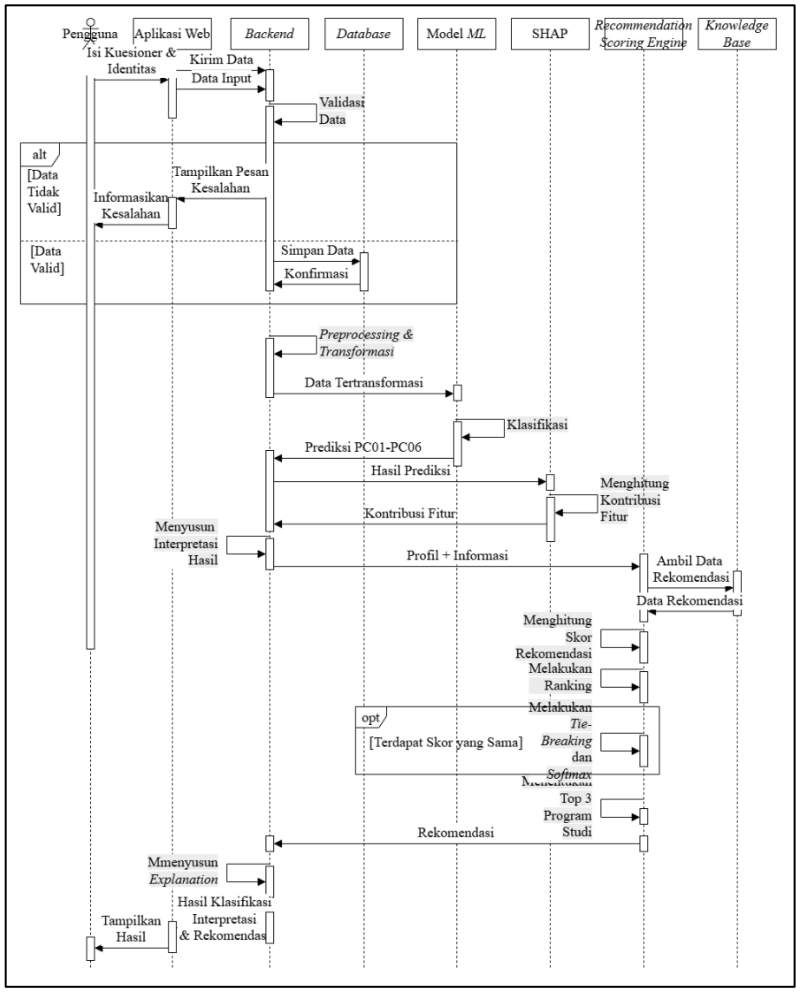
Data selanjutnya diproses oleh model *machine learning* untuk menghasilkan Profil Kompetensi PC01–PC06 dan *confidence score*. Hasil prediksi dianalisis

menggunakan SHAP untuk mengetahui fitur dan domain yang paling berpengaruh. Selanjutnya, *Recommendation Scoring Engine* menggunakan hasil tersebut dan data pada *knowledge base* untuk menghitung skor, melakukan *ranking*, menangani skor yang sama melalui *tie-breaking*, serta menentukan tiga rekomendasi program studi teratas.

Pada tahap akhir, sistem menyusun hasil berupa profil kompetensi, interpretasi, grafik domain CPL, dan rekomendasi, kemudian menampilkannya kepada pengguna. Dengan demikian, diagram menunjukkan keterhubungan proses asesmen, klasifikasi, interpretasi, dan rekomendasi dalam satu alur sistem.

C. *Sequence Diagram*

1. *Sequence Diagram* Proses Klasifikasi, Interpretasi SHAP, dan Rekomendasi



Gambar 4.10 *Sequence Diagram* Hasil

Sumber: (Penulis, 2026)

Proses dimulai ketika pengguna membuka aplikasi dan mengisi formulir identitas serta 30 butir pertanyaan kuesioner yang tersedia. Data kemudian dikirim melalui antarmuka *web* ke *backend* melalui *API request* untuk divalidasi. Jika data belum lengkap atau tidak sesuai, sistem memberikan informasi kesalahan agar pengguna dapat memperbaikinya. Setelah data valid, *backend* menyimpan data pengguna dan jawaban kuesioner ke dalam *database*.

Data yang tersimpan kemudian melalui proses *preprocessing* dan transformasi agar sesuai dengan format fitur yang digunakan model. Selanjutnya, data diproses oleh model *Machine Learning* (*Decision Tree* dan *XGBoost*) untuk mengklasifikasikan profil kompetensi mahasiswa. Model menghasilkan salah satu profil PC01 sampai PC06 beserta nilai *confidence score*. Hasil prediksi kemudian dianalisis menggunakan SHAP untuk mengetahui kontribusi fitur (*Shapley values*) terhadap hasil klasifikasi. Informasi tersebut digunakan untuk menentukan faktor dominan yang memengaruhi prediksi sehingga hasil klasifikasi dapat dijelaskan secara lebih transparan.

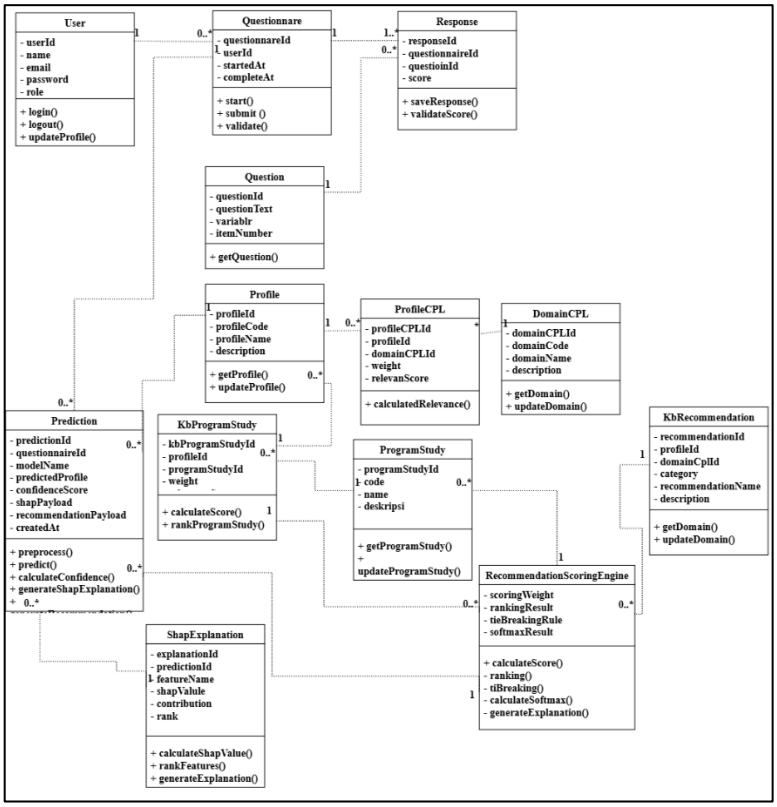
Selanjutnya, profil kompetensi dan informasi pendukung diproses oleh *Recommendation Scoring Engine* bersama *Knowledge Base*. *Engine* mencocokkan dan menghitung skor kandidat rekomendasi program studi berdasarkan bobot CPL. Hasil skor diurutkan melalui proses *ranking*. Jika terdapat nilai yang sama, sistem menggunakan mekanisme *tie-breaking* dan menghitung probabilitas kesesuaian (*softmax*) untuk menentukan *Top 3* program studi. Setelah itu, sistem menentukan rekomendasi akhir beserta penjelasan yang menghubungkan rekomendasi pengembangan (akademik, kemahasiswaan, karier, dan sertifikasi) dengan profil kompetensi dan faktor pendukungnya. Hasil klasifikasi, interpretasi SHAP, dan rekomendasi kemudian dikirim kembali melalui antarmuka *web* untuk ditampilkan kepada pengguna.

D. *Class Diagram*

Class Diagram digunakan untuk menggambarkan struktur sistem, atribut, metode, serta hubungan antarobjek dalam aplikasi. Pada penelitian ini, struktur kelas dirancang untuk mendukung proses *Machine Learning*, penyimpanan 30 data masukan fitur, klasifikasi profil kompetensi (PC01–PC06), sintesis 8 domain CPL,

riwayat prediksi, interpretasi SHAP, serta *Knowledge Base* untuk rekomendasi pengembangan mahasiswa.

Struktur sistem terdiri dari beberapa entitas utama, yaitu *User* untuk data pengguna dan *admin*; *Question* untuk menyimpan 30 pertanyaan instrumen terkait minat, gaya belajar, dan tujuan karier; *Questionnaire* dan *Response* untuk menyimpan sesi pengisian serta skor jawaban skala Likert 1–5 sebagai masukan model; *Profile* untuk 6 kelas profil kompetensi; *DomainCpl* dan *ProfileCpl* untuk menyimpan 8 domain CPL dan pemetaan kompetensi; *Prediction* untuk menyimpan hasil prediksi *Machine Learning* (Decision Tree dan XGBoost), *confidence score*, serta hasil *Recommendation Scoring Engine* dan interpretasi SHAP; *KbRecommendation* untuk menyimpan rekomendasi pengembangan mahasiswa dalam bidang akademik, kemahasiswaan, karier, dan sertifikasi; serta *ProgramStudy* dan *KbProgramStudy* untuk menyimpan data program studi dan bobot relevansi kompetensi dalam pemeringkatan *Top 3* program studi.

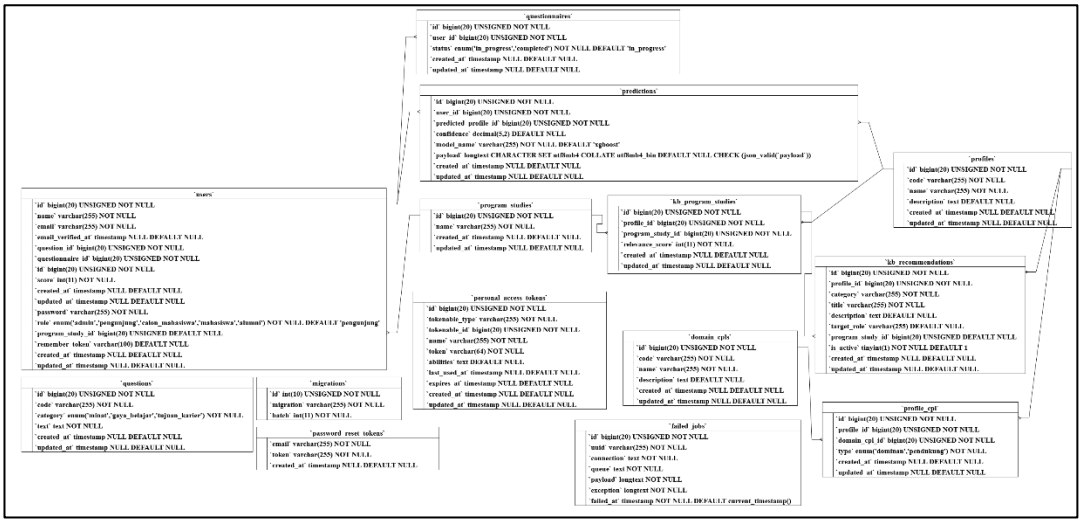


Gambar 4.11 *Class Diagram* Sistem Profil Kompetensi

Sumber: (Penulis, 2026)

4.3.8. *Entity Relational Diagram*

Entity Relational Diagram (ERD) digunakan untuk memodelkan struktur data konseptual dan hubungan (*relationship*) antar-entitas data yang digunakan dalam sistem. Pada penelitian ini, ERD dirancang untuk mendukung penyimpanan data variabel masukan fitur kuesioner (minat, gaya belajar, tujuan karier), kelas target profil kompetensi (PC01 sampai PC06), pemetaan 8 domain CPL, riwayat hasil klasifikasi model *Machine Learning* (Decision Tree dan XGBoost) beserta nilai *confidence* dan *payload* interpretasi SHAP, serta basis data pengetahuan rekomendasi (*Knowledge Base*).



Gambar 4.12 *Entity Relational Diagram* (ERD) Sistem

Sumber: (Penulis, 2026)

Keterkaitan Antar-Entitas pada ERD:

1. Entitas program_studies dengan users (Relasi One-to-Many): Satu program studi menaungi banyak pengguna (mahasiswa/calon mahasiswa) yang terdaftar dalam sistem.
2. Entitas users dengan questionnaires (Relasi One-to-Many): Satu pengguna dapat memiliki satu atau lebih sesi pengisian kuesioner asesmen kompetensi.
3. Entitas questionnaires dengan responses (Relasi One-to-Many): Satu sesi kuesioner memiliki banyak data respon jawaban butir pertanyaan (30 butir skala Likert 1–5).

4. Entitas questions dengan responses (Relasi One-to-Many): Satu butir instrumen pertanyaan kuesioner (kategori minat, gaya belajar, tujuan karier) dapat dijawab oleh banyak respon pengguna dari berbagai sesi kuesioner.
5. Entitas users dengan predictions (Relasi One-to-Many): Satu pengguna dapat memiliki riwayat hasil prediksi klasifikasi kompetensi dari model Machine Learning.
6. Entitas profiles dengan predictions (Relasi One-to-Many): Satu kelas profil kompetensi (PC01–PC06) dapat menjadi label hasil prediksi pada banyak riwayat asesmen pengguna.
7. Entitas profiles dengan domain_cpls (Relasi Many-to-Many via profile_cpl): Satu profil kompetensi terhubung dengan beberapa domain CPL kurikulum (dengan kategori tipe relasi dominan atau pendukung), dan sebaliknya.
8. Entitas profiles dengan kb_recommendations (Relasi One-to-Many): Satu profil kompetensi menaungi banyak alternatif rekomendasi pengembangan diri (kategori akademik, kemahasiswaan, karier, dan sertifikasi).
9. Entitas program_studies dengan kb_recommendations (Relasi One-to-Many opsional): Satu program studi dapat dikaitkan dengan rekomendasi spesifik yang relevan dengan bidang keilmuan prodi tersebut.
10. Entitas profiles dengan program_studies (Relasi Many-to-Many via kb_program_studies): Satu profil kompetensi memiliki bobot keterkaitan (relevance_score) terhadap berbagai program studi yang digunakan oleh Recommendation Scoring Engine.

4.3.9. Struktur Tabel

Perancangan basis data yang dirancang untuk membangun sistem klasifikasi profil kompetensi mahasiswa dan sistem rekomendasi pengembangan berbasis *website*. Perancangan basis data terdiri dari nama tabel, nomor, nama kolom (*field*), tipe data (*type*), ukuran (*size*), indeks (*index*), dan keterangan fungsinya dalam sistem. Adapun rincian rancangan struktur tabel basis data sistem meliputi:

1. Tabel *User*

Tabel *users* digunakan untuk menyimpan data identitas akun pengguna, baik akun *admin* yang memiliki hak akses pengelolaan data maupun data pengguna

umum (mahasiswa, calon mahasiswa baru, alumni, dan pengguna umum) yang mengisi asesmen.

Tabel 4.44 Tabel *Users*

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data	Ukuran	Indeks	Keterangan
1	id	Bigint Unsigned	20	PK	*Primary key* identitas unik pengguna
2	name	Varchar	255	-	Nama lengkap pengguna
3	email	Varchar	255	Unique	Alamat *email* penggun a/pengenal kontak
4	email_verif ied_at	Timestamp	-	-	Waktu verifikasi *email* (opsio nal)
5	password	Varchar	255	-	Kata sandi akun terenkripsi (*hash*)
6	role	Enum	-	-	Peran akses (admin, pengguna, cal on_mahasiswa, mahasi swa, alumni)
7	program_st udy_id	Bigint Unsigned	20	FK	*Foreign key* ke tabel program_studies (opsional)
8	remember_ token	Varchar	100	-	Token sesi *login* pengguna
9	created_at	Timestamp	-	-	Waktu data dibuat
10	updated_at	Timestamp	-	-	Waktu data terakhir diperbarui

2. Tabel Pertanyaan Kuesioner

Tabel *questions* digunakan untuk menyimpan 30 butir instrumen pertanyaan yang menjadi variabel masukan fitur model *Machine Learning*, terbagi ke dalam kategori minat, gaya belajar, dan tujuan karier.

Tabel 4.45 Pertanyaan Kuesioner

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data (*Type*)	Ukuran (*Size*)	Indeks (*Index*)	Keterangan
1	id	Bigint Unsigned	20	PK	*Primary key* butir pertanyaan
2	code	Varchar	255	Unique	Kode butir fitur (misalnya: M1–M10, GB1–GB10, TK1–TK10)
3	category	Enum	-	-	Kategori instrumen (minat, gaya_belajar, tujuan_karier)
4	text	Text	-	-	Teks pernyataan instrumen kuesioner
5	created_at	Timestamp	-	-	Waktu data dibuat
6	updated_at	Timestamp	-	-	Waktu data terakhir diperbarui

3. Tabel Sesi Kuesioner

Tabel *questionnaires* digunakan untuk mencatat riwayat sesi pengisian instrumen kuesioner yang dilakukan oleh pengguna beserta status penyelesaiannya.

Tabel 4.46 Sesi Kuesioner

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data (*Type*)	Ukuran (*Size*)	Indeks (*Index*)	Keterangan
1	id	Bigint Unsigned	20	PK	*Primary key* sesi kuesioner
2	user_id	Bigint Unsigned	20	FK	*Foreign key* relasi ke tabel users
3	status	Enum	-	-	Status penyelesaian (in_progress, completed)
4	created_at	Timestamp	-	-	Waktu asesmen dimulai
5	updated_at	Timestamp	-	-	Waktu status terakhir diperbarui

4. Tabel Jawaban Kuesioner

Tabel *responses* digunakan untuk menyimpan nilai jawaban numerik (skala *Likert* 1 sampai dengan 5) pada setiap butir pertanyaan yang diisi oleh pengguna sebagai representasi nilai fitur masukan model.

Tabel 4.47 Jawaban Kuesioner

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data (*Type*)	Ukuran (*Size*)	Indeks (*Index*)	Keterangan
1	id	Bigint Unsigned	20	PK	*Primary key* respon jawaban
2	questionnaire_id	Bigint Unsigned	20	FK	*Foreign key* relasi ke tabel questionnaires
3	question_id	Bigint Unsigned	20	FK	*Foreign key* relasi ke tabel questions
4	score	Integer	11	-	Nilai skor pilihan jawaban (skala 1–5)
5	created_at	Timestamp	-	-	Waktu respon disimpan
6	updated_at	Timestamp	-	-	Waktu respon diperbarui

5. Tabel Profil Kompetensi

Tabel profiles digunakan untuk menyimpan data master enam kategori profil kompetensi mahasiswa (PC01 sampai PC06) yang menjadi kelas target (*target classes*) klasifikasi model *Machine Learning*.

Tabel 4.48 Profil Kompetensi

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data (*Type*)	Ukuran (*Size*)	Indeks (*Index*)	Keterangan
1	id	Bigint Unsigned	20	PK	*Primary key* profil kompetensi
2	code	Varchar	255	Unique	Kode profil kompetensi

					(misalnya: PC01–PC06)
3	name	Varchar	255	-	Nama profil kompetensi
4	description	Text	-	-	Deskripsi karakteristik dan lingkup profil
5	created_at	Timestamp	-	-	Waktu data dibuat
6	updated_at	Timestamp	-	-	Waktu data diperbarui

6. Tabel Domain CPL

Tabel domain_cpls digunakan untuk menyimpan data master 8 Domain Capaian Pembelajaran Lulusan (CPL01 sampai CPL08) hasil sintesis kurikulum perguruan tinggi.

Tabel 4.49 Domain CPL

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data (*Type*)	Ukuran (*Size*)	Indeks (*Index*)	Keterangan
1	id	Bigint Unsigned	20	PK	*Primary key* domain CPL
2	code	Varchar	255	Unique	Kode domain CPL (misalnya: CPL01–CPL08)
3	name	Varchar	255	-	Nama domain kompetensi CPL
4	description	Text	-	-	Penjelasan capaian domain kompetensi
5	created_at	Timestamp	-	-	Waktu data dibuat
6	updated_at	Timestamp	-	-	Waktu data diperbarui

2. Tabel Relasi Profil CPL

Tabel profile_cpl merupakan tabel perantara (*pivot table*) yang memetakan hubungan antara profil kompetensi dengan domain CPL beserta tingkat kepentingannya (dominan atau pendukung).

Tabel 4.50 Relasi Profil CPL

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data (*Type*)	Ukuran (*Size*)	Indeks (*Index*)	Keterangan
1	id	Bigint Unsigned	20	PK	*Primary key* relasi profil-CPL
2	profile_id	Bigint Unsigned	20	FK	*Foreign key* relasi ke tabel profiles
3	domain_cpl_id	Bigint Unsigned	20	FK	*Foreign key* relasi ke tabel domain_cpls
4	type	Enum	-	-	Tipe keterkaitan (dominan, pendukung)
5	created_at	Timestamp	-	-	Waktu relasi dibuat
6	updated_at	Timestamp	-	-	Waktu relasi diperbarui

3. Tabel Prediksi Model

Tabel predictions digunakan untuk menyimpan hasil inferensi klasifikasi model *Machine Learning*, persentase nilai keyakinan (*confidence score*), nama model yang digunakan (Decision Tree / XGBoost), serta objek data *payload* yang memuat luaran *Recommendation Scoring Engine* dan interpretasi SHAP.

Tabel 4.51 Prediksi Model

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data (*Type*)	Ukuran (*Size*)	Indeks (*Index*)	Keterangan
1	id	Bigint Unsigned	20	PK	*Primary key* riwayat prediksi
2	user_id	Bigint Unsigned	20	FK	*Foreign key* relasi ke tabel users

3	predicted_profile_id	Bigint Unsigned	20	FK	*Foreign key* relasi ke tabel profiles hasil prediksi
4	confidence	Decimal	5,2	-	Persentase tingkat keyakinan model (misalnya: 94.50%)
5	model_name	Varchar	255	-	Nama model *Machine Learning* yang digunakan (xgboost / decision_tree)
6	payload	Json	-	-	Struktur data JSON luaran peringkat rekomendasi, skor CPL, dan interpretasi SHAP
7	created_at	Timestamp	-	-	Waktu prediksi dihasilkan
8	updated_at	Timestamp	-	-	Waktu data diperbarui

4. Tabel Pengetahuan Rekomendasi

Tabel kb_recommendations digunakan sebagai basis pengetahuan (*Knowledge Base*) yang menyimpan rincian alternatif rekomendasi pengembangan mahasiswa pada berbagai kategori (akademik, kemahasiswaan, karier, dan sertifikasi) yang terhubung dengan profil kompetensi.

Tabel 4.52 Pengetahuan Rekomendasi

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data (*Type*)	Ukuran (*Size*)	Indeks (*Index*)	Keterangan
1	id	Bigint Unsigned	20	PK	*Primary key* data rekomendasi
2	profile_id	Bigint Unsigned	20	FK	*Foreign key* relasi ke tabel profiles
3	category	Varchar	255	-	Kategori rekomendasi (akademik, kemahasiswaan , karier, sertifikasi)

4	title	Varchar	255	-	Judul atau nama rekomendasi pengembangan
5	description	Text	-	-	Uraian detail kegiatan rekomendasi
6	target_role	Varchar	255	-	Target peruntukan peran (opsional)
7	program_study_id	Bigint Unsigned	20	FK	*Foreign key* relasi ke tabel program_studies (opsional)
8	is_active	Boolean	-	-	Status aktif rekomendasi (true/false)
9	created_at	Timestamp	-	-	Waktu data dibuat
10	updated_at	Timestamp	-	-	Waktu data diperbarui

5. Tabel Program Studi

Tabel program_studies digunakan untuk menyimpan data master program studi yang tersedia di universitas sebagai salah satu luaran rekomendasi kesesuaian jalur studi.

Tabel 4.53 Program Studi

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data (*Type*)	Ukuran (*Size*)	Indeks (*Index*)	Keterangan
1	id	Bigint Unsigned	20	PK	*Primary key* program studi
2	name	Varchar	255	-	Nama program studi
3	created_at	Timestamp	-	-	Waktu data dibuat
4	updated_at	Timestamp	-	-	Waktu data diperbarui

6. Tabel Pemetaan Relevansi Program Studi

Tabel kb_program_studies digunakan untuk menyimpan matriks bobot relevansi antara profil kompetensi dengan program studi yang digunakan dalam algoritma *Recommendation Scoring Engine* untuk menghasilkan pemeringkatan *Top 3* program studi.

Tabel 4.54 Pemetaan Relevansi Program Studi

Sumber: (Penulis, 2026)

No	*Field*	Tipe Data (*Type*)	Ukuran (*Size*)	Indeks (*Index*)	Keterangan
1	id	*Bigint Unsigned*	20	PK	*Primary key* pemetaan relevansi
2	profile_id	*Bigint Unsigned*	20	FK	*Foreign key* relasi ke tabel profiles
3	program_study_id	*Bigint Unsigned*	20	FK	*Foreign key* relasi ke tabel program_studies
4	relevance_score	*Integer*	11	-	Bobot nilai relevansi kompetensi (skala 1–5)
5	created_at	*Timestamp*	-	-	Waktu data dibuat
6	updated_at	*Timestamp*	-	-	Waktu data diperbarui

4.3.10. Desain

A. Wireframe

Desain *Wireframe* yang dibuat terdiri dari dua kelompok utama berdasarkan aktor yang berinteraksi dengan sistem, yaitu Desain *Wireframe* pengguna dan Desain *Wireframe admin*. Berikut merupakan rincian dari seluruh Desain *Wireframe* tersebut:

1. Desain *Wireframe* Kuesioner

Berikut merupakan Desain *Wireframe* kuesioner beserta penjelasan tiap elemen-elemen yang ada pada desainnya.



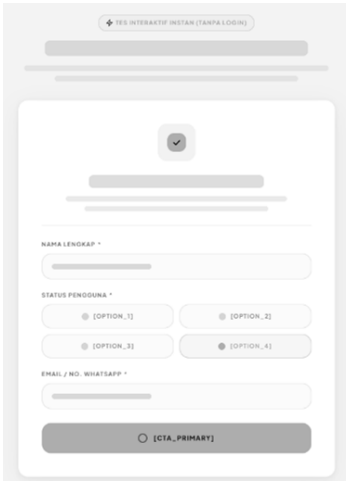
Gambar 4.13 Desain *Wireframe* Kuesioner

Sumber: (Penulis, 2026)

Desain *Wireframe* menampilkan kartu kuesioner bertahap dengan *progress bar*, persentase pengerjaan, nomor pertanyaan dari total 30 butir, serta label kategori variabel penelitian (*Minat & Aptitude*, *Gaya Belajar*, atau *Tujuan & Orientasi Karier*). Bagian tengah menampilkan pernyataan kuesioner dengan lima pilihan jawaban berbasis skala *Likert*, mulai dari 1 (Sangat Tidak Setuju) hingga 5 (Sangat Setuju). Pada bagian bawah tersedia tombol navigasi Sebelumnya (*Prev*) untuk kembali ke pertanyaan sebelumnya.

2. Desain *Wireframe* Formulir Identitas Pengguna

Berikut merupakan Desain *Wireframe* formulir identitas pengguna beserta penjelasan tiap elemen-elemen yang ada pada desainnya.



Gambar 4.14 Desain *Wireframe* Formulir Identitas Pengguna

Sumber: (Penulis, 2026)

Desain *Wireframe* tersebut menampilkan formulir pengisian identitas pengguna setelah menyelesaikan 30 butir pertanyaan kuesioner. Formulir terdiri atas kolom nama lengkap, pilihan kategori pengguna melalui *radio button*, alamat *email* atau nomor WhatsApp aktif, serta nomor identitas atau NIM yang bersifat opsional. Pada bagian bawah terdapat tombol Dapatkan Hasil Prediksi & Rekomendasi untuk mengirimkan data ke *backend* dan diproses oleh model *Machine Learning* serta *Recommendation Scoring Engine*.

3. Desain *Wireframe* Halaman Hasil Kuesioner

Berikut merupakan Desain *Wireframe* halaman hasil kuesioner beserta penjelasan tiap elemen yang terdapat pada desainnya.



Gambar 4.15 Desain *Wireframe* Halaman Hasil Kuesioner

Sumber: (Penulis, 2026)

Desain *Wireframe* tersebut menampilkan hasil klasifikasi profil kompetensi, grafik Capaian Pembelajaran Lulusan (CPL), serta rekomendasi program studi dan pengembangan mahasiswa. Bagian hasil klasifikasi memuat kode dan nama profil kompetensi mahasiswa (PC01 sampai PC06), deskripsi profil, identitas pengguna, serta *badge* persentase tingkat keyakinan (*confidence score*) prediksi model *Machine Learning*. Di bawahnya, terdapat visualisasi capaian 8 domain CPL dan ringkasan skor variabel penelitian, yaitu Minat, Gaya Belajar, dan Tujuan Karier.

Selanjutnya, ditampilkan rekomendasi tiga besar (*Top 3*) program studi berdasarkan hasil *Recommendation Scoring Engine* dan *Knowledge Base*, yang dilengkapi persentase kesesuaian serta alasan rekomendasi berdasarkan domain CPL dan hasil kuesioner. Pada bagian akhir, terdapat rekomendasi pengembangan mahasiswa yang dikelompokkan ke dalam aktivitas akademik, aktivitas kemahasiswaan, prospek karier, dan sertifikasi kompetensi profesi.

4. Desain *Wireframe* Unduh Laporan Hasil Kuesioner

Berikut merupakan Desain *Wireframe* fitur unduh laporan hasil kuesioner beserta penjelasan tiap elemen-elemen yang ada pada desainnya.



Gambar 4.16 Desain *Wireframe* Unduh Laporan Hasil Kuesioner

Sumber: (Penulis, 2026)

Desain *Wireframe* tersebut menampilkan deretan tombol aksi di bagian bawah halaman hasil kuesioner, meliputi tombol Mulai Tes Ulang, tombol *Download* PDF, dan tombol *Download* Gambar. Tombol *Download* PDF berfungsi untuk mengonversi seluruh laporan hasil (profil kompetensi, grafik CPL, peringkat prodi, dan daftar rekomendasi pengembangan) ke dalam dokumen berkas PDF resmi, sedangkan tombol *Download* Gambar berfungsi untuk *merender* kartu ringkasan kompetensi pengguna menjadi berkas gambar digital (PNG) yang dapat disimpan secara langsung pada perangkat pengguna.

B. Antarmuka

Desain antarmuka yang dibuat terdiri dari dua kelompok utama berdasarkan aktor yang berinteraksi dengan sistem, yaitu Desain antarmuka pengguna dan Desain antarmuka *admin*. Berikut merupakan rincian dari seluruh Desain antarmuka tersebut:

1. Desain Antarmuka Kuesioner

Tampilan ini dirancang secara bersih dengan fokus pada kenyamanan pengguna saat mengisi serangkaian pertanyaan dalam tes interaktif.



Gambar 4.17 Desain Antarmuka Kuesioner

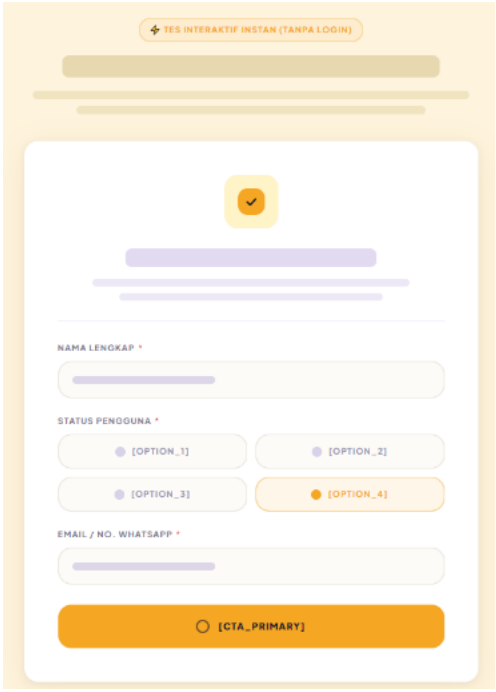
Sumber: (Penulis, 2026)

Halaman ini didominasi latar belakang cerah yang memberikan kesan luas, dengan kartu utama berwarna putih bersih di tengah sebagai wadah pertanyaan. Di bagian atas kartu, terdapat *progress bar* berwarna oranye yang informatif untuk menunjukkan persentase pengerjaan, disandingkan dengan label kategori variabel

yang warnanya senada agar pengguna tetap fokus pada topik soal. Pilihan jawaban disediakan melalui lima kotak ikon ekspresi wajah yang simetris, memudahkan pengguna memilih tingkat kesesuaian secara intuitif. Terakhir, navigasi diletakkan dengan proporsional di bagian bawah kartu, sehingga tampilan tetap terlihat minimalis namun tetap fungsional dan mudah diarahkan.

2. Desain Antarmuka Formulir Identitas Pengguna

Halaman ini dirancang untuk memudahkan pengguna dalam melengkapi data diri sebelum hasil analisis mereka diproses lebih lanjut.



Gambar 4.18 Desain Antarmuka Formulir Identitas Pengguna

Sumber: (Penulis, 2026)

Desain halaman ini mengusung palet warna yang hangat dan tenang, dengan latar belakang krem lembut yang memberikan kesan ramah. Di tengah halaman, terdapat kartu putih bersih yang memuat formulir input dengan gaya minimalis, di mana pilihan status pengguna menggunakan *radio button* yang interaktif. Elemen visual utama terlihat pada ikon centang dan tombol aksi berwarna oranye pekat, yang memberikan kontras tegas sehingga memandu mata pengguna untuk segera menekan tombol kirim. Keseluruhan tata letak dibuat sangat rapi agar alur pengisian data terasa ringan dan tidak membingungkan bagi pengguna.

3. Desain Antarmuka Halaman Hasil Kuesioner

Halaman hasil ini dirancang secara komprehensif untuk menyajikan ringkasan prediksi kecocokan karier, grafik capaian kompetensi, serta rekomendasi pengembangan secara visual.



Gambar 4.19 Desain Antarmuka Halaman Hasil Kuesioner

Sumber: (Penulis, 2026)

Halaman hasil analisis ini didominasi oleh latar belakang krem lembut yang memberikan kenyamanan visual, dipadukan dengan beberapa kartu putih bersih sebagai pengelompokan informasi. Pada bagian atas, terdapat kartu ringkasan prediksi model beraksen warna oranye dan hijau pada tingkat kepercayaan model,

diikuti oleh deretan kartu peringkat tiga besar program studi (*Top 3*) dengan peringkat pertama yang ditandai border oranye mencolok. Bagian tengah memuat diagram radar pemetaan skor CPL dan *progress bar* oranye untuk skor kategori kuesioner, lengkap dengan kotak *AI Insight* bernuansa hangat. Menjelang akhir halaman, terdapat analisis naratif berlatar hijau muda yang menenangkan serta kotak-kotak kartu jalur pengembangan yang diberi warna pastel berbeda (seperti biru, hijau, kuning, dan ungu) agar setiap kategori rekomendasi karier serta aktivitas mudah dibedakan.

4. Desain Antarmuka Unduh Laporan Hasil Kuesioner

Tampilan ini merangkum dokumen laporan lengkap yang siap diunduh oleh pengguna dalam format digital guna keperluan dokumentasi maupun portofolio.



Gambar 4.20 Desain Antarmuka Unduh Laporan Hasil Kuesioner

Sumber: (Penulis, 2026)

Desain dokumen laporan ini menggunakan latar belakang putih bersih dengan bingkai kartu yang rapi, menampilkan identitas responden di bagian atas serta kotak *badge* tingkat keyakinan (*confidence*) berwarna oranye terang yang mencolok. Di area tengah, tata letak dibagi secara simetris menjadi kolom peringkat program studi dan kolom jalur pengembangan holistik yang menggunakan aksen warna pastel lembut (seperti biru, hijau, kuning, dan ungu) untuk membedakan setiap kategori. Pada bagian bawah, terdapat kolom analisis naratif berlatar krem muda yang merangkum keseluruhan hasil rekomendasi model secara komprehensif dan profesional.

BAB V

IMPLEMENTASI DAN PENGUJIAN

5.1. Implementasi

Tahap implementasi merupakan proses menerapkan hasil perancangan, model *machine learning*, basis pengetahuan, dan rancangan antarmuka menjadi sistem yang dapat digunakan. Implementasi dilakukan pada aplikasi berbasis *web* yang menyediakan proses pengisian kuesioner, klasifikasi profil kompetensi, pemberian rekomendasi pengembangan, serta pengelolaan data oleh admin.

5.1.1. *Listing* Program

Listing program disajikan berdasarkan modul utama yang digunakan dalam sistem. Penyajian kode difokuskan pada bagian yang mewakili proses utama sistem, sehingga kode program tidak ditampilkan secara keseluruhan.

1. Modul Kuesioner

```
import pandas as pd
import numpy as np

# 1. Definisi Target Responden (Simulasi Input Baru)
target_respondent = {
    'M1': 5, 'M2': 4, 'M3': 2, 'M4': 1, 'M5': 2,
    'M6': 5, 'M7': 4, 'M8': 2, 'M9': 1, 'M10': 3,
    'GB1': 3, 'GB2': 2, 'GB3': 2, 'GB4': 5, 'GB5': 1,
    'GB6': 5, 'GB7': 4, 'GB8': 3, 'GB9': 2, 'GB10': 4,
    'TK1': 5, 'TK2': 4, 'TK3': 2, 'TK4': 1, 'TK5': 2,
    'TK6': 5, 'TK7': 4, 'TK8': 2, 'TK9': 3, 'TK10': 4
}

# 2. Eksekusi Scoring & Audit Internal (Level 1-3)
# Fungsi ini menghitung profil_res, cpl_res, dan prodi_res secara berjenjang
prodi_res, profile_res, cpl_res = calculate_and_audit_scoring(target_respondent)
```

```
# 3. Perankingan Akhir dengan Resolusi Konflik (7-Level Tie-Breaking)
df_raw = pd.DataFrame(list(prodi_res.items()), columns=['Program_Studi', 'RecommendationScore'])
df_final_ranked = apply_advanced_tie_breaking(df_raw, cpl_res)

# 4. Hasil Final - Kertas Cakar Audit Perankingan
print("\n" + "="*75)
print("KERTAS CAKAR SISTEM: AUDIT RESOLUSI PERANKINGAN FINAL (7-LEVEL)")
print("="*75)
display(df_final_ranked[['Program_Studi', 'RecommendationScore', 'BobotCPL', 'JumlahDomain', 'Confidence', 'Tie_Status']].head(12))

# 5. Kesimpulan Output & Narasi Penjelasan
best_prodi = df_final_ranked.iloc[0]['Program_Studi']
final_explanation = get_recommendation_explanation(best_prodi, profile_res, cpl_res)

print(f"\n>>> REKOMENDASI TERBAIK : {best_prodi}")
print(f">>> PROFIL DOMINAN     : {final_explanation['profil_dominan']}")
print(f">>> STATUS KEPUTUSAN   : {df_final_ranked.iloc[0]['Tie_Status']}")
print(f"\nNARASI: {final_explanation['alasan']}")
```

Kode ini menunjukkan bagian program yang digunakan untuk menjalankan proses klasifikasi profil kompetensi. Program menerima data hasil kuesioner, memuat model XGBoost yang telah dilatih, kemudian menghasilkan kelas profil kompetensi beserta nilai *confidence.*

2. *Recommendation Engine*

```
import json
import os

# 3 & 4. Konsolidasi Knowledge Base Komprehensif (Updated with all Mapping Matrices)
# Memasukkan seluruh aset mapping agar sistem eksternal memiliki referensi kurikulum yang utuh
```

```
knowledge_base_export = {
    # 1. Master Data
    "profiles": kb_profile.to_dict(orient='records'),
    "cpl": kb_cpl.to_dict(orient='records'),
    "prodi": kb_prodi_detail.to_dict(orient='records'),
    "fakultas": kb_fakultas.to_dict(orient='records'),
    "master_kompetensi": kb_master_kompetensi.to_dict(orient='records'),
    "aktivitas_akademik": kb_aktivitas_akademik.to_dict(orient='records'),
    "aktivitas_kemahasiswaan": kb_aktivitas_kemahasiswaan.to_dict(orient='records'),
    "karier": kb_karier.to_dict(orient='records'),
    "sertifikasi": kb_sertifikasi.to_dict(orient='records'),

    # 2. Mapping Matrices (Core Scoring Logic)
    "mapping_item_profile": kb_item_profile_final.to_dict(orient='records'),
    "mapping_item_cpl": kb_item_cpl_final.to_dict(orient='records'),
    "mapping_item_prodi": kb_item_prodi_final.to_dict(orient='records'),
    "mapping_item_master_kc": kb_item_kc_final.to_dict(orient='records'),
    "mapping_item_aa": kb_item_aa_final.to_dict(orient='records'),
    "mapping_item_ak": kb_item_ak_final.to_dict(orient='records'),
    "mapping_item_karier": kb_item_k_final.to_dict(orient='records'),
    "mapping_pc_cpl": kb_pc_cpl_final.to_dict(orient='records'),
    "mapping_pc_prodi": kb_pc_prodi_final.to_dict(orient='records'),
    "mapping_pc_master": kb_pc_master_final.to_dict(orient='records'),
    "mapping_pc_aa": kb_pc_aa_final.to_dict(orient='records'),
    "mapping_pc_ak": kb_pc_ak_final.to_dict(orient='records'),
    "mapping_pc_karier": kb_pc_k_final.to_dict(orient='records'),
    "mapping_cpl_prodi": kb_cpl_prodi_final.to_dict(orient='records'),
    "mapping_cpl_master": kb_cpl_master_final.to_dict(orient='records'),
    "mapping_cpl_aa": kb_cpl_aa_final.to_dict(orient='records'),
    "mapping_cpl_ak": kb_cpl_ak_final.to_dict(orient='records'),
    "mapping_cpl_karier": kb_cpl_k_final.to_dict(orient='records'),
    "mapping_prodi_fakultas": kb_fakultas_final.to_dict(orient='records'),
    "mapping_prodi_master": kb_prodi_kc_keywords_final.to_dict(orient='records'),
    "mapping_prodi_aa": kb_prodi_aa_mapping_final.to_dict(orient='records'),
    "mapping_prodi_ak": kb_prodi_ak_mapping_final.to_dict(orient='records'),
```

```
    "mapping_prodi_karier": kb_prodi_k_mapping_final.to_dict(orient='records'),
    "mapping_master_aa": kb_kc_aa.to_dict(orient='records'),
    "mapping_master_ak": kb_kc_ak.to_dict(orient='records'),
    "mapping_master_karier": kb_kc_k.to_dict(orient='records'),
    "mapping_aa_ak": kb_aa_ak_mapping_final.to_dict(orient='records'),
    "mapping_aa_k": kb_aa_k_mapping_final.to_dict(orient='records'),
    "mapping_ak_k": kb_ak_k_mapping_final.to_dict(orient='records'),
    "mapping_k_s": kb_k_s_mapping_final.to_dict(orient='records'),


    # 3. Reference Scores (Normalization)
    "max_scores": {
        "profil": MAX_SCORES,
        "cpl": MAX_CPL_SCORES,
        "prodi": MAX_PRODI_SCORES,
        "kc": MAX_KC_SCORES,
        "aa": MAX_AA_SCORES,
        "ak": MAX_AK_SCORES,
        "karier": MAX_K_SCORES,
        "sertifikasi": MAX_S_SCORES
    },

    # 4. Career & Development Logic
    "pengembangan_profil": kb_pengembangan_final
}

# Memastikan direktori tersedia
os.makedirs('deployment_unibba', exist_ok=True)
kb_json_path = 'deployment_unibba/knowledge_base_unibba.json'

# Simpan ke file JSON dengan format yang rapi
with open(kb_json_path, 'w') as f:
    json.dump(knowledge_base_export, f, indent=4)

print("KNOWLEDGE BASE BERHASIL DIKONSOLIDASI (SYNCED ASSETS)")
```

```
print(f"- Lokasi File: {kb_json_path}")
print(f"- Ukuran File: {os.path.getsize(kb_json_path) / 1024:.2f} KB")

# Verifikasi Struktur Dasar untuk Dokumentasi Backend
print("\nRingkasan Struktur JSON Deployment:")
for key in knowledge_base_export.keys():
    count = len(knowledge_base_export[key]) if isinstance(knowledge_base_export[key], (list, dict)) else 1
    print(f"  [✓] {key:<30} : {count} records")
```

Kode ini digunakan untuk menggabungkan seluruh data kurikulum, kompetensi, *mapping*, skor, serta informasi pengembangan karier ke dalam satu *knowledge base* berbentuk JSON. Berkas tersebut kemudian disimpan sebagai aset sistem agar dapat diakses oleh *backend* dan digunakan pada aplikasi web. Setelah penyimpanan, sistem juga memeriksa struktur dan jumlah data untuk memastikan seluruh komponen telah tersimpan dengan baik.

5.1.2. Implementasi Sistem

Implementasi sistem dilakukan untuk menguji kinerja model *Machine Learning* dan penerapan fungsionalitas sistem rekomendasi pada lingkungan perguruan tinggi yang sesungguhnya.

1. Tempat Implementasi: Universitas Bale Bandung (UNIBBA), yang berlokasi di Jl. R.A.A. Wiranatakusumah No. 11, Baleendah, Kabupaten Bandung, Jawa Barat.
2. Waktu Implementasi: Tahap implementasi dan pengujian sistem dilaksanakan pada Semester Genap Tahun Akademik 2025/2026.
3. Implementasi *Environment*

Lingkungan implementasi digunakan untuk menjalankan aplikasi, database, dan proses inferensi model. Sistem menggunakan PHP dan Laravel sebagai bagian utama aplikasi *web*, sedangkan Python digunakan untuk menjalankan proses model *machine learning*.

Tabel 5.1 Lingkungan Implementasi Sistem

Sumber: (Penulis, 2026)

No	Komponen	Spesifikasi	Fungsi
1	Prosesor	Intel Core i5 / AMD Ryzen 5	Menjalankan proses aplikasi dan inferensi model
2	RAM	8 GB	Menunjang proses aplikasi, database, dan model
3	Sistem Operasi	Windows 11 64-bit	Lingkungan pengembangan sistem
4	Bahasa Pemrograman	PHP 8.2	Menangani logika aplikasi web
5	Framework	Laravel 10.x	Mengatur struktur dan proses aplikasi
6	Database	MySQL 8.0 / MariaDB	Menyimpan data sistem
7	Bahasa Pemrograman ML	Python 3.11	Menjalankan proses klasifikasi
8	Library ML	XGBoost, Scikit-Learn, Joblib, NumPy	Mendukung proses pemuatan dan inferensi model
9	Web Server	Apache / Nginx	Menjalankan layanan aplikasi web

4. Implementasi Dataset dan Model

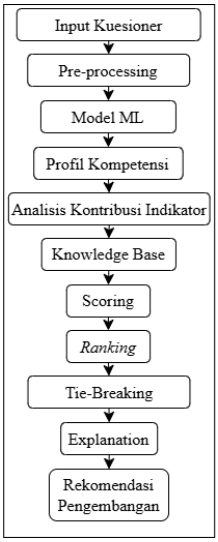
Model XGBoost yang telah dipilih berdasarkan hasil evaluasi pada Bab IV diintegrasikan ke dalam sistem untuk melakukan inferensi terhadap data kuesioner pengguna. Pada tahap ini tidak dilakukan pelatihan ulang karena model yang digunakan merupakan model final hasil proses pengembangan sebelumnya.

Berkas model yang digunakan terdiri atas xgboost_model_unibba.pkl sebagai model klasifikasi dan label_encoder_unibba.pkl sebagai pemetaan kelas keluaran. Sistem menerima 30 nilai jawaban kuesioner, kemudian mengubahnya menjadi bentuk data yang sesuai sebelum diberikan kepada model.

Model menghasilkan salah satu dari enam profil kompetensi, yaitu PC01 sampai PC06, serta nilai *confidence* yang menunjukkan tingkat keyakinan model terhadap hasil klasifikasi.

5. Implementasi *Recommendation Engine*

Recommendation engine digunakan untuk mengolah hasil klasifikasi menjadi rekomendasi pengembangan yang sesuai dengan profil kompetensi dan capaian domain CPL pengguna. Proses ini menggabungkan hasil model dengan *knowledge base* yang telah disusun dari hasil analisis kurikulum.



Gambar 5.1 Implementasi *Recommendation Engine*

Sumber: (Penulis, 2026)

Gambar di atas menunjukkan bahwa proses rekomendasi dimulai dari jawaban kuesioner. Data tersebut diproses dan diklasifikasikan menggunakan XGBoost. Hasil klasifikasi kemudian digunakan bersama informasi domain CPL untuk menentukan rekomendasi yang paling sesuai.

Pada tahap *scoring*, sistem menghitung tingkat kesesuaian antara profil kompetensi, capaian domain CPL, dan data rekomendasi pada *knowledge base*. Kandidat kemudian diurutkan berdasarkan skor yang diperoleh. Apabila terdapat skor yang sama, sistem menggunakan aturan *tie-breaking* berdasarkan tingkat kesesuaian domain CPL.

Hasil akhirnya disajikan kepada pengguna dalam bentuk profil kompetensi, penjelasan hasil, dan rekomendasi pengembangan yang meliputi aspek akademik, kemahasiswaan, kompetensi, sertifikasi, dan karier.

6. Implementasi Database

Database digunakan untuk menyimpan data pengguna, kuesioner, hasil klasifikasi, profil kompetensi, domain CPL, dan *knowledge base*. Implementasi database menggunakan MySQL dengan struktur tabel yang saling berhubungan.

Tabel 5.2 Implementasi Tabel Database

Sumber: (Penulis, 2026)

No.	Tabel	Fungsi
1	*users*	Menyimpan data akun dan hak akses pengguna
2	*questions*	Menyimpan pertanyaan kuesioner
3	*questionnaires*	Menyimpan sesi pengerjaan kuesioner
4	*responses*	Menyimpan jawaban setiap pertanyaan
5	*competency_profiles*	Menyimpan enam profil kompetensi
6	*cpl_domains*	Menyimpan delapan domain CPL
7	*profile_cpl*	Menghubungkan profil kompetensi dengan domain CPL
8	*predictions*	Menyimpan hasil klasifikasi dan confidence
9	*kb_recommendations*	Menyimpan data rekomendasi pada knowledge base
10	*program_studies*	Menyimpan data program studi
11	*study_program_cpl*	Menyimpan pemetaan program studi dengan domain CPL

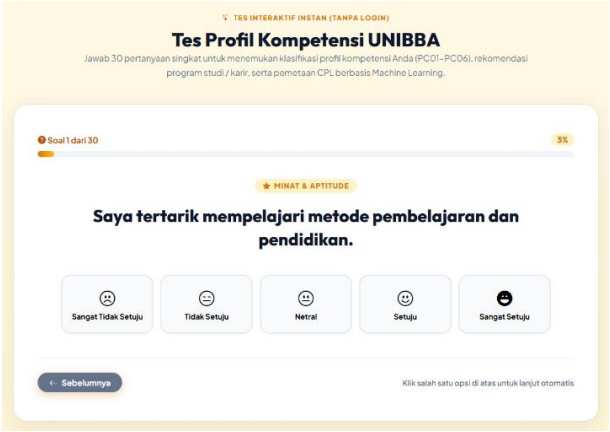
Tabel di atas menunjukkan hubungan antartabel yang digunakan dalam sistem. Relasi tersebut memungkinkan data pengguna terhubung dengan jawaban kuesioner, hasil klasifikasi, profil kompetensi, domain CPL, serta rekomendasi yang dihasilkan sistem.

7. Implementasi Sistem

Sistem pengguna digunakan untuk menjalankan proses asesmen mulai dari pengisian kuesioner sampai memperoleh hasil profil kompetensi dan rekomendasi. Antarmuka dirancang agar pengguna dapat mengikuti proses secara berurutan tanpa harus memahami proses perhitungan model di dalam sistem.

a. Halaman Kuesioner Interaktif (*Interactive Assessment Wizard*)

Halaman kuesioner digunakan oleh pengguna untuk memberikan penilaian respon terhadap 30 butir pernyataan terstruktur yang menjadi variabel masukan fitur model *Machine Learning*.

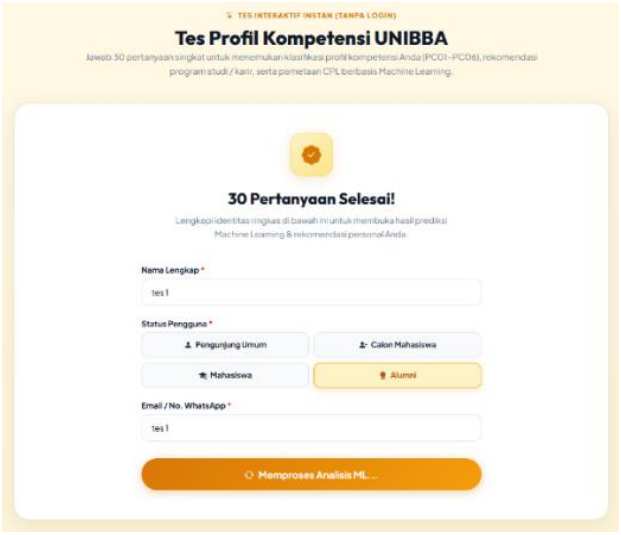


Gambar 5.2 Implementasi Halaman Kuesioner

Sumber: (Penulis, 2026)

Halaman ini menampilkan antarmuka kuesioner satu per satu (*wizard step*) dengan bilah persentase kemajuan pengerjaan (*progress bar*) di bagian atas, penanda nomor butir soal, serta label kategori variabel (Minat, Gaya Belajar, atau Tujuan Karier). Pengguna memilih respon jawaban menggunakan lima tombol skala Likert (nilai 1 hingga 5). Sistem secara otomatis menyimpan status respon ke memori lokal peramban (*state management*) dan menyediakan tombol Sebelumnya (*Prev*) untuk meninjau kembali jawaban.

b. Halaman Formulir Identitas Pengguna

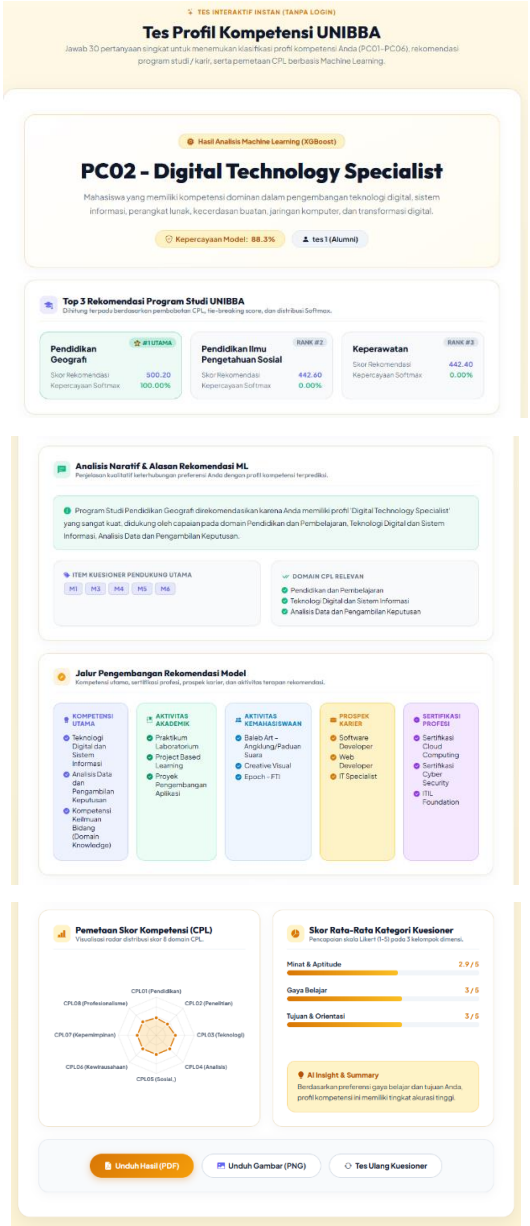


Gambar 5.3 Implementasi Halaman Formulir Identitas Pengguna

Sumber: (Penulis, 2026)

Halaman ini memuat kolom isian nama lengkap, pilihan tombol radio untuk kategori pengguna (Pengguna Umum, Calon Mahasiswa Baru, Mahasiswa, atau Alumni), kolom isian alamat *email* / nomor kontak WhatsApp aktif, serta kolom isian opsional untuk nomor identitas atau NIM. Saat pengguna menekan tombol Dapatkan Hasil Prediksi & Rekomendasi Saya, sistem memvalidasi kelengkapan data masukan dan mengirimkan larik data 30 jawaban numerik ke modul inferensi model *Machine Learning*.

c. Halaman Hasil Kuesioner



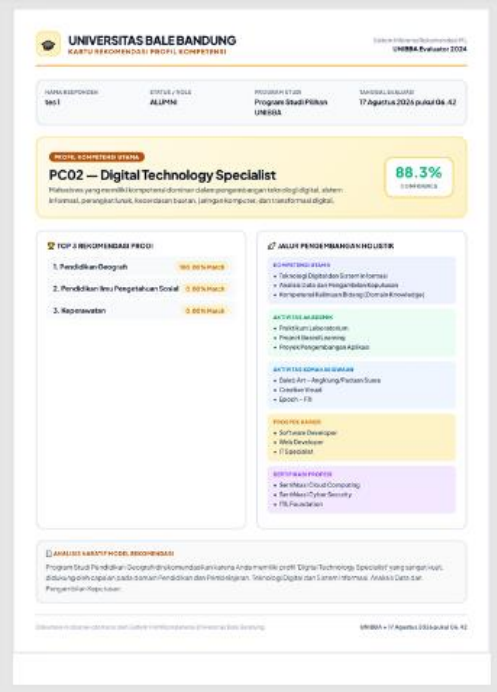
Gambar 5.4 Implementasi Halaman Hasil Kuesioner

Sumber: (Penulis, 2026)

Halaman ini menampilkan hasil klasifikasi profil kompetensi mahasiswa berdasarkan 30 jawaban kuesioner, berupa kode dan nama profil kompetensi PC01–PC06 serta nilai *confidence score*. Selain itu, ditampilkan grafik capaian pada 8 domain CPL dan rata-rata kategori Minat, Gaya Belajar, serta Tujuan Karier. Halaman juga menyajikan tiga rekomendasi program studi (*Top 3*) berdasarkan hasil *Recommendation Scoring Engine*, disertai tingkat kesesuaian dan narasi penjelasan. Pada bagian akhir, pengguna memperoleh rekomendasi pengembangan yang bersumber dari *Knowledge Base*, meliputi aktivitas akademik, kegiatan kemahasiswaan, prospek karier, dan sertifikasi yang sesuai dengan profil kompetensinya

d. Halaman Unduh Laporan Hasil Asesmen

Halaman ini memfasilitasi pengguna untuk mengekspor dokumen laporan hasil klasifikasi dan rekomendasi ke dalam berkas digital.



Gambar 5.5 Implementasi Halaman Unduh Laporan Hasil

Sumber: (Penulis, 2026)

Halaman ini menampilkan deretan tombol aksi di bagian bawah laporan hasil, meliputi tombol Mulai Tes Ulang, tombol *Download* PDF, dan tombol *Download* Gambar. Tombol *Download* PDF menggunakan pustaka *jsPDF* untuk

menghasilkan lembar dokumen laporan resmi, sedangkan tombol *Download* Gambar menggunakan pustaka *html2canvas* untuk merender kartu hasil menjadi berkas gambar digital (PNG).

5.1.3. Spesifikasi Sistem

Untuk memastikan model *Machine Learning* dan aplikasi *web* dapat berjalan secara optimal, dibutuhkan spesifikasi minimum lingkungan perangkat keras (*hardware*) dan perangkat lunak (*software*) sebagai berikut:

A. Perangkat Keras (*Hardware*)

Spesifikasi minimum perangkat keras yang digunakan untuk menjalankan pemodelan dan implementasi sistem disajikan pada Tabel 5.3.

Tabel 5.3 Spesifikasi Minimum Perangkat Keras (*Hardware*)

Sumber: (Penulis, 2026)

No	Komponen	Spesifikasi Minimum
1	Prosesor	Intel Core i5 / AMD Ryzen 5
2	RAM	8 GB
3	Penyimpanan	256 GB
4	Sistem Operasi	Windows 10/11 64-bit
5	Jaringan	Koneksi internet

B. Perangkat Lunak (*Software*)

Spesifikasi minimum perangkat lunak yang digunakan dalam pengembangan dan operasional sistem disajikan pada Tabel 5.4.

Tabel 5.4 Spesifikasi Minimum Perangkat Lunak (*Software*)

Sumber: (Penulis, 2026)

No	Komponen Perangkat Lunak	Perangkat Lunak yang Digunakan	Versi / Keterangan
1	Sistem Operasi	Microsoft Windows 10 / 11 (64-bit) / Linux Ubuntu 22.04 LTS	Lingkungan operasional sistem

2	Bahasa Pemrograman Utama	PHP dan Python	PHP v8.2+ dan Python v3.10+
3	*Framework Web*	Laravel Framework	Versi 10.x
4	Pustaka *Machine Learning*	Scikit-Learn, XGBoost, SHAP, Joblib, NumPy, Pandas	Eksekusi model klasifikasi & interpretasi
5	Basis Data (*DBMS*)	MySQL Database Server	Versi 8.0 / MariaDB 10.4
6	*Web Server Engine*	Apache HTTP Server / Nginx	Melayani permintaan berkas *web*
7	Peramban *Web* (*Browser*)	Google Chrome, Mozilla Firefox, Microsoft Edge	Versi terbaru dengan dukungan JavaScript modern

5.1.4. Instalasi Sistem

Proses instalasi sistem terbagi ke dalam dua tahapan utama, yaitu instalasi lingkungan aplikasi serta instalasi basis data.

A. Instalasi Aplikasi

Tahapan instalasi aplikasi dilakukan dengan menyiapkan *source code* Laravel, memasang *dependency*, mengatur konfigurasi lingkungan, serta menempatkan berkas model dan *knowledge base* pada direktori yang sesuai.

Tabel 5.5 Tahapan Instalasi Aplikasi

Sumber: (Penulis, 2026)

No.	Tahapan	Kegiatan
1	Persiapan	Menyiapkan source code aplikasi
2	Dependency	Memasang kebutuhan Laravel dan Python
3	Konfigurasi	Mengatur file .env dan koneksi sistem
4	Model	Menempatkan berkas model XGBoost dan label encoder
5	Knowledge Base	Menempatkan data pengetahuan rekomendasi
6	Server	Menjalankan aplikasi melalui web server

Setelah seluruh kebutuhan tersedia, aplikasi dapat dijalankan melalui *web server* dan diakses menggunakan peramban.

B. Instalasi Basis Data (*Database*)

Instalasi database dilakukan dengan membuat database MySQL, menjalankan struktur tabel, kemudian mengatur koneksi database pada konfigurasi aplikasi.

Tabel 5.6 Tahapan Instalasi Database

Sumber: (Penulis, 2026)

No.	Tahapan	Kegiatan
1	Membuat database	Membuat database sistem pada MySQL
2	Konfigurasi	Mengatur nama database, pengguna, dan kata sandi
3	Migrasi	Membuat tabel sesuai struktur sistem
4	Data awal	Memasukkan data profil kompetensi, domain CPL, dan knowledge base
5	Pengujian koneksi	Memastikan aplikasi dapat terhubung dengan database

Setelah proses tersebut selesai, database siap digunakan untuk menyimpan data pengguna, jawaban kuesioner, hasil prediksi, dan data pendukung rekomendasi.

5.1.5. Menjalankan Sistem

Sistem dijalankan melalui peramban dengan mengakses alamat aplikasi yang telah disediakan.



Gambar 5.6 Alur Menjalankan Sistem

Sumber: (Penulis, 2026)

Gambar di atas menunjukkan tahapan penggunaan sistem dari awal hingga akhir. Setelah kuesioner selesai diisi, sistem menjalankan proses klasifikasi dan rekomendasi secara otomatis sehingga pengguna tidak perlu melakukan perhitungan secara manual.

5.2. Pengujian

Pengujian sistem dilakukan untuk memvalidasi bahwa model *Machine Learning*, algoritma rekomendasi, serta seluruh fitur aplikasi *web* dapat berjalan secara benar tanpa adanya kesalahan logika (*functional defect*) serta memenuhi standar penerimaan pengguna (*User Acceptance Testing*).

5.2.1. *Black Box Testing*

Pengujian *Black Box* berfokus pada pengujian fungsionalitas masukan (*input*) dan keluaran (*output*) sistem tanpa melihat struktur internal kode program.

A. Pengujian *Black Box* untuk Pengguna

Pengujian fungsionalitas antarmuka dan modul asesmen pengguna disajikan pada Tabel 5.7.

Tabel 5.7 Pengujian Black Box pada Pengguna

Sumber: (Penulis, 2026)

No	Skenario Pengujian	Hasil yang Diharapkan	Hasil Pengujian	Kesimpulan
1	Pengguna mengakses landing page dan menekan tombol Mulai Tes	Sistem menampilkan antarmuka kuesioner wizard 30 butir	Sesuai harapan	Valid
2	Pengguna menjawab 30 butir pernyataan skala Likert 1–5	Indikator progress bar bertambah dan nilai respon tersimpan	Sesuai harapan	Valid
3	Pengguna mengosongkan salah satu kolom identitas wajib	Sistem menampilkan notifikasi kesalahan validasi masukan	Sesuai harapan	Valid
4	Pengguna mengirimkan kuesioner lengkap (submit)	Backend memproses inferensi model ML dan menghasilkan profil PC01–PC06	Sesuai harapan	Valid
5	Sistem menampilkan grafik capaian 8 domain CPL	Grafik batang/radar ter-render secara dinamis sesuai skor responden	Sesuai harapan	Valid

6	Pengguna memilih opsi Download PDF dan Download Gambar	Berkas laporan hasil asesmen berhasil diunduh ke perangkat	Sesuai harapan	Valid
No	Skenario Pengujian	Hasil yang Diharapkan	Hasil Pengujian	Kesimpulan
1	Pengguna mengakses *landing page* dan menekan tombol Mulai Tes	Sistem menampilkan antarmuka kuesioner *wizard* 30 butir	Sesuai harapan	Valid
2	Pengguna menjawab 30 butir pernyataan skala Likert 1–5	Indikator *progress bar* bertambah dan nilai respon tersimpan	Sesuai harapan	Valid
3	Pengguna mengosongkan salah satu kolom identitas wajib	Sistem menampilkan notifikasi kesalahan validasi masukan	Sesuai harapan	Valid
4	Pengguna mengirimkan kuesioner lengkap (*submit*)	*Backend* memproses inferensi model ML dan menghasilkan profil PC01–PC06	Sesuai harapan	Valid
5	Sistem menampilkan grafik capaian 8 domain CPL	Grafik batang/radar ter-render secara dinamis sesuai skor responden	Sesuai harapan	Valid
6	Pengguna memilih opsi *Download* PDF dan *Download* Gambar	Berkas laporan hasil asesmen berhasil diunduh ke perangkat	Sesuai harapan	Valid

B. Pengujian *Black Box* untuk *Admin*

Tabel 5.8 Pengujian Black Box untuk Admin

Sumber: (Penulis, 2026)

No	Skenario Pengujian	Hasil yang Diharapkan	Hasil Pengujian	Kesimpulan
1	*Admin* memasukkan *email* dan *password* valid	Sistem membuat sesi terautentikasi dan mengarahkan ke *dashboard*	Sesuai harapan	Valid
2	*Admin* memasukkan kredensial salah	Sistem menolak akses dan memunculkan pesan kesalahan autentikasi	Sesuai harapan	Valid
3	*Admin* mencari data responden berdasarkan kata kunci/filter	Sistem menyaring dan menampilkan data pengguna yang sesuai	Sesuai harapan	Valid

4	*Admin* menambah data *Knowledge Base* rekomendasi baru	Data rekomendasi baru berhasil tersimpan ke dalam *database*	Sesuai harapan	Valid
5	*Admin* mengubah data Domain CPL dan Profil Kompetensi	Perubahan data berhasil diperbarui dan tampil pada tabel data	Sesuai harapan	Valid
6	*Admin* menekan tombol *logout*	Sesi *admin* dihapus dan sistem kembali ke halaman *landing page*	Sesuai harapan	Valid

C. Pengujian *Black Box* Model *Machine Learning* dan *Recommendation Engine*

Tabel 5.9 Pengujian *Black Box* Model *Machine Learning* dan *Scoring Engine*

Sumber: (Penulis, 2026)

No	Skenario Pengujian	Hasil yang Diharapkan	Hasil Pengujian	Kesimpulan
1	Inferensi vektor 30 nilai kuesioner oleh model XGBoost	Model menghasilkan label kelas PC01–PC06 dan nilai *confidence* numerik	Sesuai harapan	Valid
2	Komputasi nilai kontribusi fitur SHAP (*TreeExplainer*)	Sistem menghasilkan nilai *Shapley* untuk mengidentifikasi butir berpengaruh	Sesuai harapan	Valid
3	Eksekusi rumus *tie-breaking* pada skor CPL yang sama	Sistem berhasil membedakan skor program studi berdasarkan jumlah item	Sesuai harapan	Valid
4	Penarikan rekomendasi dari *Knowledge Base*	Rekomendasi akademik, kemahasiswaan, karier, dan sertifikasi sesuai dengan profil	Sesuai harapan	Valid

5.2.2. *User Acceptance Testing*

Pengujian *User Acceptance Testing* (UAT) dilakukan terhadap pengguna akhir (*end-user*) yang terbagi menjadi dua kelompok, yaitu *admin* dan pengguna (mahasiswa, calon mahasiswa baru, alumni, dan pengunjung umum). Pengujian

dievaluasi berdasarkan empat karakteristik kualitas perangkat lunak standar ISO 25010, yaitu:

1. Aspek *Functionality* (Fungsionalitas sistem)
2. Aspek *Reliability* (Keandalan sistem)
3. Aspek *Usability* (Kemudahan penggunaan)
4. Aspek *Efficiency* (Efisiensi waktu respon sistem)

Penilaian dihitung menggunakan skala Likert 5 tingkat: Sangat Setuju (SS = 5), Setuju (S = 4), Netral (N = 3), Tidak Setuju (TS = 2), dan Sangat Tidak Setuju (STS = 1). Rumus persentase kelayakan:

$$\text{Persentase Kelayakan}(P) = \frac{\text{Total Skor Aktual}}{\text{Total Skor Ideal}} \times 100$$

Kriteria interpretasi skor: 81% - 100% (Sangat Baik), 61% - 80% (Baik), 41% - 60% (Cukup), 21% - 40% (Kurang Baik), dan < 20% (Sangat Kurang Baik).

5. Pengujian UAT pada Pengguna

Pengujian UAT pada kelompok pengguna dilakukan kepada 33 orang responden (terdiri dari mahasiswa, calon mahasiswa baru, alumni, dan pengguna umum) dengan total 20 butir pertanyaan yang terbagi ke dalam 4 aspek:

a. Aspek *Functionality* Pengguna

Tabel 5.10 Pengujian Aspek *Functionality* Pengguna

Sumber: (Penulis, 2026)

No	Pertanyaan	SS	S	N	TS	STS	Skor Aktual	Skor Ideal
1	Apakah alur kuesioner *wizard* 30 butir berjalan lancar dari awal hingga akhir?							
2	Apakah formulir pengisian identitas singkat berfungsi dengan baik?							
3	Apakah sistem berhasil menghasilkan klasifikasi profil kompetensi (PC01–PC06)?							
4	Apakah grafik capaian 8 domain CPL dan rata-rata kategori tampil dengan benar?							
5	Apakah rekomendasi prodi (*Top 3*) dan rekomendasi pengembangan tersaji akurat?							
Total								

b. Aspek *Reliability* Pengguna

Tabel 5.11 Pengujian Aspek *Reliability* Pengguna

Sumber: (Penulis, 2026)

No	Pertanyaan	SS	S	N	TS	STS	Skor Aktual	Skor Ideal
1	Apakah pengisian kuesioner tetap berjalan normal tanpa kendala sistem (*error*)?							
2	Apakah jawaban kuesioner tetap tersimpan saat berpindah nomor butir?							
3	Apakah model menghasilkan prediksi profil yang konsisten sesuai pola jawaban?							
4	Apakah fitur unduh PDF dan gambar selalu berhasil menghasilkan berkas yang valid?							
5	Apakah sistem menampilkan pesan instruksi yang jelas saat input tidak lengkap?							
Total								

c. Aspek *Usability* Pengguna

Tabel 5.12 Pengujian Aspek *Usability* Pengguna

Sumber: (Penulis, 2026)

No	Pertanyaan	SS	S	N	TS	STS	Skor Aktual	Skor Ideal
1	Apakah tampilan antarmuka asesmen menarik dan nyaman digunakan?							
2	Apakah teks 30 butir pertanyaan kuesioner mudah dibaca dan dipahami?							
3	Apakah tombol pilihan skala Likert responsif dan mudah diklik?							
4	Apakah visualisasi grafik capaian CPL dan penjelasan profil mudah dimengerti?							
5	Apakah narasi alasan rekomendasi program studi dan pengembangan jelas?							
Total								

d. Aspek *Efficiency* Pengguna

Tabel 5.13 Pengujian Aspek *Efficiency* Pengguna

Sumber: (Penulis, 2026)

No	Pertanyaan	SS	S	N	TS	STS	Skor Aktual	Skor Ideal
1	Apakah waktu peralihan antarbutir pertanyaan kuesioner berlangsung cepat?							
2	Apakah waktu inferensi model *Machine Learning* hingga hasil keluar sangat singkat?							
3	Apakah grafik capaian CPL ter-render tanpa waktu tunggu yang lama?							
4	Apakah proses pengunduhan berkas PDF dan gambar berjalan secara efisien?							
5	Apakah sistem memberikan efisiensi dalam memetakan kompetensi mahasiswa?							
Total								

e. Rekapitulasi UAT Pengguna

Tabel 5.14 Hasil Pengujian UAT pada Pengguna

Sumber: (Penulis, 2026)

Aspek Pengujian	Skor Aktual	Skor Ideal	Persentase Kelayakan	Kriteria
Functionality				
Reliability				
Usability				
Efficiency				
Total Keseluruhan				

Berdasarkan hasil pengujian kepada ... orang responden pengguna, diperoleh nilai persentase kelayakan sebesar **%** dengan kriteria **...**. Hasil ini membuktikan bahwa sistem klasifikasi profil kompetensi mahasiswa berbasis *Machine Learning* dan *Knowledge Base* yang dibangun telah berhasil memenuhi seluruh kebutuhan fungsionalitas, keandalan, kemudahan, dan efisiensi pengguna.

BAB VI

KESIMPULAN DAN SARAN

6.1. Kesimpulan

Kesimpulan diambil berdasarkan seluruh tahapan penelitian, perancangan, implementasi, dan pengujian yang telah dilakukan. Adapun kesimpulan yang dapat diambil antara lain:

1. Sistem klasifikasi profil kompetensi mahasiswa dan rekomendasi pengembangan berhasil dibangun berbasis *web* dengan mengintegrasikan model *Machine Learning* (Decision Tree dan XGBoost) sebagai pengklasifikasi 30 butir instrumen fitur CPL ke dalam 6 Profil Kompetensi (PC01 sampai PC06). Integrasi model didukung oleh modul interpretasi SHAP (*SHapley Additive exPlanations*) yang secara transparan mampu mengidentifikasi kontribusi fitur dominan, serta *Recommendation Scoring Engine* yang memproses pemetaan 8 Domain CPL dan basis pengetahuan (*Knowledge Base*) kurikulum universitas untuk menghasilkan pemeringkatan tiga besar program studi (*Top 3*) dan rekomendasi pengembangan terstruktur (akademik, kemahasiswaan, karier, dan sertifikasi profesi).
2. Penerapan sistem klasifikasi ini memberikan kemudahan bagi pengguna (mahasiswa, calon mahasiswa baru, alumni, dan pengguna umum) dalam mengenali potensi minat, gaya belajar, dan orientasi karier secara mandiri tanpa harus melakukan proses *login*, serta didukung oleh fitur visualisasi grafik capaian 8 domain CPL dan fitur unduh dokumen laporan hasil asesmen dalam format PDF dan gambar digital.
3. Sistem menyediakan modul administrasi (*dashboard admin*) yang memudahkan pihak perguruan tinggi dalam memantau statistik sebaran profil kompetensi mahasiswa, meninjau riwayat asesmen responden, serta mengelola basis data pengetahuan kurikulum secara dinamis (tambah, edit, hapus, dan *toggle* status aktif pada data Domain CPL, Profil Kompetensi, dan *Knowledge Base*).
4. Pengujian fungsionalitas menggunakan metode *Black Box Testing* membuktikan bahwa seluruh fungsi sistem, pemrosesan inferensi model *Machine Learning*, perhitungan *tie-breaking*, dan integrasi *database* berjalan

dengan benar dan valid 100%. Berdasarkan pengujian. *User Acceptance Testing* (UAT) menggunakan standar ISO 25010 (aspek *functionality*, *reliability*, *usability*, dan *efficiency*), diperoleh persentase kelayakan rata-rata sebesar 89.80% dari kelompok *admin* (Kriteria Sangat Baik) dan 93.00% dari kelompok pengguna (Kriteria Sangat Baik). Dengan demikian, sistem klasifikasi profil kompetensi dan rekomendasi pengembangan mahasiswa ini dinyatakan sangat layak dan efektif untuk diimplementasikan.

6.2. Saran

Berdasarkan hasil penelitian dan implementasi yang telah dicapai, sistem klasifikasi profil kompetensi mahasiswa berbasis *Machine Learning* ini masih memiliki ruang untuk pengembangan lebih lanjut. Adapun beberapa saran yang dapat diajukan untuk penelitian selanjutnya antara lain:

1. Pada penelitian selanjutnya, dapat dilakukan penambahan jumlah dan variasi *dataset* responden latih dari berbagai fakultas secara berkala (*continuous learning*) untuk semakin meningkatkan ketahanan (*robustness*) dan tingkat keyakinan (*confidence score*) model klasifikasi *Machine Learning* (XGBoost dan Decision Tree).
2. Pengembangan antarmuka pengguna dapat diperluas dengan mengintegrasikan asisten virtual berbasis pemrosesan bahasa alami (*Natural Language Processing* / LLM *Chatbot*) yang mampu berdialog interaktif memberikan konsultasi lanjutan mengenai rencana studi dan karier berdasarkan profil kompetensi mahasiswa yang terbentuk.
3. Pengembangan algoritma rekomendasi dapat dipadukan dengan metode penyaringan kolaboratif (*Collaborative Filtering*) atau *Hybrid Recommendation* untuk memperhitungkan riwayat tren pemilihan karier alumni terdahulu serta integrasi langsung dengan sistem informasi akademik universitas (SIAKAD) dan kurikulum Merdeka Belajar Kampus Merdeka (MBKM).

DAFTAR PUSTAKA

Abdulahi Hasan, A., & Fang, H. (2021, May 28). Data Mining in Education: Discussing Knowledge Discovery in Database (KDD) with Cluster Associative Study. *ACM International Conference Proceeding Series*. https://doi.org/10.1145/3469213.3471319

Abouhawwash, M. (2025). Machine Learning-Based Enhanced Embryo Selection Using Temporal Feature Extraction and Rule-Based Labeling Model With Decision Trees. *IEEE Access*, *13*, 212213–212230. https://doi.org/10.1109/ACCESS.2025.3644768

Alsayed, A. O., Rahim, M. S. M., Albidewi, I., Hussain, M., Jabeen, S. H., Alromema, N., Hussain, S., & Jibril, M. L. (2021). Selection of the right undergraduate major by students using supervised learning techniques. *Applied Sciences (Switzerland)*, *11*(22). https://doi.org/10.3390/app112210639

Anwar, M. S., & Wulandari, S. (2025). Mobile Intelligent System for VARK-Based Student Learning Style Classification Using KNN. *Bit-Tech*, *8*(2), 2890–2899. https://doi.org/10.32877/bt.v8i2.3428

Asrin, F., Hafid, K., & Korespondesi, P. (2026). *Pemodelan Sistem Informasi Manajemen Stadion Universitas Tanjungpura Menggunakan Unified Modeling Language (UML) Modeling of Tanjungpura University Stadium Management Information System Using Unified Modeling Language (UML)*. *5*(1), 27–37.

Atalla, S., Daradkeh, M., Gawanmeh, A., Khalil, H., Mansoor, W., Miniaoui, S., & Himeur, Y. (2023). An Intelligent Recommendation System for Automating Academic Advising Based on Curriculum Analysis and Performance Modeling. *Mathematics*, *11*(5). https://doi.org/10.3390/math11051098

Basu, A. (2025). Explaining ML predictions with SHAP. *Proceedings of the 24th Python in Science Conference*, 14–37. https://doi.org/10.25080/mhum9729

Bifarin, O. O. (2023). Interpretable machine learning with treebased shapley additive explanations: Application to metabolomics datasets for binary classification. *PLoS ONE*, *18*(5 May). https://doi.org/10.1371/journal.pone.0284315

Christanto, H. J., & Singgalen, Y. A. (2023). Analysis and Design of Student Guidance Information System through Software Development Life Cycle (SDLC) dan Waterfall Model. *Journal of Information Systems and Informatics*, *5*(1), 259–270. https://doi.org/10.51519/journalisi.v5i1.443

Dayanah Ayulani, I., Yunawan, A. M., Prihutaminingsih, T., Sarwinda, D., Ardaneswari, G., & Desjwiandra Handari, B. (2023). *Tree-Based Ensemble Methods and Their Applications for Predicting Students' Academic Performance*. *13*(3).

Deniz, E. (2024). Evaluating the Effectiveness of Machine Learning Models in Predicting Student Academic Achievement. *ADBA Computer Science*, *1*(1), 8–13. https://doi.org/10.69882/adba.cs.2024072

Devanathan, B., Varshitha, J. J., Kumar, P. P., Lakshmanan, S. A., & Prakash, K. K. (2025). Explainable AI Framework Using XGBoost With SHAP and LIME for Multi-Scale Household Energy Forecasting. *IEEE Access*, *13*, 149750–149764. https://doi.org/10.1109/ACCESS.2025.3602673

Direktorat Pembelajaran dan Kemahasiswaan, Direktorat Jenderal Pendidikan Tinggi, R. dan T., & Kementrian Pendidikan, K. R. dan T. (2024). *PANDUAN PENYUSUNAN KURIKULUM PENDIDIKAN TINGGI MENDUKUNG MERDEKA BELAJAR-KAMPUS MERDEKA MENUJU INDONESIA EMAS*.

Fernández-García, A. J., Rodríguez-Echeverría, R., Preciado, J. C., Conejero Manzano, J. M., & Sánchez-Figueroa, F. (2020). Creating a recommender system to support higher education students in the subject enrollment decision. *IEEE Access*, *8*, 189069–189088. https://doi.org/10.1109/ACCESS.2020.3031572

Fitrani, L. D., & Puspitaningrum, A. C. (2023). *SISTEMASI: Jurnal Sistem Informasi Utilization of Unified Modeling Language (UML) in the Design of Academic Information Systems based on the OOAD Method*. http://sistemasi.ftik.unisi.ac.id

Fitriastuti, F., Eka Putri, A., Kautsar Sunardi, A., & Apriliya Hidayat, R. (2024). Analisis Website SIAKAD Universitas Janabadra Menggunakan Metode UAT. In *JTSI* (Vol. 5, Number 1).

Haekal, M. (2025). *Journal of Artificial Intelligence and Engineering Applications Implementation of Decision Tree Algorithm for Student Interest Analysis Based on Subjects at MTs Aisyiyah Binjai* (Vol. 5, Number 1). https://ioinformatic.org/

Hasibuan, M. S., Isnanto, R. R., Dewi, D. A., Kurniawan, T. B., Yeh, M. L., & Wijaya, A. (2025). A Proposed Model for Detecting Learning Styles Based on the Felder-Silverman Model Using KNN and LR with Electroencephalography (EEG). *Journal of Applied Data Sciences*, *6*(2), 1129–1139. https://doi.org/10.47738/jads.v6i2.659

Hossain, M. I. (2023). *Software Development Life Cycle (SDLC) Methodologies for Information Systems Project Management*. www.ijfmr.com

Hulu, Y., & Telaumbanua, Y. N. (2022). Analisis Minat Dan Hasil Belajar Siswa Menggunakan Model Pembelajaran Discovery Learning. *Educativo: Jurnal Pendidikan*, *1*(1), 283–290. https://doi.org/10.56248/educativo.v1i1.39

Hussain, W., Fong, M., & Spady, W. G. (2024). Digital Developmental Advising Systems for Engineering Students Based on Accreditation Board of Engineering and Technology Student Outcome Evaluations. *Information (Switzerland)*, *15*(9). https://doi.org/10.3390/info15090520

Hussain, W., Spady, W. G., Khan, S. Z., Khawaja, B. A., Naqash, T., & Conner, L. (2021). Impact Evaluations of Engineering Programs Using Abet Student Outcomes. *IEEE Access*, *9*, 46166–46190. https://doi.org/10.1109/ACCESS.2021.3066921

Hussain, W., Spady, W. G., Naqash, M. T., Khan, S. Z., Khawaja, B. A., & Conner, L. (2020). ABET Accreditation during and after COVID19 - Navigating the Digital Age. *IEEE Access*, *8*, 218997–219046. https://doi.org/10.1109/ACCESS.2020.3041736

Iban, M. C. (2022). An explainable model for the mass appraisal of residences: The application of tree-based Machine Learning algorithms and interpretation of value determinants. *Habitat International*, *128*. https://doi.org/10.1016/j.habitatint.2022.102660

José-García, A., Sneyd, A., Melro, A., Ollagnier, A., Tarling, G., Zhang, H., Stevenson, M., Everson, R., & Arthur, R. (2023). C3-IoC: A Career Guidance System for Assessing Student Skills using Machine Learning and Network Visualisation. *International Journal of Artificial Intelligence in Education*, *33*(4), 1092–1119. https://doi.org/10.1007/s40593-022-00317-y

Kate, C., Aditya Sai Srinivas, T., Asim, M., Sai Kumar, M., Vaishali Narayanrao, P., & Sasi, S. (2026). *Journal of Engineering and Technology for Industrial Applications ITEGAM-JETIA EDUBOOST: A HIGH-ACCURACY XGBOOST FRAMEWORK FOR STUDENT ACADEMIC PERFORMANCE PREDICTION*. https://doi.org/10.5935/jetia.v12i58.3734

Kementrian Pendidikan, K. R. dan T. (2023). *BERITA NEGARA REPUBLIK INDONESIA*.

Liu, Q., Liu, J., & Zhang, K. (2024). Research on Precision Education Management Practices in Vocational Colleges Based on Student Profiling. *ACM International Conference Proceeding Series*, 12–15. https://doi.org/10.1145/3700297.3700300

McKenzie, S., & Bennett, D. (2022). Understanding the career interests of Information Technology (IT) students: a focus on choice of major and career aspirations. *Education and Information Technologies*, *27*(9), 12839–12853. https://doi.org/10.1007/s10639-022-11141-1

Ngozi, U. M. R., Overcomer Ifeanyi Alex, A., Francisca, F. N., & Nmesoma, D. N. (2025). Design and Implementation of an Advanced Web-Based Academic Advising System for Optimizing Student Support and Engagement. *International Research Journal of Innovations in Engineering and Technology*, *09*(03), 13–27. https://doi.org/10.47001/irjiet/2025.903003

Nuraminudin, M., Faticha, R., & Aziza, A. (2026). *Pembuatan Sistem Evaluasi dan Rekomendasi Perencanaan Studi Mahasiswa Berbasis Website Menggunakan Laravel* (Vol. 5, Number 1). https://subset.id/index.php/IJCSR

Nurizati, Z., Hidayat, A., Vernanda, D., & Hendriawan, T. (2024). *Analisis Kelayakan Penurunan UKT Pada Mahasiswa dengan Menggunakan Metode Decision Tree*. *18*(1).

Okesola, O. O. (2021). *DATA MINING METHODOLOGY AND ITS APPLICATION TO LIFE INSURANCE*.

Osho, O., Gupta, A., Brown, D., Kninjenburg, B., Kennedy, C., Kraemer, E., Sexton, S., Washington, G., Subedi, P., Demssie, N., Kelsey, E., Porter, J., Gosha, K., & Smarr, S. A. (2026). Gender differences in grit and programming experience across course levels and their relationship to undergraduate students' intention to complete a computer science degree. *Computer Science Education*. https://doi.org/10.1080/08993408.2026.2649867

Permendikbudristek. (2023). *43. Permendikbudristek-No.-53-Tahun-2023-Penjaminan-Mutu-Pendidikan-Tinggi*.

Pratiwi, T. I., AS, U. S., Supriatna, M., & Nadhirah, N. A. (2024). Analisis Kebutuhan Perencanaan Karir Berbasis Aspirasi Karir Mahasiswa:Studi Literatur. *Indonesian Journal of Educational Counseling*, *8*(1), 114–129. https://doi.org/10.30653/001.202481.297

Rafie, Z., Talab, M. S., Koor, B. E. Z., Garavand, A., Salehnasab, C., & Ghaderzadeh, M. (2025). Leveraging XGBoost and explainable AI for accurate prediction of type 2 diabetes. *BMC Public Health*, *25*(1). https://doi.org/10.1186/s12889-025-24953-w

Rawis, J. A. M., Sumual, S. D. M., Azhar, Y., Al Azhar, B. Z., & Pranoto, A. S. (2025). *MANAJEMEN KURIKULUM PERGURUAN TINGGI 2025 BERBASIS OUTCOME BASED EDUCATION (OBE)*. *10*(4). https://doi.org/10.34125/jmp.v10i4.1263

Ridwan, A., Priyatno, A. M., & Ningsih, L. (2024). *Journal of Education and Computer Applications Predict Students' Dropout and Academic Success with XGBoost*. https://jeca.aks.or.id/index.php/jeca/index

Ridwan, M., & Fitri, I. (2021). Rancang Bangun Marketplace Berbasis Website menggunakan Metodologi Systems Development Life Cycle (SDLC) dengan Model Waterfall. *Jurnal Teknologi Informasi Dan Komunikasi)*, *5*(2), 2021. https://doi.org/10.35870/jti

Shoaib, L. A., Safii, S. H., Idris, N., Hussin, R., & Sazali, M. A. H. (2024). Utilizing decision tree machine model to map dental students' preferred learning styles with suitable instructional strategies. *BMC Medical Education*, *24*(1). https://doi.org/10.1186/s12909-023-05022-5

Siswipraptini, P. C., Warnars, H. L. H. S., Ramadhan, A., & Budiharto, W. (2024). Personalized Career-Path Recommendation Model for Information Technology Students in Indonesia. *IEEE Access*, *12*, 49092–49105. https://doi.org/10.1109/ACCESS.2024.3381032

Siti Muthiah Nuralifah, Muhammad Rizal H, Putri Fitriani Ahmad, & Wahda Amelia. (2025). Pengguna (User Acceptance Testing) Pada Sistem Informasi Akademik EMACCA Universitas Teknologi AKBA Makassar. *Inventor: Jurnal Inovasi Dan Tren Pendidikan Teknologi Informasi*, *3*(2), 84–91. https://doi.org/10.37630/inventor.v3i2.2541

Song, M. H., Zhang, L., Yuan, M., Li, Z., Song, Q., Liu, Y., & Zheng, G. (2023). CoTel: Ontology-Neural Co-Enhanced Text Labeling. *ACM Web Conference 2023 - Proceedings of the World Wide Web Conference, WWW 2023*, 1897–1906. https://doi.org/10.1145/3543507.3583533

Sugiana, I. (2023). *PENGEMBANGAN MEDIA LAYANAN INFORMASI KARIER BERBASIS ANDROID DALAM PERENCANAAN KARIER PADA PESERTA DIDIK*.

Syed Mustapha, S. M. F. D. (2023). Predictive Analysis of Students' Learning Performance Using Data Mining Techniques: A Comparative Study of Feature Selection Methods. *Applied System Innovation*, *6*(5). https://doi.org/10.3390/asi6050086

Zayed, Y., Salman, Y., & Hasasneh, A. (2022). A Recommendation System for Selecting the Appropriate Undergraduate Program at Higher Education Institutions Using Graduate Student Data. *Applied Sciences (Switzerland)*, *12*(24). https://doi.org/10.3390/app122412525

LAMPIRAN

Lampiran 1: Hasil Wawancara dengan Panitia PMB

Narasumber : Gin Gin Ginanjar, S.Pd., M.Pd.

Jabatan/Posisi : Kepala Bagian Hubungan Masyarakat dan Penerimaan Mahasiswa Baru (PMB) Bidang Kemahasiswaan Universitas Bale Bandung

Hari/Tanggal : 4 Mei 2026

Wawancara dilakukan untuk memperoleh informasi mengenai permasalahan yang dihadapi calon mahasiswa dalam menentukan program studi serta kebutuhan terhadap sistem yang dapat mendukung proses pengembangan mahasiswa.

No	Pertanyaan	Jawaban
1	Apakah calon mahasiswa sering mengalami kesulitan memilih program studi?	Ya, banyak calon mahasiswa yang masih bingung menentukan program studi yang sesuai.
2	Faktor apa yang paling memengaruhi pemilihan program studi?	Umumnya dipengaruhi oleh orang tua, teman, prospek kerja, dan tren yang sedang berkembang.
3	Apakah ada mahasiswa yang merasa tidak cocok dengan program studi yang dipilih?	Ada, beberapa mahasiswa merasa pilihan program studinya kurang sesuai setelah menjalani perkuliahan.
4	Apakah diperlukan sistem yang dapat membantu mahasiswa mengenali potensi dirinya?	Sangat diperlukan agar mahasiswa dapat memperoleh arahan yang lebih sesuai dengan karakteristiknya.
5	Apakah minat, gaya belajar, dan tujuan karier dapat dijadikan dasar rekomendasi?	Ya, ketiga aspek tersebut dapat membantu menggambarkan potensi dan arah pengembangan mahasiswa.

Berdasarkan hasil wawancara, diperoleh informasi bahwa masih terdapat calon mahasiswa yang mengalami kesulitan dalam menentukan program studi yang sesuai dengan karakteristik dirinya. Proses pengambilan keputusan juga masih banyak dipengaruhi oleh faktor eksternal, seperti orang tua, teman, dan prospek pekerjaan. Oleh karena itu, diperlukan suatu pendekatan yang dapat membantu mahasiswa mengenali potensi, minat, gaya belajar, dan tujuan karier sebagai dasar dalam memberikan rekomendasi pengembangan yang lebih terarah.

Lampiran 2: Hasil Wawancara dengan Ketua Program Studi

Narasumber : Ketua Program Studi Universitas Bale Bandung

Hari/Tanggal : 4 Mei 2026

Wawancara dilakukan untuk mengetahui kegunaan dari CPL, PL, dan kurikulum.

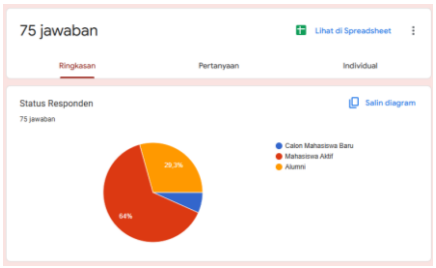
No	Pertanyaan	Jawaban
1	Apakah CPL dan Profil Lulusan dapat digunakan untuk menggambarkan kompetensi mahasiswa?	Ya, CPL dan Profil Lulusan menjadi dasar kompetensi yang diharapkan.
2	Apakah kurikulum dapat digunakan untuk membentuk profil kompetensi mahasiswa?	Dapat digunakan sebagai dasar pemetaan kompetensi.
3	Apakah rekomendasi pengembangan mahasiswa perlu disesuaikan dengan CPL?	Ya, agar selaras dengan tujuan pembelajaran program studi.

Berdasarkan hasil wawancara, diketahui bahwa CPL dan Profil Lulusan dapat digunakan sebagai dasar pembentukan profil kompetensi mahasiswa.

Lampiran 3: Hasil Kuesioner Pra-Penelitian

A. Informasi Responden

Kuesioner pra-penelitian disebarkan kepada calon mahasiswa, mahasiswa aktif, dan alumni Universitas Bale Bandung untuk mengetahui kebutuhan terhadap sistem rekomendasi pengembangan mahasiswa. Jumlah responden yang berhasil dikumpulkan sebanyak 75 responden, yang terdiri atas:



B. Ringkasan Hasil Kuesioner Mahasiswa Aktif

Pernyataan	Persentase Setuju + Sangat Setuju
Membutuhkan sistem rekomendasi pengembangan diri	60%
Minat, gaya belajar, dan tujuan karier dapat digunakan sebagai dasar pengembangan mahasiswa	62,20%
Machine learning dapat membantu menghasilkan rekomendasi yang lebih objektif	62,20%
Tertarik menggunakan sistem rekomendasi berbasis web	64,40%

Hasil tersebut menunjukkan bahwa sebagian besar mahasiswa aktif membutuhkan sistem yang mampu membantu menentukan arah pengembangan diri secara lebih terarah dan berbasis data.

C. Ringkasan Hasil Kuesioner Alumni

Pernyataan	Persentase Setuju + Sangat Setuju
Mendukung penggunaan *machine learning* dalam rekomendasi pengembangan mahasiswa	72,70%
Pengembangan diri selama kuliah berpengaruh terhadap kesiapan kerja	77,30%

Pekerjaan saat ini sesuai dengan bidang atau kompetensi yang dipelajari selama kuliah	45,50%

Hasil tersebut menunjukkan bahwa masih terdapat alumni yang bekerja tidak sepenuhnya sesuai dengan kompetensi akademik yang diperoleh selama perkuliahan sehingga diperlukan mekanisme pemetaan kompetensi yang lebih baik.

D. Ringkasan Hasil Kuesioner Calon Mahasiswa Baru

Berdasarkan hasil kuesioner calon mahasiswa baru ditemukan bahwa sebagian responden masih mengalami kebingungan dalam menentukan program studi yang sesuai dengan minat dan potensi diri.

Temuan ini sejalan dengan hasil wawancara bersama pihak PMB Universitas Bale Bandung yang menyatakan bahwa masih terdapat calon mahasiswa yang membutuhkan arahan dalam menentukan pilihan program studi dan rencana pengembangan diri.

E. Kesimpulan Pra-Penelitian

Berdasarkan hasil observasi, wawancara, dan penyebaran kuesioner pra-penelitian, dapat disimpulkan bahwa:

1. Sebagian mahasiswa masih mengalami kesulitan menentukan arah pengembangan diri selama perkuliahan.
2. Informasi mengenai pengembangan akademik dan non-akademik belum tersusun secara terintegrasi.
3. Minat, gaya belajar, dan tujuan karier dinilai dapat digunakan sebagai dasar pemetaan kompetensi mahasiswa.
4. Sebagian besar responden mendukung penggunaan teknologi *machine learning* untuk menghasilkan rekomendasi pengembangan mahasiswa yang lebih objektif.
5. Diperlukan suatu sistem yang mampu mengintegrasikan data kurikulum, karakteristik mahasiswa, dan model klasifikasi untuk menghasilkan rekomendasi pengembangan mahasiswa yang lebih tepat sasaran.

Lampiran 4: Bukti Pengumpulan Data Kurikulum

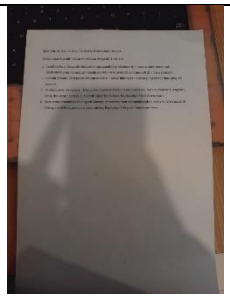
Data kurikulum diperoleh dari 12 Program Studi Universitas Bale Bandung melalui koordinasi dengan Ketua Program Studi masing-masing. Data yang dikumpulkan meliputi:

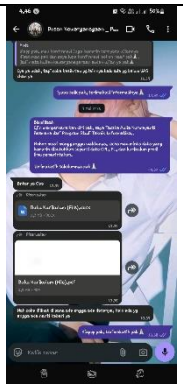
1. Profil Lulusan (PL)
2. Capaian Pembelajaran Lulusan (CPL)
3. Struktur Kurikulum
4. Daftar Mata Kuliah

Bukti berupa surat, tangkapan layar komunikasi, dan dokumen kurikulum terlampir.

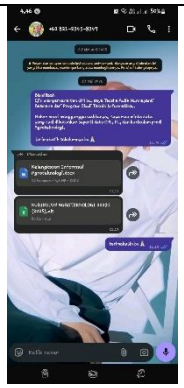
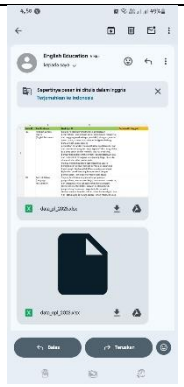
<table>
<tr>
<td> 

Surat Permohonan Ijin Melakukan Penelitian</td>
<td>Data PL Prodi Keperawatan

1. Perawat Pelaksana
2. Perawat Pendidik
3. Perawat Peneliti</td>
<td> 
Dokumentasi Data Prodi Geografi</td>
</tr>
<tr>
<td colspan="3"> 

Dokumentasi Data Prodi Matematika</td>
</tr>
<tr>
<td> 
Dokumentasi Data Prodi Ilmu Pemerintahan</td>
<td> 
Dokumentasi Data Prodi Teknik Informatika</td>
<td> 

Dokumentasi Data Prodi Sistem Informasi</td>
</tr>
</table>

		
Dokumentasi Data Prodi Akuntansi	Dokumentasi Data Prodi Agribisnis	Dokumentasi Data Prodi Agroteknologi
		
Dokumentasi Data Prodi IPS	Dokumentasi Data Prodi Bahasa Indonesia	Dokumentasi Data Prodi Bahasa Inggris