Digital Transformation Technology (Digitech) | e-ISSN: 2807-9000
Volume 5, **Number** 2, September 2025
https://doi.org/10.47709/digitech.v5i2.6340

Segmentasi Pelanggan Retail Berbasis Perilaku menggunakan Algoritma K-Means Clustering

Rhendy Diki Nugraha[1*], Dhea Dwi Adelia[2], Djastiano Rivaldi[3]
[1,2,3]Universitas Pelita Bangsa, Indonesia
[1]rhendydiki@mhs.pelitabangsa.ac.id, [2]dheadwiadelia.312210116@mhs.pelitabangsa.ac.id,
[3]djastinrv@gmail.com

open access
Histori Artikel:
Diajukan: 3 Juli 2025
Disetujui: 12 Oktober 2025
Dipublikasi: 13 Oktober 2025
Kata Kunci:
Segmentasi Pelanggan, K-Means Clustering, Data Mining, RFM, Retail.
Digital Transformation Technology (Digitech) *is an Creative Commons License This work is licensed under a Creative Commons Attribution-NonCommercial 4.0 International (CC BY-NC 4.0).*

Abstrak
Segmentasi pelanggan merupakan strategi penting dalam dunia bisnis untuk memahami perilaku konsumen dan merancang pendekatan pemasaran yang lebih efektif. Penelitian ini bertujuan untuk mengelompokkan pelanggan retail berdasarkan pola perilaku pembelian menggunakan metode *K-Means Clustering* yang berbasis pada model *RFM (Recency, Frequency, dan Monetary).* Pendekatan ini memungkinkan pengelompokan pelanggan secara objektif berdasarkan seberapa baru mereka bertransaksi, seberapa sering mereka membeli, dan seberapa besar nilai transaksi yang dilakukan. Data yang digunakan adalah data transaksi pelanggan yang telah melalui tahap pra-pemrosesan untuk menghasilkan variabel *RFM*. Penentuan jumlah klaster optimal dilakukan menggunakan metode Elbow, dan kualitas klaster divalidasi menggunakan Silhouette Score serta Davies-Bouldin Index. Hasil segmentasi menghasilkan empat klaster pelanggan dengan karakteristik yang berbeda, antara lain pelanggan loyal, pelanggan baru potensial, serta pelanggan pasif yang berisiko *churn*.Analisis menunjukkan bahwa pelanggan dengan frekuensi dan nilai transaksi tinggi berada dalam satu klaster khusus, yang direkomendasikan untuk mendapat perhatian melalui strategi loyalitas. Sementara itu, klaster pelanggan dengan aktivitas rendah menjadi fokus utama dalam strategi reaktivasi. Penelitian ini menunjukkan bahwa penerapan data mining dalam segmentasi pelanggan mampu meningkatkan efektivitas pengambilan keputusan dalam strategi pemasaran berbasis data.

PENDAHULUAN

Di tengah lanskap bisnis yang semakin kompetitif, pelanggan telah menjadi aset paling krusial bagi kelangsungan dan pertumbuhan setiap organisasi, khususnya di sektor retail (Pramudiansyah & Munte, 2021; Yunita et al., 2025). Pemahaman mendalam tentang kebutuhan, preferensi, dan perilaku pelanggan merupakan fondasi utama dalam merumuskan strategi bisnis yang efektif dan adaptif (Pramudiansyah & Munte, 2021; Yunita et al., 2025). Kegagalan dalam memahami dinamika perilaku konsumen dapat menyebabkan strategi pemasaran menjadi tidak relevan dan kehilangan daya saing (Adryan et al., 2024). Seiring dengan pesatnya perkembangan teknologi informasi, volume data transaksional dan interaksi pelanggan yang terekam oleh perusahaan retail terus meningkat secara eksponensial (Luchia Awalina & Rahayu, 2023). Data besar ini menawarkan potensi yang belum sepenuhnya dimanfaatkan untuk memperoleh insight berharga mengenai profil pelanggan (Widiyanto & Witanti, 2023).

Salah satu pendekatan strategis yang dapat digunakan untuk memanfaatkan potensi data tersebut adalah segmentasi pelanggan, yang memungkinkan perusahaan membagi basis pelanggan yang luas menjadi kelompok-kelompok yang lebih kecil dan homogen berdasarkan karakteristik tertentu (Satriawan et al., 2021; Luchia Awalina & Rahayu, 2023; Yunita et al., 2025). Melalui segmentasi ini, perusahaan dapat merancang strategi yang lebih tepat sasaran, mulai dari penawaran produk hingga komunikasi pemasaran yang dipersonalisasi (Hermawan et al., 2024). Dengan demikian, pendekatan ini membantu organisasi menghindari strategi "satu ukuran untuk semua" dan beralih menuju strategi yang lebih personal, efisien, dan efektif (Satriawan et al., 2021; Luchia Awalina & Rahayu, 2023; Yunita et al., 2025).

Dalam konteks ini, data mining menawarkan teknik-teknik canggih untuk mengekstraksi pola tersembunyi dari kumpulan data besar dan kompleks (Satriawan et al., 2021; Pramudiansyah & Munte, 2021). Salah satu metode yang relevan adalah klastering, yaitu metode pembelajaran tanpa pengawasan (unsupervised learning) yang dapat mengidentifikasi kelompok alami dalam data tanpa label yang telah ditentukan sebelumnya (Satriawan et al., 2021; Pramudiansyah & Munte, 2021). Di antara berbagai algoritma klastering, K-Means Clustering menjadi salah satu yang paling populer karena kesederhanaan, efisiensi, dan kemampuannya dalam membentuk klaster yang jelas (Satriawan et al., 2021; Luchia Awalina & Rahayu, 2023; Widiyanto & Witanti, 2023; Pramudiansyah

& Munte, 2021). Penerapan algoritma ini pada sektor retail memungkinkan identifikasi segmen pelanggan berdasarkan perilaku pembelian seperti frekuensi transaksi, nilai moneter yang dihabiskan, dan riwayat pembelian (Satriawan et al., 2021; Widiyanto & Witanti, 2023; Yunita et al., 2025).

Namun demikian, meskipun potensi data mining dan klastering K-Means telah banyak diakui, masih terdapat sejumlah permasalahan yang perlu dikaji lebih lanjut. Salah satunya adalah bagaimana mengidentifikasi segmen pelanggan yang berbeda secara bermakna dari data transaksi retail yang besar dan kompleks, terutama karena banyak perusahaan belum dapat menentukan data pelanggan mana yang benar-benar menguntungkan bagi bisnisnya (Pramudiansyah & Munte, 2021). Selain itu, setelah segmen terbentuk, diperlukan interpretasi yang akurat terhadap karakteristik perilaku dari setiap kelompok pelanggan agar dapat menghasilkan strategi pemasaran yang spesifik dan dapat diimplementasikan (Luchia Awalina & Rahayu, 2023; Widiyanto & Witanti, 2023). Oleh karena itu, penelitian ini berfokus pada penerapan algoritma K-Means Clustering untuk mengelompokkan pelanggan retail berdasarkan perilaku pembelian mereka dengan menggunakan *pendekatan Recency, Frequency, dan Monetary (RFM)* sebagai indikator utama (Hadi et al., 2017; Widiyanto & Witanti, 2023; Yunita et al., 2025).

Melalui pendekatan tersebut, penelitian ini bertujuan untuk menganalisis serta menginterpretasikan karakteristik unik dari setiap segmen pelanggan yang terbentuk (Hadi et al., 2017; Satriawan et al., 2021). Hasil segmentasi diharapkan dapat memberikan implikasi strategis berupa rekomendasi pemasaran yang lebih spesifik bagi setiap kelompok pelanggan, sehingga dapat meningkatkan efektivitas kampanye, memperkuat personalisasi layanan, serta mendorong retensi pelanggan di tengah persaingan bisnis yang semakin ketat (Hadi et al., 2017; Awalina & Rahayu, 2023; Widiyanto & Witanti, 2023; Yunita et al., 2025).

Secara teoritis, penelitian ini diharapkan dapat memperkaya literatur di bidang data mining dan segmentasi pelanggan, khususnya terkait penerapan algoritma K-Means pada data retail berbasis perilaku. Selain itu, hasil penelitian ini juga dapat menjadi referensi bagi penelitian selanjutnya yang ingin mengembangkan model segmentasi yang lebih adaptif terhadap dinamika pasar (Awalina & Rahayu, 2023). Sementara secara praktis, temuan penelitian ini dapat dimanfaatkan oleh perusahaan retail maupun e-commerce untuk merancang strategi pemasaran yang lebih personal dan efektif. Dengan memahami karakteristik setiap segmen pelanggan, perusahaan diharapkan mampu meningkatkan pemahaman terhadap konsumen, memperkuat hubungan pelanggan, serta meningkatkan daya saing dalam industri retail yang semakin kompetitif (Hadi et al., 2017; Satriawan et al., 2021; Widiyanto & Witanti, 2023; Yunita et al., 2025).

STUDI LITERATUR

Segmentasi Pelanggan

Segmentasi pelanggan merupakan sebuah proses penting dalam strategi bisnis yang bertujuan untuk membagi pasar menjadi segmen-segmen yang lebih kecil dan homogen. Pendekatan ini memungkinkan perusahaan untuk mengelompokkan pelanggan berdasarkan perilaku dan karakteristik serupa (Luchia Awalina & Rahayu, 2023). Segmentasi ini mengacu pada pembagian target pasar ke dalam kelompok-kelompok yang sesuai dengan karakteristik tertentu, seperti loyalitas, demografis, kebiasaan, atau frekuensi pembelian, untuk mengembangkan strategi bisnis yang tepat (Luchia Awalina & Rahayu, 2023). Tujuan utama dari segmentasi ini adalah untuk memahami target pasar secara lebih mendalam dan menentukan promosi yang paling cocok untuk setiap segmen pelanggan (Luchia Awalina & Rahayu, 2023). Analisis perilaku pembelian melalui model seperti RFM terbukti efektif dalam mengidentifikasi kelompok pelanggan yang paling berharga bagi perusahaan (Anitha & Patil, 2022).

Segmentasi pelanggan merupakan inti dari Teori Segmentasi, Penargetan, dan Pemosisian (STP) yang membantu bisnis memahami pelanggan secara mendalam, sehingga memungkinkan penerapan strategi pemasaran yang efektif serta meningkatkan loyalitas dan retensi pelanggan (Yunita et al., 2025). Dalam praktiknya, segmentasi pelanggan sangat krusial karena pelanggan merupakan aset utama dan sumber keuntungan bagi perusahaan di sektor retail, menuntut pemahaman yang baik untuk kelangsungan bisnis (Pramudiansyah & Munte, 2021). Mengidentifikasi dan memahami setiap pelanggan membantu menciptakan komunikasi yang personal dalam menyampaikan penawaran produk dan layanan yang disesuaikan dengan kebutuhan mereka (Luchia Awalina & Rahayu, 2023).

Data Mining dalam Pemasaran

Data mining adalah proses penemuan struktur yang menarik, tak terduga, atau berharga dalam kumpulan data yang berukuran besar (Satriawan et al., 2021; Pramudiansyah & Munte, 2021). Dalam konteks pemasaran, *data mining* memiliki potensi besar untuk membantu perusahaan berfokus pada informasi paling penting dalam gudang data mereka.

Penerapan *data mining* dalam industri retail atau perdagangan sangat penting karena banyaknya data yang tersedia, seperti logistik, pendapatan, rasio konsumsi, dan layanan pengiriman ulang (Yunita et al., 2025). *Data mining* retail membantu dalam mengenali dan memetakan perilaku serta tren konsumen sepanjang siklus hidup

bisnis, yang pada gilirannya meningkatkan layanan pelanggan dan strategi penjualan (Yunita et al., 2025). Model RFM (Recency, Frequency, Monetary) merupakan salah satu teknik segmentasi pelanggan berbasis data yang banyak digunakan dalam pemasaran, memungkinkan perusahaan mengambil keputusan secara taktis dengan menyimpan informasi waktu pembelian terakhir, frekuensi pembelian, dan jumlah uang yang dihabiskan oleh pelanggan. Penerapan RFM tidak hanya terbatas pada identifikasi pelanggan loyal, tetapi juga krusial dalam memprediksi pelanggan yang berpotensi churn atau berhenti menggunakan layanan (Hermawan et al., 2025).

Algoritma Klastering K-Means

Klastering adalah teknik pembelajaran tanpa pengawasan (*unsupervised learning*) yang bertujuan untuk membagi data dalam suatu himpunan ke dalam beberapa kelompok atau klaster, di mana kesamaan data dalam satu kelompok lebih besar dibandingkan dengan kesamaan data tersebut dengan data dalam kelompok lain (Satriawan et al., 2021; Pramudiansyah & Munte, 2021). Algoritma K-Means *Clustering* merupakan salah satu metode *klastering* non-hirarkis yang mempartisi data ke dalam satu atau lebih klaster atau kelompok. Data dengan karakteristik yang sama dikelompokkan ke dalam satu klaster yang sama, sedangkan data dengan karakteristik yang berbeda dikelompokkan ke dalam klaster yang lain (Satriawan et al., 2021; Widiyanto & Witanti, 2023).

Prinsip dasar K-Means adalah mencari pusat kelompok (centroid) secara iteratif (Pramudiansyah & Munte, 2021). Langkah-langkah utama algoritma K-Means meliputi:

1. Menentukan jumlah klaster (k) yang diinginkan.
2. Menginisialisasi k pusat klaster (centroid), yang dapat dilakukan secara acak.
3. Menghitung jarak antara setiap objek data dengan setiap pusat klaster, seringkali menggunakan rumus jarak Euclidean.
4. Mengalokasikan setiap objek ke klaster dengan pusat klaster terdekat.
5. Menghitung ulang nilai pusat klaster yang baru berdasarkan rata-rata objek yang menjadi anggota pada klaster tersebut.
6. Mengulangi langkah-langkah di atas hingga tidak ada lagi objek yang berpindah klaster, atau posisi centroid tidak berubah secara signifikan.

Metode penentuan jumlah klaster optimal (*k*) juga sangat penting. Metode *Elbow* adalah salah satu pendekatan yang umum digunakan untuk menemukan jumlah klaster terbaik dengan mengamati persentase penurunan *inertia* atau *Within Cluster Sum of Square* (WCSS) yang membentuk "siku" pada grafik (Satriawan et al., 2021; Luchia Awalina & Rahayu, 2023). Selain itu, Davies Bouldin Index (DBI) dan Silhouette Score juga digunakan untuk mengevaluasi kualitas klaster; kedua metrik ini membantu memastikan bahwa segmen yang terbentuk memiliki tingkat kepadatan intra-klaster yang tinggi dan separasi antar-klaster yang jelas (Punhani et al., 2022). DBI bertujuan untuk memaksimalkan jarak antar klaster dan meminimalkan jarak objek dalam klaster (Satriawan et al., 2021), sementara *Silhouette Score* mengukur seberapa baik setiap objek data dikelompokkan dalam klaster yang sesuai (Satriawan et al., 2021). Validasi klaster menjadi tahap krusial untuk memastikan bahwa segmen yang dihasilkan tidak hanya koheren secara internal tetapi juga cukup berbeda satu sama lain, sehingga memberikan dasar yang kuat untuk pengambilan keputusan strategis (Trivedi et al., 2021).

Penelitian Terdahulu

Beberapa penelitian terdahulu telah banyak membahas penerapan algoritma K-Means Clustering dalam segmentasi pelanggan. Salah satunya adalah penelitian berjudul *Optimalisasi Strategi Pemasaran dengan Segmentasi Pelanggan Menggunakan Penerapan K-Means Clustering pada Transaksi Online Retail* (2023). Penelitian ini menggunakan metode K-Means dengan Elbow Method untuk menentukan jumlah klaster optimal. Hasil penelitian menunjukkan terbentuknya empat klaster pelanggan yang memiliki karakteristik berbeda, di mana faktor kuantitas dan harga satuan produk terbukti berperan penting dalam mempengaruhi perilaku pembelian pelanggan.

Selanjutnya, penelitian *Segmentasi Pelanggan Telkomsel Menggunakan Metode Clustering dengan RFM Model dan Algoritma K-Means* (2021) menerapkan kombinasi RFM Model, K-Means, Elbow Method, Davies Bouldin Index (DBI), dan Silhouette Analysis. Hasilnya diperoleh empat segmen pelanggan utama, yaitu pelanggan baru, potensial, loyal, dan pelanggan yang memerlukan perhatian khusus. Nilai silhouette sebesar 0.3066 mengindikasikan bahwa hasil klaster yang terbentuk sudah cukup optimal dalam mewakili kelompok pelanggan Telkomsel.

Penelitian lain yang dilakukan pada PT Coversuper Indonesia Global tahun 2023 menggunakan pendekatan serupa dengan RFM Model dan K-Means. Hasilnya menunjukkan terbentuk empat segmen pelanggan yang berbeda, dengan akurasi sistem mencapai 100% sesuai dengan pengetahuan pengguna. Temuan ini menegaskan bahwa kombinasi RFM dengan K-Means dapat menjadi dasar yang andal dalam merumuskan strategi pemasaran perusahaan.

Kemudian, penelitian tahun 2021 mengenai segmentasi pelanggan di bidang ritel dengan RFM Model dan K-Means menghasilkan empat klaster optimal yang diberi label Platinum, Gold, Silver, dan Bronze. Distribusi

pelanggan dalam masing-masing segmen menunjukkan adanya kelompok pelanggan prioritas, dengan jumlah terbanyak berada pada klaster Platinum (557 pelanggan), sementara klaster Gold, Silver, dan Bronze memiliki jumlah yang lebih kecil namun tetap signifikan.

Terakhir, penelitian berjudul *Segmentasi Pelanggan Menggunakan K-Means Clustering: Menganalisis Metrik RFM untuk Strategi Pemasaran* (2025) memanfaatkan data transaksi penjualan di sektor ritel. Hasil penelitian menunjukkan terbentuk tiga segmen utama pelanggan, yaitu General Development, General Maintenance, dan Important Maintenance. Menariknya, terdapat perbedaan hasil antara metode evaluasi: Elbow Method menyarankan jumlah klaster optimal sebanyak empat, sementara Silhouette Analysis merekomendasikan lima klaster. Hal ini mengindikasikan adanya fleksibilitas dalam interpretasi segmentasi yang dapat disesuaikan dengan tujuan strategis perusahaan.

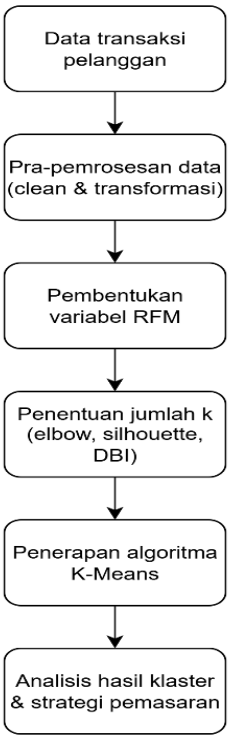
METODE

Penelitian ini menggunakan pendekatan kuantitatif deskriptif untuk menyelesaikan permasalahan segmentasi pelanggan dalam industri retail. Data yang digunakan merupakan data transaksi pelanggan yang kemudian diolah dengan model analisis perilaku berbasis RFM (Recency, Frequency, dan Monetary**)**. Model ini dipilih karena mampu menggambarkan kebiasaan belanja pelanggan secara objektif berdasarkan jarak waktu sejak transaksi terakhir, frekuensi pembelian dalam periode tertentu, serta total nilai uang yang dikeluarkan oleh pelanggan (Pramudiansyah & Munte, 2021; Yunita et al., 2025).

Tahapan penelitian diawali dengan pra-pemrosesan data, yaitu membersihkan data transaksi pelanggan dari nilai kosong dan duplikasi. Setelah itu dilakukan transformasi data untuk menghasilkan variabel RFM sebagai indikator utama perilaku pelanggan. Selanjutnya, dilakukan penentuan jumlah klaster optimal dengan menggunakan metode Elbow yang mengacu pada nilai *Within Cluster Sum of Square (WCSS)*, serta dilengkapi dengan evaluasi melalui Silhouette Score dan Davies Bouldin Index (DBI) untuk memastikan kualitas hasil pengelompokan (Satriawan et al., 2021; Awalina & Rahayu, 2023).

Tahap berikutnya adalah penerapan algoritma K-Means Clustering. Proses dimulai dengan menentukan jumlah klaster (k) dan menginisialisasi centroid secara acak. Kemudian, jarak setiap data dihitung terhadap centroid menggunakan Euclidean Distance, dan data dikelompokkan ke dalam centroid terdekat. Posisi centroid diperbarui berdasarkan rata-rata data dalam klaster, dan iterasi dilakukan berulang hingga posisi centroid stabil atau tidak mengalami perubahan signifikan (Pramudiansyah & Munte, 2021; Widiyanto & Witanti, 2023).

Tahap terakhir adalah analisis hasil klaster, di mana setiap segmen pelanggan yang terbentuk dianalisis untuk mengetahui karakteristik perilaku pembelian yang membedakan satu klaster dengan klaster lainnya. Analisis ini digunakan sebagai dasar untuk merumuskan strategi pemasaran yang lebih terarah, personal, dan sesuai dengan kebutuhan pelanggan pada masing-masing segmen (Satriawan et al., 2021).



Gambar 1. Flowchart

HASIL

Hasil segmentasi pelanggan menggunakan algoritma K-Means menghasilkan empat klaster (0–3) yang masing-masing menunjukkan karakteristik perilaku belanja berbeda berdasarkan dimensi *Recency*, *Frequency*, dan *Monetary* (RFM). Analisis dilakukan untuk memahami pola aktivitas pelanggan dan kontribusi mereka terhadap nilai bisnis perusahaan retail.Visualisasi *scatter matrix* memperlihatkan distribusi data antar dimensi RFM dengan pewarnaan berdasarkan klaster yang terbentuk. Setiap warna mewakili kelompok pelanggan dengan karakteristik serupa. Berdasarkan metode *Elbow*, jumlah klaster optimal ditetapkan pada empat segmen, yang divalidasi lebih lanjut menggunakan *Silhouette Score* dan *Davies-Bouldin Index*. Nilai *Silhouette* yang positif dan indeks DBI yang rendah mengindikasikan bahwa klaster yang terbentuk memiliki tingkat homogenitas internal yang baik dan separasi antar-klaster yang jelas (Satriawan et al., 2021; Punhani et al., 2022).

Tabel 1
Hasil Interpretasi Cluster, Recency, Frequency, Monetary

Cluster	Recency	Frequency	Monetary
0	51.63	1.29	425.63
1	11.88	1.20	437.51
2	23.22	3.68	3645.84
3	13.27	1.09	365.81

Hasil pada tabel menunjukkan variasi perilaku pelanggan yang signifikan di antara empat klaster. Nilai *Recency* merepresentasikan jarak waktu sejak transaksi terakhir, *Frequency* menunjukkan tingkat intensitas transaksi, sedangkan *Monetary* menggambarkan nilai pembelian yang dilakukan pelanggan.

Analisis Per Klaster

Klaster 0 – Pelanggan Pasif (Dormant Segment)

Klaster ini memiliki nilai *recency* tertinggi (51,63 hari) dan tingkat *frequency* rendah (1,29 kali) dengan pengeluaran kecil (Rp 425.630). Hal ini mengindikasikan bahwa pelanggan dalam kelompok ini telah lama tidak bertransaksi dan memiliki aktivitas pembelian yang minim. Segmen ini berisiko mengalami *churn* jika tidak dilakukan intervensi strategis. Fenomena ini konsisten dengan temuan Mada (2025) yang menyebutkan bahwa pelanggan dengan periode tidak aktif di atas 45 hari memiliki kecenderungan tinggi untuk berhenti bertransaksi. Strategi yang direkomendasikan adalah kampanye reaktivasi seperti *personalized offer* atau *reminder email* untuk menarik kembali minat mereka.

Klaster 2 – Pelanggan Loyal dan Bernilai Tinggi (*Loyal Segment*)

Klaster 2 menonjol sebagai kelompok pelanggan paling berharga dengan *frequency* pembelian tertinggi (3,68 kali) dan pengeluaran rata-rata terbesar (Rp 3.645.840). Nilai *recency* menengah (23 hari) menunjukkan bahwa mereka melakukan transaksi secara konsisten. Karakteristik ini menandakan pelanggan dengan *customer lifetime value* tinggi dan kontribusi signifikan terhadap pendapatan. Hasil ini sejalan dengan penelitian Widiyanto & Witanti (2023) serta Hermawan et al. (2024) yang menemukan bahwa pelanggan dengan intensitas dan nilai transaksi tinggi merupakan aset strategis yang perlu dipertahankan melalui program loyalitas, *exclusive membership*, atau *reward points system*.

Klaster 3 – Pelanggan Aktif Bernilai Rendah (*Emerging Segment*)

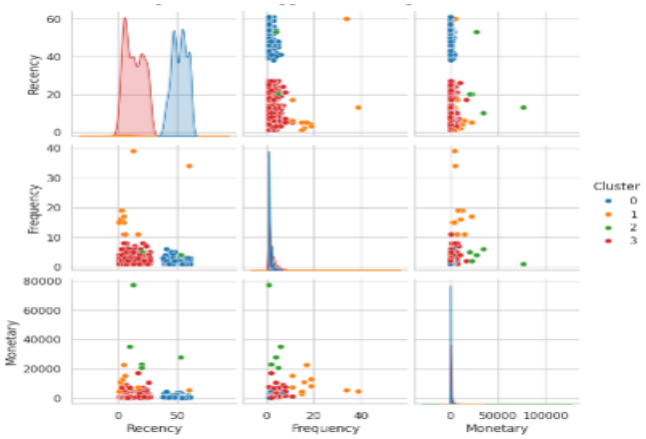
Pelanggan dalam klaster ini tergolong cukup aktif (*recency* 13 hari), tetapi memiliki *frequency* dan *monetary* yang rendah. Kondisi ini menunjukkan pelanggan yang berinteraksi secara rutin, namun kontribusi ekonominya masih terbatas. Segmen ini bisa menjadi target untuk strategi peningkatan nilai (*value upgrading*) melalui *cross-selling*, *up-selling*, atau *bundling* produk yang relevan. Hasil ini sejalan dengan temuan Siregar et al. (2023), yang menegaskan bahwa pelanggan dengan aktivitas tinggi namun nilai transaksi kecil berpotensi meningkat jika diberikan promosi berbasis perilaku.

Analisis Pola Umum dan Implikasi

Secara keseluruhan, hasil klasterisasi ini menunjukkan bahwa model RFM yang dipadukan dengan algoritma K-Means mampu menghasilkan segmentasi yang informatif dan aplikatif. Pola yang terlihat menggambarkan adanya hierarki nilai pelanggan, mulai dari pelanggan *dormant* (Klaster 0), pelanggan potensial (Klaster 1), pelanggan *loyal* (Klaster 2), hingga pelanggan aktif bernilai rendah (Klaster 3). Temuan ini mendukung studi Satriawan et al. (2021) dan Yunita et al. (2025) yang menegaskan bahwa analisis berbasis perilaku dapat menjadi dasar untuk strategi pemasaran berbasis data (*data-driven marketing*).

Visualisasi:
Scatter matrix pada gambar menunjukkan distribusi dan pola antar dimensi RFM:

- Klaster 2 (hijau) secara konsisten muncul dalam wilayah frekuensi dan monetary yang tinggi, menandakan kelompok pelanggan bernilai tinggi.
- Klaster 0 dan 3 (biru dan oranye) cenderung berada di wilayah frequency rendah dan monetary rendah, menggambarkan segmen yang kurang aktif.
- Klaster 1 (merah) terlihat tersebar pada recency rendah, menandakan pelanggan baru namun belum memiliki kontribusi signifikan.



Gambar 2. Segmentasi Pelanggan Retail dengan K-Means

PEMBAHASAN

Hasil klasterisasi menggunakan algoritma K-Means menunjukkan bahwa data pelanggan dapat dikelompokkan ke dalam empat segmen dengan karakteristik perilaku yang berbeda berdasarkan dimensi Recency, Frequency, dan Monetary (RFM). Segmentasi ini memperlihatkan variasi tingkat loyalitas serta kontribusi pelanggan terhadap bisnis, sehingga mampu memberikan gambaran yang lebih komprehensif mengenai pola interaksi konsumen.

Salah satu segmen yang paling menonjol adalah Klaster 2, yang merepresentasikan pelanggan loyal dengan nilai transaksi yang tinggi. Kelompok ini memiliki rata-rata frekuensi pembelian sebesar 3,68 kali dan total pengeluaran mencapai Rp 3.645.840, sementara nilai recency berada pada kisaran menengah, yakni 23 hari sejak transaksi terakhir. Kondisi ini mengindikasikan bahwa pelanggan dalam klaster tersebut cukup sering bertransaksi sekaligus memberikan kontribusi pendapatan signifikan bagi perusahaan. Dengan demikian, mereka menjadi pelanggan prioritas yang perlu dijaga melalui strategi khusus, misalnya program loyalitas, penawaran eksklusif, maupun layanan premium.

Berbeda dengan itu, Klaster 0 dan Klaster 3 menunjukkan karakteristik pelanggan tidak aktif dan berisiko mengalami *churn*. Klaster 0 dicirikan oleh nilai recency yang paling tinggi, yaitu 51 hari, menandakan pelanggan sudah cukup lama tidak bertransaksi. Sementara itu, Klaster 3 memiliki recency yang lebih baik, yaitu 13 hari, tetapi tetap memperlihatkan frekuensi dan nilai pembelian yang rendah. Kedua segmen ini menuntut perhatian khusus, mengingat biaya untuk memperoleh pelanggan baru seringkali jauh lebih tinggi dibandingkan mempertahankan pelanggan lama. Oleh sebab itu, strategi reaktivasi berupa promosi, diskon personalisasi, maupun pengingat transaksi dapat diterapkan untuk menghidupkan kembali interaksi dengan kelompok ini.

Sementara itu, Klaster 1 berisi pelanggan baru yang memiliki recency relatif rendah, yaitu rata-rata 11 hari sejak transaksi terakhir. Akan tetapi, jumlah transaksi dan nilai pembelian dalam klaster ini masih rendah, sehingga mereka dapat dikategorikan sebagai pelanggan potensial. Kelompok ini masih berada pada tahap awal interaksi dengan bisnis, sehingga strategi pemasaran yang sesuai adalah dengan meningkatkan keterlibatan melalui edukasi produk, pemberian *welcome offer*, maupun retargeting untuk mendorong pembelian lanjutan.

Secara keseluruhan, hasil klasterisasi ini memperlihatkan bahwa penggunaan model RFM yang dipadukan dengan algoritma K-Means mampu memberikan gambaran yang lebih dalam terkait pola perilaku pelanggan. Analisis segmen yang terbentuk dapat dijadikan dasar dalam merumuskan strategi pemasaran yang lebih personal dan efektif. Pelanggan loyal di Klaster 2 dapat dipertahankan melalui retention strategy, sementara pelanggan pasif di Klaster 0 dan 3 membutuhkan reaktivation campaign. Adapun pelanggan baru di Klaster 1 memiliki potensi besar untuk ditingkatkan kontribusinya melalui growth strategy. Dengan pendekatan berbasis data ini, perusahaan dapat melakukan pengambilan keputusan secara lebih terukur, objektif, dan efisien dibandingkan metode segmentasi konvensional.

Perhitungan Nilai RFM
Nilai Recency, Frequency, dan Monetary dihitung dari data transaksi pelanggan sebagai berikut:

$$Recency_i = Tanggal\ Analisis - Tanggal\ Transaksi\ Terakhir_i \quad (1)$$
$$Frecuency_i = Jumlah\ Transaksi_i \quad (2)$$
$$Monetary_i = \sum_{j=1}^{n_i} Nilai\ Transaksi_{ij} \quad (3)$$

Keterangan:
i = ID pelanggan
j = ke- j transaksi pelanggan i
n_i = jumlah transaksi pelanggan i

Jarak Euclidean pada K-Means
Untuk menghitung jarak antara data pelanggan ke centroid klaster:

$$d(x, c) = \sqrt{\sum_{i=1}^{n}(x_i - c_i)^2} \quad (4)$$

Keterangan:
x = vektor fitur data pelanggan (R, F, M)
c = vektor centroid klaster
n = jumlah fitur (3 untuk RFM)
Update Centroid pada K-Means
Centroid setiap klaster diupdate dengan menghitung rata-rata seluruh data yang termasuk dalam klaster tersebut:

$$c_j = \frac{1}{|C_j|}\sum_{x_i \in C_j} xi \quad (5)$$

Keterangan:
c_j = centroid klaster ke- j
C_j = himpunan data dalam klaster j
x_i = data pelanggan
Silhouette Score (Evaluasi Kualitas Klaster)
Untuk mengevaluasi apakah klasterisasi sudah baik digunakan rumus:

$$S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (6)$$

Keterangan:
$a(i)$ = rata-rata jarak dari titik i ke semua titik lain dalam klaster yang sama
$b(i)$ = jarak terkecil dari titik i ke klaster lain (klaster terdekat)

KESIMPULAN

Penelitian ini berhasil mengimplementasikan algoritma K-Means Clustering dengan pendekatan model RFM (Recency, Frequency, Monetary) untuk segmentasi pelanggan pada sektor retail, dan hasilnya menunjukkan bahwa pelanggan dapat dikelompokkan ke dalam empat klaster utama, yaitu pelanggan loyal dan bernilai tinggi, pelanggan pasif atau tidak aktif, serta pelanggan baru yang berpotensi untuk dikembangkan. Temuan ini membuktikan bahwa pendekatan berbasis data mampu memberikan gambaran objektif mengenai perilaku pelanggan sekaligus menjawab permasalahan utama dalam penelitian, yakni bagaimana mengelompokkan pelanggan secara efektif agar strategi pemasaran lebih personal, efisien, dan tepat sasaran. Implementasi strategi seperti program loyalitas untuk pelanggan utama, kampanye retensi bagi pelanggan pasif, serta promosi onboarding untuk pelanggan baru menjadi lebih terarah berkat hasil segmentasi ini. Selain itu, penelitian ini menegaskan efektivitas K-Means dalam mengolah data perilaku pelanggan, meskipun pengembangan lanjutan dapat mempertimbangkan metode alternatif seperti DBSCAN atau Hierarchical Clustering untuk membandingkan kinerja segmentasi. Dengan demikian, penelitian ini tidak hanya memberikan kontribusi praktis bagi perusahaan dalam mendukung pengambilan keputusan berbasis data, tetapi juga memperkaya literatur ilmiah mengenai penerapan teknik data mining dalam strategi pemasaran modern.

REFERENSI

Awalina, E. F. L., & Rahayu, W. I. (2023). Optimalisasi Strategi Pemasaran dengan Segmentasi Pelanggan Menggunakan Penerapan K-Means Clustering pada Transaksi Online Retail. *Jurnal Teknologi Dan Informasi*, *13*(2), 122–137. https://doi.org/10.34010/jati.v13i2.10090

Pramudiansyah, A., & Munte, H. (2021). Segmentasi Pelanggan Menggunakan Algoritma K-Means Berdasarkan

Model Recency Frequency Monetary. *Jurnal Ilmiah Ilmu Komputer*, *7*(2), 06–19. https://doi.org/10.35329/jiik.v7i2.201

Satriawan, M. A., Andreswari, R., & Pratiwi, O. N. (2021). Segmentasi Pelanggan Telkomsel Menggunakan Metode Clustering Dengan Rfm Model Dan Algoritma K-Means Telkomsel Customer Segmentation Using Clustering Method With Rfm Model and K-Means Algorithm. *E-Proceeding of Engineering :*, *8*(2), 2876–2883.

Widiyanto, A. T., & Witanti, A. (2021). Segmentasi Pelanggan Berdasarkan Analisis RFM Menggunakan Algoritma K-Means Sebagai Dasar Strategi Pemasaran (Studi Kasus PT Coversuper Indonesia Global). *KONSTELASI: Konvergensi Teknologi Dan Sistem Informasi*, *1*(1), 204–215. https://doi.org/10.24002/konstelasi.v1i1.4293

Yunita, I., Ali, P. R., Kartawidjaja, M. A., & Sukwadi, R. (2025). *Segmentasi Pelanggan Menggunakan K-Means Cluster ing : Menganalisis Metrik RFM untuk Strategi Pemasaran Customer Segmentation Using K-Means Clustering : Analyzing RFM Metrics for Enhanced Marketing Strategies*. *9*(1), 58–66. https://doi.org/10.35194/jmtsi.v9i1.4452

Adryan, Y., Rizqi, F., Bayu, I., Yosafat, R., & Saprudin. (2024). Analisis Segmentasi Pelanggan Mall Menggunakan Metode K-Means Clustering Dan Elbow Untuk Optimasi Strategi Pemasaran. *JRIIN :Jurnal Riset Informatika dan Inovasi, 2*(9), 1698–1708.

Anitha, P., & Patil, M. M. (2022). RFM model for customer purchase behavior using K-Means algorithm. *Journal of King Saud University - Computer and Information Sciences, 34*(5), 1785–1792.

Hermawan, A., Saputra, A., Rafi, M. D., Basmallah, S., Putra, Y. T. S., & Nabila, W. (2025). Implementing XGBoost Model for Predicting Customer Churn in E-Commerce Platforms. *Repeater : Publikasi Teknik Informatika Dan Jaringan, 3*(2), 17–31.

Hermawan, A., Kahfi, R. A., Surya, E., Aini, U., & Hidayat, R. (2024). Penerapan Metode RFM dengan Python dalam Segmentasi Pelanggan. *Jurnal Bisnis Inovasi dan Digital, 1*(3), 92–102.

Iqbal, M. (2025). Strategi Pemasaran Digital untuk Meningkatkan Loyalitas Pelanggan di Era Media Sosial. *Inisiatif Jurnal Ekonomi Akuntansi dan Manajemen, 4*(2), 174-186.

Mada, Y. P. (2025). Prediksi Churn Pelanggan di Layanan Streaming Berbasis Analisis Perilaku dan Sentimen dengan Ensemble Machine Learning: Studi Platform Lokal Vidio Vs. Netflix Indonesia. *Jurnal Kajian Ilmu Manajemen, 5*(1), 13-21.

Punhani, A., Faujdar, N., Mishra, K. K., & Subramanian, M. (2022). Binning-Based Silhouette Approach to Find the Optimal Cluster Using K-Means. *IEEE Access, 10*, 2025-03-30.

Gultom, Y. T., Putra, A. S., & Mulyani, A. (2023). Segmentasi Pelanggan E-Commerce Menggunakan Model LRFMP dan Algoritma K-Means. *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer, 7*(12), 6524–6533

Siregar, S. F., Nasution, B. I., & Syahputra, M. F. (2023). Optimalisasi Segmentasi Pelanggan Ritel dengan Algoritma K-Means Berbasis RFM untuk Strategi Pemasaran. *JURIKOM (Jurnal Riset Komputer), 10*(6), 1634-1641.

Trivedi, S. K., Patra, S. K., & Singh, R. (2021). An unsupervised learning approach for customer segmentation based on purchasing behaviour. *Journal of Management Analytics, 8*(4), 606-630.